

一种基于深度平移 (GAN) 的变化检测网络 SAR 遥感图像

李兴华 a , 杜正顺 a , 黄彦元 a , 谭振宇 b , *

*2 . 武汉大学遥感与信息工程学院 , 湖北武汉 430079

这是一个有意义的问题

关键词:
变化检测深度平移深度可分离卷积 GAN
多尺度损耗光学和 SAR 图像

Abstract

随着天基成像技术的发展,各种成像形式和分辨率的图像越来越多。光学图像反映了地物丰富的光谱信息和几何形状,在恶劣的大气条件下,地物的质量容易退化。合成孔径雷达 (SAR)图像虽然不能提供感兴趣区域 (ROI)的光谱特征,但可以捕捉到全天候、全时的极化信息。在自然界中,光学图像和 SAR 图像封装了大量的互补信息,对于恶劣天气条件下的变化检测(CD)具有重要意义。然而,由于光学图像和 SAR 图像的成像机理不同,传统的差值或比值算法难以直接进行光学图像和 SAR 图像的 CD。最近的 CD 方法都采用了图像平移的方法来减小它们之间的差异,但结果都是通过普通的代数方法和阈值分割得到的,精度有限。为此,本文提出了一种基于深度翻译的变化检测网络(DTCDN),用于光学和 SAR 图像。深度平移首先通过循环结构将图像从一个域(如光学)映射到另一个域(如 SAR),并映射到相同的特征空间。经过深度翻译,它们的特点相似,具有可比性。与以往的研究不同的是,该方法将翻译结果导入到一个有监督的光盘网络中,该网络利用深度上下文特征来分离不变的像素和变化的像素。在实验中,我们对来自美国加州 Gloucester 和曙光村的 4 个具有代表性的数据集进行了测试。通过与现有方法的比较,验证了该方法的有效性和鲁棒性。

1.简介

遥感变化检测(CD)是通过同一地理区域的多时相图像来识别物体或现象差异的过程(Ashbindu 1989)。CD 是遥感领域非常流行和重要的课题,在灾害评估等实际应用中发挥着关键作用(Ji et al. 2019;Sub - lime 和 Kalinicheva 2019 年),资源调查(Khan 等人 2017 年;Lunetta 等人 2006 年)和城市规划(Jaturapitpornchai 等人 2019 年;Lyu 等人 2018 年;阮和汉 2020 年)。

目前,人们对单一数据源的遥感光盘,尤其是光学遥感影像的光盘的研究较多。不同时空分辨率的光学图像不仅能提供地物的光谱信息,还能反映地物的纹理和几何形状,从而保证了 CD 的可能性和准确性。如 Tian et al.(2014)实现了自动 CD

通过使用非常高分辨率(VHR)光学图像的 Kullback-Leibler 散度相似度测量来测量建筑物。此外,还提出了一种人工神经网络,用于从 Landsat TM 图像中提取城市扩张的特征(Tong et al. 2010)。

合成孔径雷达(Synthetic aperture radar, SAR)图像反映了地表在任何时间、任何天气条件下的散射信息。因此, SAR 图像与光照条件的独立性使其对特定的 CD 任务非常有利(Geng 等人, 2019)。Saha 等人 (2018)利用 VHR SAR 图像深度编码的潜力来识别地震后被摧毁的建筑。此外,基于 Sentinel-1 和 TerraSAR-X 图像(Planin`si`c 和 Gleich 2018),使用日志累积量和堆叠自动编码器进行火灾损害评估。这些研究已经实现了对 SAR 图像的有效 CD。

在大气条件较差的情况下, SAR 图像虽然优于光学图像,但由于缺乏丰富的光谱信息而受到影响

通讯作者。

电子邮箱 :tanzhenyu@nwu.edu.cn o

<https://doi.org/10.1016/j.isprsjprs.2021.07.007>

2021 年 5 月 13 日;已于 2021 年 7 月 4 日收到订正表;接受于 2021 年 7 月 13 日
0924-2716/©2021 国际摄影测量和遥感学会(ISPRS)。版权所有爱思唯尔 B.V.出版。

通过斑点噪声。基于光盘的光学和合成孔径雷达图像之所以流行，是因为它们可以提供互补的信息。将光学和 SAR 遥感影像相结合，可以及时准确地反映事件前后的情况。特别是在洪水、火灾等灾害发生后，受到水蒸气或烟雾的影响，光学成像无法获得清晰的地表信息，而 SAR 可以帮助我们快速应对这些情况。由于光学和 SAR 遥感影像的成像机理、辐射特性和几何特性不一致，光盘是一个难题。为了克服这些限制，我们提出了一些 CD 模型，并将其分为五类：

- (1)参数化方法。参数化方法通常利用混合的元高斯分布或多元分布来估计不同传感器图像之间的关系。通过求解这些参数，提取出相应的变化指标。具有代表性的方法包括基于 kullbac - leibler 的变化测度(Mercier et al. 2008)、局部联合分布(Prendes et al. 2015)和用于多模态变化检测的 Markov 模型(M3CD) (Touati et al. 2019)。这些方法基于关联函数理论，利用局部统计量从不同的图像中提取精确的变化图。然而，它们通常依赖于一个特定的分布来描述一对遥感图像之间的关系。面对快速发展的多模态传感器，该方法不易推广。
- (2)非参数方法。与参数算法不同的是，这种方法不需要估计重要参数，可用于任何对异质传感器。例如，基于能量的最小二乘模型采用基于能量的模型，使两幅图像的每个像素对满足一组超约束(Touati 和 Mignotte 2017)。虽然这些方法可以应用于不同的遥感图像，但它们不如基于参数的方法适用于一对预先分配的遥感图像。
- (3)基于不变相似测度的方法。这种方法强调了异质图像之间图像点的相似性。相似度测度一般采用图像块的相关比或互信息作为标准。然后，将相似度高的 patch 作为不变的像素点，变化的像素点代表相似度的异常值。这些方法包括相似性地图估计 (Alberga 2009)，像素对算法(PP) (Ayhan 和 Kwan 2019;Kwan 等人，2019 年)、成像模态不变(Touati 等人，2017,2018)、patch 相似图矩阵(PSGM) (Sun 等人，2020 年)、自适应局部结构一致性 (ALSC) (Lei 等人，2020 年)和改进的基于非局部 patch 的图 (INLPG) (Sun 等人，2021a;Sun 等人，2021b)。相似度图可以定量地测量地物的变化程度，但当地物变化较大或图像覆盖范围较广时，变化程度的测量就比较困难和复杂。
- (4)分类方法。与前三种方法相比，它们不仅能识别出变化区域，还能获得类信息。他们通过比较异构遥感影像的分类图获得 CD 结果，如分类后比较(PC-CC) (Mubea 和 Menz 2012;Wan et al. 2019)和 multi-temporal segmentation and mixed classification (MS-CC) (Zhou et al. 2008)。然而，其准确性往往取决于分割或分类的效果，从而遭受了累积的分类误差。
- (5)基于转换和投影的方法。其主要思想是将异构或多模态图像转换为相同的特征空间，从而使图像在 CD 任务中更具可比性。主要有两大类，包括常规转换和基于深度学习的转换。机器

学习和统计方法是典型的传统变换，如同质像素变换(HPT) (Liu et al. 2018b)，聚类分裂和合并识别(Luppino et al. 2017)，分形投影和基于马尔可夫分割的方法(FPMSMCD) (Mignotte 2020)。基于深度学习的转换技术是近年来兴起的。例如，对称卷积耦合网络(SCCN) (Liu et al. 2018a)、条件生成对抗网(cGAN) (Niu et al. 2019)、X-Net 和 ACE-Net 方法使用循环对抗网(Luppino et al. 2020)。深度学习模型利用深度特征将原始不同区域的图像统一到同一区域进行比较。总的来说，基于转换和投影的方法由于易于推广和解释，是异构 CD 研究的一个很有前途的方向。

事实上，基于转换和投影的 CD 模型不仅取决于生成图像的质量，还取决于这些转换图像的有效利用。图像平移后，以往的 CD 方法大多基于无监督思想，结果一般采用传统的差分 and 阈值分割。然而，原始图像与生成图像之间的关系仍然难以描述，结果容易受到噪声的影响，降低了变化区域的检测精度。在最近的研究中，也发现深度学习具有非线性表征和出色的图像特征提取能力来提高 CD (Chen and Shi 2020;彭等，2019)。在此基础上，提出了一种基于深度翻译的光学和 SAR 遥感图像变化检测网络(DTCN)。我们的 DTCN 不像前面的方法那样处理翻译后的图像，而是将它们与参考图像一起导入到一个受监督的 CD 网络中。本研究的贡献主要体现在以下三个方面：

- (1)提出了一种通用的 DTCN 框架，用于自动提取光学和 SAR 遥感影像的变化区域。其核心思想是先将光学遥感图像和 SAR 遥感图像转换成相同的特征域，然后将其输入到 CD 网络中，而不是直接使用无监督的方法。CD 网络可以有效地提取和利用深度图像特征生成 CD 二值图。
- (2)为 CD 任务构建了一个改进的 UNet++。通过深度可分卷积，减少了网络参数的数量，改进了训练过程。提出了一种不同于多侧面输出融合(multiple sideoutput fusion, MSOF)的多尺度损耗函数(Peng et al. 2019)。多尺度损失函数考虑了不同尺度的特征，优化了全局和局部效应。
- (3)在光学和 SAR 遥感影像 CD 中验证了深度图像平移的有效性，通过深度图像平移实现了光学和 SAR 影像的统一。此外，研究表明，一个更好的平移模型可以改善生成的图像，从而提高 CD 的结果。

本文的其余部分组织如下。在第 2 节中，研究区域和数据集被描述。第 3 节详细介绍了所提出的方法，然后在第 4 节进行了实验和结果。讨论将在第 5 节中进行。最后，我们在第 6 节得出结论。

2.研究区域和数据描述

本文使用了来自三个不同地区的四对光学和 SAR 遥感数据集，包括英国的 Gloucester (Longbotham et al. 2012;Mignotte 2020;Touati 等人，2019)。，美国加利福尼亚州 (<https://sites.google.com/view/luppino/data>)，以及

表 1
四套光学和 SAR 数据集的详细信息。

2012

中国曙光村(Mignotte 2020;Touati 等人, 2019)。每个数据集使用一幅光学图像、一幅 SAR 图像和相应的异构 CD 的地面真相。表 1 报告了它们的详细信息。所有的数据集都被重新取样, 共同注册和裁剪以覆盖相同的地理区域。

第一个 Gloucester I 数据集由英国 Gloucester (UK)洪水前后拍摄的两幅图像组成, 如图 1 所示(Mignotte 2020;Touati 等人, 2019)。光学图像由 Quickbird 2 号于 2006 年 7 月获得, SAR 图像由 TerraSAR-X 于 2007 年 7 月获得。这两幅图像覆盖面积相同, 图像尺寸为 2325×4135 , 分辨率为 0.65 m。这个 ground truth 是通过整合一些先验信息和专家知识人工生成的。

Gloucester II 数据集也来自于 Gloucester, 并用于 2009-2010 年 IEEE GRSS 数据融合竞赛, 如图 2 所示(Longbotham et al. 2012)。同样, 该数据集也包含洪水, 但与 Gloucester i 数据集的传感器和时间不同

图像是由 ERS-1 于 2000 年 11 月拍摄的。空间分辨率约为 25 m, 地面真实度由 IEEE 数据融合技术委员会提供。

第三个数据集是在美国加利福尼亚州(California)获得的洪水前后的多光谱和 SAR 图像, 如图 3 所示(Luppino et al. 2019)。这张光学图像由陆地卫星 8 号于 2017 年 1 月 5 日拍摄, 覆盖加州萨克拉门托县、尤巴县和萨特县。该 SAR 图像由 Sentinel 1-A 拍摄, 于 2017 年 2 月 18 日覆盖同一地理区域。与其他三个数据集相比, SAR 图像的特征是 3 个波段, 分别记录在极化 VV 和 VH 中, 两种强度的比值作为第三通道。两幅图像的尺寸为 2000×3500 , 分辨率约为 15 米。地面真实度由另外两幅单偏振 Sentinel-1 图像同时获得。

第四数据集包含中国东营市曙光村采集的两幅图像, 如图 4 所示(Mignotte 2020;Touati 等人, 2019)。这两张尺寸为 419×342 的图片显示的是一个从农田开始建造的建筑, 在右下方是一条河流的变化 SAR 图像由 Radarsat-8 于 2008 年 6 月拍摄, 光学图像由谷歌 Earth 于 2012 年 9 月拍摄, 分辨率为 8 m。基于输入图像, 将先验信息与专家知识相结合, 人工获取地面真值。

3.方法论

本文提出的光学和 SAR 遥感图像 CD 的 DTCDN 方法由深度平移网络和 CD 网络两部分组成(图 5), 由于光学和 SAR 图像的成像差异, 直接将光学和 SAR 图像导入 CD 网络检测变像元会产生显著的误差。如图 5 所示, 为了减少误差, 首先利用深度平移网络将一幅异构图像平移到另一幅图像的域中。本文仅介绍了一种将光学图像转换为 SAR 图像的平移方法。然后将平移后的图像和同一域中的另一个参考图像导入同构 CD 网络, 生成最终的变化映射。在训练阶段,





图 1。Gloucester I 数据集。(a)光学图像。(b) SAR 图像。(c)基本事实。请注意(c)中的更改区域用白色填充。



图二。Gloucester II 数据集在英国。(a)光学图像。(b) SAR 图像。(c)基本事实。请注意(c)中的更改区域用白色填充。




图 3。加利福尼亚数据集在美国。(a)光学图像。(b) SAR 图像。(c)基本事实。请注意(c)中的更改区域用白色填充。

将光学和 SAR 图像对送入深平移网络。另外，我们的 CD 网络是有监督的，需要有相应的标签。

3.1。深度翻译网络

深度翻译网络的目的在于减少英汉翻译之间的差异
通过对光学图像和 SAR 图像进行编码和转换，将它们转化为相同的特征空间，也为光盘网络做了准备。图像到

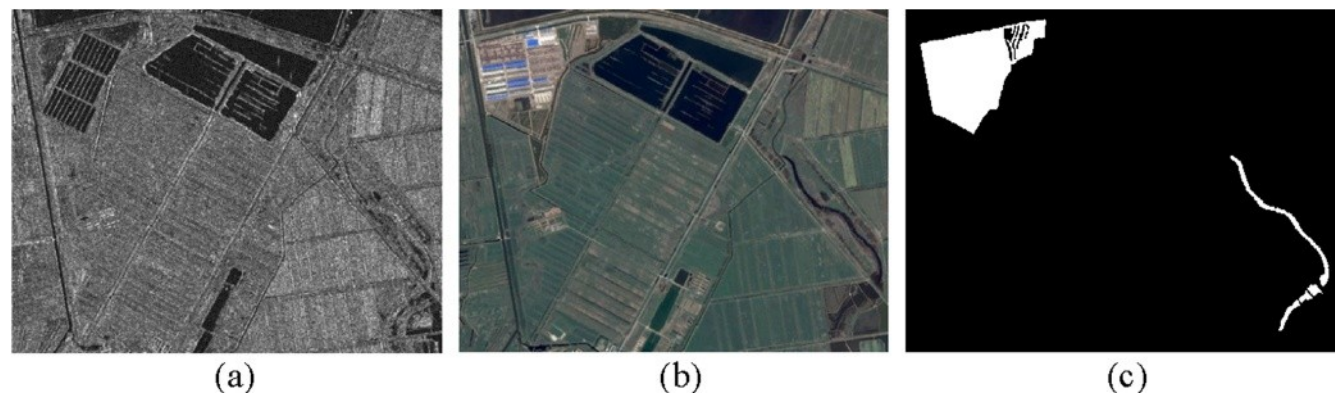


图 4。中国曙光村数据集。(a) SAR 图像。(b)光学图像。(c)基本事实。请注意(c)中的更改区域用白色填充。

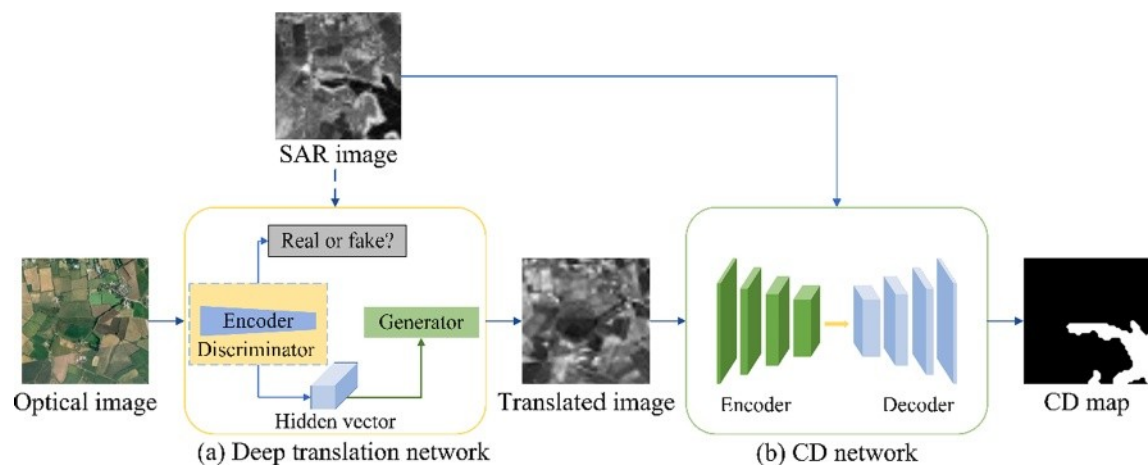


图 5。提出的 DTCDN 结构有两个步骤。(a)深度翻译网(b)光盘网。

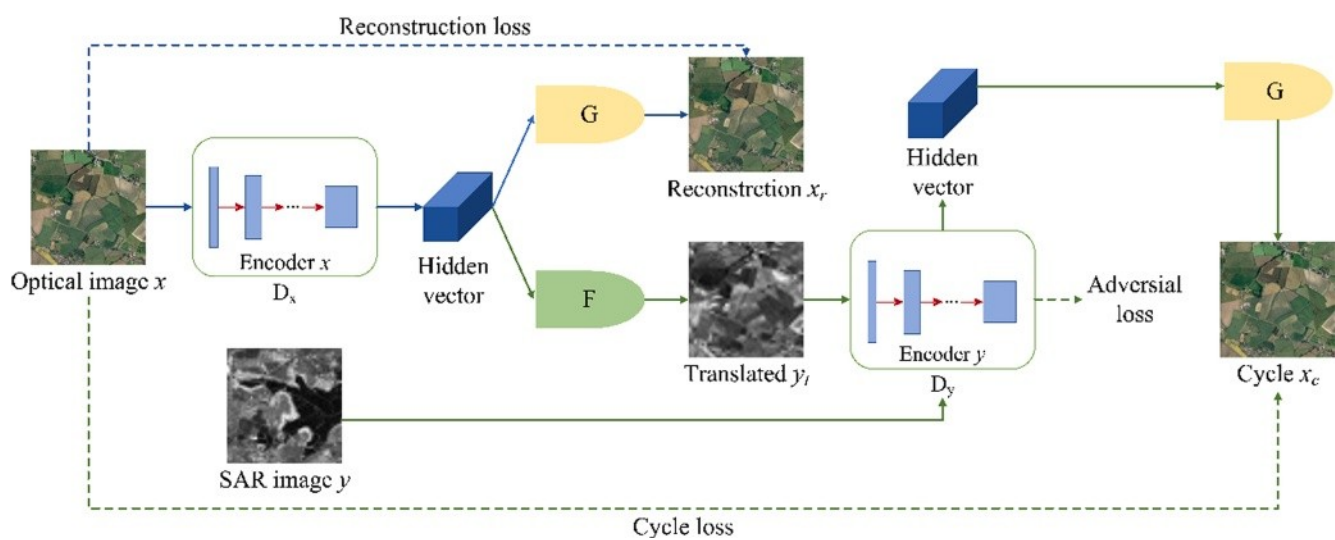
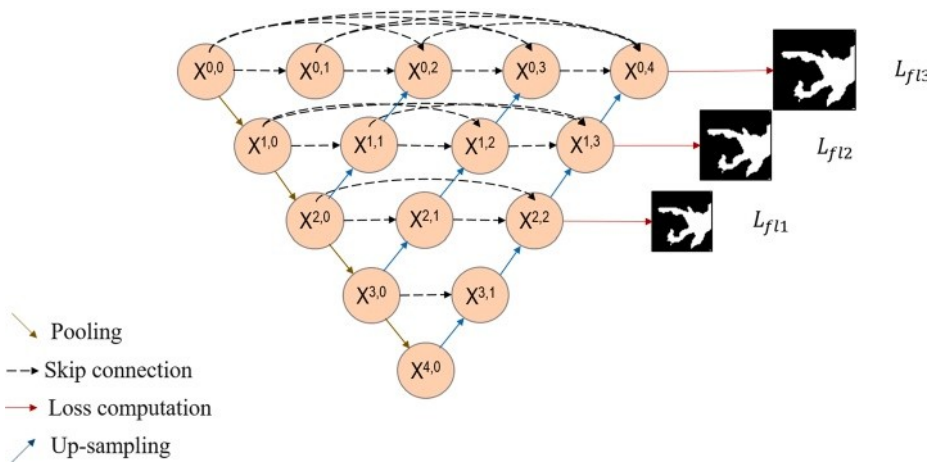


图 6。以光学图像到 SAR 图像的深度平移模型为例。G 和 F 分别代表域 X 和 Y 的生成器。 D_x 和 D_y 分别为 X 和 y 域的鉴别器。对抗损耗、重建损耗和循环损耗可以在循环过程中提高生成的 SAR 图像的质量。

图像平移是一种常用的图像处理方法，其基本思想是用一组对齐的图像对训练集学习输入图像和输出图像之间的映射函数 (Zhu et al. 2017)。它起源于图像类比，实现了从单个图像到单个图像的转换 (Hertzmann et al. 2001)。用 pix2pix

随着 GAN 的出现，基于图像平移的 GAN 吸引了更多的关注 (Isola et al. 2017)。无监督循环一致广告网络 (cycle-gan) 可以通过循环一致性损失将特征从一个域转移到另一个域 (Zhu et al. 2017)。pix2pixHR 是 pix2pix 的改进版本，它引入了一个粗糙的



图七。改进的 U-Net++。黑色箭头表示跳跃连接，红色箭头表示不同水平预测结构和下采样标签的多尺度损失。(本图图例中有关颜色的参考资料，读者可参考本文的网络版。)

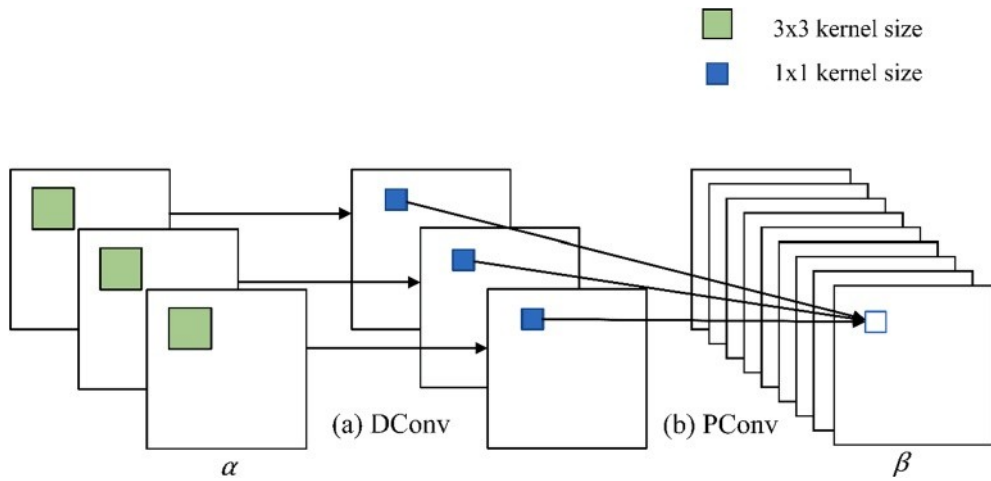


图 8。深度可分离卷积的例子，它分为两个部分:(a)深度卷积(DConv)，和(b)点卷积(PConv)。

表 2
Gloucester I 数据集的 CD 结果。

数据集	方法	精度 (%) ↑	回忆 (%) ↑	f 1 (%) ↑	o a (%) ↑
格洛斯特 我	r	15	30	2	76
	x	.7	.6	0.	.6
	inl	8	4	8	3
	pg	28	61	3	80
	S	.5	.2	3	.7
	C	1	7	8.	0
	N	59	61	9	91
	cG	.7	.6	1	.9
	A	4	8	6	9
	N	33	68	0.	83
	x	.8	.6	7	.4
	网	4	8	0	2
	ace	66	78	4	93
	网	.2	.7	5.	.8
	高温	6	5	3	5
	高压	65	70	4	93
	没有翻译	.6	.7	7	.3
DTC DN		5	3	1.	5
		31	65	9	82
		.7	.1	7	.4
		5	8	6	6
		83	80	8.	96
		.2	.9	1	.4
		1	2	0	5
				4	2.
				6	.9
				8	8
				8	2.
				0	0
		89	89		97
		.9	.9		.9
		6	3		8

到精细生成器和多尺度鉴别器架构，以产生高分辨率生成的图像 (Wang 等人，2018 年)。基于优秀对抗判别网络的翻译思想也被应用于遥感图像领域(Shi et al. 2020)。此外，辩证 GAN 将 Sentinel 1 图像转换为 Terra- SAR 图像(Ao et al. 2018)。Fuentes Reyes 等人(2019)进一步讨论了 Cycle-GAN 的极限，并优化了从 SAR 到光学图像的转换结构。Turnes 等人(2020)提出了一种 atrouss - cgan 来增强从生成的光学图像中的细节

基于非对称空间金字塔池(ASPP)的 SAR 在多尺度上挖掘空间背景。这些研究表明，图像平移对遥感图像也有很好的效果。

这里使用的深度翻译模型是基于 Cycle-GAN 的非独立分量编码 GAN (NICE-GAN) (Chen et al. 2020;Zhu et al. 2017)。原始的 Cycle-GAN 算法利用编码器将图像转换为一个包含隐藏信息的向量，然后由生成器生成另一个域的图像，最后由鉴别器对生成的图像进行真伪分类。此外，尼斯- gan，即内省网络(INN)，在鉴别器中重用一定数

量的早期层，以提高生成质量，使整个结构更紧凑和高效(Jin et al. 2017;Lazarow 等人，2017 年;Lee 等人，2018)。我们的实验采用了原有的具有多尺度配方和残留注意的 NICE-GAN。如图 6 所示，本文提出的 NICE-GAN 方法将异质遥感图像的一个域 X 转换为另一个域 Y，甚至实现了 Y 和 X 的交换。以 X 域中的一幅光学图像为例，将光学图像导入到判据器 Dx 中，它具有将图像编码成隐藏向量并将图像分类为真或假的功能。将隐藏向量输入到生成器 G 和 F 中，生成重构 xr 和平移 yt。然后将 yt 输入到 Dy 中进行编码和计算

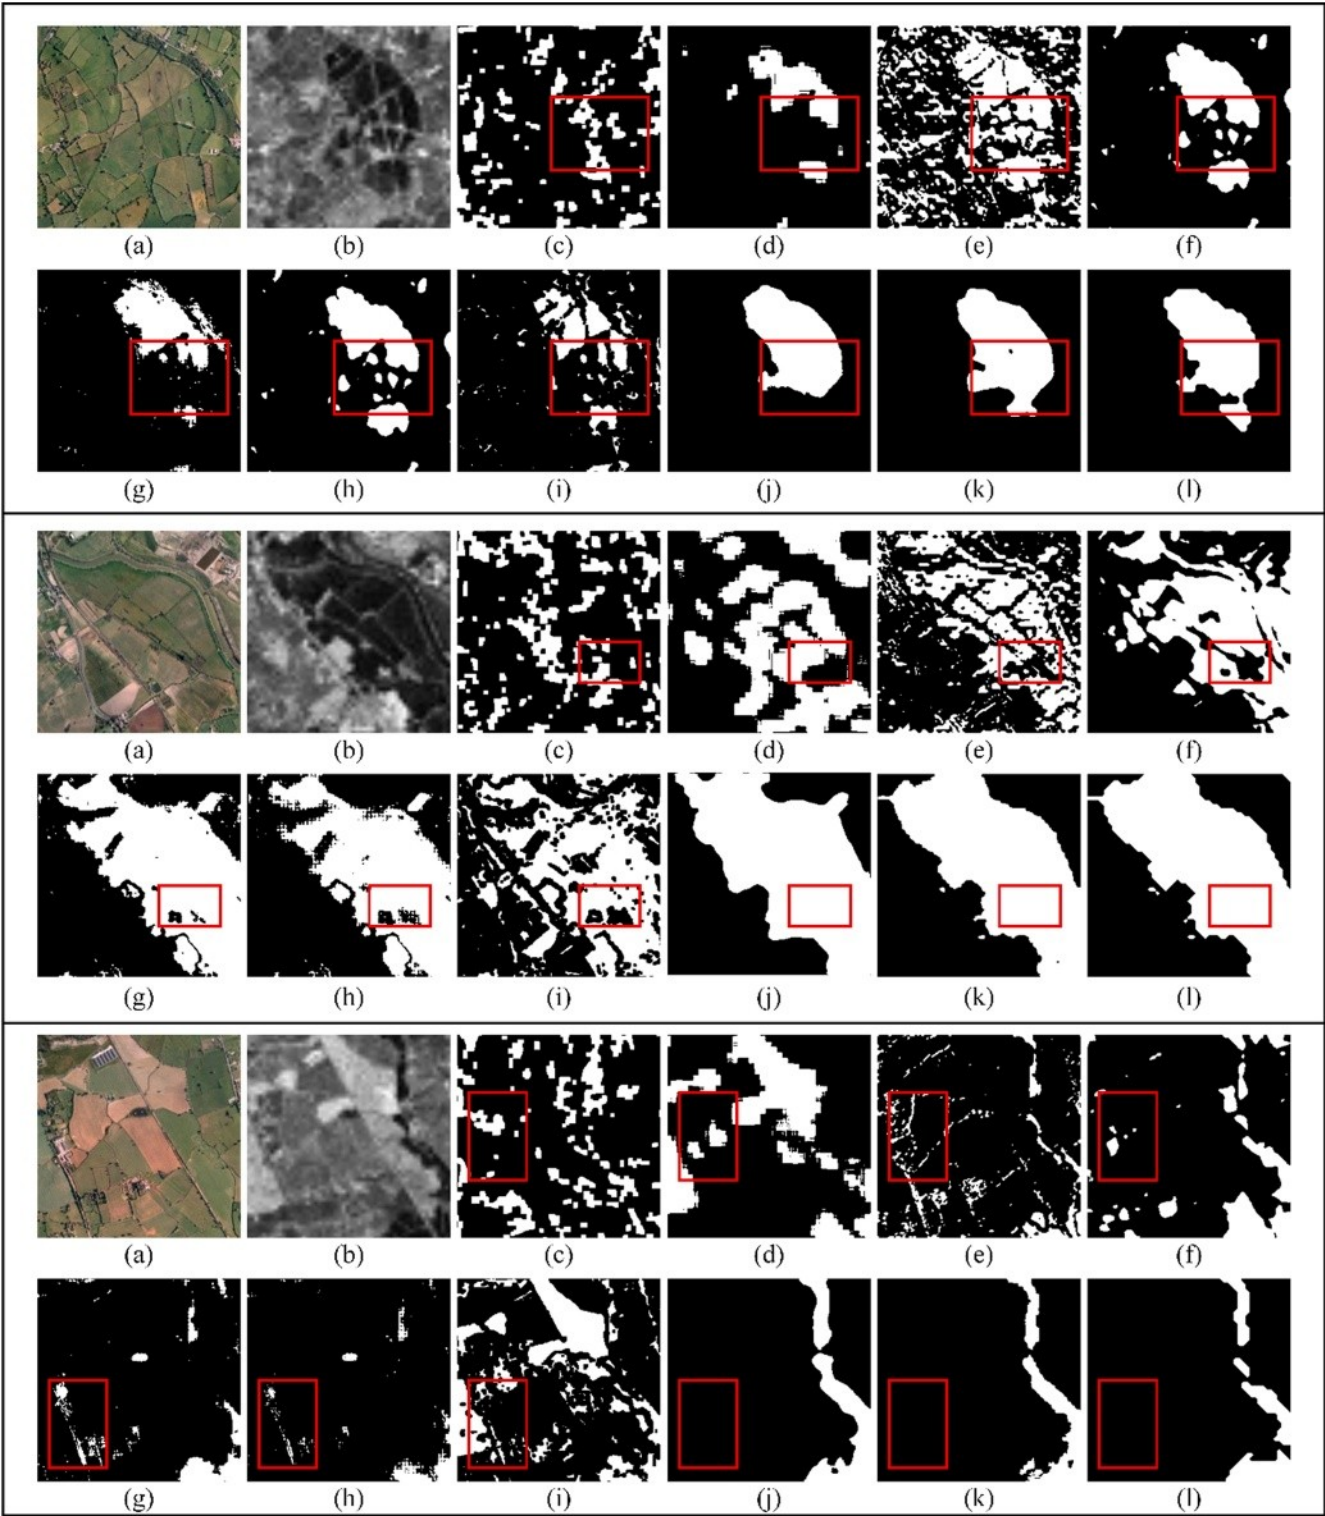


图9。使用不同方法对 Gloucester I 数据集进行 CD 结果的视觉比较。从左到右:(a)图像 T1 , (b)图像 T2 , (c) RX , (d) INLPG , (e) SCCN , (f) cGAN , (g) X-Net , (h) ACE-Net , (i) HPT , (j) Without translation , (k) DTCDN , (l) ground truth。

对抗性损失。在这个过程中，将提供 SAR 图像 y 作为参考并参与计算。然后将 D_y 中的隐向量输入到 G 中，得到循环 x_c 。这意味着一个完整的迭代。此外， y 域中的 SAR 图像 y 在每次迭代中也进行了相同的操作。在网络结构中，定义了三种重要损耗:对抗损耗 L_{adver} 、重构损耗 L_{recon} 和周期损耗 L_{cyc} ，分别定义如下：

$$L_{adver} = E_{y \sim p_{data}(y)} \left[(D_y(y))^2 \right] + E_{x \sim p_{data}(x)} \left[1 - D_y(F(x))^2 \right] \tag{1}$$

$$+ E_{x \sim p_{data}(x)} \left[(D_x(x))^2 \right] + E_{y \sim p_{data}(y)} \left[1 - D_x(G(y))^2 \right] \tag{2}$$

$$L_{recon} = E_{x \sim p_{data}(x)} [\|G(x) - x\|_1] + E_{y \sim p_{data}(y)} [\|F(y) - y\|_1] \tag{3}$$

$$L_{cyc} = E_{x \sim p_{data}(x)} [\|G(F(x)) - x\|_1] + E_{y \sim p_{data}(y)} [\|F(G(y)) - y\|_1]$$

表 3
Gloucester II 数据集的 CD 结果。

数据集	方法	精度 (%) ↑	回 忆 (%) ↑	f 1 (%) ↑	o a (%) ↑
格洛斯特 II 数据集	r	2	4	3	70
	x	7.	0.	2.	.4
	inl	3	6	7	7
	pg	6	8	1	75
	S	4	4	4	.3
	C	2.	2.	2.	6
	C	4	4	4	72
	N	8	7	8	.3
	e	3	3	3	5
	G	4.	5.	4.	77
	A	1	3	7	.0
	N	2	6	3	1
	x	3	5	4	82
	网	6.	2.	2.	.1
	ace	5	1	9	4
	网	3	3	6	85
	高温	5	3	4	.6
	高压	3.	7.	3.	9
	没有	2	2	8	88
	翻译	6	3	3	.5
DTCDN	DT	7.	9.	6.	93
	CD	1	8	9	.4
	N	2	4	4	5
		5	4	5	
		0.	9.	0.	96
		4	6	0	.3
		6	5	5	3
		8	8	8	
		3.	0.	1.	
		0	6	8	
		5	5	3	
		90	86	88	
		.7	.6	.6	
		8	6	7	

从异构的图像，将被馈送到 CD 网络。由于深度卷积神经网络(CNN)的快速发展，深度学习方法已被证明可以在遥感图像中获得良好的性能(Daudt et al. 2018;Guo et al. 2020;Kampffmeyer 等人 2016 年;Liu et al. 2020b;Touati 等人，2020)。基于深度学习的 CD 方法已经得到了迅速的研究和应用(Liu et al. 2021;Wang et al. 2019)。U-Net 是 CNN 的一个更好的版本，因为跳过连接(Ronneberger et al. 2015)。我们建议的 CD 网络基于改进的 U-Net，称为 U-Net++ (Zhou 等人，2018)。与 U-Net 相比，U-Net++填补了中间层的空洞，采用了一系列嵌套、密集的跳线

表 4
加州数据集的 CD 结果。

--

其中，图像分布概率表示为 $x \sim p_{data}(x)$ 和 $y \sim p_{data}(y)$ 。|||1 表示 l1 范数。用方程式。(1)、(2)、(3)在对抗判别过程中，将生成更精确的光学图像和 SAR 图像。本研究实现了两种翻译模式:1)从光学图像到 SAR 图像，2)从 SAR 图像到光学图像。在这种情况下，光学图像和 SAR 图像将被统一到同一空间。

3.2。变化检测网络

经过深度图像平移，得到均匀图像




图 10。使用不同方法对 Gloucester II 数据集进行 CD 结果的视觉比较。从左到右:(a)图像 T1 , (b)图像 T2 , (c) RX , (d) INLPG (e) SCCN , (f) cGAN , (g) X-Net , (h) ACE-Net , (i) HPT , (j) Without translation , (k) DTCDN , (l) ground truth。




图 11。使用不同方法对加州数据集进行 CD 结果的视觉比较。从左到右:(a)图像 T1 , (b)图像 T2 , (c) RX , (d) INLPG (e) SCCN , (f) cGAN , (g) X-Net , (h) ACE-Net , (i) HPT , (j) Without translation , (k) DTCDN , (l) ground truth。

结合功能的连接。其优点是可以捕获和集成不同级别的特征，通过特征串联增强鲁棒性。虽然 U-Net++ 可以取得更好的结果，但其大量密集的连接导致参数量和推理时间大幅增加。为此，深度可分离卷积(Chen et al. 2018;Liu et al. 2020a;引入 Shang et al. 2020)来代替普通的卷积。同时，

在不同层次的预测中加入多尺度损失，以提取更多的上下文信息，提高训练速度。改进后的 UNet++ 如图 7 所示。

3.2.1。U-Net++ 的深度可分卷积

标准卷积 Conv 同时对空间和信道起作用，但这种操作消耗了大量的计算量。The

表 5
曙光数据集的 CD 结果。

数据集	方法	精度 (%) ↑	回忆 (%) ↑	f1 (%) ↑	o a (%) ↑
曙光 村庄	r	4	4	4	9
	x	6	3	4	2
	inl	2	7	9	7
	pg	8	7	9	6
	SC	3	9	5	9
	C	9	0	5	0
	C	9	0	2	4
	N	0	1	9	0
	cG	3	4	3	8
	A	0	3	5	9
	N	2	4	6	9
	x	1	2	2	7
	网	5	8	6	9
	acc	4	7	6	5
	网	0	2	7	5
	高温	3	3	3	2
	高压	6	7	7	9
	没有	8	5	1	6
	翻译	1	8	8	3
	DTC	9	2	0	7
	DN	7	7	7	9
		9	5	5	7
		1	8	3	1
		7	7	4	3
		5	8	6	9
		1	9	5	6
		8	9	7	2
		1	9	6	5
		8	7	7	9
		0	9	9	7
		3	0	7	4
		4	7	0	9
		92	90	91	99
		.9	.2	.5	.7
		2	5	6	5

深度可分卷积 SConv 可以将标准卷积分解为两个步骤，深度卷积 DConv 和点卷积 PConv (Chollet 2017)，这大大减少了数学运算和参数的数量。Conv、DConv、PConv、SConv 的公式可以表示为：

$$\text{Conv}(W, a)_{(i,j)} = \sum_{m,n,k}^{M,N,K} a(i+m,j+n,k); \tag{4}$$

$$DConv(W_d, a)_{(i,j)} = \sum_{m,n,k}^{M,N,K} W_{d(m,n)} \cdot a(i+m,j+n) \tag{5}$$

$$PConv(W_p, a)_{(i,j)} = \sum_k^K W_p \cdot a_{(i,j)} \tag{6}$$

$$SConv(W_p, W_d, a)_{(i,j)} = PConv(W_p, a)_{(i,j)} (W_p, DConv(W_d, a)_{(i,j)}) \tag{7}$$

W, W_d 和 W_p 分别为 Conv、DCov、PCov 的权值矩阵。I, j 为像素在 feature map 中的位置。m, n, k 为核大小的三维。

图 8 为 SConv 的一个具体例子。让 α∈PH×W×3 表示来自图像 P 的 3 个通道的输入特征。第一步 DConv 对每个通道分别应用 3×3 的卷积核进行特征提取。当然，这 3 个通道的输出也可以从 DConv 得到，作为 PConv 的输入。利用 PConv 在 1×1 卷积核上进行特征融合，生成输出特征映射 β∈RH×W×C0，其中 C0 为输出通道数。

3.2.2. 损失函数

基于深度学习的分类器的一个常见问题是，一些类的训练示例数量明显高于其他类。这种现象被称为乳糜泻中的阶级不平衡(Buda 等人，2018 年)。这类不变的像素通常占主导地位，

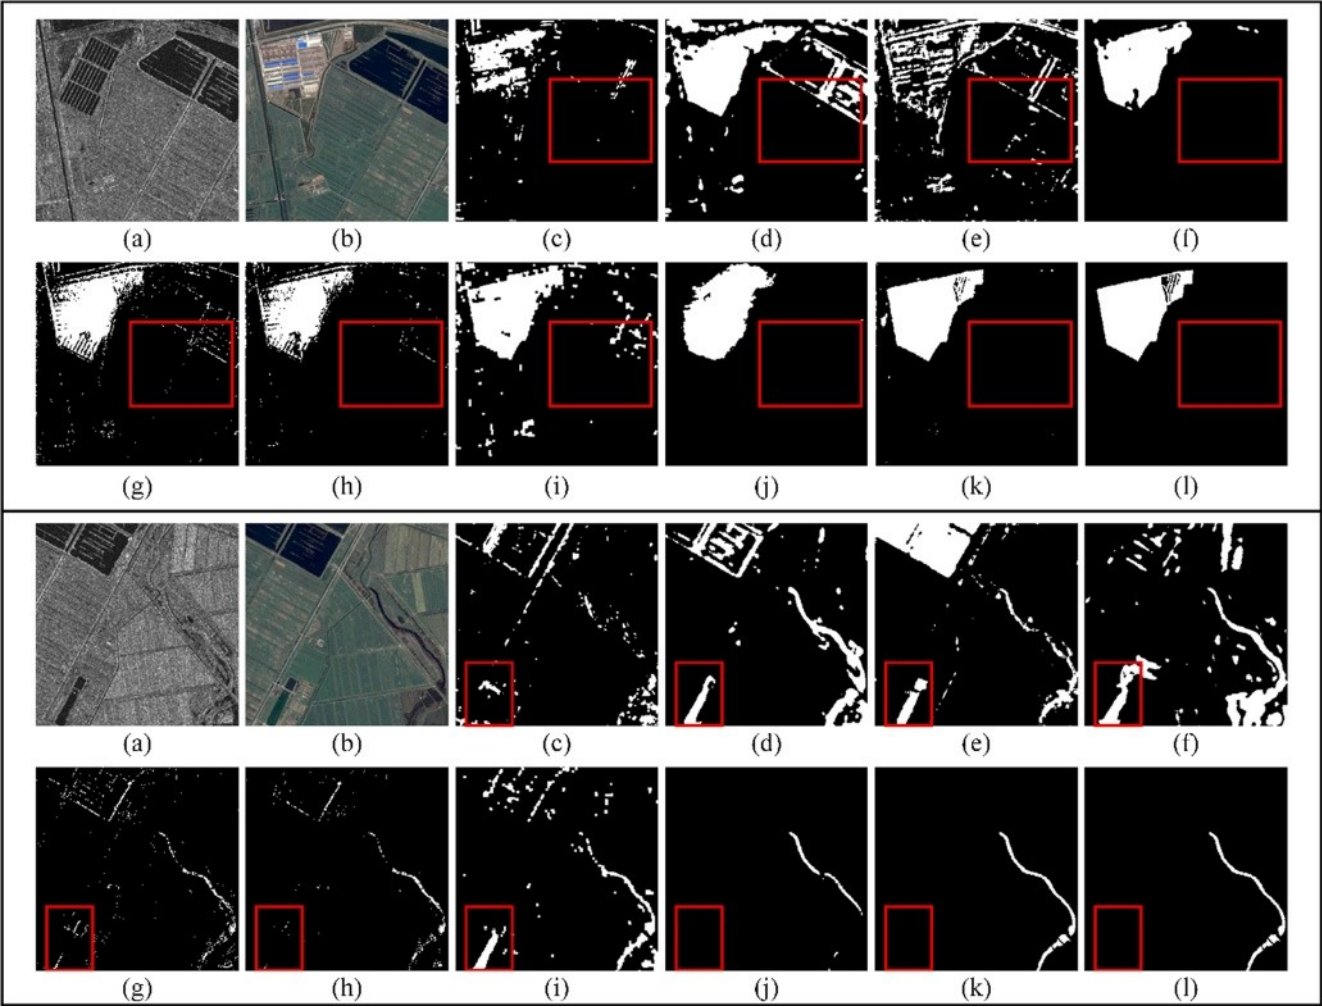


图 12. 不同方法对曙光数据集 CD 结果的可视化比较。从左到右:(a)图像 T1，(b)图像 T2，(c) RX，(d) INLPG (e) SCCN，(f) cGAN，(g) X-Net，(h) ACE-Net，(i) HPT，(j) Without translation，(k) DTCDN，(l) ground truth。




图 13。Gloucester II 数据集的光学和 SAR 图像。(a)事件前光学图像。(b)事件后光学图像。(c)事件前 SAR 图像。(d)事件后 SAR 图像。

表 6
三对图像的 CD 结果评估。

像对	精度(%)↑	Recall(%)↑	F1(%)↑	Oa(%)↑
光学和光学	89	90	90	96
SAR 和 SAR	9	8	4	8
光学与 SAR (DTCDN)	9	4	1	1
	90	8	8	95
	.5	1.	5.	.4
	5	1	6	8
	90	5	0	96
	.7	8	8	.3
	8	6.	8.	3
		6	6	
		6	7	

而只有一小部分的改变像素。为了减少类别不平衡的影响，在我们的模型中采用并修正了标准交叉熵损失(de Boer et al. 2005)的焦点损失(Lin et al. 2017a)。该损失函数可以降低易分类样本的权重，使训练时的重点放在难分类样本上。局灶性损失如下：

$$L_f = -\alpha_t(1 - p_t)^\gamma \log(p_t)$$
 (8)

其中 t 为像素点的位置，pt 为改变类的概率，αt 为权重因子。可调聚焦参数 γ≥0。

受特征金字塔网络的启发，采用多尺度损耗优化模型(Lin et al. 2017b)。多尺度损耗主要作用于跳线较长的上三层，因为上三层包含更多有价值的特征。对标签进行下采样，从上面三层的每一层的预测中计算一个焦点损耗。总损失的计算方法如下：

$$Loss = w_1 * L_{f1} + w_2 * L_{f2} + w_3 * L_{f3}$$
 (9)

其中 wi 表示第 i 层的局灶损失权重，i = 1,2,3。多尺度损耗可以利用不同尺度的更多信息，使损耗函数快速收敛并趋于稳定。

4.实验与结果

在本节中，我们利用上述四个数据集进行实验，以证明我们所提出模型的有效性。对四个数据集的结果分别进行了详细的分析。为了验证 DTCDN 的有效性，将其与其他光学和 SAR 遥感图像的 CD 模型进行比较，包括 Reed-xiaoli (RX) (Reed 和 Yu 1990)、INLPG (Sun et al. 2021b)、SCCN (Liu et al. 2018a)、cGAN (Niu et al. 2019)、X-Net 和 ACE-Net (Luppino et al. 2020)和 HPT (Liu et al. 2018b)。RX 假设背景服从多元正态分布，构造似然比检测算子。它可以应用于原始图像和翻译图像的 CD (Guo et al. 2014;周等, 2016)。INLPG 构建 K-NN 图，计算非局部 patch 相似性结构差值来衡量变化水平。SCCN 从耦合层中的两个编码图像中获得差分图像。cGAN 将光学图像通过平移网络传输到 SAR 图像，SAR 图像通过近似网络得到与传输图像相似的域。X-Net 以仿射有限信息为先验知识，将两幅图像经循环 GAN 网络变换后得到差分图像。类似地，ACE-Net 引入了一个潜在空间，在这个空间中，图像被转换成四个网络的结构。HPT 是一种超监督的异构 CD 方法，它通过对像素进行 K-最近邻的映射来实现变换。在我们的实验中，HPT 中使用的标签与 DTCDN 中使用的标签相同。对于异构遥感影像的 CD，监督的方法并不多，所选方法大多是无监督的，只能在一定程度上与我们的方法相比较。为此，进行了不平移实验，将原始图像不平移直接导入 CD 网络。此外，将 Gloucester II 中两个时间步长对应的 SAR 和光学图像直接输入 CD 网络，进一步探讨该方法的有效性。

在该模型的图像平移网络中，选择了带有残差块的 6 层生成器和 7 层编码器。选用学习率为 0.0005 的 Adam 作为优化算法。对于 CD 网络，采用编码器部分的四层 U-Net++，其卷积滤波器个数为 {32,64,128,256}。通过将一幅光学图像和一幅 SAR 图像拼接，输入张量大小为 256 × 256 × C，其中 C 为两幅图像的通道和。经反复试验，多尺度损失 w1、w2、w3 的最优权重分别为 0.2、0.3、0.5。对于焦损耗参数，分别取 γ = 2 和 α = 0.25。所有的实验都是在 Pytorch 上完成的，运行在 NVIDIA RTX 2080Ti 上，内存为 11 GB。

4.1. 评价指标

为了得到一个清晰、定量的评价，我们将深度翻译的中期结果和 CD 结果分别用不同的标准进行评价。对于图像平移，Frchet 初始距离(FID) (Heusel et al. 2017) 和核初始距离(KID) (Bin'kowski et al. 2018)可以定量描述

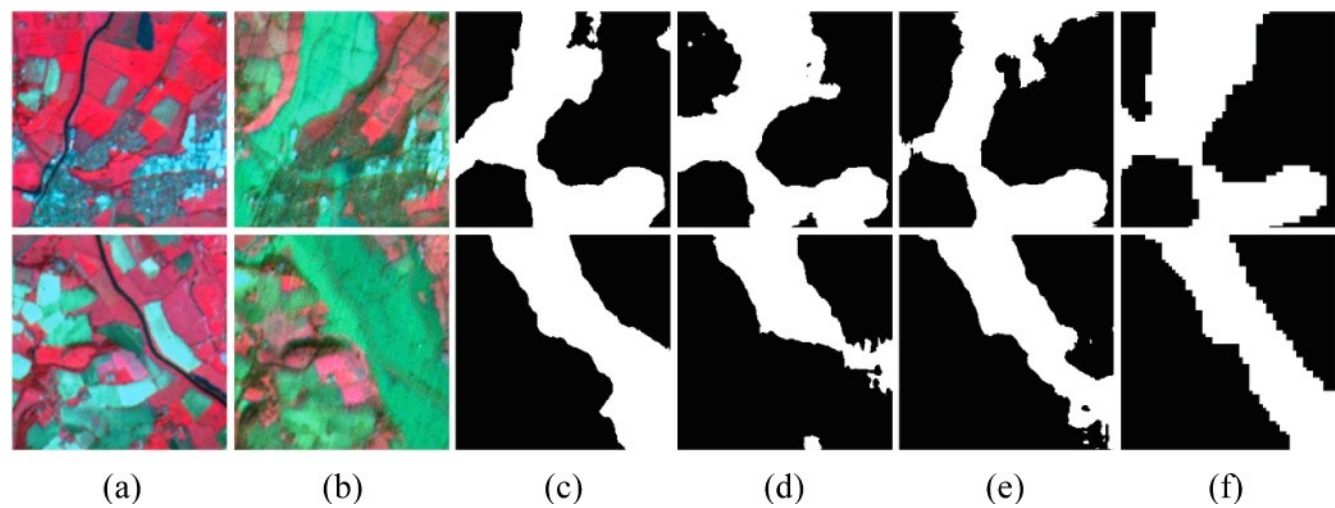


图 14。CD 来自不同的图像对。(a) T1 光学图像，(b) T2 光学图像，(c)光学和光学，(d) SAR 和 SAR，(e)光学和 SAR (DTCDN)，(f)地面真相。

表 7
在四个数据集上，通过两种不同的模式对深度翻译进行评估。

Σ_r 、 Σ_g 分别为 r 、 g 的协方差矩阵。 Tr 表示矩阵的轨迹。 $\|\cdot\|_2$ 计算 μ_r 和 μ_g 的差值的平方。

先启表示与一个多项式核函数 k 之间的平方最大平均偏差(MMD)被用来计算 KID，

$$KID = E_{r, r', pdata(r), g, g', pdata(g)} [k(r, r') - 2k(r, g) + k(r, g')] \tag{11}$$

$$k(\theta, \theta') = (\frac{1}{d} \theta^T \theta' + 1)^3 \tag{12}$$

真实图像与生成图像之间的特征距离。FID 应用预先训练的 Inception V3，在完全连接的层作为图片的一个特征之前提取 2048 维向量。

$$FID = \|\mu_r - \mu_g\|^2 + Tr(\Sigma_r + \Sigma_g - 2(\Sigma_r \Sigma_g)^{\frac{1}{2}}) \tag{10}$$

其中 r 和 g 分别为实图像和生成图像的特征。 μ_r 和 μ_g 分别代表 r 和 g 的平均值。

其中 r, r' 样本来自真实的图像， g, g' 是生成的图像中的样本。 D 表示图像 θ 的维数。与 FID 相比，KID 有更多的优点。KID 是一个无偏估计，没有使用活化分布的参数形式。两个指标的数值越低，翻译效果越好。

CD 结果以混淆矩阵中的真阳性(TP)、真阴性(TN)、假阳性(FP)和假阴性(FN)样本计算精密度和召回率。F1 是精度和召回的综合结果。总体精度(OA)是对所有样本的正确率的评价。计算公式的四在

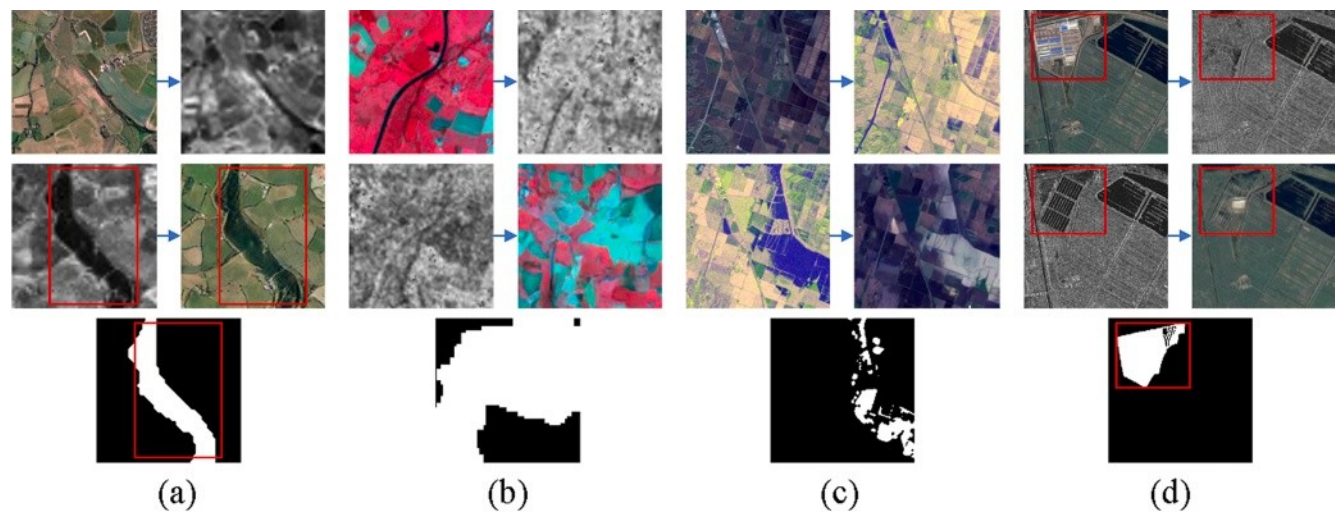


图 15。四个数据集上的翻译图像。(a) Gloucester I 数据集。(b) Gloucester II 数据集。(c)加州数据集。(d)曙光村数据集。从上到下:光学图像到 SAR 图像，SAR 图像到光学图像，地面真实。

表 8
四组数据上两种不同模式的 CD 结果。

独裁者如下：

精度 = TP/(TP + FP)

(13)

回忆 = TP/(TP + FN)

(14)

OA = (TP + TN)/(TP + TN + FP + FN)

(15)

(16)

表 9
四种不同的 Gloucester I 数据集翻译方法的 FID 和 KID。

SAR			
	Op→SAR	130.16	5.76

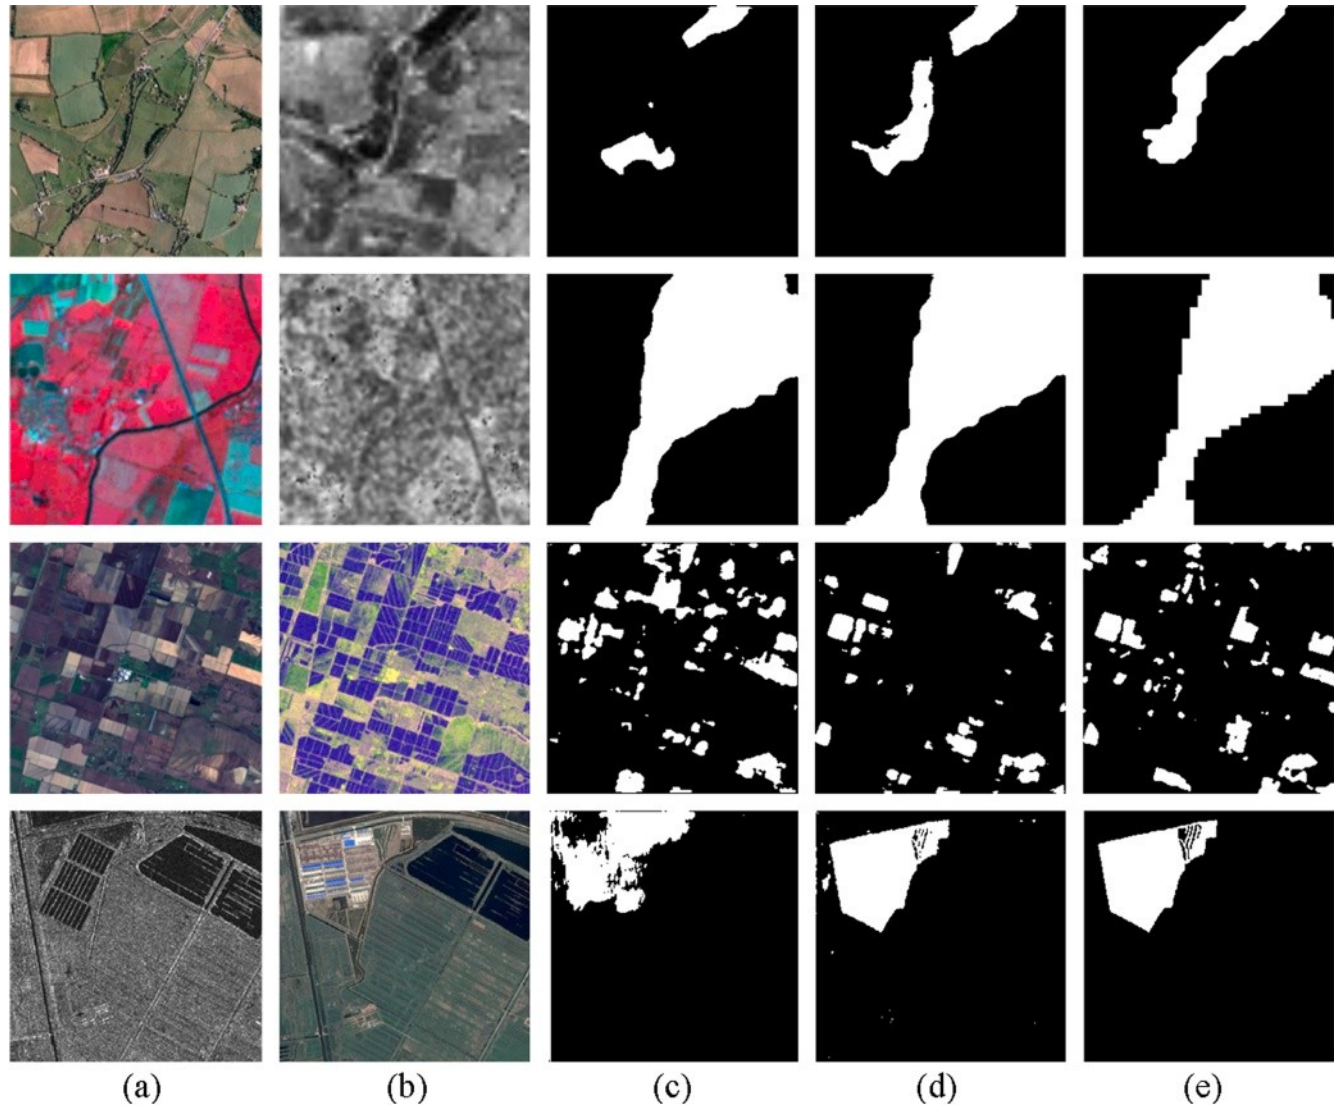


图 16。使用两种翻译模式对四组数据进行 CD 结果的可视化比较。从左到右:(a)图像 T1 , (b)图像 T2 , (c) SAR→Op , (d) Op→SAR , (e) ground truth。从上到下:Gloucester I, Gloucester II , 加利福尼亚和曙光数据集。




图 17。Gloucester I 数据集上使用不同方法的图像翻译结果的可视化比较。从左到右:(a)图像 T1 , (b)图像 T2 , (c) ground truth , (d) pix2pix , (e) pix2pixHR , (f) Cycle-GAN , (g) NICE-GAN。

表 10
CD 评估了不同的翻译方法和没有翻译的 Gloucester I 数据集。请注意，这里的结果只使用光学到 SAR 图像的模式。

翻译方法	精度(%)↑	Recall(%) ↑	F1(%) ↑	Oa(%) ↑
没有翻译	83	80	8	96
像素	.2	.9	2.	.4
1	1	2	0	5
pix2pix	85	82	5	96
HR	.1	.0	8	.7
循环	9	3	3.	7
gan	87	86	5	97
尼斯干	.9	.1	8	.4
	4	5	8	3
	83	90	7.	97
	.8	.6	0	.3
	1	5	4	1
	89	89	8	97
	.9	.9	7.	.9
	6	3	1	8
			0	
			89	
			.9	
			5	

其中 60%用于培训，20%用于验证，20%用于翻译网络中的测试。CD 网络使用相同的样本，包括原始图像、翻译后的图像和相应的标签。

如表 2 所示，与其他方法相比，我们的方法在 Gloucester I 数据集上得到的 CD 结果在检测变化区域和未变化区域方面具有优势，且误判较少。特别是在 F1 中，DTCDN 有明显的改进，这意味着其他方法的检错和漏检次数更多，如表 11 所示
使用标准卷积和深度可分离卷积比较参数和时间。

4.2。Gloucester I 数据集的变化检测结果

对于 Gloucester I 数据集，两幅图像之间的主要变化像素是洪水灾害覆盖了包括农田和建筑在内的部分地面。这些图像被裁剪成 256 × 256 块

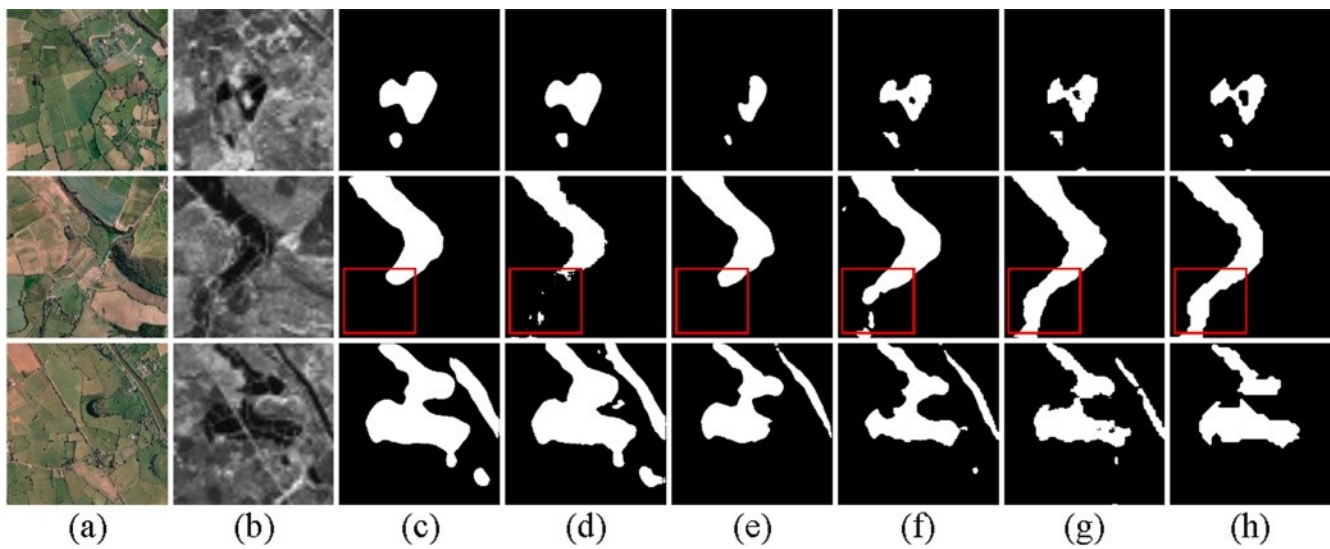


图 18. 使用不同方法对 Gloucester I 数据集进行 CD 结果的视觉比较。从左到右:(a)图像 T1 , (b)图像 T2 , (c)不平移, (d) pix2pix , (e) pix2pixHR , (f) CycleGAN , (g) NICE-GAN , (h) ground truth。

表 12
使用标准卷积和深度可分离卷积的 CD 结果的比较。

数据集	卷积方法	精度 (%) \uparrow	回忆 (%) \uparrow	f1 (%) \uparrow	oa (%) \uparrow
格洛斯特一世	标准	7	92	8	96
	深度	5	.5	3	.2
	可分离的	5	2	1	4
格洛斯特二世	标准	1	89	6	97
	深度	89	.9	89	.9
	可分离的	.9	3	.9	8
加利福尼亚	标准	6	89	5	95
	深度	8	.1	8	.9
	可分离的	6	1	7	7
曙光村庄	标准	8	86	9	96
	深度	8	.6	8	.3
	可分离的	90	6	88	3
曙光村庄	标准	.7	77	.6	96
	深度	8	.0	7	.3
	可分离的	6	6	7	5
	标准	4	78	0	97
	深度	5	.2	2	.6
	可分离的	6	4	6	1
	标准	66	72	72	
	深度	.7	87	.0	98
	可分离的	3	.4	3	.0
	标准	9	8	8	0
	深度	0	.2	8	.7
	可分离的	3	5	8	5
	标准	3	8	8	
	深度	92	91	91	
	可分离的	.9	.5	.5	
	标准	2	6	6	

侦查 RX 的性能很差，因为它的精度最低，这表明它错误地将许多未改变的像素作为改变的像素。虽然 INLPG 有超过 60% 的良好召回率，但它的表现是第二差的。大多数基于深度学习的方法都取得了良好的性能，X-Net 和 ACE-Net 结构相似，F1 和 OA 都有第二和第三高。SCCN 是唯一的非基于 gan 的方法，排名中间。由于精度较低，cGAN 的整体结果并不好。值得注意的是，虽然在我们的实验中 HPT 使用了未改变的像素作为监督，但它比一些无监督的方法更差。由于 CD 网络的特征分析能力突出，不平移方法获得了第二次高评价，而 DTCDN 具有更好的可分辨性，在识别变化的像素方面具有最好的性能。

为了直观地比较结果，Gloucester I 数据集的变化二值图如图 9 所示。可见，DTCDN[图 9 (j)]的性能是最好的。如图 9 (c)所示，RX 在探测泛洪区方面表现最差。INLPG[图 9 (d)]漏掉了许多改变后的像素。SCCN 的预测[图 9 (e)]被打破，并且有大量的模糊。基于对抗性编码器网络的 X-Net[图 9 (g)]和 ACE-Net[图 9 (h)]也达到了类似的效果。cGAN 的结果[图 9 (f)]总体看起来是第三好的结果。HPT 预测中存在许多不连续的小噪声跳台[图 9 (i)]。对于第 1~4 行，DTCDN[图 9 (k)]模型可以在泛洪区检测到更多的空孔。此外，在第五排和第六排的红色框架中还包含了一座未改变的建筑物和一条道路。由于其与 SAR 遥感图像中的洪水具有相似的特征，其他方法大多将其视为变化区域。通常情况下，DTCDN 对变化区域形状的检测性能最好，且检测结果完整、准确。

4.3。Gloucester II 数据集的变化检测结果

在本数据集中发生的事件与 Gloucester i 相同，图像和标签的处理可参考 Gloucester i。此外，我们观察到该数据集的 SAR 图像中含有一些小噪声，可能会影响我们最终的 CD 结果。

表 3 显示了异构 CD 结果的度量。如表 3 所示，与第一个数据集相似，我们的 DTCDN 检测方法明显优于其他检测方法。与 Gloucester I 数据集不同，有监督 HPT 方法优于其他无监督方法。由于简单假设图像关系的缺点，RX 的性能仍然比基线差。在非监督方法中，基于深度学习的 X-Net、ACE-Net 和 cGAN 的得分高于 INLPG。SCCN 在识别改变的像素方面的结果是第二差的。得益于更接近的图像特征，DTCDN 比不平移具有更高的精度。

图 10 中显示了所有基线的一些二进制 CD 结果。我们可以看到，除了 DTCDN [Fig. 10 (k)]，其他方法都容易丢失大部分的变化像素(Row 1 和 Row 2)并进行检测

DTCDN [Fig. 10 (k)]可以很好地处理这两个问题，但是在 ground truth 中，一些被认为是不变的相对较小的区域属于改变的区域。

4.4。加州数据集变化检测结果

如前所述，加州数据集中发生了洪水。与其他两个数据集不一致的是，该数据集的 SAR 图像是由多极化的 VV 和 VH 数据合成的，这给我们带来了挑战。将图像和标签裁剪成 256 × 256 个 patch，数据集的分割方法与上述两个数据集相同。

加州数据集的 CD 结果如表 4 所示，我们的 DTCDN 在大多数评价中也达到了最高值。RX 在这个数据集中仍然有一个最差的性能。HPT 获得 F1 和 OA 的第三个高分。此外，INLPG 在召回方面表现最好，但精度较低，这意味着它容易对改变的像素取不变的像素。同样，ACE-Net 的召回率也只比 DTCDN 稍差一点，而且在准确率上也不理想。cGAN 和 X-Net 的准确率和召回率非常相似。结果表明，翻译对最终的 CD 值有影响，在所有的计算中，不翻译的 CD 值都低于 DTCDN。值得注意的是，本文提出的方法明显优于 8 种比较方法。

我们提出的方法和所有比较方法的变化二值图如图 11 所示。从图 11 的第一行和第二行可以看出，INLPG[图 11 (d)]，SCCN[图 11 (e)]和 ACE-Net[图 11 (h)]连接了需要分离的部分的白色变化区域，这说明它们含有更多的假阳性像素。如图 11 的 3-6 行所示，红色框包含的是光学图像和 SAR 图像上不变的像素，其颜色和纹理与变化后的像素相似。DTCDN[图 11 (k)]可以避免将这些像素作为改变的像素，而其余方法都将其识别为改变的像素。此外，HPT[图 11 (i)]在我们的结果中忽略了许多小的改变对象。在这个数据集中，DTCDN 方法仍然得到了最好的结果，并且没有造成太多的误分类。

4.5。曙光村数据集变化检测结果

曙光村数据集包括建筑物改造和河流改造。在 256 × 256 中裁剪后，由于尺寸较小，对两个主要变更区域采用交叉验证的方法。

曙光村数据集 CD 结果如表 5 所示。SCCN 的性能是所有标准中最差的。X-Net 和 ACE-Net 的精度明显高于 cGAN。HPT 和 INLPG 在召回率上都取得了很好的结果，接近 90%，但是它们会误检出一些变化的像素，导致 F1 值下降。值得注意的是，DTCDN 模型达到了 F1 的 90% 以上。在 OA 方面，由于图像以不变像素为主，所有算法都具有较高的 OA。DTCDN 性能最好。

为了定性地评估我们的结果，所有方法的预测图如图 12 所示。从直观上看，DTCDN 的结果[图 12 (k)]与 ground truth 更加一致，准确分类的像素越多，假阳性样本越少。在建筑区域内，DTCDN[图 12 (k)]虽然对建筑边界的检测性能最好，但也存在一些无法完全识别的孔洞。

4.6。异质与均匀的

为了综合评价 DTCDN，我们又引入了 Gloucester II 几乎同时采集的两幅图像，如图 13 所示。

我们的 CD 网络部分分别对同质光学图像和 SAR 图像进行训练，以更客观地比较 DTCDN。The




图 19。使用不同卷积方法对四组数据进行 CD 结果的可视化比较。从左到右:(a)图像 T1 , (b)图像 T2 , (c)标准卷积 , (d)深度可分离卷积 , (e) ground truth。

表 13
直接计算、MSOF 和多尺度损耗的 CD 结果比较。

数据集	损失计算	精度 (%) ↑	回忆 (%) ↑	f1 (%) ↑	oa (%) ↑
格洛斯特一世	直接计算	84.4	85.6	85.0	96.7
	ms	4	3	3	9
	of			88	97
	多尺度损耗	8	91	.8	.6
格洛斯特二世	直接计算	63	.40	1	9
	ms	3	0	89	97
	of	6	8	.9	.9
	多尺度损耗	89	9	5	8
加利福尼亚	直接计算	.9	9	85	94
	ms	6	3	.3	.8
	of	8	9	0	0
	多尺度损耗	0.1	1	87	95
曙光村庄	直接计算	7	3	.2	.6
	ms			1	9
	of	8	88	88	96
	多尺度损耗	5.8	.5	.6	.3
	直接计算	8	8	7	3
	ms	7	8	68	95
	of	90	6	.6	.1
	多尺度损耗	.7	6	9	9
	直接计算	8	6		
	ms	6	7	71	96
	of	3	4	.5	.2
	多尺度损耗	8	3	9	3
	直接计算	5	3	72	97
	ms			.0	.6
	of	67	7	3	1
	多尺度损耗	.4	6	85	96

三对 CD 图像的定量评估如表 6 所示。我们可以看到，光学成像对达到了我们预期的最佳性能。然而，令人惊讶的是，大多数异构图像对的评价指标都优于同质 SAR 图像。特别是，与 SAR 图像对相比，异构图像对的召回率、F1 值和 OA 值分别提高了 5.51%、3.07%和 0.85%。我们认为这可能是由于 SAR 图像的质量造成的，这证明了我们的方法在翻译 SAR 图像时，可以提高图像质量，减少一些误差。

最终检测结果的预测如图 14 所示。这里我们只显示 T1 和 T2 光学图像对[图 14 (a)和(b)]，因为它们足以显示变化区域。显然，图 14 (c)的结果最好，因为光学图像对提供了有效的光谱和空间信息。我们的 DTCDN[图 14 (e)]存在一些假阳性和假阴性，需要在今后进行改进。实验结果表明，该方法能够较好地接近光学图像或 SAR 图像的变化检测结果，有助于在无法获得均匀图像的情况下实现变化检测。

5.讨论

在本节中，我们将进一步分析 DTCDN 模型的影响因素。讨论了深度翻译和 CD 网络的主要结构对网络的影响。在此基础上，探讨了光学和 SAR 遥感影像 CD 的解决方案。

5.1。深层翻译的作用

四组数据分别采用光学图像到 SAR 图像和 SAR 图像到光学图像两种模式进行转换。图像平移的定量值如表 7 所示。可以看出，4 个数据集的 FID 都在 200 以下，其中从光学到 SAR 的 Gloucester II 数据集的翻译效果最好，但从 SAR 图像到光学图像的翻译效果最差。这可能受到含有一定量斑点噪声的原始 SAR 图像的影响。加州数据集的转换结果优于 Gloucester I 数据集。两种方法在曙光数据集上的性能都不差。此外，这四种数据集的两种翻译模式也存在一些差异。对于 California, Glou- cester I 和 II 数据集，生成的 SAR 图像更接近参考。这是因为光学图像包含更多的信息，比 SAR 图像更复杂。光学图像的生成是一个比较困难的过程。相反，曙光村数据集更适合转换为光学图像。原因可能是这个数据集的数量很少。

注意，Op→SAR 和 SAR→Op 表示从

分别从光学图像转化为 SAR 图像和从 SAR 图像转化为光学图像。4 个数据集的可视化翻译结果示例如图 15 所示。翻译后的图像能准确匹配原始图像的纹理信息和部分颜色信息，但风格更接近于参考图像。对于发生变化的像素点，平移后的图像保留了较大的差异，而在未发生变化的区域，平移后的图像几乎可以表现出与参考点相同的特征。在图 15 (a)中本应被淹没的红色区域，虽然不能直接转换成水体，但被转换成与周围地貌不一致的坑形。侧面，在图 15 (d)的红色框中，原光学图像中的建筑物在平移光学图像中变化较大，更容易识别。

FID 和 KID 表示平移后的图像与真实图像的相似度。然而，对于裁谈会来说，这并不是说越近越好。因此，对这四个数据集进行了两个方向的翻译实验。如表 8 所示，Gloucester I、California 和 Shuguang 在光学到 SAR 图像的转换上表现更好，因为它们容易生成质量更好的假 SAR 图像。相比之下，在 Gloucester II 数据集上合成孔径雷达对伪光学图像的合成效果更好。我们推测 CD 会受到原始图像的噪声的影响，当原始图像是模糊的时候，精度会降低。

如图 16 所示，有两种平移模式的 CD 样例。对于 Gloucester I 数据集，光学到伪 SAR 图像可以检测到更多的洪水区域，这导致了较高的召回率。第三行显示了加州数据集中很多建筑被洪水淹没。这反映出伪 SAR 图像不会导致误检，形状更符合地物特征。对于曙光最后一行数据集，假光学图像的预测无法提取出精确的建筑物形状。从表 8 和图 16 我们可以得出结论，虽然距离可以度量生成的图像和参考图像的相似度，但它不能完全解释最终变化检测的效果。

图像平移已被用于无监督的异质遥感影像 CD 领域，但将平移结果用作 CD 网络输入的可能性尚属首次。因此，本文将现有的图像平移方法与 NICE-GAN 进行比较，并以 Gloucester I 数据集为例进行简捷性研究。pix2pix、pix2pixHR、Cycle-GAN 和 NICE-GAN 图像平移结果的 FID 和 KID 如表 9 所示。结果表明，将分类器和编码器结合在鉴别相位的 NICE-GAN 在两种模式下都有较低的 FID 和 KID。pix2pix 和 pix2pixHR 没有循环结构，需要双倍的训练时间，可能会影响翻译效率。更重要的是，pix2pix 缺乏多尺度方法，我们认为这是其精度最低的原因。在 SAR 图像转换为光学图像的模式下，Cycle-GAN 和 pix2pix 具有较高的 FID 和 KID。与此相反，pix2pixHR 和 Nice- GAN 对 SAR 图像的翻译效果更好。

为了更直观地比较这四种方法，如图 17 所示为光学到 SAR 的视觉平移。从视觉上看，Nice- GAN[图 17 (g)]和 Cycle-GAN[图 17 (f)]在传递风格上都取得了很好的效果，并保留了原有的特点。pix2pix[图 17 (d)]是最差的，有噪声和模糊效果。此外，由于 pix2pixHR[图 17 (e)]更适合生成更高分辨率的图像，所以平移后的图像过于平滑。Cycle-GAN [Fig. 17 (f)]生成的图像与 NICE-GAN [Fig. 17 (g)]生成的图像相似，但在第一行的红色框中存在盐噪声，这可能会影响 CD 的结果。此外，图 17 的第二行和第三行显示了一些光学图像和 SAR 图像之间的变化区域的图像对。NICE-GAN 翻译后的 SAR 图像[图 17 (g)]中发生变化的淹水像素不表现出洪水特征，导致原 SAR 图像与翻译后的 SAR 图像存在区别。这一现象表明，图像平移不仅可以减少不变像素的差异，而且可以减少不变像素之间的差异




图 20. 四组数据使用不同损耗计算方法进行 CD 结果的可视化比较。从左到右:(a)图像 T1 , (b)图像 T2 , (c)直接计算 , (d) MSOF , (e)多尺度损失 , (f)地面真实度。

也保持一定的区别改变像素。图像平移的结果启发我们，一个鲁棒的平移模型可以产生更有效的 CD 网络输入。

进一步进行光学图像到 SAR 图像的平移实验，观察图像平移对 CD 结果的的实际影响，不同深度图像平移方法的 CD 结果如表 10 所示。很明显，翻译后的光盘可以得到改进。通过 Nice-GAN 转换，准确率提高了 0.06，召回率提高了 0.09,F1 提高了 0.07。正如预期的那样，pix2pix 在四种翻译方法中效果最差。pix2pixHR 的结果更接近于循环 GAN。Cycle-GAN 在召回率方面略优于 NICE-GAN，而 NICE-GAN 在精度、F1 和 OA 方面表现最好。

不同平移模型的 CD 映射如图 18 所示。显然，NICE-GAN[图 18 (g)] 优于其他方法，其翻译过程中的 FID 和 KID 都较小。虽然 Cycle-GAN[图 18 (f)]的结果很好，但是在第二行红色帧中，它并不能完全检测出一些变化的区域。同样，pix2pixHR[图 18 (e)]也存在大量的泄漏检测。与没有平移的[Fig. 18 (c)]相比，pix2pix [Fig. 18 (d)]只是略有改善，因为生成的图像有很多噪声。准确的预测结果在一定程度上证明了光学和 SAR 图像光盘的图像平移是可行的。同时，研究结果表明，随着图像平移方法的改进，光学和 SAR 遥感图像 CD 效果将得到增强。

5.2。深度可分卷积对 U-Net++ 的影响

本文提出了深度可分卷积来代替标准卷积。表 11 给出了 CD 网络中标准卷积和深度可分卷积的结果。如前所述，深度可分卷积可以减少模型参数的数量，提高性能。结果表明，深度可分卷积的参数数仅为 52.7 M，比参数数量为 91.8 M 的标准卷积少了 40%。更少的参数使训练数据集拟合效果更好，每幅图像推理时间减少 0.15 s。

深度可分卷积默认假设标准卷积核在 feature map 的信道维数上具有类似于线性组合的分解特征。标准卷积核需要同时学习空间相关性和通道相关性。深度可分卷积将这两种相关性显式地分开。对两种卷积方法的 CD 结果的定量评价见表 12。对于这四个数据集，大多数的评估通过深度可分卷积获得改进。特别是在 Gloucester I 数据集上，F1 几乎增加了 6.5%。在这个数据集中，标准卷积比深度可分方法的召回率稍好一些，而深度可分卷积在精度上有很大的优势。然而，对于 Gloucester II 数据集，增益并不显著，最大 F1 增益小于 1%。在另外两个数据集中，我们的模型在所有条件下都高于标准卷积。

两种卷积方法的二进制变化映射如图 19 所示。可以看出，使用深度可分卷积(deep convolution)检测二值地图[图 19 (d)]比标准卷积[图 19 (c)]获得更好的视觉性能。具体来说，我们的算法可以更准确地检测出变化区域的边缘，对于小的地物有更好的提取效果，比如最后一排的河流。

5.3。U-Net++ 的多尺度损失效应

在初始的 U-Net++ 中，深度监管的损失函数是通过将顶层除第一层外的所有特征串联起来计算的(Zhou et al. 2018)。基于 MSOF 的深度监督方法也被用于遥感图像 CD (Peng et al. 2019)。然而，这些方法会使损失函数达到最小局部预估，从而限制了最优参数。因此，我们的模型中没有使用这样的损失函数。或者，使用多尺度损耗来计算在不同尺度上得到最后一个特征图后的损耗。多尺度损耗旨在整合不同层次的信息，提高 CD 结果。

表 13 给出了直接计算、MSOF 和多尺度损失的定量评价。与直接计算最后一个特征的损耗相比，MSOF 和多尺度损耗得到了改善。在这些数据集中，大部分评价指标的多尺度损耗都高于 MSOF。由于它能够充分利用上下文信息，并在不同分辨率下映射特征，因此可以获得更好的详细和全局检测结果。

不同损耗函数的 CD 结果如图 20 所示。从视觉上看，多尺度损失的整体效果与地面真相的相似性高于其他两种方法。从第 1 行和第 2 行的红色帧中，没有检测到直接损失函数的一些变化像素，这代表了较高的假阳性率。在第 4 行中，虽然我们的方法忽略了小的变化像素，但这并没有导致更严重的错误，即很多未变化的像素被另外两种方法识别为变化的像素。此外，如第 5 行和第 6 行所示，直接计算的损失在检测建筑物和河流变化时准确度最低。像多尺度损失一样，MSOF 可以检测出建筑物的完整边界，但不能检测出建筑物的孔洞。在结果方面，用于检测的不变像素接近或在

改变区域，我们的算法比 MSOF 算法有更好的性能。

6.结论

异构遥感影像可以克服单一数据源的限制，扩大光盘的潜力。本文提出了一种基于深度翻译(GAN)的光盘网络 DTCDN，用于光学和 SAR 遥感影像。其基本思想是首先利用图像平移来减少异构遥感图像的差异，然后利用改进的深度网络来检测两个周期之间的变化。四种不同数据集的光学和 SAR 遥感实验 CD 结果验证了该方法的有效性。与之前的方法相比，我们的方法能够显著提高准确率、召回率、F1 和 OA 的性能。此外，在 U-Net++ 的改进中还发现了另外两个潜力。(1)与普通卷积相比，深度可分卷积具有较好的性能，可以减少模型参数的数量和时间。然而，网络参数的数量是矛盾的，参数太少会导致网络的不稳定性。因此，如何在减少参数量的同时解决更复杂的 CD 问题是未来的研究工作。(2)多尺度损失利用不同层次的信息来计算损失，可以充分结合不同接受域的语境来提高 CD 性能。对于四层 U-Net++ 网络，只选择包含长跳连接的层。因为过低的分辨率会带来采样后小变化区域的误差。当然，在其他 CD 网络中，是否有更好的方法来计算损耗函数还有待研究。

该方法存在一定的局限性。例如，更复杂的多源遥感图像的检测能力需要进一步提高。与单偏振数据相比，加州数据集的多极化 SAR 图像具有更复杂的特征和噪声。具有更多来源和更高复杂性图像的光盘是一个值得探索的问题。此外，我们的 DTCDN 与使用两幅光学图像进行 CD 相比还有一些不足之处，需要进一步探索。

竞争利益声明

作者声明，他们没有已知的可能影响本文报告的工作的竞争财务利益或人际关系。

确认

国家重点研发计划项目(No. 2019YFB2102904);国家自然科学基金项目(No. 41701394)。关键词:岩石力学，蠕变试验，数值模拟，数值模拟作者非常感谢蒙特利尔大学 Max Mignonette 教授分享 Gloucester I 和曙光村的光学和 SAR 数据集。加州数据集的图像由美国宇航局的土地过程分布式活动存档中心和欧洲航天局的哥白尼支持。作者还想感谢来自 UiT 的 Luigi T. Luppino。挪威北极大学，获奖理由是它提供了加州数据集的真实数据和比较方法的代码。

参考文献

阿尔贝加, V., 2009。用于变化检测应用的遥感多传感器图像的相似性度量。遥感技术 1(3), 122-143。 <https://doi.org/10.3390/rs1030122>。

Ao, D., Dumitru, C.O, Schwarz, G., Datcu, M., 2018。sar 图像转换的辩证 gan:从 sentinel-1 到 terrasar-x。遥感学报, 1597。 <https://doi.org/10.3390/rs10101597>。

Ashbindu, S., 1989。综述了基于遥感数据的数字变化检测技术。整数遥感学报, 29(6), 593 - 598。 <https://doi.org/10.1080/01431168908903939>。

Ayhan, B., Kwan, C., 2019. 一种利用异构图像进行变化检测的新方法. 见:2019 IEEE 第十届普适计算, 电子与移动通信年会(UEMCON), pp. 0192-0197. <https://doi.org/10.1109/UEMCON47517.2019.8993038>.

Bińkowski, M., Sutherland, D.J, Arbel, M., Gretton, A., 2018。揭开烟雾病的神秘面纱。见:国际学习表征会议(ICLR), 加拿大温哥华, 1-8。

布达, M., Maki, A., Mazurowski, m.a., 2018. 卷积神经网络中类不平衡问题的系统研究。关键词:神经网络;<https://doi.org/10.1016/j.neunet.2018.07.011>。

陈浩, 石卓, 2020. 一种基于时空注意的遥感图像变化检测方法 & 数据集. 遥感技术 12(10), 1662. <https://doi.org/10.3390/rs12101662>。

陈 l.c., 朱勇, 帕潘德里欧, 施罗德, F., 亚当, H., 2018. 基于 atrous 可分离卷积的语义图像分割编码器-解码器. 见:欧洲计算机视觉会议(ECCV), 慕尼黑, 德国, 第 801-818 页. [HTTPS://doi.org/10.1007/978-3-030-01234-2_49](https://doi.org/10.1007/978-3-030-01234-2_49)。

陈锐, 黄伟, 黄斌, 孙芳, 方斌, 2020. 在编码中重用鉴别器:面向无监督图像到图像的转换. 见:计算机视觉与模式识别(CVPR)会议, 美国, Seattle, USA, pp. 8168-8177. <https://doi.org/10.1109/CVPR42600.2020.00819>。

乔里特, F., 2017. 例外:深度可分离卷积的深度学习. 见:计算机视觉与模式识别(CVPR)会议, 夏威夷, 夏威夷, 美国, 1251-1258 页. <https://doi.org/10.1109/CVPR.2017.195>。

Daudt, R.C, Le Saux, B., Boulch, A., 2018. 变化检测的全卷积连体网络. 见:IEEE 图像处理国际会议(ICIP), 雅典, 希腊, 第 4063-4067 页. <https://doi.org/10.1109/ICIP.2018.8451652>。

德布尔, p., 克罗斯, D.P., 曼诺, S., 鲁宾斯坦, R.Y., 2005. 交叉熵方法的教程。安。Opera. 第 134(1)条, 19-67 条. <https://doi.org/10.1007/s10479-005-5724-z>。

Fuentes Reyes, M., Auer, S., Merkle, N., Henry, C., Schmitt, M., 2019. 基于条件生成对抗算法的 sar - 光学图像平移网络优化, 机会和限制. 遥感 11,2067. <https://doi.org/10.3390/rs11172067>。

耿军, 马晓东, 周晓东, 王慧, 2019. 显著性引导深度神经网络的 sar 图像变化检测. IEEE 译. 地质遥感信息 5(10), 7705 - 7706. <https://doi.org/10.1109/TGRS.2019.2913095>。

郭浩, 史强, 杜斌, 张磊, 王东, 丁浩, 2020. 场景驱动的高分辨率遥感影像建筑物提取多任务并行注意网络. IEEE 译. 地质传感器 1-20. <https://doi.org/10.1109/TGRS.2020.3014312>。

郭强, 张波, 冉强, 高磊, 李军, 2014. 加权 rxd 和基于线性滤波的 rxd:改进高光谱图像异常检测的背景统计估计. IEEE J. Sel. 顶部. 应用地球 Obs 遥感 7(6), 2351-2366. <https://doi.org/10.1109/JSTARS.460944310.1109/JSTARS.2014.2302446>。

Hertzmann, A., Jacobs, c.e., Oliver, N., Curless, B., Salesin, D.H., 2001. 图像类比。见:第 28 届计算机图形与交互技术年会, 纽约, 美国, 页 327-340. <https://doi.org/10.1145/383259.383295>。

Heusel, M., Ramsauer, H., Unterthiner, T., nesler, B., & Hochreiter, S., 2017. 用两个时间尺度更新规则训练的 Gans 收敛于局部纳什均衡. 见:神经信息处理系统(NIPS)会议, 长滩, 加州, 美国, 6629-6640。

朱俊英, 朱俊英., 周涛, & Efros, a.a., 2017. 基于条件对抗网络的图像到图像转换. 见:计算机视觉与模式识别(CVPR)会议, 美国, Honolulu, Hawaii, USA, pp. 1125-1134. <https://doi.org/10.1109/CVPR.2017.632>。

jaturpitpornchai, R., Matsuoka, M., Kanemoto, N., Kuzuoka, S., Ito, R., Nakamura, R., 2019 基于深度学习的 sar 图像新建结构检测. 遥感技术 11(12), 1444. <https://doi.org/10.3390/rs11121444>。

季敏, 刘亮, 杜锐, 杜锐, 杜瑞华, 2019. 基于地震前和震后卫星图像的纹理和卷积神经网络特征检测地震后倒塌建筑物的比较研究. 遥感 11,1202. <https://doi.org/10.3390/rs11101202>。

金磊, 拉扎罗, 杜志刚, 2017. 基于卷积网络的内省分类. 见:神经信息处理系统会议(NIPS), 长滩, 加州, 美国, 第 823-833 页. <https://dl.acm.org/doi/abs/10.5555/3294771.3294850>。

Kampffmeyer, M., Salberg, A.-B., & jensen, R., 2016. 基于深度卷积神经网络的城市遥感图像小目标语义分割和不确定性建模. 见:IEEE 计算机视觉与模式识别研讨会(CVPRW), 拉斯维加斯, 内华达州, 美国, pp. 688. <https://doi.org/10.1109/CVPRW.2016.90>。

Khan, S.H, He, X., Porikli, F., Bennamoun, M., 2017. 基于深度神经网络的不完全卫星图像森林变化检测. IEEE 译. 地质遥感信息 5(9), 5403 - 5403. <https://doi.org/10.1109/TGRS.2017.2707528>。

Kwan, C., Ayhan, B., Larkin, J., Kwan, L., Bernab'e, S., Plaza, A., 2019. 使用异构图像和扩展多属性概要文件(emaps)的变化检测算法的性能. 遥感技术 11(20), 2377. <https://doi.org/10.3390/rs11202377>。

金磊, 杜志刚, 2017. 用于生成建模的内省神经网络. 见:IEEE 计算机视觉国际会议(ICCV), 威尼斯, 意大利, 页 2774-2783. <https://doi.org/10.1109/ICCV.2017.302>。

李凯, 徐伟, 范芳, 杜志刚, 2018. 沃瑟斯坦内省神经网络. 见:IEEE 计算机视觉与模式识别(CVPR)会议, 美国犹他州, Salt Lake City, USA, pp. 3702-3711. <https://doi.org/10.1109/CVPR.2018.00390>。

雷磊, 孙勇, 邝光, 2020. 基于局部结构一致性的自适应异构遥感变化检测. IEEE geoosci. Remote sens.lett. 1-5 <https://doi.org/10.1109/LGRS.2020.3037930>。

林 t.y., 戈亚尔, P., Girshick, R., He, K., Doll'ar, P., 2017a. 密集目标检测的焦损。见:计算机视觉与模式识别(CVPR)会议, 美国, Honolulu, Hawaii, USA, pp. 2980-2988. <https://doi.org/10.1109/TPAMI.201.8.2858826>。

Lin T., Doll'ar, P., Girshick, R., He K., Hariharan, B., Belongie, S., 2017b. 目标检测的特征金字塔网络. 见:计算机视觉与模式识别(CVPR)会议, 夏威夷, 美国, 936-944 页. <https://doi.org/10.1109/CVPR.2017.106>。

刘军, 龚明, 秦凯, 张鹏, 2018a. 基于异构光学和雷达图像的深度卷积耦合网络变化检测. IEEE 译. 神经网络学习. 29(3), 545-559. <https://doi.org/10.1109/TNNLS.2016.2636227>。

刘锐, 江东, 张磊, 张卓, 2020a. 基于深度可分离卷积网络的光学航空图像变化检测. IEEE J. Sel. 顶部. 应用地球 Obs 遥感信息 13,1109-1118. <https://doi.org/10.1109/jstars.460944310.1109/jstars.2020.2974276>。

刘帅, 史强, 张磊, 2020b. 基于多任务深度学习的未知类少镜头高光谱图像分类. IEEE 译. 地质远程传感器 1-18. <https://doi.org/10.1109/TGRS.2020.3018879>。

刘涛, 杨磊, 龙嘉, D., 2021. 基于对象图像分析的深度学习变化检测. 遥感环境. 256,112308. <https://doi.org/10.1016/j.rse.2021.112308>。

刘志, 李刚, Mercier, G., He Y., Pan Q., 2018b. 基于均匀像素变换的异构遥感图像变化检测. IEEE 译. 图像处理. 27(4), 1822-1834. <https://doi.org/10.1109/TIP.2017.2784560>。

N. Longbotham, Pacifici, F. Glenn, T. Zare, A., Volpi, M. Tuia, D. Christophe, E. Michel, J., Inglada, J., Chanussot, J., Du Q., 2012. 多模态变化检测, 在洪泛区检测中的应用:2009-2010 年数据融合竞赛结果. IEEE J. Sel. 顶部. 应用地球 Obs 遥感 5(1), 331-342. <https://doi.org/10.1109/jstars.460944310.1109/jstars.2011.2179638>。

鲁内塔, r.s., 奈特, j.f., 埃迪瑞维克雷玛, J., 里昂, j.g., 沃西, l.d., 2006. 基于多时相 modis ndvi 数据的土地覆盖变化检测遥感学报, 35(2), 393 - 397. <https://doi.org/10.1016/j.rse.2006.06.018>。

Luppino, lt., Anfinsen, s.n., Moser, G., Jenssen, R., Bianchi, f.m., Serpico, S., Mercier, G., 2017. 一种异构变更检测的聚类方法. 见:北欧图像分析会议(SCIA), 挪威特罗姆瑟, 181-192 页. https://doi.org/10.1007/978-3-319-59129-2_16。

Luppino, lt., Bianchi, f.m., Moser, G., Anfinsen, s.n., 2019. 基于非监督图像回归的异构变化检测. IEEE 译. 地质遥感信息 5(12), 9960-9975. <https://doi.org/10.1109/TGRS.2019.2930348>。

卢皮诺, lt. Kampffmeyer, M., Bianchi, F.M., Moser, G., Serpico, S.B., jensen, R., & 安芬森, s.n., 2020 年. 基于亲和力变化先验的深度图像平移无监督多模态变化检测. arXiv:2001.04271 -16。

吕红, 吕红, 牟磊, 李伟, 怀特杰, 李晓霞, 李晓霞, 王静, 于磊, 龚萍, 2018. 应用深度信息学习方法对陆地卫星数据进行不同大洲四个城市的长期年测. 遥感 10,471. <https://doi.org/10.3390/rs10030471>。

默瑟, G., 莫泽, G., 塞尔皮科, s.b., 2008. 基于条件联结的异构遥感图像变化检测. IEEE 译. 地质遥感信息 5(5), 1428-1441. <https://doi.org/10.1109/TGRS.2008.916476>。

米格诺特, 2020 年. 基于分形投影和马尔可夫分割的多模态变化检测方法. IEEE 译. 地质遥感信息 5(11), 8046-8058. <https://doi.org/10.1109/TGRS.2020.2986239>。

Mubea, K., Menz, G., 2012. 利用多传感器卫星数据监测纳库鲁(肯尼亚)的土地利用变化. 遥感 1,74 - 84. <https://doi.org/10.4236/ars.2012.13008>。

阮廷林, 韩东, 2020. 利用卷积连体网络从多时相无人机图像中检测路面变化。可持续发展 12,2482. <https://doi.org/10.3390/su12062482>。

牛欣, 龚敏, 詹涛, 杨勇, 2019. 一种用于异构图像变化检测的条件对抗网络. IEEE geoosci. 遥感快报 16(1), 45-49. <https://doi.org/10.1109/LGRS.2018.2868704>。

彭冬, 张勇, 关辉, 2019. 基于改进 unet++ 的高分辨率卫星图像端到端变化检测. 遥感学报 11,1382. <https://doi.org/10.3390/rs11111382>。

计划, P., Gleich, D., 2018. 利用对数累加和和堆叠自动编码器检测 sar 图像中的时间变化. IEEE geoosci. 远程传感器 15(2), 297-301. <https://doi.org/10.1109/LGRS.2017.2786344>。

Prendes, J., Chabert, M., Pascal, F., Giros, A., Tournet, J.-y. 2015 年. 一种新的多变量统计模型用于同质和异质传感器采集的图像变化检测. IEEE 译. 图像处理. 24(3), 799-812. <https://doi.org/10.1109/TIP.2014.2387013>。

Reed, I.S., Yu X., 1990. 光谱分布未知的光学图样的自适应多波段 cfar 检测. IEEE 译. 声学. 语音信号处理. 38,1760 - 1770. <https://doi.org/10.1109/29.60107>。

Ronneberger, O., Fischer, P., & 布鲁克斯, T. 2015 年. U-net:用于生物医学图像分割的卷积网络. 见:医学图像计算和计算机辅助干预国际会议(MICCAI), 慕尼黑, 德国, 234-241 页. https://doi.org/10.1007/978-3-319-24574-4_28。

Saha, S., Bovolo, F., Bruzzone, L., 2018. 基于深度特征的 vhr sar 图像破坏建筑物检测. 见:第 22 届遥感图像和信号处理, 柏林, 德国. <https://doi.org/10.1117/12.2325149>。

何建军, 尚锐, 何建军, 王军, 徐坤, 焦立林, 2020。基于密集连接和深度可分离卷积的 cnn 偏振 sar 图像分类。诺尔。基于系统 194,1-12。 <https://doi.org/10.1016/j.knosys.2020.105542>。

史强, 刘明, 刘小平, 刘鹏, 张鹏, 杨军, 李晓霞, 2020。基于域自适应的卫星图像细粒度城中村提取。IEEE geoosci. Remote sens Lett. 17(8), 1430-1434。 <https://doi.org/10.1109/LGRS.885910.1109/LGRS.2019.2947473>。

崇高, J.卡利尼切瓦, E., 2019。利用深度学习技术进行变化检测的灾后破坏自动制图:以日本东北部海啸为例。遥感 11,1123。 <https://doi.org/10.3390/rs11091123>。

孙勇, 雷磊, 李新, 孙浩, 匡刚, 2021a。基于非局部斑块相似度的异构遥感变化检测。模式识别, 109,107598。 <https://doi.org/10.1016/j.patcog.2020.107598>。

孙勇, 雷磊, 李晓东, 谭晓东, 匡刚, 2020。基于斑块相似图矩阵的均匀和异构传感器无监督遥感变化检测。IEEE 译。地质远程传感器 1-21。 <https://doi.org/10.1109/TGRS.2020.3013673>。

孙勇, 雷磊, 李晓东, 谭新, 匡刚, 2021b。基于结构一致性的遥感图像无监督变化检测图。IEEE 译。地质 Remote Sens. 1-21 <https://doi.org/10.1109/TGRS.2021.3053571>。

田建平, 崔顺实, 李晓明, 2014。基于卫星立体影像和数字地表模型的建筑物变化检测。IEEE 译。地质遥感信息 5(1), 421 - 421。 <https://doi.org/10.1109/TGRS.2013.2240692>。

佟晓东, 张晓东, 刘敏, 2010。基于遗传算法-进化神经网络分类的遥感城市蔓延检测——以上海市嘉定区和普陀区为例整数遥感学报, 31(6), 1485 - 1404。 <https://doi.org/10.1080/01431160903475290>。

Touati, R., Mignotte, M., 2017。一种基于能量的编码非局部成对像素交互的多传感器变化检测模型。IEEE 译。地质遥感 56,1046-1058。 <https://doi.org/10.1109/TGRS.2017.2758359>。

Touati, R., Mignotte, M., Dahmane, M., 2017。一种新的异构遥感影像变化检测器。见:图像处理理论、工具和应用(IPTA)国际会议, 蒙特利尔, 加拿大, 1-6。 <https://doi.org/10.1109/IPTA.2017.8310138>。

Touati, R., Mignotte, M., Dahmane, M., 2018。基于成像模态不变 mds 表示的异构遥感图像变化检测。在:IEEE

图像处理技术与应用, 北京, 2009。 <https://doi.org/10.1109/ICIP.2018.8451184>。

Touati, R., Mignotte, M., Dahmane, M., 2019。基于无监督像素两两马尔可夫随机场模型的遥感图像多模态变化检测。IEEE 译。图像处理。29,757-767。 <https://doi.org/10.1109/TIP.2019.2933747>。

Touati, R., Mignotte, M., Dahmane, M., 2020。异构遥感影像变化检测的部分不耦合连体模型。[jj] 遥感技术与应用, 2011,21(4):527 - 532。

特恩斯, j.n., 卡斯特罗, J.D.B., 托雷斯, d.l., 维加, p.j.s., 费托萨, R.Q., 哈普, p.n., 2020 年。Atrous cgan 用于 sar 到光学图像的平移。IEEE geoosci. Remote sens.lett. 1-5 <https://doi.org/10.1109/lgrs.2020.3031199>。

万磊, 向阳, 尤慧, 2019。一种 sar 与光学图像变化检测的后分类比较方法。IEEE geoosci. Remote Sens. Lett. 16(7), 1026-1030。 <https://doi.org/10.1109/LGRS.885910.1109/LGRS.2019.2892432>。

王琦, 袁卓, 杜强, 李昕, 2019。Getnet:一个用于高光谱图像变化检测的通用端到端二维 cnn 框架。IEEE 译。地质遥感信息 5(1), 3-13。 <https://doi.org/10.1109/TGRS.2018.2849692>。

王涛, 刘敏, 朱军, 陶爱玲, 陶爱玲, Kautz, J. Catanzaro, B., 2018。用条件 gan 进行高分辨率图像合成和语义处理。计算机视觉与模式识别(CVPR)会议 <https://doi.org/10.1109/CVPR.2018.00917>。

周静, 关志刚, 艾汉, 艾思曼, 2016。一种新的高光谱图像异常与变化检测的聚类核 rx 算法。IEEE 译。地质遥感学报, 35(6), 693 - 694。 <https://doi.org/10.1109/TGRS.2016.2585495>。

周玮, Troy, A., Grove, M., 2008。基于多时相高分辨率遥感数据的巴尔的摩都市区土地覆盖地物分类与变化分析传感器 8,1613-1636。 <https://doi.org/10.3390/s8031613>。

周卓, Siddiquee, M.M.R, Tajbakhsh, N, Liang J, 2018。Unet++:用于医学图像分割的嵌套 u-net 架构。医学图像分析中的深度学习和临床决策支持中的多模态学习。施普林格。

朱俊宇., Park, T., Isola, P., Efros, A.A, 2017。使用循环一致对抗网络的非配对图像到图像的翻译。见:IEEE 计算机视觉国际会议(ICCV), 威尼斯, 意大利, 页 2223-2232。 <https://doi.org/10.1109/ICCV.2017.244>。