

VHR SAR 图像中的建筑变化检测

通过无监督深度转码

Sudipan Saha, IEEE 研究生会员, Francesca Bovolo, IEEE 高级会员,
Lorenzo Bruzzone, Fellow, IEEE

摘要:建筑物变化检测(CD)在城市监测中具有重要的应用价值,通过比较变化前和变化后的高空间分辨率(VHR)合成孔径雷达(SAR)图像,可以实现近实时的建筑物变化检测。然而,多时相 VHR SAR 图像很复杂,因为它们具有高度的空间相关性,容易产生阴影,并且显示出不均匀的特征。为了有效检测此类图像的变化,需要考虑空间背景。近年来,基于卷积神经网络(CNN)的迁移学习技术在 VHR 多光谱图像的 CD 处理中表现出了良好的性能。然而,由于缺乏标记的 SAR 数据,因此缺乏预训练的网络,其直接用于 SAR CD 受到阻碍。为了克服这个问题,我们利用配对未标记的 SAR 和光学图像的可用性,使用循环一致生成对抗网络(CycleGAN)训练将 SAR 图像转码为光学图像的次优任务。CycleGAN 由两个生成器网络组成:一个用于将 SAR 图像转码到光学图像域,另一个用于将光学图像投影到 SAR 图像域。该生成器经过无监督训练后,将 SAR 图像转换为光学图像,作为双时深度特征提取器,从双时 SAR 图像中提取类光学特征。因此,深度变化向量分析(DCVA)和模糊规则可以应用于识别变化的建筑物(新建/毁坏)。我们在拉奎拉(意大利)和特伦托(意大利)的两个由双时 VHR SAR 图像组成的数据集上验证了我们的方法。

索引术语:变化检测(CD)、深度变化矢量分析(DCVA)、生成对抗网络(GAN)、多时相图像、遥感、合成孔径雷达(SAR)、高分辨率图像。

我的介绍。
非像高空间分辨率(VHR)图像、
新建、多时相、应用非常重要。

近十年来,新一代 VHR 卫星传感器已经发射,可以获得空间分辨率为一米或更低的图像。VHR 数据的可用性使我们能够分析单个人造结构,例如建筑物[2]。在此背景下,

稿件收到 2020 年 4 月 10 日;2020 年 5 月 26 日改稿;2020 年 5 月 28 日录用。发表日期 2020 年 6 月 18 日;当前版本日期 2021 年 2 月 25 日。(通讯作者:Francesca Bovolo)

Sudipan Saha 就职于意大利特伦托 38123 号布鲁诺凯斯勒基金会,以及意大利特伦托 38123 号特伦托大学信息工程与计算机科学系(电子邮件:saha@fbk.eu)。

Francesca Bovolo 就职于意大利特伦托 38123 号布鲁诺凯斯勒基金会(e-mail:bovolo@fbk.eu)。

Lorenzo Bruzzone, 特伦托大学信息工程与计算机科学系,意大利特伦托 38123。

本文中一或多个图形的彩色版本可在 <https://ieeexplore.ieee.org> 上在线获取。

数字对象标识符 10.1109/TGRS.2020.3000296

利用无源(光学)[3]、[4]和主动[合成孔径雷达(SAR)]传感器[5]–[8],已经开发了几种分析城市地区的技术。SAR 传感器在需要快速响应的应用(例如,灾害管理)中特别有用,因为它们可以有效地绘制受影响地区的地图,而不受一天中的时间或天气条件的影响[7],因此具有更好的时间分辨率。目前,几颗具有 SAR 传感器的卫星正在运行(例如,TerraSAR-X、Tandem-X、cosmos - skymed 星座和 cosmos - skymed 第二代星座),可以获取 VHR 图像。

在 CD 文献中,无监督方法[9]–[12]是首选,因为收集多时间标记数据的困难,在灾后 CD 的情况下变得更加严重。基于差分的无监督 CD 方法[9]及其基于对数的变体[13], [14](以抑制乘性斑点噪声)在文献中很受欢迎。VHR SAR 图像比低/中分辨率图像更复杂,因为它们具有较高的空间相关性[15], [16]。语义同质的物体,如建筑物,由于子物体的散射贡献不同,在高分辨率下表现出不均匀的特征[5]。需要利用上下文和对对象级信息来有效地提取变化信息。文献中很少有作品能够处理多时相 VHR SAR 数据的复杂性[5], [17], [18]。Brett 和 Guida[17]提出了一种利用曲线特征来检测地震引起的变化的方法。Marin 等人[5]提出了一种利用后向散射的增量和递减以及一组模糊规则来检测建筑物变化的方法。Yousif 和 Ban[18]提出了一种基于目标的 HR SAR 图像 CD 方法。这些方法的局限性如下。

- 1)仅从 VHR 图像中提取低级特征(如纹理和曲线特征)用于 CD,这些特征对于表示双时图像的语义信息不具有鲁棒性。
- 2)它们仅依赖于模型假设或所考虑场景中的相似程度。因此,它们无法利用目前可用的大量未标记的遥感数据,这些数据可以用来提高性能。

近年来,深度神经网络,特别是卷积神经网络(CNN)在图像处理任务中表现出了显著的性能[19]。它们适用于提取语义丰富的特征来捕获对象级信息[20]。受此启发,一些作品已经

0196-2892©2020 IEEE. 允许个人使用,但重新发布/再分发需要 IEEE 许可。更多信息请参见 <https://www.ieee.org/publications/rights/index.html>。

授权许可使用仅限于:浙江工业大学。下载于 2023 年 8 月 11 日 08:55:12 UTC 从 IEEE Xplore。限制适用。

提出了用于 SAR CD 的方法, 这些方法大多是有监督的[21], [22]和/或处理低/中分辨率图像[23], [24]。Gong 等人[21]提出了一种 CD 方法, 该方法首先以无监督的方式训练循环玻尔兹曼机(RBM), 并以监督的方式对其进行调谐。Gao 等人[22]提出了主成分分析网络(PCANet), 该网络利用 PCA 滤波器作为卷积滤波器, 随后, PCA 滤波器的输出被馈送到分类器中以预测 CD 映射。设计了一种预分类方案, 以获得高精度的标记样本来训练 PCANet。该方法的准确性在很大程度上取决于预分类方案的准确性。Li 等人[25]在 PCANet 中引入了图像显著性的概念。Li 等人[26]提出了一种基于预分类方案的方法, 其中通过无监督空间模糊聚类产生初始伪标签。类似地, [27]也使用空间模糊聚类生成伪标签。Gong 等人[28]使用稀疏自编码器将对数比差分图像转换为特征空间, 并对这些特征进行聚类以生成伪标签。Liu 等[29]提出了一种用于非均匀光学和 SAR 图像 CD 的对称卷积耦合网络。在[23]中, 提出了一种基于低分辨率图像的卷积小波神经网络(CWNN)的海冰 CD 监督方法。与[22]类似, [23]中的方法使用预分类方案来生成训练样本。在[30]中, 使用双通道 CNN 来估计双时间斑块之间的相似性。这些方法的局限性如下。

- 1)它们中的大多数都是有监督的, 不能解释在大尺度上缺乏标记的多时相数据[31], [32]。
- 2)依赖于预分类的方法不需要标记数据。然而, 它们仍然无法利用目前可用的大量遥感数据, 这些数据可以用来提高性能。此外, 它们的准确性取决于预分类方案的准确性。

最近, 基于深度学习的监督方法[33], [34]很少被提出用于建筑 CD。Chen 和 Yu[33]提出了一种利用残差深度网络绘制地震诱发的受损建筑的监督方法。Li 等人[34]利用残差 U-Net 检测 Sentinel-1 图像中的建筑变化。

深度学习领域的另一个进步是迁移学习, 它使在某个任务上训练的模型能够用于另一个任务[35]。迁移学习在不同的遥感任务中表现出了优异的能力[36], [37]。受迁移学习成功的启发, Saha 等人[4]通过利用从预训练网络中提取的深度特征, 提出了多光谱光学卫星图像 CD 的深度变化矢量分析 (deep-change-vector-analysis, DCVA)[38]。为了应用 DCVA 框架, 使用像素标记的 VHR 数据库(非多时相)来训练深度网络, 该网络随后用作多时相深度特征提取器。DCVA 是无监督的, 因为它不需要任何标记的多时数据。然而, 它成功地利用了大量可用的遥感数据。尽管它取得了成功

对于 VHR 光学图像中的 CD[4], 将 DCVA 应用于 VHR SAR 图像并非易事。由于 VHR SAR 图像标记困难, 获取标记 VHR SAR 数据集非常具有挑战性[39]。因此, 需要一种方法, 可以绕过标记 SAR 图像的必要性。

深度网络范式的一个进步是生成对抗网络(GANs), 它可以从未标记的数据中学习模拟复杂的数据分布。它在迁移学习任务中显示出了很有前途的能力[40], 这激发了它在遥感中的应用[41], [42]。Ley 等人[42]表明, 将 SAR 图像转编码为光学图像会迫使 GAN 学习深层特征以区分不同的地表。该机制不需要标记数据。考虑到重复穿越地球的许多 VHR SAR 和光学传感器的可用性[39], 可以从地球上的同一位置获得多时相对的 SAR 和光学图像, 从而允许将 SAR 图像无监督地转码为光学图像, 并训练深度网络, 绕过标记数据的必要性。将 SAR 图像转编码为光学图像的任务是次优的/病态的, 因为 SAR 图像中存在光学图像中不存在的特征, 反之亦然[42], [43]。SAR 图像强调的是目标表面的物理特性, 而光学图像强调的是结构细节[43]。即使不可能将 SAR 数据完全转码为实际的光学数据, Ley 等人[42]和 Reyes 等人[43]观察到, 任务 GAN 学习这种转码会迫使 GAN 学习有用的语义特征[42]。基于此, 我们提出了一种 CD 方法, 该方法使用 sar-光学转码[43]来训练深度网络, 该网络随后在 DCVA 框架中用作双时间深度特征提取器。该方法假定从同一位置或类似地理位置获得的一组 SAR 和光学图像的可用性, 即。即代表相似行为的图像。文献中有不同的 GAN 变体[44]-[46]。受 Reyes 等人[43]工作的启发, 该方法利用周期一致 GAN (CycleGAN)[44]框架来学习 SAR 与光学图像之间的转码。CycleGAN 框架不需要存在成对/共注册的 SAR 和光学对。CycleGAN 框架由两个生成器网络和两个鉴别器网络组成。一个生成器负责将 SAR 图像转码到光学域, 而另一个生成器负责将光学图像转码到 SAR 域。该网络利用一组为对抗训练和周期一致性设计的损失函数进行学习。因此, 经过 CycleGAN 的无监督训练后, 生成器网络将 SAR 图像转换为光学图像, 作为多时相 SAR 图像的深度特征提取器。使用 CycleGAN 学习 SAR 与光学图像之间的转码如下。

- 1)帮助训练一个深度网络, 不需要任何标记的训练数据。
- 2)不假设存在共配 SAR 和光学图像。虽然 SAR 和光学图像可以从相似的地理位置收集, 但收集共同登记的对是困难的。这极大地放松了 CD 中最强的约束之一。

3)从训练过程中使用的大量未标记图像中摄取知识。与迁移学习类似,随后在 CD 过程中使用 CycleGAN 的生成器作为深度特征提取器,该框架可以使用从大量图像中学习到的语义特征来完成 CD 任务。

该方法利用 SAR 光学转码学习有用的语义特征,用于多时相 SAR 图像分析。从 SAR 数据中恢复光学数据有其局限性[42], [43], 超出了本文的讨论范围。

通过多层 CNN(即。(即生成器), 获得深度特征。将深度特征相互比较, 得到深度变化超向量, 该超向量使用最初仅为光学图像开发的 DCVA 框架[4]和模糊建筑物检测模型[5]进行处理, 以识别变化的建筑物(新建/毁坏)。

本文的新颖之处在于, 我们提出了一种无监督的方法来训练一个深度网络, 该网络用于从 DCVA 框架中处理的 SAR 图像中作为多时相光学类深度特征提取器。与[22]和[26]-[28]相反, 所提出的机制是完全无监督的, 可以在训练过程中从大量未标记的图像中摄取知识。将多时相特征提取器与 DCVA 框架[4]和模糊建筑检测模型[5]适当耦合, 在实际应用中证明了其有效性。、建筑

CD 。

这篇文章被组织成以下几个部分。第二节阐述问题陈述, 并对提出的解决方案进行概述。第三节详细介绍了用于探测被毁建筑物的拟议 CD 框架。实验结果在第四节中给出。我们总结了本文, 并在第五节中讨论了进一步研究的范围。

2 问题的表述和建议解决方案的概要

SAR 是一种主动成像系统, 对连续雷达脉冲的后向散射回波进行相干处理, 形成 SAR 图像。由于这种获取机制, 斑点噪声(盐和胡椒颗粒模式)固有地表现在 SAR 图像中 [47]。散斑噪声本质上是乘法的。因此, 为了降低它的影响, 我们假设图像是 dB 级的。

让 $X_{1\text{ null}}$ 和 $X_{2\text{ null}}$ 为同一地理区域在时间 t 上拍摄的两幅 VHR SAR 图像 $t_{1\text{ null}}$ 和 $t_{2\text{ null}}$, 分别使用相同的传感器和相同的采集角度。让双时间场景中所有像素的集合用 \mathcal{X} 表示。所提出的方法旨在检测 \mathcal{X} 之间对应建筑的变化 $t_{1\text{ null}}$ 和 $X_{2\text{ null}}$ 以无监督的方式, 即, 不使用任何标记的双时间数据。

假设未标记 VHR SAR 补丁的通用数据集 $X = \{X_{i\text{ null}} \forall i = 1, \dots, I\}$ 和 VHR 光学补丁 $Z = \{Z_{i\text{ null}} \forall i = 1, \dots, I\}$ 都是可用的。考虑到 SAR 光学转码任务的难度, 我们认为光学片是全色的。 I 为图中 patch 的个数

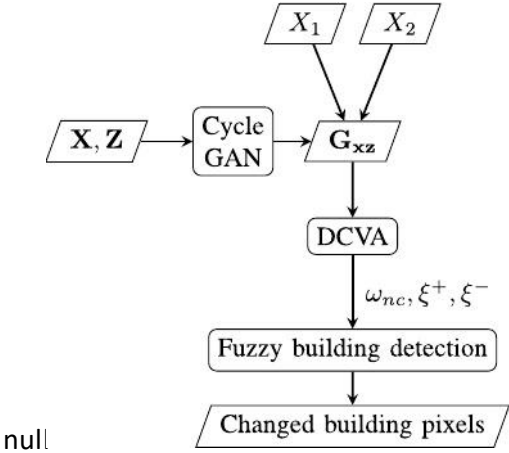


图 1 所示。提出的 CD 框架。

数据集。X 和 Z 不需要配对共注册。但是, 它们必须从相似的地理位置获取, 从而暗示相似的信息内容和图像分布。这一条件大大放宽了 CD 方法的典型假设, 即图像对必须共同配准。此外, X 和 Z 不一定包括 X 地理区域的图像 $t_{1\text{ null}}$ 和 $X_{2\text{ null}}$ 。该方法利用 X 和 Z 来训练一个 CycleGAN 框架, 该框架由两个生成器组成: 一个用于将 SAR 图像从 X 转编码到 Z 的光学域, 另一个用于将图像从 Z 转编码到 X 的域。训练完成后, 将图像从 X 转编码到 Z 的生成器用于从 SAR 图像 X 中提取类光学双时相深度特征 $t_{1\text{ null}}$ 和 $X_{2\text{ null}}$ 。应用为 VHR 光学图像定义的 DCVA 框架[4]划分所有像素的集合。以无监督的方式分成两个子集 $\mathcal{X}_{c\text{ null}}$ 和 $\mathcal{X}_{nc\text{ null}}$ 分别对应改变像素和未改变像素。中的像素 $\mathcal{X}_{c\text{ null}}$ 进一步分析聚类成两种不同类型的变化, 对应于深度特征空间中的增量(ξ^+)和递减(ξ^-)。在此之后, 采用模糊构建检测模型[5]构建 CD, 所提方法的分块方案如图 1 所示。

3 该方法

该方法通过以下步骤实现:1)使用 CycleGAN 学习 SAR 图像与光学图像之间的转码;2)利用 CycleGAN 对 SAR 图像进行双时间类光学深度特征提取;3)利用 DCVA 框架和模糊建筑检测模型进行变化建筑检测。

A. 学习 SAR 和光学之间的转码

选择 CycleGAN[44]来学习 VHR SAR 和 VHR 光域之间的转码, 因为它们能够处理空间不耦合的图像。CycleGAN 训练过程使用未标记 VHR SAR $X = \{X_{i\text{ null}} \forall i = 1, \dots, I\}$, 光学 $Z = \{Z_{i\text{ null}} \forall i = 1, \dots, I\}$ patches。假设 X 中的 SAR 片取自分布 $p^*(X)$, 而 Z 中的光学片取自分布 $q^*(Z)$, 则不配对的片到片转换学习分布之间的对应关系

SAR ($p^*(x)$)和光学($q^*(z)$)。由于网络必须学习语义实体才能从 SAR 图像中合成相应的光学纹理, 因此学习这种转换/对应关系是不平凡的和次优的。然而, 我们只训练一个 SAR-光学转码器作为一个代理任务, 便于从 SAR 图像中学习语义属性。为了完成训练过程, CycleGAN[44]使用了两个生成器 G_{xz} 和 G_{zx} 和两个鉴别器 D_z 和 D_x 。这些组件的交互遵循两个标准。

1)对抗性标准优化 G_{xz} 和 D_z 在一起。发电机 G_{xz} 不能接触到真实的光学贴片 z 。给定 X , 它只能通过与鉴别器 D_z 。 D_z 可以同时使用 Z 的补丁和 G 生成的补丁 z_{xz} 。对抗性机制的工作原理是基于这样的假设:如果 G_{xz} 成功地学会了将 X 中的图像转换为 Z , D 中的图像 z_{xz} 将无法区分 Z 中的真实 patch 和 G 生成的 $patch_{xz}$ 。因此, 基于鉴别器 D 产生的反馈 z_{xz} 以迭代的方式改进其对 $q^*(z)$ 的逼近。下面是在 more 细节。

- a)发电机 G_{xz} 生成 $Z \sim$, 它模拟给定 X 的分布 $q^*(Z)$, 该分布是从分布 $p^*(X)$ 中得出的。生成器有一个编码器-变压器-解码器架构, 由一系列卷积层、ResNet 块和反卷积层组成。
- b)鉴别器 D_z 尝试区分由 G 生成的 $patch Z \sim_{xz}$ (通常称为假补丁[44])从 z 绘制的真实补丁中提取 z_{xz} 和鉴别器 D_z 以极大极小的方式相互作用, 其中 G_{xz} 试图最小化, 而 D_z 试图最大化相同的目标函数

$$\min_{G_{xz}} \max_{D_z} E[\log D_z(z_{xz})] + E[\log(1 - D_z(z))].$$
 (1)

同理, 发生器 G_{zx} 和鉴别器 D_x 共同学习生成 $X \sim$, 它模拟给定 Z 的分布 $p^*(X)$, 该分布是从分布 $q^*(Z)$ 中得出的。 G_{zx} 和 D_x 以对抗性的方式进行训练以优化目标函数

$$\min_{G_{zx}} \max_{D_x} E[\log D_x(x_{zx})] + E[\log(1 - D_x(x))].$$
 (2)

对抗准则不足以在 X 和 Z 的图像之间学习适当的转码[44]。这是因为它只任务 G_{xz} 将 X 中的 patch 转换为 z 中的 patch。然而, 它不能确保输入和输出对应于相同的对象。例如, 在 X 中显示建筑物的补丁可以转换为在 z 中显示真实道路的补丁。对抗性标准只强制生成的输出属于适当的域, 而不确保输出在语义上与输入相关。

2)循环一致性准则研究对抗性准则的局限性, 其灵感来自领域适应文献中的循环策略[48]。它确保了从 SAR 图像中采样的补丁




图 2 所示。CycleGAN 训练过程。




图 3 所示。循环一致性约束:左矩形和右矩形分别表示 $X(p^*(X))$ 和 $Z(q^*(Z))$ 所跨越的分布空间。从分布 $p^*(x)$ 中绘制, 并通过 G 处理两次 G_{xz} 和 G_{zx} 得到 $p^*(x)$ 中的原点。

(X)通过 G 连续变换两次 G_{xz} 和 G_{zx} , 我们在 X 中得到原始补丁

$$G_{zx}(G_{xz})(x) \approx x.$$
 (3)

同样, 如果从光学图像(Z)中采样的斑块通过 G 连续变换两次 G_{zx} 和 G_{xz} , 我们就能得到 Z 的原始光学补丁

$$G_{xz}(G_{zx})(z) \approx z.$$
 (4)

使用此准则, 可以确保由 G 生成的输出 z_{xz} , 和 G_{zx} 在语义上与它们对应的输入相关。这是因为如果生成器在没有学习对象到对象对应关系的情况下学习转码到其他域, 那么在转码两次之后, 获得相同对象的可能性是非常小的, 例如, 如果 G_{xz} 将建筑物投影到现实的道路上, 有全概率 G_{zx} 将无法将道路投影回真实的建筑物。因此, 循环一致性确保了在转码过程中保持语义一致性。此外, 周期一致性约束有助于 CycleGAN 网络从 X 和 Z 的未配对补丁中学习 SAR 和光学域之间的转码, 即., 给定 X 中的训练 patch, 则训练过程不需要在 Z 中获得相应的精确地理定位 patch。因此, 加上对抗损失的周期一致性损失使得训练过程更加鲁棒[43]。

将循环一致性准则与对抗损失相结合, 产生了学习 $p^*(x)$ 和 $q^*(z)$ 之间转码的完整目标。这个学习阶段是完全无监督的, 即。也就是说, 它不需要标记训练数据。图 2 显示了对抗性学习机制, 图 3 显示了循环一致性准则。

B.基于cyclegan 的双时间深度特征提取

训练 CycleGAN 后, 生成器 G 的权值 G_{xz} 被冻结并用作双时间深度特征提取器。CNN G_{xz} 由多个卷积层组成, 但它没有任何完全连接的层。因此,这

CNN 表现为一个完全卷积的 CNN，任何空间大小的输入都可以馈送给它。变化前和变化后的 SAR 图像 I_{null} 和 X_{2null} 分别通过 G_{xznull} 以获得所分析场景的每个像素的类似光学的多时相深度特征。这允许使用专为光学图像设计的 CD 方法。在这里，我们使用了一种受 DCVA[4]启发的方法，该方法最初是针对 VHR 光学图像提出的。

从多层 CNN 中获取特征[49]，[50]可以在多个抽象层次和尺度上进行推理。在此基础上，我们进一步选择合适的层 L 来为 CD 提取特征 x_{znull} 捕获原始特征，如边缘，并可能在 CD 过程中添加噪声。先前关于迁移学习的研究[4]、[42]、[49]、[51]、[52]表明中间层更适合迁移学习任务。更深的卷积层更倾向于训练网络的任务，不太适合迁移学习。因此，该方法从中间层中选择 L 中的层。利用双线性插值[4]将 I 中第 1 层的特征上采样到输入 SAR 图像的空间大小，得到 f_{inull}^1 和 f_{inull}^{2null} 。

分层深度特征的差异(通过减去 f_{inull}^1 从 f_{inull}^{2null})得到变化向量 G_{lnull} ，对应第 1 层。一些特征携带 CD 的相关信息，而另一些特征不携带。我们假设捕获相关变化信息的特征比那些对变化信息反应较差的特征具有更高的方差/标准差[4]，[53]。计算差值图像后， G_{lnull} 不受变化影响的显示值都趋于零(没有变化意味着像素随着时间的推移具有相似的值)。G 中的特征 $lnull$ 受变化影响的部分既显示不受变化影响的部分趋向于零的值，也显示受影响的部分远离零的值(变化意味着像素随着时间的推移假设不同的值)。相应地，后一种情况下特征的方差往往大于前一种情况。在此基础上，我们采用基于方差的自动特征选择策略[4]来分层选择判别特征。得到的深度变化超向量 G_{lnull} 吗? (G_{lnull} 吗? $\in G_{lnull}$) 有效地强调变化信息。分层选择的特征 G_l ? 将 I 中的所有层 l 连接起来，以获得 d 维深度变化超向量 G ，该超向量捕获所选层的多尺度变化信息

$$G = (G_1', \dots, G_l', \dots, G_L').$$

(5)

C. 变建筑检测

深变超向量 G 的分量表示为 $G^d_{null}(d = 1, \dots, D)$.假设未改变的像素产生相似的深度特征，而改变的像素则不会，可以假设 G 的分量(即。 g^d_{null})对于未改变的像素(ω_{ncnull})与改变后的像素($?_{cnull}$)[4]。使用这个属性，对于每个特征组件 g^d_{null} ，我们将像素分割成两个集合 $?_{dc}(\forall |g^d_{null}| \geq t^d_{null})$ 和 $\omega_{ncnull}^dnull(\forall |g^d_{null}| < t^d_{null})$ 使用特定于组件的阈值 T^d 。任何自动和无监督阈值方案[31]都可以用来确定 T^d_{null} 。因此，

$null$ 得到 D 个不同的 CD 图，每个特征 g 对应一个 d_{null} G .为每个像素分配适宜性分数 τ ，该分数表示 D 个特征中同意改变一个像素的比例。从[54]中的多尺度集成决策级融合中获得灵感，使用多数投票将像素分为改变的和不变的，即。，像素被划分为 $?_{cnull}$ (如果 $\tau \geq 0.5$)， ω_{ncnull} 不变 $ncnull$ (如果 $\tau < 0.5$)。

吗? $?_{cnull}$ 包括两个免费课程:改变的建筑物和其他变化。改变的建筑物(新建/毁坏)根据深度特征空间中的增量(ξ_+)和递减(ξ_-)的组合产生特定的签名，从而使它们能够被识别并与其他类型的变化分离[5]。因此， $?_{cnull}$ 通过使用深度方向分析将深度变化超向量 G 聚类为两类，进一步分析，如[4]所述。采用 Marin 等人[5]提出的模糊建筑 CD 系统对新建/被毁建筑的存在/不存在进行分析。建筑物产生一个特征，其特征在于存在:1)来自地面、垂直墙壁和建筑物屋顶(中途停留区)的后向散射贡献;2)地面和垂直墙之间的多重散射(双弹跳线);以及 3)由于建筑物对传感器的遮挡(阴影区域)。场景中建筑物的出现/消失会导致这些原语在 VHR SAR 图像中出现/消失[5]。将深度特征空间中的两个主导变化识别为 $\delta_+ \in \xi_+$ 和 $\delta_- \in \xi_-$ ，并使用模糊规则对它们进行评估，以识别变化的建筑物。

Iv.数据集和实验结果

训练基于 cyclegan 的深度转码器的数据集详见第 IV-A 节。在 IV-B 节中描述的两个数据集上进行了实验。比较方法的选择在 IV-C 节中说明。双时间深度特征提取的层的选择在第 IV-D 节中详细说明。随后，第 IV-E 节讨论了深度特征可视化，第 IV-F 节详细介绍了我们的结果。

A.CycleGAN 训练

本文使用在城市分析背景下提出的 sarpical 数据集[39]进行 CycleGAN 训练(X 和 Z)。该数据集提供了从 TerraSAR- X 聚光灯图像和航空 UltraCAM 光学图像中提取的 10000 多对 SAR 和光学斑块[39]。尽管 sarpical 数据集提供了成对的补丁，但该方法不需要对它们进行配对。在我们的训练过程中，使用了来自 SAR 和光学图像的 8000 个补丁。表 I 示出发生器 G 的关键结构 x_{znull} 和 G_{zxnull} 。表 2 给出了鉴别器的关键结构

D_z and D_x.

对于 CycleGAN 训练，我们使用 batch 大小为 1 的 Adam 优化器[55]。训练执行 750 次，学习率为 0.0001，动量为

¹ $null$ 详细的 CycleGAN 结构 :<https://github.com/sudipansaha/sarCdUsingDeepTranscoding>

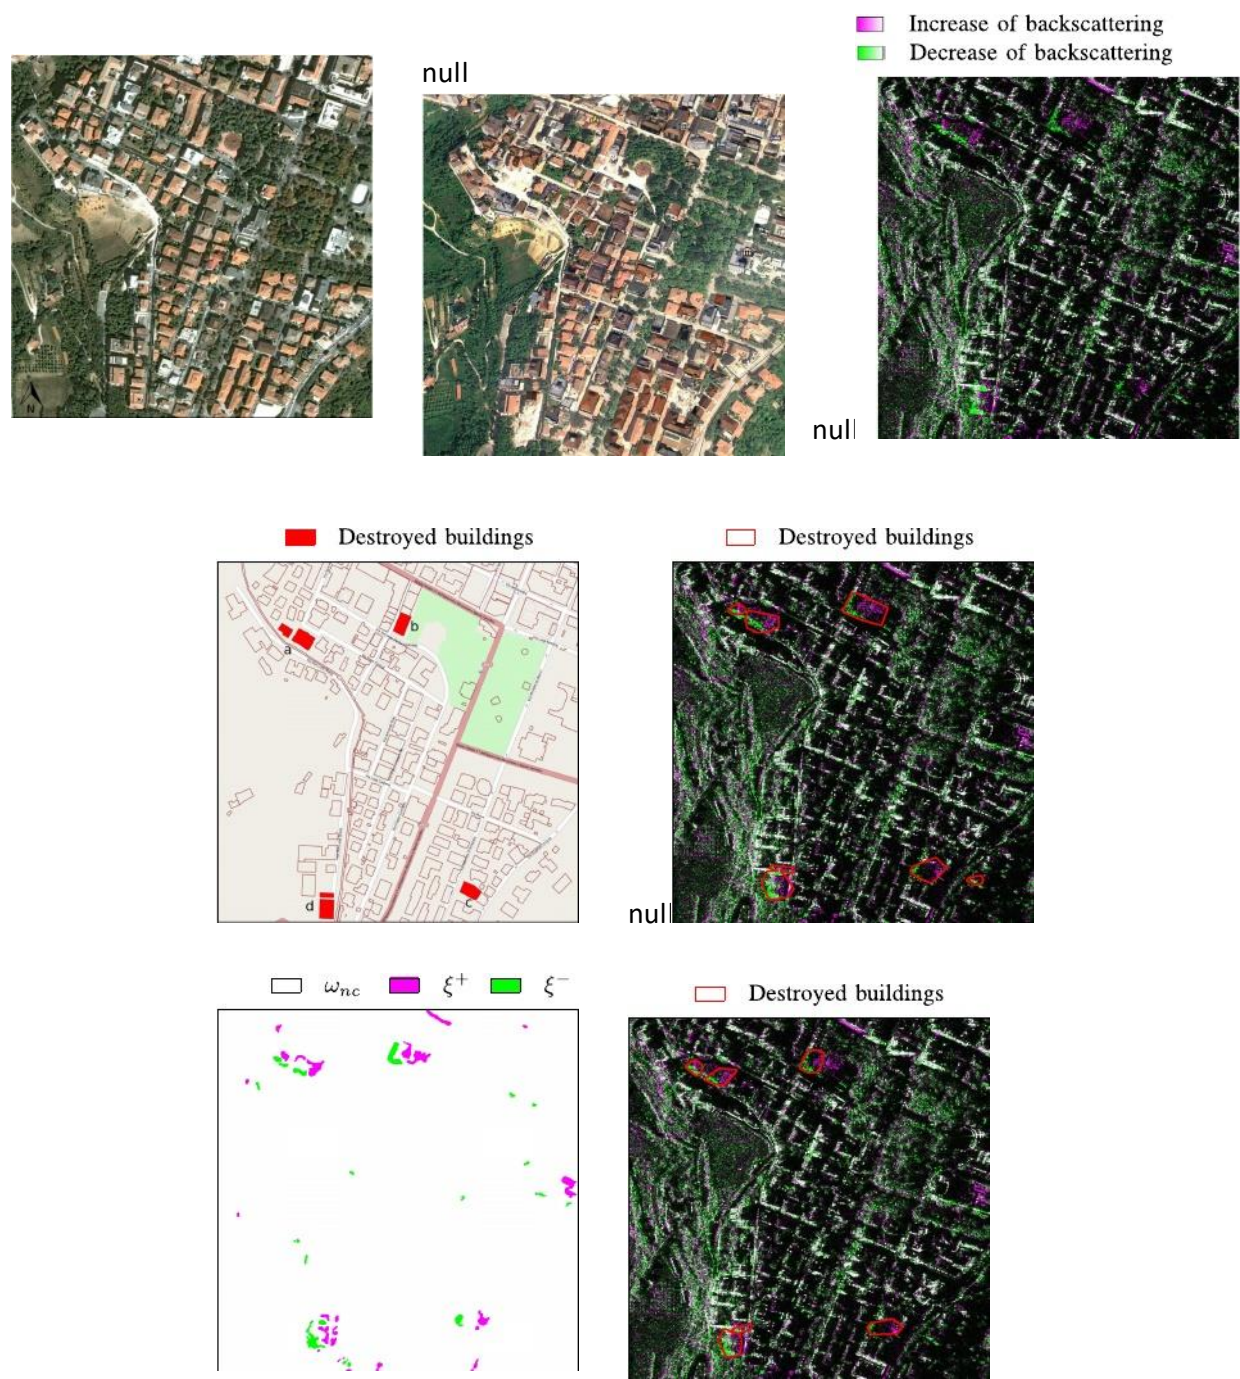


图 4所示。L 'Aquila(意大利)数据集。(a)光学图像(2006 年 9 月 4 日)[5][58]。(b)光学图像(2009 年 5 月 8 日)[58]。(c) cosmo - skymed 图像的 RGB 多时相合成(R: 2009 年 9 月 12 日;G: 2009 年 4 月 5 日;B: 2009 年 9 月 12 日)。(意大利空间局, 2009)。(d)该地区地籍图。(e) Marin 等[5]探测到的被毁建筑物。(f)本文方法检测到的深度特征空间的增减。(g)本文方法检测到的被毁建筑物。

(β_{1null})[55]的 0.5。学习率在前 250 个 epoch 保持固定, 在接下来的 500 个 epoch 线性衰减到零。

B. CD 数据集

实验在两个数据集上进行。其中一个与 2009 年发生在意大利中部阿布鲁佐地区的拉奎拉地震有关。另一幅描绘了意大利特伦托在 2011 年至 2013 年间的城市演变。

null 拉奎拉地震数据集[5]由 2009 年 4 月 5 日和 9 月 12 日在意大利拉奎拉市(42° 21')的 HH 偏振下获得的两张聚光模式 x 波段 cosmo - skymed 单幅图像组成。N, 13° 24 'E)。2009 年 4 月 6 日, 拉奎拉受到 6.3 矩级地震的影响。图片显示的面积为 1024 × 1024 像素。因此, 在地震发生前获取预变图像, 在立即救援操作完成后获取后变图像。图 4(a)和(b)显示了与面积相对应的前变和后变光学图像

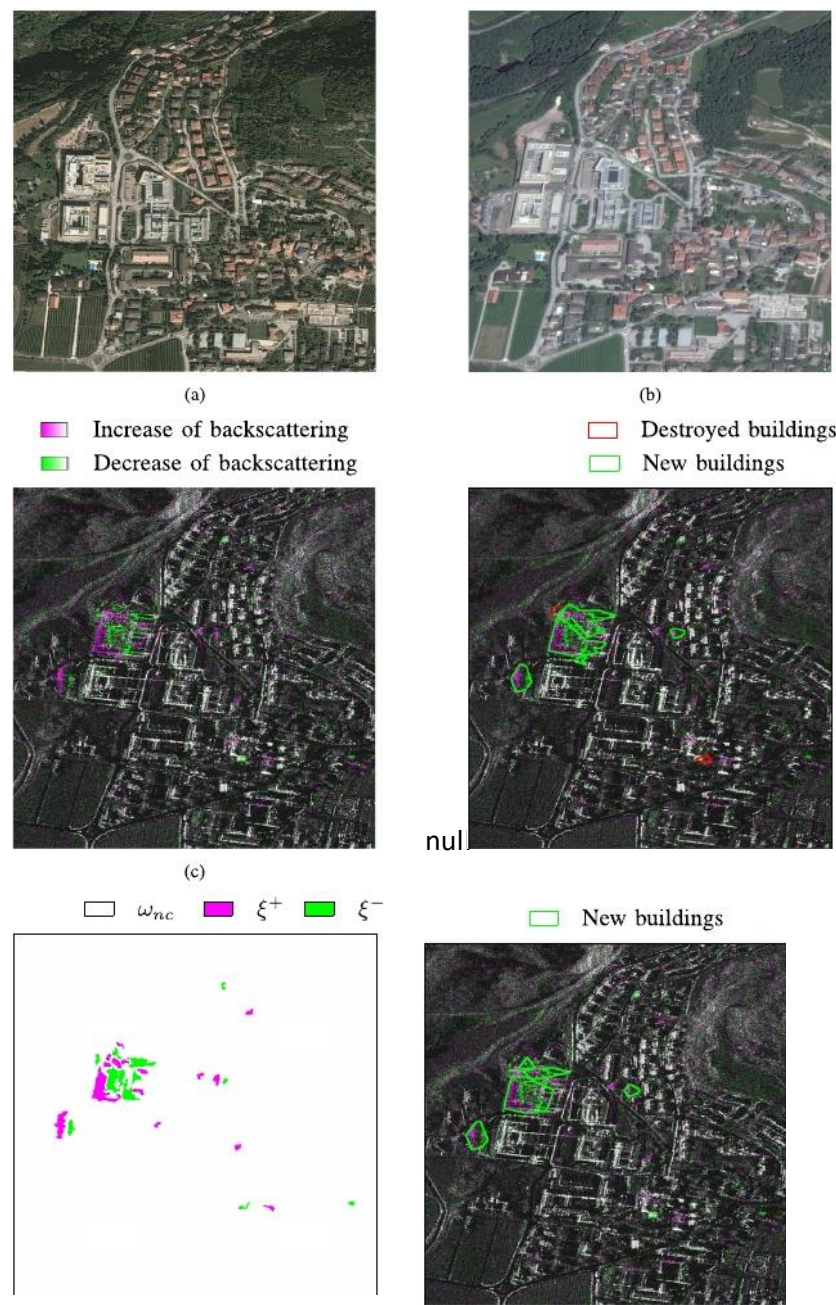


图 5 所示。特伦托(意大利)数据集。(a)光学图像(2011 年[58])。(b)光学图像(2014 年[58])。(c)聚光灯下 TerraSAR-X 和 TanDEM-X 图像的 RGB 多时相组成 (R: 2013 年 4 月 3 日;G: 2011 年 1 月 21 日;B: 2013 年 4 月 3 日)。(d) Marin 等[5]检测到的变化建筑物。(e)本文方法检测到的深度特征空间的增减。(f)本文方法检测到的变化建筑物。

的兴趣。数据集的多时相假色合成(红色通道:9 月 12 日, 2009;绿色通道:2009 年 4 月 5 日;蓝色通道:2009 年 9 月 12 日)如图 4(c)所示。不变的像素出现在灰度中, 后向散射值增加的像素出现在品红色色调中, 后向散射值减少的像素出现在绿色色调中。该区域的地籍图如图 4(d)所示。地震发生后, 6 座建筑物被确定为完全毁坏。一些被毁的建筑物彼此靠得很近。在图 4(d)中标记为 a-d 的四个区域中发现了六座被摧毁的建筑物。其他小变化的数量

null 存在于与建筑物不对应的分析场景中。

特伦托数据集[5]包括 2011 年 1 月 21 日和 2013 年 4 月 3 日在 HH 偏振下获得的两张聚光模式高分辨率 x 波段 Tandem-X 和 TerraSAR-X 图像, 这些图像是在意大利特伦托市(46° 04'N, 11° 07'E)。选择的测试场地为一个截面(1024 × 1024 像素), 覆盖特伦托大学工程与计算机科学系周围的区域。图 5(a)和(b)显示了与感兴趣区域对应的变化前和变化后的光学图像。数据集的 Multitemporal 假色合成(红色通道:




图 6 L 'Aquila(意大利)数据集上第二卷积层特征的可视化。(a) -(c)前三个特征。(d) -(f)最下面三个特征。表一表二
鉴别器的生成器键结构的键结构

Layer number	Layer type	Kernel number	Kernel size
1	convolutional	64	(7,7)
2	convolutional	128	(3,3)
3	convolutional	256	(3,3)
4	residual block	256	(3,3)
5	residual block	256	(3,3)
6	residual block	256	(3,3)
7	residual block	256	(3,3)
8	residual block	256	(3,3)
9	residual block	256	(3,3)
10	residual block	256	(3,3)
11	residual block	256	(3,3)
12	residual block	256	(3,3)
13	transposed convolutional	128	(3,3)
14	transposed convolutional	64	(3,3)
15	convolutional	1	(7,7)
16	Tanh	1	0

2013 年 4 月 3 日;绿色通道:2011 年 1 月 21 日;和蓝色通道:2013 年 4 月 3 日)如图 5(c)所示。不变的像素出现在灰度中, 后向散射值增加的像素出现在品红色调中, 后向散射值减少的像素出现在 a

Layer number	Layer type	Kernel number	Kernel size
1	convolutional	64	(4,4)
2	convolutional	128	(4,4)
3	convolutional	256	(4,4)
4	convolutional	512	(4,4)
5	convolutional	1	(4,4)

绿色的基调。在考虑的期间内, 在场地上新建了三座建筑[5]。在第二次收购期间仍在部分施工的大型建筑位于图像的左中。一个中等规模的建筑在图像的左侧, 一个小的建筑在图像的中心。因此, 数据集中发生变化的建筑物的大小是不均匀的。

C.比较方法

将本文提出的方法与 Marin 等人[5]提出的最先进的无监督建筑 CD 方法进行了比较。由于所提出的方法是无监督的, 并且




图 7 所示。L 'Aquila(意大利)数据集上第三卷积层特征的可视化。(a) - (c)前三个特征。(d) - (f)最下面三个特征。

在其目标/设计选择方面与最先进的基于深度学习的方法无关，这里没有对它们进行比较。这些将在下面进行更详细的展示。

- 1)基于深度学习的构建 CD 方法[33]，[34]是有监督的。将所提出的无监督方法与此类有监督方法进行比较是不公平的。
- 2)文献中大多数 SAR CD 方法都是有监督的[21]-[23]。此外，它们不是为处理构建 CD 而设计的。
- 3)基于预分类方案的方法[26]-[29]可以在没有监督的情况下工作。然而，它们的性能取决于预分类方案。此外，建筑变化通常是稀疏的

null 分布在图像中，因此，生成伪标记数据来进一步训练深度网络实际上是不可能的。

D.层的选择

表 1 显示了 CNN G 的详细结构，用于双时间深度特征提取。之前关于迁移学习的研究[4]、[49]、[51]、[56]、[57]表明中间层更适合迁移学习任务。Ley 等人[42]的工作也是如此，在基于 sar 到光学转码的预训练之后，只保留生成器的较浅层作为分类器进行训练。在此基础上，从中间的 $L = \{2,3,4,5,6\}$ 层中提取深层特征。




图 8 所示。L 'Aquila(意大利)数据集上第 14 层特征的可视化。(a) - (c)前三个特征。(d)底部特征。

E.深度特征可视化

图 6 通过对 L 'Aquila 地震数据集的单个特征获得的差分图进行可视化，展示了在第二个卷积层中学习到的特征。图 6(a) - (c)显示了根据方差准则选择的前三个特征[4]。这三个特征都突出显示了变化的建筑物。这表明这些特征已经学习了用于建筑检测的语义相关信息。图 6(d) - (f)显示了根据方差标准选择的最下面的三个特征。它们与建筑物无关，不会在差异图中突出显示变化的建筑物。

同样的现象可以在第三个卷积层中观察到(见图 7)，然而，即使是第 14 层的顶层特征(见图 8)也不会差图中突出显示变化的建筑。这证明了我们在第 IV-D 节中的假设，即更深层的 G_{xz}^{null} 不适合 CD 的深度特征提取，因此地表特征之间的对比度很差。

为简洁起见，这里只展示了 L 'Aquila 数据集的深度特征可视化，但 Trento 数据集也得到了类似的结果。

F. CD 结果

1) L ' aquila 数据集:在区分了变化的像素和不变的像素之后，将它们进一步聚类为两种类型: ξ_{+} 和 ξ_{-} ，如图 4(f)所示，以洋红色和绿色表示。由于地震造成的建筑物消失，我们观察到由 $\delta_{+} \in \xi_{+}$ 和 $\delta_{-} \in \xi_{-}$ 组成的结构化模式。除此之外，还有一些其他的孤立

表 3

在 l'Aquila 数据集上的表现(建筑总数=200)

Method	Correctly detected destroyed buildings	Missed destroyed buildings	Falsely detected destroyed buildings
Marin <i>et. al.</i> [5]	6	0	1
Proposed	6	0	0

表 4

trento 数据集上的性能(建筑物总数=187)

Method	Correctly detected new buildings	Missed new buildings	Falsely detected destroyed buildings
Marin <i>et. al.</i> [5]	3	0	1
Proposed	3	0	0

观察到 ξ_{+} 和 ξ_{-} 的出现。按照模糊建筑检测方法，识别出被破坏的建筑，如图 4(g)所示。所提出的方法正确地识别了所有六栋建筑[见图 4(g)]。没有产生误报。因此，所提出的方法优于产生一个假警报的最先进方法[5][见图 4(e)]。与之前基于 sar 的建筑 CD 的工作[5]一致，本文以物体(建筑)而不是像素来讨论结果。定量结果如表 III 所示。

此外，所提出的方法比[5]更准确地模拟了被毁建筑物的形状。对于地籍图中标记为“b”和“c”的建筑物来说，这一点很明显[见图 4(d)]。为了更好地可视化“b”建筑，图 9(a) - (c)分别显示了震前光学图像的放大视图、Marin 等人[5]获得的结果和本文方法获得的结果。




图 9 所示。拉奎拉数据集地图籍图中建筑物“b”的放大视图。(a)光学图像(2006 年 9 月 4 日)[58]。(b) Marin 等人探测到的被毁建筑[5]。(c)本文方法检测到的被毁建筑。

2) Trento 数据集:采用最先进的方法[5]获得的结果如图 5(d)所示。虽然[5]检测到所有三个新建筑,但它错误地将一个建筑分类为被摧毁。所提出的方法将像素聚类改变为两种类型: ξ_+ 和 ξ_- ,如图 5(e)中的品红和绿色所示。通过遵循模糊建筑检测方法,可以识别出新的建筑,如图 5(f)所示。提出的方法正确地识别了所有三个新建筑,尽管它们的大小不均匀。我们从第 IV-B 节中回忆起,图像左中心的建筑物明显大于场景中的其他建筑物。而且,在第二次采集时,它的某些部分仍在施工中,从而造成了建筑足迹的不连续性。这座建筑的重建足迹被分为三个不同的部分。尽管如此,考虑的三个部分共同正确地定位了建筑的足迹。重建的建筑足迹对于中小型建筑是准确的。尽管在分析的图像中有许多建筑物进行了轻微的翻新,但所提出的方法没有产生假警报。因此,所提出的方法优于[5]将一栋建筑错误分类为被毁的方法。这表明所提出的方法能够在异质条件下工作,并且可以区分拆除的建筑物和未拆除的建筑物,尽管该地区的建筑物密度很高(187)。定量结果如表 4 所示。

与配备 GPU NVidia Geforce GTX 1080 Ti 和 Intel I7 CPU (3.2 GHz)的机器相比,所提出的方法需要额外 81 秒(平均超过 10 次执行)的运行时间[5]。

诉的结论

本文提出了一种基于无监督深度学习的多时相 VHR SAR 图像 CD 构建方法。众所周知, CNN 在处理 VHR 图像方面是有效的,因为基于深度学习的特征适合捕捉上下文信息。然而,由于难以获得像素标记的 SAR 数据,其在无监督多时相 VHR SAR 分析中的应用受到限制。为了解决这些问题,我们提出了一种新的无监督 CD 技术,该技术利用 CycleGAN 框架来训练 SAR-光学深度转码器

nullSAR-光学数据集,与像素标记的 SAR 数据集相比,更容易获得。在对 CycleGAN 进行训练后,使用生成器网络从变化前和变化后的 SAR 图像中获取类光学深度特征,并将其用于最初为光学图像开发的 DCVA 框架[4]中的 CD。所提出的方法进一步使用模糊建筑检测规则[5]来识别变化的建筑像素。该方法表明, SAR-光学转码的代理任务是训练深度网络进行多时相分析的有效方法。考虑到在 VHR SAR 图像分析中标记数据的困难,这是一个重要的结论。此外,这开辟了一种在无监督多时相分析中使用未标记数据知识的方法。以这种方式,无监督 CD 方法不需要局限于分析的场景,而是可以使用当前收集的大量遥感数据中的知识来处理未知场景。在包含地震前和地震后图像的数据集以及包含新建建筑物的另一个数据集上进行的实验证明了所提出方法的有效性。虽然在建筑 CD 上得到了验证,但所提出的方法也可以用于其他应用。通过进一步利用 SAR-光学转码过程,在我们未来的工作中,我们计划设计一种多传感器 CD 方法,同时接收来自光学和 SAR 传感器的图像。我们还计划将我们的工作扩展到由两个以上图像组成的时间序列分析。

参考文献

[1]朱勇,孙志军,沈建军,朱勇,“基于大数据的遥感研究”,《IEEE》,第 4 卷,第 1 期。11, pp. 2207-2219, 2016 年 11 月。

[2]张晓明,张晓明,张晓明,“基于 SAR 数据的地震震害定位方法研究”,中国地质大学学报(自然科学版), 2014 . (ei): 444 - 444。Geosci. Remote Sens. Symp. (IGARSS), 2015 年 7 月, pp. 2723-2726。

[3]F. Bovolo, “一种基于多层包裹的高分辨率图像变化检测方法”, IEEE, 格奥西。遥感,左., 第 6 卷,第 6 期。1, 第 33-37 页, 2009 年 1 月。

[4]张志强, F. Bovolo, L. Bruzzone, “基于无监督深度变化向量分析的 VHR 图像检测”,《IEEE Trans》。格奥西。《遥感技术》,第 57 卷,第 57 期。6, 第 3677-3693 页, 2019 年 6 月。

[5]张志强, C. Marin, F. Bovolo, L. Bruzzone, “高分辨率 SAR 图像的建筑变化检测”, IEEE Trans. 格奥西。《遥感技术》,第 53 卷,第 53 期。5, pp. 2664-2682, 2015 年 5 月。

[6]蒋凯等,“基于 SAR 图像的汶川地震震害分析”, IEEE 国际期刊, Proc. 格奥西. *遥感*, vol. 5, July 2009, p. v. 108.

[7]张建军,“基于高分辨率 terasar - x 图像的地震震害检测”,《Proc》,第 8 期,国际期刊.遥感讲习班,灾害管理.,第 9 卷.日本东京:东京技术研究所., 2010, pp. 19.

[8] F. Bovolo, C. Marin, L. Bruzzone,“一种基于高分辨率 SAR 图像的变化检测方法”, Proc, IEEE. 格奥西. *遥感*, 2012 年 7 月,第 1992-1995 页.

[9]李建军,李建军,李建军,“基于广义高斯模型的 SAR 图像自动检测方法”,《IEEE Trans》. 格奥西. *遥感技术*,第 43 卷,第 3 期. 4,第 874-887 页, 2005 年 4 月.

[10]王志强,王志强. Tourneret 和 J. Inglada,“基于二元伽马分布的多传感器 SAR 图像变化检测”,《IEEE Trans》. *图像的过程*, vol. 17, no. 3,第 249-258 页, 2008 年 3 月.

[11]张晓明,张晓明,张晓明,“基于 mean-shift 聚类的 SAR 图像非参数变化检测”,《IEEE Trans》, 2011. 格奥西. *遥感技术*,第 51 卷,第 5 期. 4, pp. 2022-2031, 2013 年 4 月.

[12]龚明,苏磊,贾明,陈伟,“基于模糊聚类的合成孔径雷达图像变化检测方法”,《IEEE Trans》. *模糊系统*, vol. 22, no. 1,第 98-109 页, 2014 年 2 月.

[13]李志刚, F. Bovolo,“一种基于尺度驱动的多尺度 SAR 图像变化检测方法”, IEEE Trans. 格奥西. *遥感技术*,第 43 卷,第 3 期. 12,第 2963-2972 页, 2005 年 12 月.

[14]龚冀明,曹艳,吴强,“基于邻域的 SAR 图像变化检测方法”, IEEE 格奥西. *遥感*,左.,第 9 卷,第 9 期. 2,第 307-311 页, 2012 年 3 月.

[15]张晓明,张晓明,张晓明,“高分辨率 SAR 数据在城市区域分析中的应用”,测绘与工程学报., vol. 153, no. 5. 3,第 294-300 页, 2006 年 6 月.

[16]李晓明,李晓明,李晓明,“基于高分辨率 SAR 和干涉 SAR 的城市区域雷达成像”, IEEE Trans. 格奥西. *遥感技术*,第 46 卷,第 2 期. 10, pp. 2971-2982, Oct. 2008.

[17]张志强,“基于线性曲线特征的城市地震震害检测”,《IEEE Trans》. 格奥西. *遥感技术*,第 51 卷,第 5 期. 9,第 4877-4884 页, 2013 年 9 月.

[18]张晓明,王晓明,王晓明,“一种基于目标的高分辨率 SAR 图像生成方法”,国际期刊.《遥感技术》,第 38 卷,第 2 期. 7,第 1765-1787 页, 2017 年 4 月.

[19] Y. LeCun, Y. Bengio and G. Hinton,“深度学习”,《自然》,第 521 卷,第 436-444 页, 2015 年 5 月.

[20]张晓明,周晓明,张晓明,“基于深度特征的场景识别方法”, Proc 学报,中文信息学报. *系统*, 2014,第 487-495 页.

[21]龚明,赵军,刘军,苗清,焦磊,“基于深度神经网络的合成孔径雷达图像变化检测”, IEEE Trans. *神经. 学习. 系统*,第 27 卷, no. 1, pp. 125-138, 2016 年 1 月.

[22]高飞,董建,李波,徐清,“基于 PCANet 的合成孔径雷达图像自动变化检测”, IEEE 格奥西. *遥感*,左.,第 13 卷,第 3 期. 12, pp. 1792-1796, december 2016.

[23]高飞,王生,高飞,董建,王生,“基于卷积小波神经网络的 SAR 图像海冰变化检测”, IEEE 格奥西. *遥感*,左.,第 16 卷,第 6 期. 8,第 1240-1244 页, 2019 年 8 月.

[24]高翼,高翼,董军,王勇,“基于深度学习的海冰变化检测方法”, 电子工程学报, 格奥西. *遥感*,左.,第 16 卷,第 6 期. 10,第 1655-1659 页, 2019 年 10 月.

[25]李明,李明,张鹏,吴,宋文文,安霖,“基于 PCANet 的 SAR 图像变化检测”, 电子工程学报地球物理. *遥感*,左.,第 16 卷,第 6 期. 3,第 402-406 页, 2019 年 3 月.

[26]李明,陈峰,焦亮,周磊,尚仁,“一种基于深度学习的合成孔径雷达图像变化检测方法”,《电子工程学报》. 格奥西. *遥感技术*,第 57 卷,第 57 期. 8,第 5751-5763 页, 2019 年 8 月.

[27]王晓明,王志强.尹,“基于深度学习的 SAR 图像变化检测”,国际科学杂志. J.洛特. *空间科学*,第 21 卷,第 549-559 页, 2019 年 10 月.

[28]龚明,杨辉,张鹏,“基于深度学习的 SAR 图像特征学习与变化特征分类”,中国图象图象学报. *遥感技术*,第 129 卷,第 212-225 页, 2017 年 7 月.

[29]刘建军,龚明,秦凯,张鹏,“基于深度卷积的非均匀光学和雷达图像变化检测”, 电子工程学报. *神经. 学习. 系统*,第 29 卷,第 29 号. 3,第 545-559 页, 2018 年 3 月.

[30]崔波,张鹏,闫亮,魏军,吴,“基于随机子空间集成学习的无监督 SAR 变化检测方法”, 遥感, vol. 11, no. 11. 11, p. 1314, 2019 年 6 月.

[31]张晓明,张晓明,“基于时间变量的数据融合方法研究”, 电子工程学报, 格奥西. *遥感杂志》第 3 卷第 2 期*. 3, pp. 8-26, sept . 2015.

[32]张磊,张鹏,杜斌,“基于深度学习的遥感数据提取技术”, 电子工程学报, 格奥西. *遥感杂志》第 4 卷第 1 期*. 2, pp. 22-40, 2016 年 6 月.

[33]陈峰,于斌,“基于多任务深度学习框架的地震诱发建筑损伤映射”, 电子工程学报, vol. 7, pp. 181396-181404, 2019.

[34]李明,王勇,张鹏,张鹏,吴,“基于差分图像和残差 U-Net 网络的 SAR 图像中城市建筑变化检测”, 遥感, vol. 11, no. 11. 9, p. 1091, May 2019.

[35]张晓明,张晓明,“一种安霖的识别基线”,《电子工程学报 Conf 程序》, 计算机. *视觉模式识别. 研讨会, 2014 年 6 月*,第 806-813 页.

[36] O. A. B. Penatti, K. Nogueira, J. A. dos Santos,“从日常物体到遥感和航空场景的深度特征推广?”《电子工程学报 Conf 程序》, 计算机. *视觉模式识别. 《工场》, 2015 年 6 月*,第 44-51 页.

[37] K. Nogueira, O. A. B. Penatti, J. A. dos Santos,“基于卷积神经网络的遥感图像分类”, 模式识别., vol. 61, pp. 539-556, 2017 年 1 月.

[38]张志强,张志强,“基于卷积神经网络的图像深度语义标注”,《电子工程学报》. 格奥西. *遥感技术*,第 55 卷,第 55 期. 2,第 881-893 页, 2017 年 2 月.

[39]王勇,朱,“密集城区 SAR 与光学影像联合分析的 sarp 数据集”, 电子工程学报, 程序. 格奥西. *遥感. (中国科学院学报)*, 2018 年 7 月, pp. 6840-6843.

[40]王晓明,王晓明,王晓明,“对抗特征学习”[j]. 中文信息学报, 2016, (学术期刊)555 - 557. (在线). 可用: <http://arxiv.org/abs/1605.09782>

[41]张晓明,张晓明,张晓明,“基于语义融合的半监督卫星图像分类方法”, 程序,第 25 期, 电子工程学报国际科学杂志. Conf: 图像处理. (ICIP), 2018 年 10 月,第 684-688 页.

[42]张晓明,张晓明,张晓明,“基于 gan 的 SAR 图像转码技术研究”,《程序》第 12 期. Conf. *Synth. 孔径雷达*, 2018, pp. 1-6.

[43]张晓明,张晓明,“基于条件生成对抗网络的 SAR-光学图像转换”,《遥感技术》, vol. 11, no. 11. 17, p. 2067, 2019.

[44]王志强. 朱, P. Park, P. Isola, A. A. Efros,“基于周期一致对抗网络的非配对图像到图像翻译”, 2017. 学术期刊: 1703.10593. (在线). 可用: <http://arxiv.org/abs/1703.10593>

[45]张晓明,张晓明,张晓明,“基于 GANs 的图像合成”, 程序, 34(国际科学杂志). Conf. *学习. (ICML)*, vol. 70, 2017, pp. 2642-2651.

[46]王志强,王志,王志强,“生成对抗网络在计算机视觉中的应用”,《计算机科学》, 2019, 学术期刊,第 6 卷第 1 期. (在线). 可用: <http://arxiv.org/abs/1906.01529>

[47]任德华,王晓明,王晓明,“基于局部自适应中值滤波的 SAR 图像散斑降噪方法”, 遥感技术, vol. 41, no. 17. 3,第 244-266 页, 九月 2004.

[48]李志强,刘志强,“一种基于虚拟机的分类方法及其应用”,《电子工程学报》. *模式识别. 马赫. 智能*, vol. 32, no. 5,第 770-787 页, 2010 年 5 月.

[49]张晓明,张晓明,张晓明,“基于多列的目标分割方法”, 计算机科学与技术会议, 计算, 程序. *Vis. Pattern recognition . (CVPR)*, 2015 年 6 月,第 447-456 页.

[50]王勇,刘强,王勇,“基于卷积神经网络特征的卫星图像变化检测”, 中国图象科学学报, vol. 31, no. 11, 2016, Art. 不. 100110 w.

[51]张伟等,“基于深度学习的生物图像分析方法”,《电子工程学报》。《大数据》,第6卷,第2期。2,第322-333页,2020年6月。

[52]黄忠,潘忠,雷斌,“基于深度卷积神经网络的 SAR 目标分类”,《遥感》,vol. 9, no. 5。9, p. 907, august 201708。

[53]张志强,李志强,张志强,“基于多时间点图像的无监督变化检测方法研究”,《科学》杂志,2013。Geosci.《遥感技术》,第45卷,第5期。6,第1658-1670页,2007年6月。

[54]杜强,佟晓明,刘胜,刘志强,Bovolo,“基于多尺度压缩变化向量的无监督多变化检测”,IEEE,2011,31(4):448 - 448。主题:。地球 Observ.《遥感技术》,第10卷,第5期。9,第4124-4137页,九月2017。

[55]王晓明,王晓明,王晓明,等。一种随机优化方法。计算机应用学报,2014,31(4):444 - 444。(在线)。可用: <http://arxiv.org/abs/1412.6980>

[56]张志强。Lee, Y. Lee and b.s. Shin,“用于医学图像小规模数据集迁移学习的中级特征提取器”,载于《计算机科学与普适计算进展》。新加坡:Springer, 2018, pp. 8-13。

[57]张晓明,张晓明,张晓明,“基于卷积神经网络的图像学习与图像识别”,计算机科学与技术会议,计算,程序。Vis. Pattern recognition .。 , 2014年6月,第1717-1724页。

[58]谷歌地图。获取日期:2020年4月10日。(在线)。可用: <https://maps.google.com>



Sudipan Saha (IEEE 研究生会员于 2011年获得印度加尔各答工程与管理学院电子与通信工程学士学位,并于 2014年获得印度孟买印度理工学院电子工程硕士学位。他目前在意大利特伦托特伦托大学和特伦托 Fondazione 布鲁诺凯斯勒大学攻读信息与通信技术博士学位。

曾在新竹台积电有限公司担任工程师。

2015年至2016年任职台湾。2019年,他在德国慕尼黑工业大学(TUM)担任客座研究员,为期三个月。主要研究方向为多时相遥感图像分析、域自适应、时间序列分析、图像分割、深度学习、图像处理、模式识别等。

Saha 先生是几家国际期刊的评论员。



Francesca Bovolo (IEEE 高级会员分别于 2001年、2003年和 2006年在意大利特伦托大学获得 Laurea(学士学位、Laurea Specialistica硕士学位和通信与信息技术博士学位。

2013年之前,她是特伦托大学的研究员。她是特伦托布鲁诺凯斯勒基金会(Fondazione Bruno Kessler)数字地球遥感部门的创始人和负责人,也是成员之一

特伦托遥感实验室她是欧洲航天局木星冰月探测器的冰月雷达探测仪器的联合研究员之一。她的研究兴趣包括遥感图像处理、多时相遥感图像分析、多光谱、高光谱、合成孔径雷达图像中的变化检测、非常高分辨率图像、时间序列分析、基于内容的时间序列检索、域自适应以及光探测与测距(LiDAR)和雷达探测仪。她在多个国家和国际项目的背景下对这些研究课题进行研究。

nullBovolo 博士是多个国际会议和研讨会的计划和科学委员会成员。她曾在 2006 年丹佛 IEEE 国际地球科学与遥感研讨会的学生论文比赛中获得第一名。她是多时相遥感图像分析国际研讨会 (MultiTemp, 2011 年和 2019 年)的技术主席。自 2014 年以来,她一直担任 SPIE 遥感信号和图像处理国际会议的联合主席。她是 2015 年国际地球科学与遥感研讨会的出版主席。自 2011 年以来,她一直担任 IEEE《应用地球观测与遥感专题精选》杂志的副主编,并担任 IEEE 地球科学与遥感学报《多时相遥感数据分析》特刊的客座编辑。她还担任多家国际期刊的裁判。



Lorenzo Bruzzone (Fellow, IEEE)分别于 1993 年和 1998 年在意大利热那亚大学获得电子工程硕士学位(以优异成绩获得)和电信博士学位。

他是意大利特伦托特伦托大学 (University of Trento)电信专业的全职教授,教授遥感、雷达和数字通信。他是创办人和主任遥感实验室,信息工程与计算机科学系

在特伦托。他的研究兴趣集中在遥感、雷达和 SAR、信号处理、机器学习 and 模式识别领域。他在许多国家和国际项目的框架内推动和监督这些主题的研究。他是许多研究项目的首席研究员。其中,他是欧洲航天局 (ESA)木星冰月探测器 (JUICE)任务框架下的冰月雷达探测 (RIME)仪器的首席研究员,以及 ESA 气候变化倡议框架下高分辨率土地覆盖项目的科学负责人。他在国际期刊上发表了 259 篇科学论文(其中 193 篇发表在 IEEE 期刊上),在会议论文集集中发表了 330 多篇文章,并撰写了 22 本书章节。

Bruzzone 博士自 2009 年以来一直是 IEEE 地球科学与遥感学会 (GRSS)行政委员会的成员,自 2019 年以来一直担任专业活动副总裁。1998 年 7 月在西雅图举行的 1998 年 IEEE 国际地球科学与遥感研讨会 (IGARSS)学生论文比赛中获得第一名。从那时起,他获得了许多国际和国家荣誉和奖项,包括最近的 IEEE GRSS 2015 年杰出服务奖,2017 年和 2018 年 IEEE IGARSS 研讨会奖论文奖,以及 2019 年 WHISPER 杰出论文奖。自 2003 年以来,他一直担任 SPIE 遥感图像和信号处理会议主席。曾为多家国际期刊特刊共同客座编辑。他是 IEEE 多时相遥感图像分析 (MultiTemp)系列国际研讨会的联合创始人,也是该系列研讨会的常设指导委员会成员。他是 18 本书籍/会议论文集和 1 本科学书籍的编辑/共同编辑。从总被引次数 (超过 31600 次)和 h 指数值 (83 次)(来源:Google Scholar)可以证明,他的文章被引率很高。他曾受邀在 40 多个国际会议和研讨会上担任主题演讲嘉宾。他是 IEEE 地球科学与遥感杂志的创始人,并于 2013 年至 2017 年担任主编。他是 IEEE 地球科学与遥感学报的副主编。2012 年至 2016 年,他是 IEEE GRSS 的杰出演讲者。