

ISNet:提高远程可分离性 传感图像变化检测

Gong Cheng ,  Member, IEEE, Guangxing Wang, and Junwei Han  , IEEE 院士

摘要 :深度学习通过提取判别性层次特征极大地推动了遥感图像变化检测。然而,随着越来越高分辨率的遥感图像具有丰富的空间细节但有限的光谱信息,使用传统的骨干网络会导致层次特征之间的不同语义之间的界限变得模糊。这解释了为什么最终预测中的大多数误报分布在变化边界周围。为了解决这个问题,我们注重特征细化,并提出了可提高可分离性的深度学习网络 (ISNet)。我们的 ISNet 从应用于细化双时态特征层次结构的两种策略中获得了优势:1)边缘最大化,澄清了变化和未变化语义之间的差距;2)注意力机制的有针对性的安排,指导通道注意力 (CA)和空间注意力的使用 (SA)分别用于突出语义和位置信息。

具体来说,我们将 CA 模块插入到份额加权主干网络中,以促进特定于语义的特征提取。然后,通过边缘最大化模块澄清提取的双时态分层特征中的语义边界,然后通过 SA 模块来增强位置变化响应。

自上而下的融合路径使得最终的细化特征覆盖多尺度表示,并且对于遥感图像变化检测具有很强的可分离性。广泛的实验评估表明,我们的 ISNet 在 LEVIR-CD、SYSU-CD 和 Season-Varying 数据集上的整体精度 (OA)、Intersection-of-Union (IoU) 方面实现了最先进的性能,和 F1 分数。代码可在 <https://github.com/xingronaldo/ISNet> 获取。

索引术语 注意力机制、变化检测、深度学习。

一、简介

使用双时态远程控制土地覆盖变化检测 传感图像在各种应用中都有实际用途,包括土地管理、损害评估和环境监测[1]-[3]。给定显示光谱行为改变的双时态图像 [1],变化检测旨在区分由感兴趣的变化引起的光谱变化与不完全一致的成像带来的光谱变化

稿件于2022年1月29日收到; 2022 年 4 月 19 日修订; 2022年5月7日接受。出版日期2022年5月11日;当前版本日期为 2022 年 6 月 1 日。这项工作部分得到了国家自然科学基金委员会 62136007 的资助,部分得到了广东省基础与应用基础研究基金 2021B1515020072 的资助,部分得到了广东省基本科研业务费专项资金的支持。中央大学。(通讯作者:龚诚。)

作者单位:西北工业大学自动化学院,中国西安 710129;西北工业大学深圳研究院,中国深圳 518057 (e-mail:gheng@nwpu.教育网)。

数字对象标识符 10.1109/TGRS.2022.3174276

1558-0644 © 2022 IEEE。允许个人使用,但重新发布/重新分发需要 IEEE 许可。
有关更多信息,请参阅 <https://www.ieee.org/publications/rights/index.html>。

授权许可使用仅限于:浙江工业大学。于 2023 年 10 月 20 日 04:21:49 UTC 从 IEEE Xplore 下载。存在限制。

状况。图像配准和辐射校正是消除几何和辐射因素负面影响不可或缺的图像预处理程序[4]。

传统的变化检测方法与基本分析单元相关,即从独立图像像素到涉及上下文信息的分割对象[5]-[7]。

大多数基于像素的方法都以无监督的方式工作[8]。首先,通过简单的算术运算 (例如,图像差分 and 图像配给)、简单的变换 (例如,变化矢量分析和主成分分析)或两者的组合来生成差异图像[9]。然后,通过对差异图像进行阈值处理或聚类分析来获得感兴趣的变化图[10]、[11]。分类后比较范式的兴起使得能够对大量可用数据进行监督学习[9]、[12]、[13]。虽然基于像素的方法独立地利用光谱信息,但基于对象的方法的出现是为了通过利用分割对象中的空间上下文来应对极高分辨率 (VHR)遥感图像中的光谱变化[1]。

然而,经典的基于对象的方法的性能仍然受到以下因素的严重限制:1)通常手工制作的阴影特征编码的变化不足;2)从对象分割到变化检测的错误累积问题[14],[15]。总体而言,传统的变化检测方法很难检测日益高分辨率的遥感图像中的变化。

深度学习的最新进展已经扩散到遥感图像变化检测领域。卷积神经网络 (CNN),例如ResNet系列[16]和UNet系列[17],通常被用作骨干网络来帮助从双时态遥感图像中提取判别性层次特征[18]、[19]。基于深度学习的变化检测方法的一个主要区别是“早期融合”与“后期融合”[20]。实现早期融合的方法在图像级别 (即网络输入)集成双时态信息。例如,郑等人。[21]沿着通道维度堆叠双时图像,并提出了一种跨层 CNN 来合并多尺度特征和多级上下文。相比之下,实现后期融合的方法在特征级别集成双时态信息。

一般来说,份额加权 (又名基于 Siamese 的)主干网络首先用于单独提取双时态特征。然后对提取的特征进行处理和融合以进行下游决策。张等人。[22]遵循该方案,提出了一种深度监督的图像融合网络来处理 VHR图像的复杂性。我们的

提出的变化检测方法也符合该方案。

长期以来的加强变化信息和抑制不变信息的思想[23]也适用于当前基于深度学习的方法。

注意力机制作为技术载体[24]。

近年来,已经出现了各种由注意力机制支持的方法,用于增强深度学习特征的可分离性[25]-[31]。仅举几例,刘等人。 [25] 和施等人。 [26]使用卷积块注意力模块[32]组合通道注意力 (CA)和空间注意力 (SA)来优化层次特征。

陈等人。 [27] 修改了视觉变换器 [33],它传递自我注意力以细化基于 CNN 的主干最后一层产生的特征。上述方法独立处理双时态特征,并在特征细化的最后进行双时态特征融合。为了尊重特征级时间相关性[9],我们提出的方法逐步处理和融合双时态特征。

多光谱成像的发展使得VHR遥感图像可以方便地获取,它包含丰富的空间细节,可以精细地描述纹理、形状等[3],[4]。然而,VHR 图像中有限的光谱信息带来了较低的类间变异 (和较高的类内变异)[4],因此给变化检测带来了巨大的挑战。另一方面,在传统骨干网络 (例如ResNet系列和UNet系列)中使用普通卷积会产生规则的接收场。由于数据特性和网络特性,特征提取过程中详细信息的丢失会导致层次特征之间不同语义之间的界限模糊。因此,围绕变化边界的预测将是令人难以置信的,并且会引发大量的误报。方等人。 [31]强调了与大量空间细节相关的高分辨率低级特征的重要性,并提出了用于深度监督的集成CA。然而,无论是否使用低级特征或注意机制,变化边界都没有受到直接限制。在本文中,我们建议策略性地细化提取的层次特征以缓解该问题。在特征细化过程中,我们进行边缘最大化,直接约束变化边界,以澄清每个阶段产生的双时态特征中变化和未变化语义之间的差距。

为了促进这一目标,我们提出了一种有针对性的注意机制安排,以指导使用 CA 和 SA 分别突出语义和位置信息。

我们设计了一种自上而下的融合路径,使得最终的细化特征涵盖多尺度表示,并且对于遥感图像变化检测具有很强的可分离性。

通过上述策略和精心的架构设计,我们提出了可提供改进的可分离性的深度学习网络 (ISNet) 。

我们的贡献总结如下。

1)为了解决不同语义之间的模糊界限,我们提出了一种边距最大化策略来澄清




图 1. 残差块的图示。

双时态特征层次结构的每个级别上已更改和未更改的语义之间的差距。

2)我们采用有针对性的注意力机制安排来促进最终结果。具体来说,我们分别利用 CA 来促进特定于语义的特征提取,并利用 SA 来增强特征细化。我们证明,这种有针对性的安排允许适当使用几个即插即用的注意模块来改善变化检测结果。

3)我们提出深度学习网络,通过结合上述两种策略和复杂的架构来提供改进的可分离性 (ISNet) 。借助 ResNet 系列主干,我们的 ISNet 在遥感图像变化检测的三个公共数据集上实现了最先进的性能。此外,我们还表明,配备我们的战略和架构设计的一组轻量级骨干网的性能可以接受。

本文其余部分的结构如下。第二节

简单介绍了残差网络 (ResNets)和注意力机制的一些初步知识。第三节详细描述了我们的算法设计。第四节提供实验评估。第五节总结了本文。

二. 预赛

A. 残差网络

ResNets[16]的整体架构是通过堆叠残差块构建的。残差块的一次前向传递通常对应于一次性下采样,因此被称为阶段。一个残差块由两个残差单元组成,每个残差单元有两个卷积层和一个跳跃连接,如图1所示。具体来说,第一个残差单元中第一个卷积层的步长和第一个跳过连接是可选的。

当两个步长设置为1时,输入特征图会跳过skip连接中的卷积操作,并且它们的大小在经过残差块后将保持不变。

事实上,下采样是通过将它们设置为 2 来实现的。

模型缩放衍生出一系列具有相似架构设计但深度或宽度不同的ResNet模型 (包括ResNet变体),例如ResNet-18/34/50、ResNeXt-50_32 × 4d [34]和Wide_ResNet-50_2 [35]]。本文转用在ImageNet上预训练的ResNet系列模型作为特征提取的骨干网络。

B. 注意力机制

注意力机制可显著提高深度学习的性能和可解释性




图 2. (a)–(c) T1 实例、T2 实例和相应标签的插图。(d)–(f) T1 实例的特征可视化，T2 实例，以及在第 1 阶段生成的边距最大化后的特征（MM 特征）。(g)–(i) T1 实例特征的可视化，即特征 T2 实例的特征，以及在第 2 阶段生成的边距最大化后的特征。这些特征是从训练有素的模型中获得的。为了可视化，我们采用主成分分析并保留三个波段。

架构[36]。在计算机视觉和远程领域感知、CA、SA 和自注意力在算法中占主导地位设计。CA 允许深度学习模型学习什么应强调语义[37]。它强调具体通过学习每个通道的不同权重来识别特征图中的通道频道[29]。SA 使深度学习模型能够区分应突出显示的空间位置[37]。它通过学习强调特征图中的特定空间位置

每个空间位置的权重不同[29]。自我关注学习反映每个空间之间相关性的权重特征图中的元素来捕获远程依赖性[33]，[37]–[39]。考虑到应用自注意力

会带来大量的计算负担，我们限制我们注意在此方面正确使用 CA 和 SA 文章。

三.具有改进的可分离性的变化检测

我们通过阐述以下问题来开始本节双时态遥感图像变化检测。然后，我们详细阐述我们的战略和架构设计考虑双时态图像特征。最后，我们提出了用于训练整个模型的损失函数框架。

A. 问题陈述

双时态遥感图像变化检测分析记录相同内容的一对遥感图像

不同时间T1和T2的地理区域。设IT1 ⊂ R3×H×W、IT2 ⊂ R3×H×W和Y ⊂ RH×W为域T1实例的数量[例如，T1图像中不重叠的补丁；参见图 2(a)]，T2 实例 [例如，T2图像；参见图2(b)]，以及它们的二进制变化标签[参见分别如图2(c)]。H和W是实例高度，宽度。形式上，变化检测的任务旨在学习映射如下：

$$\{IT1, IT2\} \rightarrow Y。$$
 (1)

在本文中，我们格式化了变革的算法管道检测作为三个关键部分的顺序组合。步骤 i（特征提取）：份额加权主干网络将 T1 实例和 T2 实例转换为多级

分层特征分别为{ fff T1}和{ fff T2₁¹，在这里，这些 f₁¹，f₂¹，f₃¹，f₄¹，f₁²，f₂²，f₃²，f₄²来自不同阶段的层次特征份额加权骨干网络。

步骤 ii（特征细化）：对双时态特征层次进行策略性处理和融合，呈现最终结果

涵盖多尺度表示的精炼特征fRefined。步骤 iii（决策）：两级（即“改变”）在fRefined上运行的分类与“未更改”相比，完成了 (1) 中呈现的映射。我们遵循这个公式并提出深度学习网络，以提供改进的

与 ResNet 系列主干的可分离性（ISNet），如图所示如图 3 所示。

B. 策略 (i):利润最大化

遥感影像的分辨率越来越高其特点是空间细节丰富，但光谱信息有限，导致类间变异较低。在传统的骨干网络中，使用普通卷积

产生常规的接收场。然而，改变了对象在遥感图像中，通常是定向的并且具有不规则形状。在这种情况下，丢失详细信息特征提取过程中的信息往往会变得模糊层次结构中不同语义之间的边界特征。我们可以从图 2 中得到该问题的直观说明，其中 (d)、(e)、(g)和 (h)可视觉化 T1 实例在阶段 1 的特征，T2 实例在阶段 1 的特征阶段 1、阶段 2 的 T1 实例和阶段 2 的 T2 实例，分别。

缓解问题并改进更改/不变的可分离性，我们建议最大化边距，即澄清更改和更改之间的差距通过策略性特征细化保持语义不变[见图2(f)和(i)]。我们认为这是违反直觉的忽略双时态之间固有的时间相关性每个阶段产生的层次特征。因此，我们引入了边际最大化模块来对特征对进行操作

$$(f_{T1}^1, F_{T2}^1), (f_{T1}^2, f_{T2}^2), (f_{T1}^3, F_{T2}^3), \text{ 和 } (f_{T1}^4, f_{T2}^4)。$$

4说明了边际最大化的细节模块。我们让每个特征对 {(ff T2), i = 1, 2, 3; f_i⁴} 通过边际最大化和阶段级融合。可变形卷积层[40]、[41]学习澄清改变和未改变的语义之间的差距，给定携带改变的语义和学习到的 T2 特征 T1 特征的串联卷积的偏移量和 T2 功能。受到黄等人的启发。[41]，傅等。[42]，徐等人。[43]和王等人。[44]，我们传播 T1 使用远程跳过连接和串联的功能与边距最大化后的特征（MM特征）完成阶段级融合。我们凭经验发现，以这种方式表现良好。

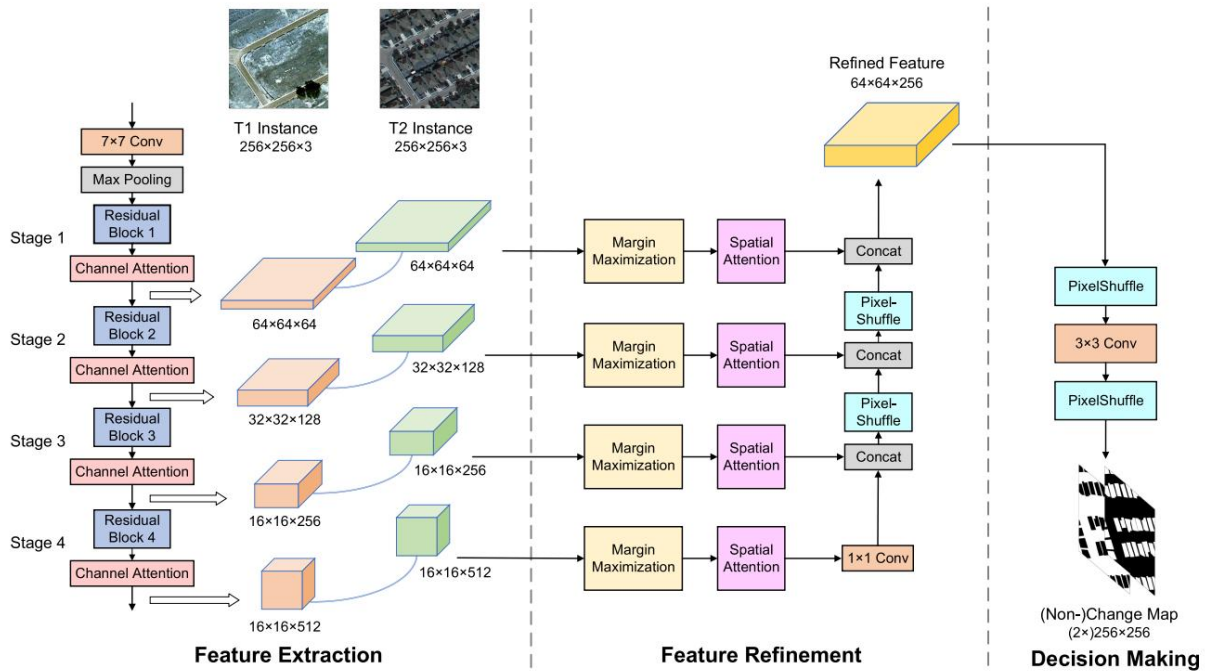


图 3. 提议的 ISNet 概述。特征提取: 双时态实例 (即 T1 实例和 T2 实例) 共享相同的 ResNet 系列主干并导出各自的层次特征。CA 模块被插入到每个阶段以促进特定于语义的特征提取。特征细化: 自上而下的融合路径在双时态特征层次结构上运行, 以创建覆盖不同尺度的紧凑的细化特征。两种类型的模块有助于每个阶段的细化。边缘最大化模块澄清了变化的语义和未变化的语义之间的差距, 并实现了阶段级双时态特征融合。然后, SA 模块突出显示阶段级融合特征中的位置变化响应。我们使用 PixelShuffle 来实现自顶向下融合过程中的上采样。决策: 由两个 PixelShuffle 操作和一个卷积层组成的简单分类器接收细化特征作为输入, 并将其转换为不变图和感兴趣的变化图。




图 4. 利润最大化模块的图示。

下面我们正式分析为什么可变形卷积可以作为边缘最大化函数。令 $\forall (i, j), i \in \{-1, 0, 1\}, j \in \{-1, 0, 1\}$ 枚举一个规则的 3×3 网格, 它位于特征图中的 patch x 之下。令 w 为要学习的权重。简单卷积中的计算采用以下形式:

$$\text{转换 } x(0,0) = w(i,j) \times x(i,j), \quad \forall (i,j) \quad (2)$$

在可变形卷积中, 为每个索引 (i, j) 引入水平偏移 i 和垂直偏移 j 。计算采用以下形式:

$$\text{Deformable_Conv } x(0,0) = \sum_{\forall (i,j)} w(i,j) \times x(i+j, j+j). \quad (3)$$

$\forall (i+j, j+j), i \in \{-1, 0, 1\}, j \in \{-1, 0, 1\}$ 确定一个非刚性多边形, 该多边形打乱接收场先前的规则形状。这使得学习能够将变化的语义的边界与不同的语义相匹配。

方向和不规则形状。变化和未变化响应在学习过程中逐渐彼此不同, 从而很大程度上消除了变化边界周围的模糊性。换句话说, 改变和未改变的语义之间的差距被扩大和澄清。通过这种与变化边界相关的直接细化, 双时态层次特征的可分离性因此得到提高。

C. 策略 (二): 注意力机制的针对性安排

由于双时态实例共享主干网络, 它们不同的外观不可避免地使特征提取复杂化。由此产生的无与伦比的语义和位置信息将使特征级别的边界变得令人难以置信。

我们建议以注意力机制的使用为目标, 以协助利润最大化。我们重新审视 CA 和 SA 的功能, 以及特征提取和特征细化的作用。不失一般性, 我们从 [32] 中的卷积块注意力模块中分解出 CA 和 SA, 并将它们分别安排在特征提取和特征细化中。通过实验评估, 我们进一步证明其他现成的即插即用注意力模块也以这种方式工作。

1) 特征提取中的通道注意力: 在大多数遥感应用中, 变化是特定于语义的, 例如, 土地管理中的新建建筑物。对 CA 的深入洞察在于, 它突出了对特定语义的响应




图 5.CA 模块图示。




图 6.SA 模块图示。

改进特定语义的表示[45]。深度学习模型中的特征提取正是表示学习的过程[46]。根据这一协议,我们将 CA 模块插入到份额加权骨干网络中,以促进特定于语义的特征提取。

图5说明了CA模块的图[32]。权重函数由一个最大池化层、一个平均池化层、两个 1×1 卷积层和一个 Sigmoid 激活层组成。两个池化层是空间层面的,通过挤压空间维度将输入的 3D 特征映射重塑为 1D 向量。导出的两个向量分支共享两个 1×1 卷积层,其中包含完全可调的参数。逐点求和整合了学习到的两个分支权重,然后通过最终的 Sigmoid 激活进行标准化。将学习到的权重分配给原始特征图的通道,并进行乘法运算。

2)特征细化中的空间注意力:位置信息对于变化检测非常重要,变化检测基于双时态输入获得预测。双时态特征的位置强调应该完全匹配。另一方面,特征细化旨在联合处理提取的双时特征,以增强其可分离性,以利于最终的空间决策。因此,我们在特征细化过程中将SA模块放在边缘最大化模块后面,以强调阶段级融合特征的位置变化响应。

图6说明了SA模块的图[32]。加权函数由最大池化层、平均池化层、串联操作、 3×3 卷积层和 Sigmoid 激活层组成。它与CA的加权函数有两侧不同。首先,两个池化层是通道式的,通过挤压通道维度将输入 3D 特征映射重塑为 2D 矩阵。其次,将学习到的权重相应地分配给原始特征图的空间元素,并进行乘法。

D. 建筑设计

我们提出了由上述两种策略增强的 ISNet,如图 3 所示。我们的 ISNet 的整体架构包括: 1)用于特征的份额加权骨干网络

表一
轻量级主干架构。
“BN”表示批量归一化

Index	Filter	Stride	Padding	BN	Activation
Layer 1	3×3 Conv, $N/8$	2	1	Yes	Hardswish
Layer 2	3×3 Conv, $N/4$	2	1	Yes	Hardswish
Layer 3	3×3 Conv, $N/2$	2	1	Yes	Hardswish
Layer 4	3×3 Conv, N	2	1	Yes	Hardswish

萃取; 2)用于特征细化的自上而下的融合路径; 3)用于决策的简单分类器。

1)用于特征提取的骨干网络:我们选择在 ImageNet 上预训练的 ResNet 作为 ISNet 中的骨干网络,以在给定双时实例的情况下导出双时分层特征。使用的 ResNet 系列主干有四个残差块。CA 模块被插入到每个阶段中,以促进特定于语义的特征提取(参见图 3 最左边的插图)。在我们的 ISNet 中,我们将前三个残差块中的两个步幅设置为 2,将最后一个残差块中的步幅设置为 1。这为最后两个阶段产生的双时特征提供了相同的空间大小,避免了高级特征太小了。

此外,我们引入了一组轻量级骨干网络,可以极其有效地提取特征。我们的直觉是利用 ImageNet 预训练的有效性来减少主干网络中的大量参数。为此,我们构建了与 LeViT [39] 中的卷积部分相同的轻量级主干架构。如表一所示,只有四个卷积层执行连续下采样。

改变过滤器的基本数量N (即最后一层中的过滤器数量),遵循 LeViT $N \in \{128, 192, 256, 384\}$,产生一组轻量级主干网。为了避免混淆,我们将配备这些轻量级主干的模型称为 ISNet-lw。

2)用于特征细化的自上而下的融合路径:我们设计了一种自上而下的融合路径来战略性地、渐进地处理和融合双边层次特征(参见图3 (中)的说明)。由于不同阶段的特征图通常具有不同的空间分辨率,因此它们表现出固有的多尺度表示[47],[48]。对于每个阶段产生的双时态层次特征,边际最大化模块澄清了变化语义和未变化语义之间的差距,并实现了相应尺度的阶段级融合。下面,SA 模块重点介绍了融合双时态特征中的位置变化响应。为了融合不同阶段之间的多尺度特征,我们采用 PixelShuffle [49] 来实现上采样和简单的通道级联来堆叠跨阶段特征。回想一下,最后两个特征图具有相同的空间大小。

我们只是使用 1×1 卷积来减少通道数。下游 PixelShuffle 操作重新排列特征图中的元素[49],同时执行上采样并减少通道数量。经过多尺度特征融合,最终的细化特征fRefined覆盖了多尺度表示,对于双时态变化检测具有很强的可分离性。

3)决策分类器:我们将最终决策分为两类（即“已更改”与“未更改”）分类。我们设计了一个极其简单的分类器来执行此任务（参见图 3（右）的说明）。两个 PixelShuffle 操作将细化特征的空间尺寸扩展到标签的空间尺寸，即H × W。

我们在两个 PixelShuffle 操作之间放置一个卷积层。我们的主要目标是通过参数化层调整通道数量。分类器将输入的细化特征转换为非变化图和感兴趣的变化图,完成变化检测的流程。

E. 损失函数

已更改像素和未更改像素之间的数据不平衡往往会导致分类偏差（通常朝向“未更改”）[50]。为了缓解这个问题,我们选择交叉熵损失和骰子损失 [51]的组合作为最小化的目标。

令 $y \in Y$ 为一对实例的标签,并令 $y(i, j)$ 索引标签 y 中元素的坐标。每个元素指示其相应的成像视野是否发生变化。如果发生变化,则表示 $y(i, j) = 1$,否则表示 $y(i, j) = 0$ 。交叉熵损失 L_{ce} 和骰子损失 L_{dice} 的形式如下:

1

H

在

高×宽

我=1

j=1

$y(i, j) \log y(i, j)$

$+ 1 - y(i, j) \log 1 - y(i, j)$

Lce = -

(4)

其中 y 表示一对实例的预测

1

在

HI=1

$y(i, j) \times y(i, j) \times 2$

高×宽

1 -

HI=1

$W_j = 1y(i, j) + y(i, j) +$

骰子=

(5)

其中 ϵ 是一个小常数（默认为 $1e-7$ ）,避免被零除。

我们的完整损失函数 L_{full} 是

$L_{full} = L_{ce} + \lambda L_{dice}$

(6)

其中 λ 控制两个损失的相对重要性,在本文中设置为1。

四.实验

A. 数据集

我们对由 VHR 图像组成的三个公共变化检测数据集进行了严格的比较: LEVIR-CD 数据集 [27],SYSU-CD 数据集 [26] 和 Season-Varying 变化检测数据集 [52]。我们对 LEVIR-CD 数据集进行了广泛的消融研究。 LEVIR-CD 数据集是特定于语义的,适用于检测建筑物的变化。它包含从 Google Earth 收集的 637 对带标签的双时态图像块。每个实例/标签的原始大小是 1024×1024 。为了符合最先进的变化检测方法常用的输入大小,我们裁剪每个实例/标签

表二
与LEVIR-CD数据集上最先进的方法进行比较。带上标的方法*显示原始文章中报告的结果

Method/Metric (%)	precision	recall	OA	IoU	F1
FC-Siam-conc [53]	90.76	58.95	97.60	55.61	71.47
FC-Siam-diff [53]	91.97	57.84	97.60	55.06	71.02
IFN [22]	86.95	75.24	98.16	67.61	80.67
SNUNet [31]	91.80	88.53	99.01	82.04	90.14
DSAMNet [26]	80.61	88.98	98.35	73.29	84.59
BIT* [27]	89.24	89.37	98.92	80.68	89.31
CLNet [21]	90.07	85.70	98.79	78.30	87.83
ISNet (ours)	92.46	88.27	99.04	82.35	90.32

表三
与SYSU-CD数据集上最先进的方法的比较。带上标的方法*显示原始文章中报告的结果

Method/Metric (%)	precision	recall	OA	IoU	F1
FC-Siam-conc [53]	81.33	66.40	88.48	57.62	73.11
FC-Siam-diff [53]	90.18	48.28	86.56	45.87	62.89
IFN [22]	82.39	73.57	90.06	63.57	77.73
SNUNet [31]	78.41	73.38	88.96	61.05	75.81
DSAMNet* [26]	74.81	81.86	-	64.18	78.18
BIT [27]	79.18	77.01	89.80	64.04	78.08
CLNet [21]	79.62	74.97	89.57	62.90	77.22
ISNet (ours)	80.27	76.41	90.01	64.44	78.29

1024×1024 个实例/标签到 $16\ 256 \times 256$ 个实例/标签。因此,分别有 7120/1024/2048 对实例和相应的标签用于训练/验证/测试。 SYSU-CD 数据集对于一般变化检测来说是一个具有挑战性的数据集。它包含 20 000 对尺寸为 256×256 的带标签的双时图像块。分别有 12 000/4000/4000 对实例和相应的标签用于训练/验证/测试。季节变化数据集也适用于一般变化检测。它包含 15 998 对双时态实例,这些实例表现出由季节因素和相关标签引起的不同外观。每个实例/标签的大小是

256×256 。分别有 10 000/2998/3000 对实例和相应的标签用于训练/验证/测试。

B. 实施细节

我们使用 Python 结合 PyTorch 库来实现我们提出的变更检测方法。我们使用在 ImageNet 上预训练的权重来初始化主干网络,并使用正常初始化来初始化剩余层。

除非另有说明,我们使用 ResNet-18 作为骨干网络。初始学习率设置为 0.0001。对于 LEVIR-CD 数据集,默认批量大小为 16。常规历元数为 200,衰减历元数为 100。

对于 SYSU-CD 数据集,默认批量大小为 8。常规历元数为 50,衰减历元数

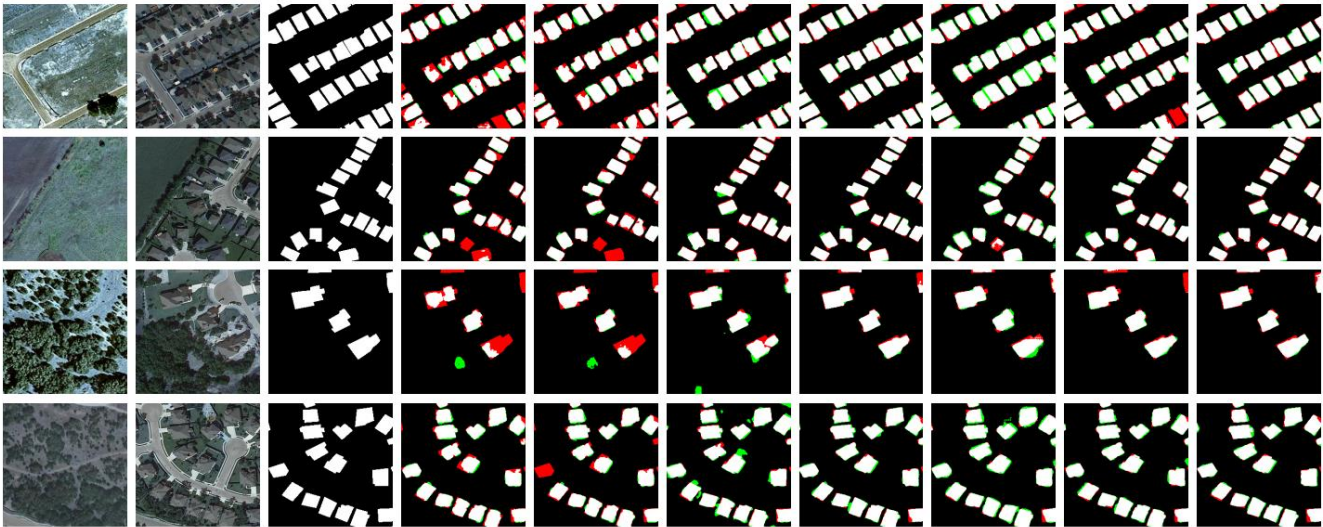


图 7. LEVIR-CD 数据集的定性比较。从 (左)到 (右) :T1实例、T2实例、标签、FC-Siam-conc [53]、FC-Siam-diff [53]、IFN [22]、SNUNet [31]、DSAMNet [26]的预测、CLNet [21] 和我们的 ISNet。颜色:TP 为白色 (即“已更改”),TN 为黑色 (即“未更改”),红色代表 FP,绿色代表 FN。




图 8. SYSU-CD 数据集的定性比较。从 (左)到 (右) :T1 实例、T2 实例、标签、FC-Siam-conc [53] 的预测、FC-Siam-diff [53]、IFN [22]、SNUNet [31]、BIT [27]、CLNet [21] 和我们的 ISNet。颜色:TP 为白色 (即“已更改”),TN 为黑色 (即“未更改”),红色代表 FP,绿色代表 FN。

是 50。对于季节变化变化检测数据集，默认批量大小为 8。常规 epoch 数量为 50 衰减纪元为 150。我们使用随机水平翻转、随机垂直翻转、随机裁剪和

随机模糊以实现训练数据增强数据。我们使用 Adam 优化器并设置 $\beta_1 = 0.5$ 并且 $\beta_2 = 0.999$ 。所有实验均在 TITAN 上进行 X GPU。我们的源代码和经过训练的模型可在以下位置获取：
<https://github.com/xingronaldo/ISNet>。

C. 评估指标

我们采用五个通用指标进行定量评估:精确度、召回率、总体准确度 (OA)、交集交集 (IoU)和 F1 分数。我们报告以下方面的结果

两级分类 “变”了。这些指标可以是

表四
与最先进的方法的比较
随季节变化的数据集。带上标的方法_ *呈现原始文章中报告的结果

Method/Metric(%)	precision	recall	OA	IoU	F1
FC-Siam-conc [53]	77.31	49.43	92.32	43.17	60.31
FC-Siam-diff [53]	80.80	51.16	92.80	45.62	62.65
IFN [22]	97.15	91.70	98.70	89.29	94.34
SNUNet [31]	94.82	92.45	98.51	88.00	93.62
DSAMNet* [26]	94.54	92.77	-	88.13	93.69
BIT [27]	95.31	87.31	98.00	83.71	91.13
CLNet [21]	93.30	89.80	98.03	84.36	91.52
ISNet (ours)	95.18	94.43	98.78	90.12	94.80

由以下组合计算得出
真阳性 (TP)、假阳性 (FP)、假阳性的数量




图 9. 季节性变化数据集的定性比较。从 (左) 到 (右) :T1 实例、T2 实例、标签、FC-Siam-conc [53] 的预测、FC-Siam-diff [53]、IFN [22]、SNUNet [31]、BIT [27]、CLNet [21] 和我们的 ISNet。颜色:TP 为白色 (即“已更改”) ,TN 为黑色 (即“未更改”) ,红色代表 FP,绿色代表 FN。

表五
轻量级主干在LEVIR -CD、SYSU-CD和随季节变化的数据集上的性能

Dataset	LEVIR-CD					SYSU-CD					Season-Varying				
Model_N/Metric(%)	precision	recall	OA	IoU	F1	precision	recall	OA	IoU	F1	precision	recall	OA	IoU	F1
ISNet-lw_128	90.07	80.73	98.57	74.13	85.14	79.87	71.76	89.07	60.77	76.00	90.56	84.11	97.09	77.33	87.22
ISNet-lw_192	89.28	84.72	98.70	76.90	86.94	79.76	73.23	89.30	61.75	76.35	91.95	84.14	97.26	78.37	87.87
ISNet-lw_256	89.41	86.01	98.77	78.06	87.68	79.24	73.52	89.21	61.65	76.28	92.14	86.56	97.54	80.61	89.26
ISNet-lw_384	90.24	85.40	98.78	78.18	87.75	78.42	74.31	89.12	61.59	76.31	93.44	88.13	97.87	82.99	90.70

阴性 (FN) 和真阴性 (TN)

精度=
$$\frac{\text{城市}}{\text{TP}+\text{FP}}$$

回忆=
$$\frac{\text{城市}}{\text{TP}+\text{FN}}$$

OA =
$$\frac{\text{TP}+\text{TN}}{\text{TP}+\text{FP}+\text{FN}+\text{TN}}$$

借条=
$$\frac{\text{城市}}{\text{TP}+\text{FP}+\text{FN}}$$

F1=
$$\frac{2\text{TP}}{2\text{TP}+\text{FP}+\text{FN}}.$$

- (7) 在Season-Varianing上取得第二高的表现，它在 LEVIR-CD 上输给了 ISNet 近 10%。
- (8) 无花果。7-9 可视化定性比较
分别是 LEVIR-CD、SYSU-CD 和季节变化测试集。选择四对测试实例来举例说明每个数据集。很明显，大多数误报
- (9) 高性能方法分布在变化边界周围。我们的 ISNet 提供的错误预测明显减少
- (10) 在这些场景中与其他方法进行比较。尤其，我们的 ISNet 产生了少量的 FN,这要归功于使用
- (11) 用于消除歧义的边际最大化模块
围绕变化边界。

D. 与最先进方法的比较

我们选择了七种最先进的方法进行比较 :FC-Siam-conc [53]、FC-Siam-diff [53]、IFN [22]、SNUNet [31]、DSAMNet [26]、BIT [27] 和 CLNet [21]。

表 II-IV 给出了定量比较
分别是 LEVIR-CD、SYSU-CD 和季节变化测试集。可以发现,我们的 ISNet 在 LEVIR-CD 和 Season-Varying 上明显优于其他方法。

OA、IoU 和 F1 分数。我们的 ISNet 还实现了
SYSU-CD 上的整体最佳性能。我们的 ISNet 节目
对不同数据集的鲁棒性。 SNUNet 是一个比较强的
LEVIR-CD 和 Season-Variant 的竞争对手。然而,其
SYSU-CD 上的性能似乎没有竞争力。而干扰素

E. 轻量级骨干网的性能

我们继续评估我们提出的轻量化方案
模型,即ISNet-lw。表V报告了具有不同基本数量的滤波器的ISNet-lw的整体性能

N,关于 LEVIR-CD、SYSU-CD 和季节变化测试
套。结果大体上是可以接受的,即使对于
具有季节性干扰的季节变化数据集。

此外,我们直观地比较了主要组成部分的参数数量和三个方面的F1分数

图 10 中 ISNet-lw 和 ISNet 之间的数据集。它揭示了
ISNet 在以下方面大幅超过 ISNet-lw
主干网络和边际最大化 (MM)模块的参数,但没有击败 ISNet-lw 太多

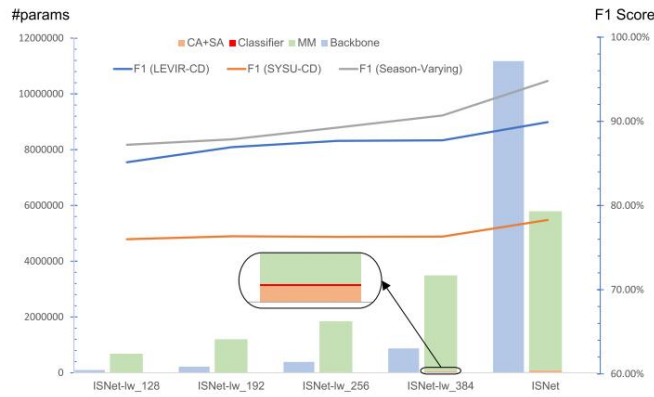


图 10 ISNet-lw 和 ISNet 主要构成部分的参数数量 (左列)以及 LEVR-CD,SYSU-CD 和 Season-Varying 数据集 (右列)的 F1 分数比较。

在性能方面,同时,CA模块加上SA模块和分类器的参数几乎可以忽略不计。我们发现边缘最大化模块在 ISNet-lw 中主导了参数数量,并且骨干网络在 ISNet 中引入了更多的参数。

ISNet 和 ISNet-lw 之间的性能提升凸显了利用先进的深度学习产品对遥感图像变化检测进行有效特征提取的重要性。考虑到不同部分的参数数量,ISNet-lw 的可接受结果也表明特征细化在改善变化检测结果方面具有很大的权重。

F. 消融研究

在这一部分中,我们在 LEVR-CD 数据集上对 ISNet 进行了广泛的消融研究。我们稍微更改了默认设置,以应对因替换某些组成部分而可能增加的计算负担。在所有消融研究中,批量大小减小至 8。常规历元和衰减历元分别调整为 50 和 150。

1)利润最大化和注意力机制有针对性的安排的效果:表六评估了我们提出的两种策略的有效性,即利润最大化 (MM)和注意力机制的有针对性的安排 (CA和SA)。具体来说,删除 MM 会导致性能下降最显着,删除 SA 其次,删除 CA 最后。我们的结论是,MM 的使用在理论上和经验上都是合理的。尽管 MM 导出了大部分参数,但我们认为参数的数量并不能解释这一事实。MM/SA/CA的参数比确实是 79163:1:1209。令人惊讶的是,仅仅去除 MM 后的性能甚至比去除所有三种类型模块后的性能还要差。我们推测这反映了两种策略的协同效应。具体来说,CA,MM,SA 在各个阶段可以看作是依次作用的。准确的语义强调有利于忠实的边距最大化,并进一步使位置强调变得明智。

2) PixelShuffle 对上采样的效果:表 VII 将 PixelShuffle 与双三次插值、双线性插值和反卷积对上采样特征图进行了比较。

表六

利润最大化的效果和目标 关注机制的安排							
MM	CA	SA	precision	recall	OA	IoU	F1
✓	✓	✓	91.74	88.26	99.00	81.67	89.97
×	✓	✓	87.92	88.87	98.81	79.20	88.39
✓	×	✓	91.00	88.31	98.96	81.22	89.64
✓	✓	×	89.93	87.82	98.88	79.96	88.86
×	×	×	90.19	87.13	98.86	79.59	88.63

表七

PixelShuffle 对上采样的影响						
Method	Δparams	precision	recall	OA	IoU	F1
PixelShuffle	-	91.74	88.26	99.00	81.67	89.97
bicubic	+0.34M	91.01	88.06	98.95	81.01	89.51
bilinear	+0.34M	90.88	88.33	98.95	81.13	89.58
deconvolution	+5.51M	90.70	88.49	98.95	81.13	89.58

表八

不同Resnet系列主干的影响						
Backbone	Δparams	precision	recall	OA	IoU	F1
ResNet-18	-	91.74	88.26	99.00	81.67	89.97
ResNet-34	+10.11M	91.19	87.87	98.95	80.99	89.50
ResNet-50	+86.24M	90.92	89.80	99.02	82.41	90.36
ResNeXt-50_32x4d [34]	+85.71M	91.38	90.07	99.06	83.01	90.72
Wide_ResNet-50_2 [35]	+129.56M	91.06	90.06	99.04	82.75	90.56

我们在特征细化和决策过程中使用上述上采样方法替换所有 PixelShuffle 操作。为了确保其他层和操作保持不变,我们在插值操作之后使用额外的 1×1 卷积层来专门调整通道。在参数最少的情况下,使用 PixelShuffle 的 ISNet 获得了最好的性能。

3)不同ResNet系列主干的影响:表VII列出了不同ResNet系列主干的影响。我们实现了 ResNet-34,ResNet-50,ResNeXt-50_32 \times 4d [34] 和 Wide_ResNet-50_2 [35] 来替代默认的 ResNet-18。与 ResNet-18 中的残差块相比,这些主干网中的残差块要么加深,要么加宽,因此引入了相当大的计算负担。具体来说,除了 ResNet-34 之外,这些升级后的主干网络在参数方面带来了超过 8500 万的增量。他们增强的学习能力带来了显着的绩效提升。由于参数增加相对较少,ResNet-34 并没有比 ResNet-18 带来性能提升。这意味着 ResNet-18 成功地充当了一个不错的骨干网络。此外,我们推测特征提取中相对少量的参数增加并不能决定最终的结果,因为

特征细化的发明。

4)不同通道和空间注意力模块的影响:表IX评估了不同即插即用CA模块 (CA [32],ECA [54],SE [55]和CAM [56])和SA模块的影响 (SA [32],DA [57],SSE [58] 和 PAM [56])。结果表明,这些现成的

表九
不同CA和SA模块的影响

Channel-wise	Spatial-wise	precision	recall	OA	IoU	F1
CA [32]	SA [32]	91.74	88.26	99.00	81.67	89.97
CA [32]	DA [57]	93.00	87.25	99.02	81.87	90.03
ECA [54]	SA [32]	91.00	88.58	98.98	81.52	89.82
SE [55]	SA [32]	91.15	88.50	98.98	81.49	89.80
SE [55], [58]	SSE [58]	90.76	88.94	98.98	81.56	89.94
CAM [56]	PAM [56]	90.19	87.23	98.87	79.67	88.68

表十
不同批量大小的影响

Batch Size	precision	recall	OA	IoU	F1
8	91.74	88.26	99.00	81.67	89.97
16	91.97	87.95	99.00	81.67	89.91
24	89.03	89.39	98.89	80.52	89.21
32	88.00	90.16	98.87	80.29	89.07
40	87.09	89.33	98.77	78.88	88.19

在我们的有针对性的安排下,注意力同样有效。使用 {CAM, PAM} 是唯一“失败”的情况。

5)不同批量大小的影响:表X报告了不同批量大小{8,16,24,32,40}的影响。当其他设置保持默认时,batch size 8和batch size 16带来了可比的顶级性能。有趣的是,批量大小的进一步增加反而会导致性能下降。这表明仅仅为了训练 ISNet 而增加批量大小并不一定会带来性能提升。

五. 结论

本文研究了遥感图像变化检测的战略和架构设计。我们研究了层次特征之间不同语义之间界限模糊的问题。我们提出了深度学习网络,它提供了改进的可分离性 (ISNet),配备了两种策略 (即边缘最大化和注意力机制的有针对性的安排)和精心设计的架构的组合。我们的 ISNet 在三个公共数据集上实现了最先进的性能。此外,我们表明,双时态分层特征的有效细化对于准确的变化检测很重要。

参考

[1] M. Hussain,D. Chen,A. Cheng,H. Wei 和 D. Stanley,“遥感图像的变化检测:从基于像素的方法到基于对象的方法”,ISPRS J. Photogramm.遥感,卷。 80,第 91-106 页,2013 年 6 月。

[2] S. Liu,D. Marinelli,L. Bruzzone 和 F. Bovolo,“多时相高光谱图像变化检测综述:当前技术、应用和挑战”,IEEE Geosci.遥感杂志,卷。 7,没有。 2,第 140–158 页,2019 年 6 月。

[3] D. Wen等人,“极高分辨率光学遥感图像的变化检测:方法、应用和未来方向”,IEEE 地球科学.遥感杂志,卷。 9,不。 4,第 68-101 页,2021 年 12 月。

[4] Z. Lv,T. Liu,JA Benediktsson 和 N. Falco,“土地覆盖变化检测技术:超高分辨率光学图像:综述”,IEEE 地球科学.遥感杂志,卷。 10,不。 1,第 44-63 页,2022 年 3 月。

[5] AP Tewkesbury,AJ Comber,NJ Tate,A. Lamb 和 PF Fisher,“遥感光学图像变化检测技术的关键综合”,Remote Sens. Environ.,卷。 160,第 1-14 页,2015 年 4 月。

[6] 徐建,罗成,陈晓,魏世,罗勇,“基于多向自适应特征融合和感知相似性的遥感变化检测”,遥感,2015 13,没有。 15,p。 3053,2021 年 8 月。

[7] Z. Wu,W. Zhu,J. Chanussot,Y. Xu 和 S. Osher,“通过背景的全局和局部联合建模进行高光谱异常检测”,IEEE 传输.信号处理,卷。 67,没有。 14,第 3858–3869 页,2019 年 7 月。

[8] R. Touati,M. Mignotte 和 M. Dahmane,“使用无监督像素成对马尔可夫随机场模型进行遥感图像多模态变化检测”,IEEE Trans.图像处理,卷。 29,第 757–767 页,2020 年。

[9] F. Bovolo 和 L. Bruzzone,“数据融合中的时间变量:变化检测视角”,IEEE Geosci.遥感杂志,卷。 3,没有。 3,第 8-26 页,2015 年 9 月。

[10] 彭晓,钟瑞,李子,李强,“基于注意力机制和图像差异的光学遥感图像变化检测”,IEEE 传输.地理学.遥感,卷。 59,没有。 9,第 7296–7307 页,2021 年 9 月。

[11] T. Liu,L. Yang 和 D. Lunga,“使用深度学习方法和基于对象的图像分析进行变化检测”,遥感环境,卷。 256,2021 年 4 月,艺术。不。 112308。

[12] Z. Wu等人,“云计算架构上大规模高光谱图像分类的调度引导自动处理”,IEEE 传输.赛博恩,卷。 51,没有。 7,第 3588–3601 页,2020 年 7 月。

[13] Z. Wu,J. Sun,Y. Zhang,Z. Wei 和 J. Chanussot,“遥感大数据处理的并行和分布式计算的最新进展”,Proc. IEEE,卷。 109,没有。 8,第 1282–1305 页,2021 年 8 月。

[14] A. Karpatne,Z. Jiang,RR Vatsavai,S. Shekhar 和 V. Kumar,“监测土地覆盖变化:机器学习视角”,IEEE Geosci.遥感杂志,卷。 4,没有。 2,第 8-21 页,2016 年 6 月。

[15] H.Zhang,M.Lin,G.Yang 和 L.Zhang,“ESNet:用于超高分辨率遥感图像的端到端超像素增强变化检测网络”,IEEE Trans.神经网络.学习.系统,抢先体验,2021 年 7 月 5 日,doi: [10.1109/TNNLS.2021.3089332](https://doi.org/10.1109/TNNLS.2021.3089332)。

[16] K.He,X.Zhang,S.Ren,J.Sun,“图像识别的深度残差学习”,Proc. IEEE 会议计算.维斯.模式识别.(CVPR),Jun. 2016, pp. 770–778.

[17] O. Ronneberger,P. Fischer 和 T. Brox,“U-Net:用于生物医学图像分割的卷积网络”,《医学图像计算和计算机辅助干预》,卷。 9351。

德国慕尼黑:施普林格,2015 年,第 234-241 页。[在线的]。可用:https://itations.springernature.com/item?doi=10.1007/978-3-319-24574-4_28

[18] G. Cheng,C. Yang,X. Yao,L.Guo 和 J. Han,“当深度学习遇到度量学习:通过学习判别式 CNN 进行遥感图像场景分类”,IEEE Trans.地理学.遥感,卷。 56,没有。 5,第 2811–2821 页,2018 年 5 月。

[19] L.Zhang,Q.Zhang,B.Du,X.Huang,YYTang,D.Tao,“高光谱图像的同步光谱空间特征选择和提取”,IEEE Trans.赛博恩,卷。 48,没有。 1,第 16-28 页,2018 年 1 月。

[20] X. Hou,Y. Bai,Y. Li,C. Shang 和 Q. Shen,“具有动态多尺度特征的高分辨率三重网络,用于卫星图像变化检测”,ISPRS J. Photogramm.遥感,卷。 177,第 103–115 页,2021 年 7 月。

[21] Z. 郑,Y. 万,Y. 张,S. 项,D. 彭,B. 张,“CLNet:用于光学遥感影像变化检测的跨层卷积神经网络”,ISPRS J.摄影图.遥感,卷。 175,第 247-267 页,2021 年 5 月。

[22] C. 张等人,“用于高分辨率双时相遥感图像变化检测的深度监督图像融合网络”,ISPRS J. Photogramm.遥感,卷。 166,第 183–200 页,2020 年 8 月。

[23] T. Le等人,“用于 VHR 遥感图像变化检测的差异增强和空间光谱非局部网络”,IEEE Trans.地理学.遥感,卷。 60,2021,艺术。不。 4507013。

[24] N. Wang,S. Ma,J. Li,Y.Zhang,and L.Zhang,“用于图像修复的多级注意力网络”,模式识别,卷。 106,2020 年 10 月,艺术。不。 107448。

[25] M. Liu,Q. Shi,A. Marinoni,D. He,X. Liu 和 L. Zhang,“基于超分辨率的变化检测网络,具有针对不同分辨率图像的堆叠注意模块”IEEE 传输.地理学.遥感,卷。 60,第 1-18 页,2022 年。

[26] Q. Shi,M. Liu,S. Li,X. Liu,F. Wang 和 L. Zhang,“基于深度监督注意力度量的网络和用于遥感变化检测的开放航空图像数据集”,IEEE 传输.地理学。遥感,卷。 60,第 1-16 页,2022 年。

[27] H. Chen,Z. Qi 和 Z. Shi,“利用变压器进行遥感图像变化检测”,IEEE Trans.地理学.遥感,卷。 60,第 1-14 页,2022 年。

[28] J. Huang,Q. Shen,M. Wang 和 M. Yang, “用于高分辨率图像变化检测的多重注意力连体网络”, IEEE Trans. 地理学.遥感,卷. 60,第 1-16 页,2022 年。

[29] L.Zhang,X.Hu,M.Zhang,Z.Shu 和 H.Zhou, “使用双相关注意力引导检测器进行对象级变化检测”, ISPRS J.摄影图.遥感,卷. 177,第 147-160 页,2021 年 7 月。

[30] D. Wang,X. Chen,M. Jiang,S. Du,B. Xu 和 J. Wang, “ADS-Net:一种用于遥感图像变化检测的基于注意力的深度监督网络”,Int. J.应用程序.地球观测.地理信息,卷. 101,2021 年 9 月,艺术.不. 102348。

[31] S. Fang,K. Li,J. Shao 和 Z. Li, “SNUNet-CD:用于 VHR 图像变化检测的密集连接连体网络”, IEEE Geosci. 遥感通讯,卷. 19,第 1-5 页,2022 年。

[32] S. Woo,J. Park,J.-Y. Lee 和 IS Kweon, “CBAM:卷积块注意力模块”, Proc 中.欧元.会议.计算.维多, 2018 年,第 3-19 页。

[33] A. Dosovitskiy等人, “一张图像相当于 16×16 个单词:用于大规模图像识别的 Transformers”,Proc.国际.会议. 学习.代表., 2021.。[在线]。可用:https://openreview.net/forum?id=YicbFdNTTy

[34] S. Xie,R. Girshick,P. Dollar,Z. Tu 和 K. He, “深度神经网络的聚合残差变换”,Proc. IEEE 会议计算. 看法.模式识别. (CVPR),七月. 2017 年,第 5987-5995 页。

[35] S. Zagoruyko 和 N. Komodakis, “宽残差网络”, Proc. 英国人马赫.你要.会议, 2016 年,第 14 页. 87.

[36] M.-H. Guo等人, “计算机视觉中的注意力机制:一项调查”,2021 年, arXiv: 2111.07624。

[37] 牛志强、钟国强、于华, “深度学习注意力机制综述”,神经计算, 2015 452,第 48-62 页, 2021 年 9 月。

[38] X. Feng,J. Han,X. Yao 和 G. Cheng, “TCANet:用于遥感图像中弱监督目标检测的三重上下文感知网络”, IEEE Trans.地理学.遥感,卷. 59,没有. 8,第 6946-6955 页, 2021 年 8 月。

[39] B. Graham等人, “LeViT:披着 ConvNet 外衣的视觉转换器,可实现更快的推理”, Proc. IEEE/CVF 国际.会议.计算.访问, 2021 年 10 月,第 12259-12269 页。

[40] J. Dai等人, “可变形卷积网络”, Proc. IEEE 国际. 会议.计算.维多. (ICCV), 2017 年 10 月,第 764-773 页。

[41] S. Huang,Z. Lu,R. Cheng 和 C. He, “FaPN:用于密集图像预测的特征对齐金字塔网络”,Proc. IEEE/CVF 国际.会议. 计算.维多. (ICCV), 10 月2021 年,第 101-1 页864-873。

[42] X. Fu,J. Huang,D. Zeng,Y. Huang,X. Ding 和 J. Paisley, “通过深度细节网络从单幅图像中去除雨水”,Proc. IEEE 会议 帐户你要.模式识别. (CVPR),七月. 2017 年,第 17 页. 1715-1723。

[43] Z. Xu,K. Wu,L. Huang,Q. Wang 和 P. Ren, “阴天图像算法:阴天场景合成范式及其在基于深度学习的薄云去除中的应用”,IEEE Trans.地理学.遥感,卷. 60,2022, 艺术.不. 5612616。

[44] T.-C.王,M.-Y.刘,J.-Y. Zhu,A.Tao,J.Kautz 和 B.Catanzaro, “条件 GAN 的高分辨率图像合成和语义操作”,Proc. IEEE/CVF 会议计算.维多.模式识别, 2018 年 6 月,第 8798-8807 页。

[45] J. Fu等人, “用于场景分割的双重注意网络”, Proc. IEEE/CVF 会议帐户你要.模式识别. (CVPR),六月. 2019 年,第 17 页. 3141-3149。

[46] Y. LeCun,Y. Bengio 和 GE Hinton, “深度学习”,《自然》,卷. 521,第 436-444 页, 2015 年 12 月。

[47] T.-Y. Lin,P. Dollar,R. Girshick,K. He,B. Hariharan 和 S. Belongie, “用于对象检测的特征金字塔网络”,参见Proc. IEEE 会议 帐户你要.模式识别. (CVPR),七月. 2017 年,第 17 页. 936-944。

[48] Q. Chen,Y. Wang,T. Yang,X. Zhang,J. Cheng, and J. Sun, “You only Look one-level feature,” in Proc. IEEE/CVF 会议计算.维多.模式识别. (CVPR), 2021 年 6 月,第 13034-13043 页。

[49] W. Shi等人, “使用高效的子像素卷积神经网络实现实时单图像和视频超分辨率”, Proc. IEEE 会议 帐户你要.模式识别. (CVPR),六月. 2016 年,第 17 页. 1874-1883。

[50] Z. Wang,C. Peng,Y. Zhang,N. Wang,L. Luo, “基于全卷积连体网络的具有焦点对比损失的光学航空图像变化检测”,神经计算,卷. 457,第 155-167 页,2021 年 10 月。

[51] F. Milletari,N. Navab 和 S.-A. Ahmadi, “V-Net:用于体积医学图像分割的全卷积神经网络”, Proc 中. 第四国际.会议. 3D 视觉. (3DV), 2016 年 7 月,第 565-571 页。

[52] MA Lebedev,YV Vizilter,OV Vygodov,VA Knyaz 和 AY Rubis, “使用条件对抗网络进行遥感图像变化检测”, Int.拱.摄影.遥感. 空间信息.科学,卷. 42,没有. 2,第 565-571 页,2018 年 6 月。

[53] R. Caye Daudt,B. Le Saux 和 A. Boulch, “用于变化检测的全卷积通罗网络”, Proc. 第 25 届 IEEE 国际会议会议. 图像处理. (ICIP), 2018 年 10 月,第 4063-4067 页。

[54] Q. Wang,B. Wu,P. Zhu,P. Li,W. Zuo 和 Q. Hu, “ECA-Net:深度卷积神经网络的高效通道关注”,Proc. IEEE/CVF 会议帐户你要.模式识别. (CVPR),六月. 2020 年,第 17 页. 11531-11539。

[55] J. Hu,L. Shen 和 G. Sun, “挤压和激励网络”,载于Proc. IEEE/CVF 会议计算.维多.模式识别, 2018 年 6 月,第 7132-7141 页。

[56] T. Chen等人, “ABD-Net:细心但多样化的人员重新识别”, Proc. IEEE/CVF 国际.会议.计算.维多. (ICCV), 2019 年 10 月,第 864-873 页。

[57] Y. Chen,Y. Kalantidis,J. Li,S. Yan 和 J. Feng, “A2-Nets:双重注意力网络”,载于 Proc.副词.神经信息.过程.系统,卷. 2018 年 31 月,第 352-361 页。

[58] AG Roy,N. Navab 和 C. Wachinger, “使用空间和通道 ‘挤压和激励’ 模块重新校准全卷积网络”, IEEE Trans.医学.图像,卷. 38,没有. 2,第 540-549 页,2019 年 2 月。



程功 (IEEE会员)于2007年在中国西安电子科技大学获得学士学位,并于2007年在西安电子科技大学获得硕士和博士学位.分别于2010年和2013年获得西北工业大学 (西安)学士学位。

现任西北工业大学教授.主要研究兴趣为计算机视觉、模式识别、遥感图像处理。

程博士还是《IEEE地球科学与遥感》杂志的副主编和《IEEE应用地球观测与遥感精选主题杂志》的客座编辑。



王广兴于2018年获得山东科技大学电子信息科学与技术学士学位,并于2018年获得中国石油大学 (华东)信息与通信工程硕士学位, 2021年在青岛.目前正在攻读博士学位.毕业于西北工业大学控制科学与工程专业,获工学博士学位。

他的研究兴趣包括深度学习和学习遥感应用。

Junwei Han (IEEE 院士)获得学士、硕士和博士学位.分别于1999年、2001年和2003年获得西北工业大学模式识别与智能系统博士学位。

2003年至2010年在新加坡南洋理工大学、香港中文大学、爱尔兰都柏林城市大学、英国邓迪大学担任研究员.现任西北工业大学教授.他的研究兴趣包括计算机视觉和脑成像分析。