



ScienceDirect提供内容列表

信息融合

期刊主页: [www.elsevier.com/locate/inffus](http://www.elsevier.com/locate/inffus)



用于多变量时间序列异常检测的深度学习 :方法、应用和挑战Gen Li,Jason J. Jung

★

中央大学计算机工程系, 84 Heukseok-ro, Dongjak-gu, 首尔, 06974, 大韩民国

文章信息

关键词:  
异常检测  
多元时间序列  
研究挑战

抽象的

异常检测最近已应用于各个领域,并且已经提出了几种基于深度学习的技术来分析多元时间序列。在本研究中,我们将异常分为三种类型,即异常时间点、时间间隔和时间序列,并回顾了用于检测每种类型的最先进的深度学习技术。长短期记忆和自动编码器是检测异常时间点和时间间隔最常用的方法。此外,一些研究还实现了动态图来检查时间序列之间的关系特征并检测异常时间间隔。然而,异常检测仍然面临一些限制和挑战,例如异常的可解释性。许多研究只关注异常检测方法,而没有考虑异常的原因。因此,增加异常的可解释性是异常检测中的一个重要研究课题。

一、简介

异常检测是一项数据挖掘任务,旨在识别与大多数其他数据显着不同的数据。异常检测在不同环境下的许多应用已经开发出来,包括金融卡欺诈、工业入侵和医疗疾病检测。

记录了来自各个领域的大量时间序列,包括医学、工业和自然科学。以提取有用信息为目的的时间序列分析已成为一个主要的研究领域。提取的信息可用于解决各种问题。时间序列异常检测作为问题之一,旨在从不同区域记录的时间序列中发现异常事件。例如,Dwivedi 等人。论文[1]使用计算机网络的集成特征选择和 Grasshopper 优化方法来通过支持向量机改进网络入侵检测。西尼奥斯格鲁等人。[2]使用基于自动编码器的生成对抗网络来识别智能电网系统中的异常情况。

传统的异常检测方法基于数据集的统计指标和密度。然而,传统方法存在一些局限性。例如,传统方法在医学图像和序列数据集的异常检测中的性能很糟糕,因为它们无法捕获数据中的复杂结构。此外,传统方法无法扩展到大规模数据来发现异常。还有,边界

时间序列数据中异常行为与正常行为之间的定义通常不精确,并且不断变化。缺乏明确定义的代表性法线边界对传统方法提出了挑战。因此,提出了基于深度学习的方法。深度异常检测技术从时间序列数据中学习层次判别特征。这个自动功能

学习能力消除了领域专家手动开发功能的需要。因此提倡解决时间序列上的异常检测问题。

有很多调查论文介绍了用于时间序列异常检测的深度学习方法。如论文[3]回顾了异常时间序列检测相关的方法和应用,并总结了这些方法面临的挑战。然而,本文仅考虑一维时间序列,并且有大量的多元时间序列是从现实世界记录的。在

此外,现有与时间序列异常检测相关的调查论文没有介绍常用的数据集和研究挑战。因此,为了填补这些空白,我们回顾了与多元时间序列异常检测的方法、应用、研究挑战和数据集相关的论文。

由于时间序列分析中涉及的输入数据和异常类型可能有很大差异,因此需要不同的异常检测技术。如图1所示,异常主要有三种类型,分别是异常时间点、异常时间区间和异常。

\* 通讯作者。  
电子邮件地址: [j3ung@cau.ac.kr](mailto:j3ung@cau.ac.kr) (郑俊杰)。




图 1. 异常类型和应用。




图2.异常时间点示例。




图 3. 异常时间间隔示例。

时间序列。主要基于异常时间点的应用  
检测包括欺诈检测、攻击检测和噪声检测。  
异常时间间隔检测常用于癫痫发作  
检测、气候监测和污染监测。故障检测、状态诊断、事件检测都是在异常情况的基础上进行的。

时间序列检测。

异常时间点是指数值出现异常的某个时间点  
监测变量的值与任意值的值显着不同  
其他时间点。其公式为  $(x_t - \mu) / \sigma > \tau$  或  $(x_t - \mu) / \sigma < -\tau$  其中  $\tau$  为第  $t$  个时间点， $(x_t - \mu) / \sigma$  为时间异常得分  
检测异常的阈值。异常时间点  
时间序列一般对应一个极值。在某些情况下，  
异常对应于数据中的噪声。因为在这样的情况下  
异常影响数据分析结果，必须检测出来  
并从给定的时间序列中删除。在其他情况下，这种类型的  
异常可能代表感兴趣的事件。例如，图2所示  
三个记录的脑电图（EEG），其中三个极端  
显示值。这些异常点表示噪声或  
该时间点的相关事件。因此，检测此类  
异常对于时间序列分析很有用。兰詹等人。[4]改进  
传统的基于时间窗滑动的预测方法  
检测给定时间序列中的异常并提高电力系统规划和运行的预测准确性。相似地，

王等人。[5]应用卷积神经网络（CNN）来检测  
从风力发电系统收集的时间序列中的异常  
改善短期预测。  
时间间隔异常。异常时间间隔是一定时间  
时间序列，在此期间变量的行为显着不同  
的其余部分的间隔。公式为  $(x_t - \mu) / \sigma > \tau$  或  $(x_t - \mu) / \sigma < -\tau$  其中  $\tau$  是第  $t$  个时间间隔， $(x_t - \mu) / \sigma$  是异常值  
时间分数，是检测异常的阈值，

通常表示异常事件的发生。分析师可能  
专注于这些异常来探索检测到的事件的含义。  
图3展示了三个异常时间间隔的示例  
脑电图信号，其中红色区域对应于癫痫发作  
一位患者所遭受的痛苦。李和荣格[6]提出了反常时间  
从多变量脑电图中识别癫痫发作的间隔检测方法  
信号。因为有没有脑放电是完全不同的  
癫痫发作，作者认为癫痫发作间隔是异常的  
时间间隔并提出了一种基于图的检测方法。在这个  
案例中，检测此类异常可以帮助专家分析和  
了解异常事件的模式。陈等人。[7]提出  
一种利用物联网检测网络攻击的方法  
（物联网）时间序列。这项研究帮助专家认识并分析了  
网络攻击的模式。  
异常时间序列。异常时间序列是指某个时间  
公式为  $(x_t - \mu) / \sigma > \tau$  或  $(x_t - \mu) / \sigma < -\tau$  这与其他时间序列有显着不同。这是  
 $(x_t - \mu) / \sigma > \tau$  或  $(x_t - \mu) / \sigma < -\tau$  的系列是时间的异常得分，其中  $\tau$  是第  $t$  个时间序列， $(x_t - \mu) / \sigma$  是检测阈值  
异常。图4显示了三个时间序列，其中两个信号表现出  
高相关性，与因此检测到的红色相关性相反  
作为异常时间序列[8]。如Li和Jung [9]发现  
股票和金融独立公司之间的关系。然后，一个动态的  
图用于对这些关系进行建模。最后出现异常  
通过提出图嵌入模型来检测股票。  
本文的其余部分安排如下。分节  
异常点、异常时间间隔、2.3.4技术  
和异常时间序列检测分别进行了讨论。在第5节中，讨论了选择阈值的方法。在  
第六节，基于多元时间异常检测的应用  
系列进行审查。在第7节中，可用的开放获取时间序列  
列出了用于异常检测的数据集。在第8节中，限制和




图 4. 异常时间序列示例。

多元时间序列异常检测的研究挑战是呈现。最后,第9节讨论了结论。

2.异常时间点

多元时间中常见的异常时间点系列,代表噪声或在某一时刻发生的事件。本节回顾了可用于检测异常的技术多元时间序列中的时间点。图 2提供了一个示例异常时间点的检测。三个时间序列对应显示从三个通道记录的患者脑电图信号。每个信号都表现出异常,但由于这三个异常确实不是在同一时刻发生,它们之间没有相关性。由于多元时间序列中的异常时间点由极值组成,因此检测该类型的基本流程

异常是预测或估计某个时间戳的值,然后计算该值与基本事实。如果预测值或估计值之间存在差异并且groundtruth值大于设定的阈值,该值为检测为异常。基本方法表述如下。

$$I_t = \begin{cases} 1 & \text{if } | \hat{y}_t - y_t | \geq \theta \\ 0 & \text{otherwise} \end{cases} \quad (1)$$

其中  $\theta$  是阈值、时间戳和 检测异常时间  $t$  是第  $t$  处的真实值的最常用方法  $\hat{y}_t$  是 的预测值或估计值。

多元时间序列中的点基于预测模型。和随着深度学习技术的发展,众多的模型已经出现被提出用来预测时间序列。例如,一个时间序列是公式为  $\{x_t\}_{t=1}^T$ ,其中  $x_t \in \mathbb{R}^d$ ,时间戳处的值,并且是之后的下一个时间戳处的值  $x_{t+1}$ 。为了检测该值是否异常,预测模型在当前  $t$  处使用过去的值。阮 预测值等人。[10]应用LSTM模型来预测某个时间的值系列并利用自动编码器 (AE)从中提取特征。这作者首先将过去的值输入 LSTM 模型并进行预测当前值。随后,假设它是独立的,他们将预测值输入到自动编码器以获得新的预测值价值。最后,他们计算预测值和预测值之间的误差使用损失函数的真实值  $\| \hat{y}_t - y_t \|^2$ ,其中  $\| \cdot \|^2$  是时间序列中时间戳的数量。

例如,Girish 和 Rao [11]将 LSTM 模型应用于云检测多变量时间序列中的异常事件的环境。

然而,这项研究仅应用了简单的 LSTM 架构来检测从收集的多变量时间序列中的异常

云环境,使得该模型不适合其他应用程序。乌拉等人。[12]首先检测到监控网络中的异常从多元时间序列中提取空间特征卷积神经网络,然后将提取的特征输入到双向LSTM (Bi-LSTM)模型中以预测未来数据。

最后,应用统计方法来检测预测是否正确。数据异常。秦等人。[13]输入控制器局域网总线连接到 LSTM 模型来预测网络的未来值然后通过获取LSTM的损失来识别网络攻击。如果损失大于阈值,则相应的时间戳被检测为异常。

然而,存在多种形式的异常,并且时间序列确实存在不指定他们。因此,发表了多篇论文为了解决这个问题,他们中的大多数人试图采用无人监督的方式学习模型[14]。例如,Kieu 等人。[15]重建使用两个自动编码器模型的输入。一般来说,常规数据是比异常数据更丰富。因此,当自动编码器接收异常输入,重建损失变得很大并且,如果设置了自动编码器损失的阈值,则可以将异常值检测到。他们的模型在实验中优于基线模型。其他研究人员也研究了合并的可能性

带有自动编码器的卷积神经网络来识别紊乱 etc.这包括 Yin 等人的工作。[16]谁提出的使用循环神经网络来记录时间信息增强异常集成模型的性能鉴别。然而,集成模型无法证明增强的性能。

预测多元时间序列很困难,因为变化其中所涉及的变量受到多种因素的影响,基于预测的模型在检测异常方面的有效性多元时间序列的影响是有限的。为了解决这个问题,一些研究旨在结合 LSTM 和自动编码器来检测异常时间点。LSTM-自动编码器 (LSTM-AE)模型的核心思想就是利用LSTM单元作为自动编码器的隐藏层重建输入数据[17]并通过获取来识别异常输入和重建阈值之间的差异也被设置为使用等式检测异常。(1).

价值观。A

其他方法利用监督学习模型来检测多元时间序列中的异常。例如,杨等人。[18]将异常检测视为类不平衡问题,标记每个时间戳的类并应用监督学习模型了解标记数据的特征。同样,苏等人。[19]提议使用以下方法研究多元时间序列中正态数据的模式识别异常的监督学习模型。因为模型学习正常数据的模式,模型的准确性为如果异常包含在学习阶段,则会受到影响。因此,一个根据监督模型的损失发现异常。

例如,Maleki 等人。[20]应用了一种这样的混合模型检测多元时间序列中的异常。陈等人。[21]还应用LSTM-AE模型检测电机异常时间点风力涡轮机系统故障。LSTM-AE模型已得到应用于各种领域的异常检测,例如工业物联网和体育[22,23]。用于检测异常时间的附加技术表1总结了要点。

3.时间间隔异常

多元时间序列中的异常时间间隔对应到非典型事件发生的时期。本节评论检测多元时间中异常时间间隔的方法系列。

表格1  
异常时间点检测方法。

参考	数据集	建筑学	临界点	特征提取	评估指标
阮等人。 [10]	C-MAPSS数据集	LSTM 和自动编码器	最佳阈值	不	AUC、MSE 和 F1 分数
吉里什和拉奥 [11]	云环境数据集	长短期记忆网络	固定阈值	不	准确性
乌拉等人。 [12]	UCF-Crim	CNN 和 LSTM	无门槛	是的	AUC 和 ROC
秦等人。 [13]	车辆数据集	长短期记忆网络	固定阈值	是的	AUC 和 ROC
乔等人。 [15]	心电图数据集	循环自动编码器	固定阈值	不	PR-AUC
鲁纳宁等人。 [14]	传感器数据集	自动编码器	最佳阈值	不	召回率、AUC 和 ROC
尹等人。 [16]	物联网数据集	自动编码器	最佳阈值	不	F1分数
杨等人。 [18]	金融数据集	长短期记忆网络	具体阈值	不	F1分数
陈等人。 [21]	风力涡轮机数据集	LSTM 和自动编码器	自适应阈值	不	MSE 和 MAE
刘等人。 [22]	心电图	LSTM 和自动编码器	最佳阈值	是的	灵敏度
马莱基等人。 [20]	亚马逊网络服务	LSTM 和自动编码器	最佳阈值	不	F1 分数和准确度
霍马尼等人。 [23]	Covid-19 数据集	LSTM 和自动编码器	具体阈值	是的	均方误差
穆尼尔等人。 [24]	物联网	长短期记忆网络	自适应阈值	是的	F1分数
丁等人。 [25]	Numenta 异常基准	长短期记忆网络	最佳阈值	是的	F1分数
金和曹 [26]	网络流量数据集	长短期记忆网络	最佳阈值	是的	F1分数

3.1.基于 LSTM 的方法

基于 LSTM 的自动编码器模型利用 LSTM 单元来提取来自多元时间序列的时间特征,然后由自动编码器用来重建输入时间间隔。这使用自动编码器模型进行异常检测背后的想法是为了获得输入和输出之间的损失[27–31]。例如,林等人。 [32]将变分自动编码器模型 (VAE)与用于检测环境多元时间序列异常的 LSTM 模型和机器温度。首先,利用自动编码器模型从多元时间序列中提取局部特征。随后,LSTM 单元从局部特征中捕获时间信息。最后,异常检测分数被定义为等于损失输入和输出时间间隔之间。

考虑到生成对抗网络 (GAN)已经 Niu 等人迅速发展。 [33]改进了基于LSTM的VAE模型通过添加 GAN。研究表明,尽管 GAN 已用于许多领域的异常检测,但它们仍然需要大量的时间进行训练。提出的基于 LSTM 的 VAE-GAN

模型试图解决这一挑战。怀着这样的目标首先研究编码器、解码器、生成器的所有隐藏层,和判别器是使用 LSTM 单元建立的。接下来,时间将多元时间序列中的区间输入到 VAE 模型中计算随后的低维嵌入向量输入到生成器。随后,发电机的输出和地面实况被输入到鉴别器进行训练。最后,测试数据被送入组合单元计算平均值每个输入时间间隔的异常分数,如果分数更大比设定的阈值输入时间间隔被识别为异常。然而,这项研究有一些局限性。首先,作者利用 LSTM 和 VAE 构建 GAN 模型,但报告称所提出的模型可以减少训练时间。这是因为基于 LSTM 的 VAE-GAN 模型的结构比基于 LSTM 的 VAE 模型,因此需要更多的训练时间比后者。其次,所提出的模型是监督学习模型,它的性能不能比它更好,也不能应用于更多的情况无监督学习模型。

3.2.基于动态图的方法

使用动态图来表示时间序列正在被广泛使用用于分析异常情况。异常检测的核心思想是动态图是利用多元时间之间的关系系列为每个时间间隔构建单个图表。优势这些方法的一个特点是它们可以识别关系模式用作异常检测的基础。为了便于说明,图 5给出了从三个不同通道 01、02和 02 记录的时间序列03,其中是第th个时间间隔,红色区域对应到一个时间间隔异常。图是通过计算构建的

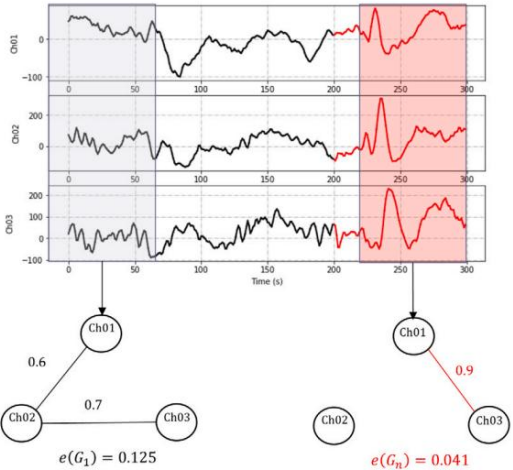


图 5.基于动态图的方法。

三个时间序列之间的相关系数并分配将它们作为图中边的权重,其中( )是图的熵。因为多元变量之间的关系红色区域时间间隔的时间序列与那些有很大不同在其他时间间隔,检测到红色区域的时间间隔为异常的时间间隔。

因为图对于建模对象及其关系很有用,一些研究已经应用动态图来表示多元时间序列及其在连续时间间隔内的相关性。为了例如,Deng 和 Hooi [34]尝试将深度学习结合起来结构和图神经网络 (GNN)来检测时间间隔异常。本研究将多变量时间序列分为几个时间间隔,依次转化为静态每个顶点对应于多元时间之一的图系列和每条边代表一对之间的关系时间序列。然后提出了图注意力模型来预测未来的多变量时间间隔,这些用于比较来检测异常情况。在另一项研究中,赵等人。 [35]已利用一维卷积核从多元时间中提取特征系列,通过图表对这些特征及其关系进行建模。然后他们应用图卷积网络 (GCN)来检测通过图预测异常。陈等人。 [7]将系列到图技术应用于从三个传感器收集的物联网数据系列。

因此,构建的图由三个节点组成,每个节点代表从单个传感器收集的时间序列。来检测是否

两个节点之间存在连接,他们应用 Gumbel-Softmax 采样策略对向量进行采样。最后是图学习模型用于查找多元物联网时间序列中的异常。



表2  
异常时间间隔检测方法。

参考	数据集	建筑学	临界点	特征提取	评估指标
林等人。 [32]	亚马逊网络服务	LSTM-AE	固定阈值	不	F1分数
普罗沃塔等人。 [27]	各种信号数据集	LSTM-AE	最佳阈值	不	准确性
牛等人。 [33]	雅虎数据集	VAE-GAN	最佳阈值	是的	F1分数
刘等人。 [28]	MIT-BIH 心律失常数据集	LSTM-CNN	自适应阈值	是的	敏感性和特异性
吴等人。 [29]	工业物联网数据集	神经网络	最佳阈值	是的	AUC,ROC 和 F1 分数
沃斯等人。 [30]	变速箱数据集	神经网络	具体阈值	不	F1分数
张等人。 [31]	跌倒检测数据集	LSTM-CNN	具体阈值	不	敏感性和特异性
邓和陶[34]	传感器数据集	神经网络	最佳阈值	是的	F1分数
赵等人。 [35]	美国宇航局数据集	GCN	非参数化 决策阈值	是的	F1分数
陈等人。 [7]	安全水处理数据集	神经网络	自适应阈值	是的	F1分数
李和荣格[36]	气象数据集	神经网络	具体阈值	是的	F1分数
李和荣格[38]	气象数据集	神经网络	具体阈值	是的	F1分数
李等人。 [39]	交通数据集	神经网络	具体阈值	是的	F1分数

关系模式对于异常检测很重要。这最常用的关系是相关性。然而,相关性忽略了多元时间序列之间的因果关系。到

为了解决这个问题,在之前的研究中,我们建议识别

作为模式的虚假关系[9,36]。虚假关系是定义为两个不具有相关性的时间序列之间的时间序列

因果关系。一项研究提出了这样一种关系来自荷兰,其中发现之间存在相关性

春季筑巢的鹳鸟数量和人类数量

同一时期出生的孩子,尽管没有因果关系

连接,因为这两个变量仅与观测前九个月的气象条件有关。相似地,

霍弗等人。 [37]考察了统一后的德国并发现

临床分娩和鹳数量之间没有相关性,但是

发现院外分娩与鹳数量增加之间存在关联

人口。异常时间间隔处理方法总结

检测结果如表2所示。

4. 异常时间序列

异常时间点和间隔的检测可以揭示

多元时间序列中感兴趣的事件和有用的信息,

这解释了为什么许多技术被提出来检测

他们。异常时间序列检测的目标是识别时间

与数据集中其他时间序列的关系与其余序列之间观察到的关系显着不同的序列。

异常时间序列检测也很重要,因为它表明

时间序列表现出长期的异常行为。这个不正常的

行为可能导致高风险或成为风险的原因。所以,

检测异常时间序列可以帮助人们分析异常原因

风险并避免它。例如,在分析气候变化时,

我们必须记录几个时间序列,例如压力、温度。在

长期以来,天气呈现高温。我们可以

认为长期高温是气候变化的一个原因。

然而,检测异常时间序列的方法较少

比检测异常时间点和间隔的方法更敏感。

检测异常时间序列的主要步骤是比较

所有涉及的时间序列之间的相似性。这意味着

检测异常所需的计算量大大增加

与时间序列数据集的规模。贝格尔等人。 [40]使用过

它们描述正常变量的形状并检测异常值

多元时间序列中的时间相关变量。小形状

从每个时间序列中提取,深度神经网络是

应用于学习 shapelet 的模式。那么,异常时间

系列是根据 shapelet 的模式检测的。张

等人。 [41]提出了一种基于时空卷积神经网络

的关系网络 (STCNN-RN)来学习之间的相关性

金融公司。然后,他们应用遗传算法

通过拟合STCNN-RN模型发现异常公司。在

表3  
异常时间序列检测方法。

参考	数据集	架构/阈值
贝格尔等人。 [40]	加州大学河滨分校数据集	神经网络 具体阈值
张等人。 [41]	库存数据	STCNN-RN 特定阈值
李和荣格[9]	库存数据	GCN 具体阈值
李等人。 [42]	安全水处理 GAN	最佳阈值
奥迪伯特等人。 [43]	安全水处理自动编码器	最佳阈值

我们之前的研究[9],我们确定了之间的关系特征

股票和金融指数。然后,创建一个动态图

用于对这些特征进行建模。动态图嵌入模型为

建议绘制动态图。最后我们检测到异常

嵌入空间中的库存。尽管我们研究中的异常现象是

定义为一定的时间间隔,研究的目的是确定

某个时间间隔出现异常库存,即异常时间

系列检测。此外,李等人。 [42]利用建立GAN模型

LSTM 和自动编码器模型。重建损失和解散

定义犯罪损失来计算异常分数。最后,

通过优化 GAN 选择阈值。在那项研究中,LSTM 单元

用于从多元时间序列中提取特征并创建

生成器和鉴别器。自动编码器用于建立

和异常检测器。奥迪伯特等人。 [43]利用自动编码器

重建多元时间序列。异常时间序列为

通过获取自动编码器的损失来检测。总结如下

异常时间间隔检测的方法如表3所示。

5. 阈值选择

阈值是一个重要的参数,它决定了最终的结果

多元时间序列异常检测的性能。这

最典型的异常检测方法是基于箱线图。

在我们之前的研究[9]中,我们尝试应用动态图

嵌入方法建立嵌入空间来映射

时间间隔。然后,使用箱线图方法来检测异常

在嵌入空间中。箱线图方法的阈值基于

下四分位数和上四分位数的两个值表示为1和

分别为3个。四分位距 ( ) 的计算方法为

这些值公式为= 3 − 1。如果

数据大于3 + 1.5或小于1 − 1.5。

另一种阈值选择方法是非参数阈值方法。该方法支持检测值表示为

因为真值表示为 在这种情况下,

检测值和真值可以表示为( ) = | − 计算公式化误差的指数加权平均值 |。然后

作为= { | ε [0, ]]。阈值使用以下函数计算

= ( ) + ( )。研究[44,45]利用LSTM模型来预测

时间序列并应用非参数动态阈值

根据预测误差检测异常。

苏等人。 [46]提出了一种用于自动异常阈值选择的调整峰值阈值方法,其性能优于非参数动态阈值方法。李等人。 [47]提出了一种 FluxEV 方法,它是一种快速有效的无监督时间序列异常检测框架。该论文还应用了峰值超阈值方法来自动确定异常检测的阈值。

此外,许多研究通过优化深度学习模型来选择阈值。最佳阈值是根据深度学习模型的损失函数来训练的[10,14,16]。首先,这些研究计算了每个样本的损失。然后就可以得到损失的分布。最后,根据损失的分布确定阈值。如尹等人。 [16]利用自动编码器来重建多元时间序列。然后,计算重建结果与输入时间序列之间的损失。他们计算每个时间间隔的损失并获得损失的分布。最后,他们根据统计指标选择了检测异常时间间隔的阈值。

自适应阈值在异常检测中也很流行,它可以通过使用特定的算法自动选择阈值[21,28]。如陈等人。 [21]提供了基于支持向量回归的自适应阈值。首先,他们发现了深度学习模型中的参数与最终性能值之间的映射关系。将映射函数表示为输入到模型中,可以计算出相应的参数和最终的性能值,其公式为( )。然后阈值被公式化为= ( ) + 其中 是预期性能指标值。在这种情况下,如果性能大于阈值,则该时间间隔被检测为异常。

= → 。当时间序列

此外,一些研究选择了检测异常的特定阈值。如论文[6]选择了几个阈值进行实验。然后,根据最终性能确定阈值。另外,有些领域的门槛是根据经验确定的。例如在金融领域[18],根据研究[48]将跳跃检测的阈值设置为4.60001。

6. 应用

6.1. 基于异常时间点的应用

时间序列上的异常点通常是由于某种原因引起的极值。在某些情况下,该点代表噪音或异常活动。例如工业物联网 (IIoT)环境中分布式拒绝服务 (DDoS)攻击的某个时间点。例如,Huong 等人。 [49]提出了一种 VAE-LSTM 模型来检测对 IIoT 数据的攻击。基本思想是计算 VAE 模型的损失以检测异常活动。分布式拒绝服务 (DDoS)攻击是物联网环境中的典型异常现象,它会导致服务器长时间无法运行,导致服务在高负载下崩溃。夏尔马等人。 [50]应用PCA来减少物联网时间序列的维度并利用统计

一种在简化的 IoT 时间序列中检测 DDoS 攻击的方法。詹等人。 [51]提出了一种新方法,该方法表示具有不同层次的时间序列,允许提取时间和显着幅度并检测具有异常特征的时间点。

他们将他们的方法应用于UCR时间序列数据集[52],实验结果表明他们的方法比基线表现更好。

尽管如此,异常点检测在金融领域发挥着重要作用,例如欺诈检测。随着科技的兴起和现代社会经济的不断发展,欺诈行为在金融行业日益普遍,每年给机构和消费者造成数千亿美元的损失。

骗子不断想出新的手段来利用

金融部门目前实施的安全措施中发现的漏洞。欺诈检测的挑战是金融时间序列中标记数据的不足,这阻碍了现有的监督学习模型有效地检测欺诈。为了解决这个问题,Xiao 和 Jiao [53]提出在标记数据的可用性有限时利用多元实例学习模型来检测欺诈。该模型的理论基于袋空间学习,它使用聚类方法构造多个袋。簇的标签取决于簇中的标记数据。如果数据来自属于欺诈集群一部分的时间点,则它们会被标记为欺诈。一些研究通过预测用户行为来检测欺诈行为。

例如,Benchaji 等人。 [54]从多个客户那里收集了180天的交易数据。然后,他们将这些数据输入 LSTM 模型以预测客户行为。给定的数据集被标记为欺诈或正常。所提出的方法利用监督学习通过检测异常行为来检测信用卡欺诈。

此外,智能家居和智慧城市领域的异常点检测也很有价值。在智慧城市的背景下,物联网可以帮助识别异常路况。此外,利用智能机器的数据来检测高拥挤者位置并为客户提供替代路线的路线查找应用程序正在变得司空见惯。例如,用户的位置数据可用于发现和聚合奇怪的运动模式,这可以帮助他们避开拥挤的区域并减轻其旅行对环境的影响[55]。小型物联网网络正在以越来越快的速度部署在商业和住宅建筑中,生成可用于检查和提高能源效率的数据[56-58]。

6.2. 基于异常时间间隔的应用

异常时间间隔检测通常应用于生物信号,例如脑电信号中的癫痫发作检测。癫痫发作是大脑在一定时间间隔内表现出异常放电。因此,大多数癫痫发作检测方法都是基于异常时间

间隔检测[59–61]。例如,马蒂尼等人。 [62]应用自我监督学习模型来实时检测脑电图信号中的癫痫发作。此外,据统计,全球每年因疲劳驾驶引发的安全事故导致超过130万人死亡。考虑到这种情况,Chaabene 等人。 [63]利用深度 CNN 模型从脑电图信号中检测睡意。实验结果表明,该方法的准确率达到90.42%。这项研究的目的是监测潜水员的大脑状态,以减少驾驶疲劳造成的损失。心电图 (ECG)是监测人类健康的另一个重要工具。许多人工智能技术已被应用于检测心电图信号的异常变化,并允许在疾病发作阶段及时采取措施[64,65]。

城市地区空气污染水平是全世界关注的另一个主要问题。多项研究表明,网络传感器可用于检测和监测城市的污染水平[66]。

人们提出了基于智能家居数据的活动监控来支持辅助生活环境,通过这种方式,可以了解个人的日常习惯,并将较大的偏差标记为异常,从而提高护理人员或医疗服务的意识。

6.3. 基于异常时间序列的应用

由于电网内监控和传感的增加,能源监管发生了变化。目前,智能电表正在多个国家的网络中安装。这些设备可以监控它们在不同时间使用的电量,并自动向网络运营商发送信息。监控用电量的好处是,电力公司可以主动检测本地配电网络中的缺陷,而不是依赖客户来警告他们停电。

表4 基于异常检测的应用程序及其方法的总结。				
参考	异常类型	模型	临界点	应用
洪等人。[49] 夏尔马等人。[50]	观点	长短期记忆网络	核分位数估计器	攻击检测
	观点	长短期记忆网络	非参数化 决策阈值	攻击检测
本查吉等人。[54]	观点	长短期记忆网络	非参数化 决策阈值	欺诈识别
Xiao and Jiao [53]	观点	长短期记忆网络	非参数化 决策阈值	欺诈识别
德安德里亚和马切罗尼[55]	观点	长短期记忆网络	不同的门檻	事件检测
维贾亚塞卡拉等人。[56]	观点	基于模糊规则的模型	灵敏度阈值	状态检测
阿拉亚等人。[58]	观点	神经网络	模式识别引擎	状态检测
周等人。[57]	观点	神经网络	具体阈值	欺诈识别
詹等人。[51]	观点	长短期记忆网络	具体阈值	状态检测
你等人。[59]	间隔	脚	最佳阈值	癫痫发作检测
拉吉尼坎特等人。[60]	间隔	神经网络	具体阈值	癫痫发作检测
瓦罗内等人。[61]	间隔	神经网络	最佳阈值	癫痫发作检测
马蒂尼等人。[62]	间隔	长短期记忆网络	自适应阈值	癫痫发作检测
查贝内等人。[63]	间隔	CNN模型	具体阈值	状态检测
佛罗吉法尔等人。[65]	间隔	神经网络	最佳阈值	诊断
埃尔汗等人。[64]	间隔	神经网络	最佳阈值	诊断
普那教和沙阿[66]	间隔	神经网络	具体阈值	污染监测
张等人。[41]	系列	***	具体阈值	库存数据
马杜拉维等人。[67]	系列	图嵌入	具体阈值	库存数据

此外,投资者面临金融市场的重大风险  
不稳定,其中可能包括由系统性因素引起的市场崩溃  
虚假炒作造成的危险和股价极端波动。  
发现股票市场的异常现象可以使投资者减少  
因股票市场状况不稳定而造成的损失。张等人。[41]提出了一种基于关系网络的模型来检测股  
市异常。首先,他们利用 CNN 来捕获空间和时间

公司的特点。然后使用图表来模拟公司之间的关系。最终,检测到异常情况

应用遗传算法。

马杜拉维等人。[67]还构建了一个图表来检测股市异常。在他们的图中,顶点对应于投资者

两个顶点之间的边代表相互作用。第一的,  
他们使用滑动时间窗口将股票数据分为几个  
时间间隔。接下来,对于每个时间间隔,他们构建了一个图表  
为投资者及其互动建模。随后,他们申请了  
对图进行分组的聚类方法。在这种情况下,密度  
异常图的发生率较低。最后,他们应用了局部异常值  
检测聚类图中异常的因子方法。异常现象  
基于检测的应用及其方法总结于  
表4。

7. 数据集

因为在多元时间里标注了异常的标签  
系列很耗时,标签内的数据集很小。为了  
例如,脑电图信号中的癫痫发作片段很短,医生  
需要花费一定的时间来诊断和识别  
发生间隔。在这项研究中,我们提供了多元时间序列  
来自不同领域的数据集。

四个数据集可用于工业中的异常检测  
物联网领域。第一个是[68]发布的电力系统攻击数据集,  
代表电力系统攻击数据集。数据集包括  
从电网获取的 128 个时间序列。有  
37种不同情况可供选择,包括自然灾害、无  
灾害,并攻击灾害。情况分为五种  
类型包括短路故障、线路维护、远程脱扣命令注入、继电器整定修改和数据注入。

短路故障是最常见的情况。攻击事件  
在提供的数据集中进行了标记。  
研究[69-71]提供了三种不同的天然气管道数据集。  
新的天然气管道数据集由 20 个独立的元素组成,分为

表5 用于异常检测的常用时间序列数据集摘要。			
参考	数据集	系列数	标签
潘等人。[68]	工业互联网	56	不
海狸等人。[69]	燃气管道	128	是的
莫里斯和高[70]	燃气管道	12	是的
莫里斯和桑顿[71]	燃气管道	7	是的
CHB-麻省理工学院[72]	脑电图数据集	23	是的
舒尔茨-邦哈奇[75]	脑电图数据集	23	是的
克莱默[74]	ECoG数据集	64	是的
安杰雅克[76]	脑电图数据集	128	是的

分为三类,即网络信息、有效负载信息和标签信息。网络信息包含

燃气管网站址及条件  
与站点地址和情况相对应的时间戳。  
有关系统控制和天然气管道状态的信息  
控制系统,例如其操作模式、压力测量、  
和控制方案,记录在有效负载信息中。标签  
包含燃气管道的当前状态,指示是否  
当前日期管道出现异常。在里面  
所呈现的数据集,状态被分类为正常或异常。

医学领域最常用的数据集是 CHB-MIT 头皮脑电图数据库[72]。它包含来自 23 名儿童的数  
据  
患有癫痫症,波士顿儿童医院使用国际  
10-20 个传感器记录来自大脑的所有脑电图信号。此外,  
该研究[73]还提供了其他脑电图数据集。收集到的数据集  
由加州大学伯克利分校癫痫中心提供[74]  
收集患者的皮层电图。数据集[75]由弗莱堡大学医院癫痫中心收集。

最终数据集[76]由来自五个人的脑电图记录组成  
患者。

另外,在其他领域,还有一些公开的时间序列图  
用于事件检测的数据集和多变量时间序列的时间序列点数据集。雅虎数据集[77]包括实际和

包含标记异常点的合成时间序列。数据集  
评估不同异常类别的准确性,例如  
可以检测到异常值和变化点。合成数据集是  
由具有不同程度的趋势、噪声和季节性的时间序列组成。异常检测常用的时间序列数据集

总结于表5 中。

8. 研究问题与挑战

尽管多元时间序列异常检测的方法和应用正在迅速发展,但该领域仍存在一些研究问题和挑战。在这里,我们列出了多元时间序列中异常检测的一些未决问题,这些问题可以在早期阶段检测异常,理解异常的含义,并解释异常的原因。

第一个是在多元时间序列的早期检测异常。及早发现异常的最常见策略是预测多元时间序列的未来变化。例如,由于主动虚拟机迁移通常漫长且耗时,因此尽快检测未来潜在的故障至关重要。

网络拥塞的检测是另一个重要的例子。交通系统拥堵是一个严重的问题[78]。尽快对异常情况 进行主动检测对于减少未来发生有害后果的可能性至关重要。参考号[79]提供了一种主动异常检测集成 (ADE)技术来处理上述问题,重点是早期异常检测。为了确定其准确性,随着时间的推移,针对特定数据集类型检查了每种策略。 ADE 根据之前对测量与训练数据集相同参数的数据的学习来检测输入数据中的任何异常。该方法根据用于训练模型的历史数据提供加权异常窗口。

通过预测多元时间序列很难在异常发生之前识别它们。对于某些非周期时间序列,预测性会受到多种因素的影响。因此,保持早期异常检测的高精度是一个重要的研究课题。在这里,我们提供了一种早期检测异常的新方法。我们假设多元模型中的异常是由历史时间点的微小变化引起的。例如,在交通系统中,车速过高是发生事故的原因之一。如果车辆速度快速增加,发生事故的可能性就很高。可以提取车速的变化,以便及早发现事故。还有很多问题需要利用这个想法来解决。高速并不是事故发生的唯一原因,事故的发生也不仅仅取决于速度。因此,发现异常与微小变化之间的关系是一个研究挑战。

第二个问题是发现这些异常的含义。现有的研究主要集中在检测给定数据集中的异常情况。了解这些异常的含义很重要。

异常模式的类型在多元时间序列中有所不同。一些罕见的模式经常被忽视,但这些异常很可能导致严重的灾难。例如,在金融时间序列中,人们主要关注欺诈检测。然而,在某些情况下,金融时间序列包含与金融危机相关的异常模式。

这些模式不是欺诈检测的目的,很容易被忽视。然而,这些异常模式的风险很大。

许多研究试图定义异常的含义,例如脑电图中的癫痫信号、金融时间序列中的金融欺诈以及仪表数据集中的能源盗窃。然而,理解大多数数据集中的异常事件是很困难的。例如,脑电图信号中存在许多异常放电,这些异常放电预示着某种疾病。如果只注重癫痫的检测而忽视其他异常模式,将会给患者带来很大的风险。因此,这些异常的分类具有挑战性。现有的分类方法基于监督学习模型,但我们无法标记脑电图信号中的所有异常。因此,需要一种通用的方法来理解各种异常模式的含义。

第三个问题是解释异常现象。了解异常的原因可以帮助人们分析异常并规避风险,而解释异常是一个重要的问题。在多元时间序列中,变量之间存在高度相关性。其中一个时间序列的微小变化可能会导致未来时间间隔内另一个时间序列的较大变化。因此,这个小小的改变可以

被认为是此异常的原因。此外,如果可以发现微小的变化,就可以在异常发生之前检测到它。这样的话,我们就可以在异常事件发生之前规避风险。

近年来,归因在气候变化检测领域得到了广泛的研究。研究人员通常从多元气象时间序列中检测气候变化,并试图确定气候变化的原因。里伯斯等人。 [80]将统计模型应用于全球平均气温,发现全球变暖主要归因于人为因素,自然因素的贡献有限。

异常现象的解释存在一些挑战。首先是如何发现与异常相关的模式。由于这些模式可能是时间序列中的微小变化,因此发现它们与异常之间的关系是一项研究挑战。有许多不同的异常模式。因此,开发解释异常的通用模型也是一个挑战。此外,多元时间序列的异常受到多种因素的影响。时间序列的规模影响异常的可解释性。如果多元时间序列的规模较大,则包含的信息量较大,解释异常的准确性较高。然而,大规模多元时间序列中的异常检测非常耗时。因此,开发大规模多元时间序列异常检测模型是一项研究挑战。

9. 结论

在本研究中,我们定义了多变量时间序列中发现的三类异常,即异常时间点、时间间隔和时间序列。此外,我们回顾了检测多元时间序列中每种类型异常的相应技术,以及异常检测在各个领域和几个开放数据集中的应用。最后,我们讨论了多元时间序列异常检测研究仍然面临的开放性问题和挑战。

异常时间点通常表示某个时间戳处的噪声或事件。为了检测此类异常,基本思想是应用回归模型来预测时间序列的未来值,然后计算预测值和真实值之间的损失,识别出现重大损失的异常时间点。

多元时间序列中的异常时间间隔通常表示在特定时期内发生的事件。检测异常时间间隔的主要方法是使用LSTM-AE模型重建每个时间间隔并确定输入和重建间隔之间的损失。如果损失大于某个阈值,则相应的时间间隔被检测为异常。然而,这种方法未能考虑多元时间序列之间的关系模式。因此,提出了基于动态图的方法。这些方法背后的想法是使用动态图来表示每个时间间隔的多元时间序列之间的关系,然后应用异常检测方法来确定该图是否对应于异常

时间间隔。

异常时间序列检测最常用的方法是降维。由于与数据集中的其他时间序列相比,异常时间序列表现出显著不同的模式,因此异常时间序列在低维特征空间中与其他时间序列相距甚远。因此,PCA成为检测异常时间序列的流行方法。

异常时间间隔检测比时间点和时间序列检测更重要,因为异常时间间隔通常代表一个事件。通过检测异常时间间隔,我们可以在各个领域创建广泛的应用。因此,我们也总结了多元时间序列异常检测在医学、物联网等不同领域的一些应用。



G.李和JJ Jung	信息融合91 (2023)93–102
<p>在这项研究中,我们提供了几个用于异常检测的开放数据集。这些数据集包含工业物联网、医疗、气象和智慧城市领域。每个数据集包含不同数量的时间序列,并且大多数给定数据集中都标记了异常。</p> <p>例如,所有给定的脑电图数据集都标记了癫痫发作间隔。可以使用标记数据来评估所提出的异常检测方法。</p> <p>本次调查提出了多元时间序列异常检测的三个未决问题。首先,我们提出,早期检测异常是多元时间序列中的一个研究挑战。困难在于发现有助于早期检测异常的模式。其次,理解时间序列中异常的含义也起着重要作用。在这种情况下,我们可以了解某个时间点发生的异常事件的类型。挑战在于开发一个模型来理解这些异常事件。最后,解释异常在异常检测领域很重要,用于解释异常的原因。挑战在于发现异常时间点和导致异常的时间点之间的关系。</p>	<p>[9] G. Li,JJ Jung,金融时间序列异常检测的动态关系识别,模式识别. 莱特。 145 (2021)194–199。</p> <p>[10] H. Nguyen,KP Tran,S. Thomassey,M. Hamad,使用 LSTM 和 LSTM 自动编码器技术进行预测和异常检测方法及其在供应链管理中的应用,Int. J.信息.管理。 57 (2021)102282。</p> <p>[11] L. Girish,SK Rao,使用人工智能技术进行云环境中的异常检测,计算 (2021)1–14。</p> <p>[12] W. Ullah,A. Ullah,IU Haq,K. Muhammad,M. Sajjad,SW Baik,利用双向 LSTM 实现监控网络实时异常检测的CNN功能,多媒体工具应用。 80 (11) (2021)16979–16995。</p> <p>[13]秦浩,严明,纪华,基于时间序列预测的控制器局域网 (CAN)总线异常检测应用,Veh.交流。 27 (2021) 100291。</p> <p>[14] N. Reunanen,T. Rätty,JJ Jokinen,T. Hoyt,D. Culler,传感器数据流中异常值的无监督在线检测和预测,Int. J.数据科学. 肛门。 (2019)1–30。</p> <p>[15] T. Kieu,B. Yang,C. Guo,CS Jensen,循环自动编码器集合的时间序列异常值检测,见:第二十八届国际人工智能联合会论文集,IJCAI-19,国际人工智能组织联席会议,奥地利维也纳,2019 年,第2725–2732 页。</p> <p>[16] C. Yin,S. Zhang,J. Wang,NN Xiong,基于卷积循环自动编码器的物联网时间序列异常检测,IEEE Trans.系统.曼赛博恩。 52 (1) (2022)112–122。</p> <p>[17] CY Priyanto,Hendry,HD Purnomo,结合隔离森林和 LSTM自动编码器进行异常检测,见:2021 年第二届创新和创意信息技术国际会议 (ICITech),印度尼西亚沙拉迪加, 2021 年,第 35–38 页。</p> <p>[18] JFA Yeung,Z.-k. Wei,KY Chan,HY Lau,K.-FC Yiu,使用机器学习算法进行金融时间序列的跳跃检测,软计算。 24 (3) (2020)1789–1801。</p> <p>[19] Y. Su,Y. Zhu,C. Niu,R. Liu,W. Sun,D. Pei,通过随机循环神经网络进行多元时间序列的鲁棒异常检测,见:第 25 届 ACM SIGKDD 国际会议论文集关于知识发现和数据挖掘,KDD 19,计算机协会,美国纽约州纽约市,2019 年,第 2828–2837 页。</p> <p>[20] S. Maleki,S. Maleki,NR Jennings,使用统计数据过滤的 LSTM 自动编码器进行无监督异常检测,Appl.软计算。 108 (2021) 107443。</p> <p>[21]陈浩,刘浩,储旭,刘强,薛大,基于LSTM-AE神经网络的风电机组异常检测与SCADA关键参数识别, Renew.能源 172 (2021) 829–840。</p> <p>[22]刘鹏,孙旭,韩宇,何志,张文,吴成,基于时间序列异常检测的LSTM自编码器心律失常分类,Biomed.信号处理. 控71 (2022)103228。</p> <p>[23] H. Homayouni,I. Ray,S. Ghosh,S. Gondalia,MG Kahn, COVID-19 时间序列数据中的异常检测,SN Comput.科学。 2 (4) (2021) 1–17。</p> <p>[24] M. Munir,SA Siddiqui,A. Dengel,S. Ahmed,Deepant:时间序列中无监督异常检测的深度学习方法, Ieee Access 7 (2018) 1991–2005。</p> <p>[25] N.丁,H.马,H.高,Y.马,G.谭,基于长短期记忆和高斯混合模型的实时异常检测,Comput.电.工程师。 79 (2019)106458。</p> <p>[26] T.-Y.金,S.-B. Cho,使用 C-LSTM 神经网络进行网络流量异常检测,专家系统.应用。 106 (2018)66–76。</p> <p>[27] OI Provotar,YM Linder,MM Veres,使用基于 LSTM 的自动编码器对时间序列进行无监督异常检测,见: 2019 年 IEEE 国际信息论高级趋势会议,ATIT,乌克兰基辅,2019 年,第513–517页。</p> <p>[28] F. Liu,X. Zhou,J. Cao,Z. Wang,T. Wang,H. Wang,Y. Zhang,基于自动数据分割和注意力LSTM-CNN的准周期时间序列异常检测, IEEE 传输.知道.数据工程34 (6) (2022)2626–2640。</p> <p>[29] D. Wu,Z. Jiang,X. Xie,X. Wei,W. Yu,R. Li,使用贝叶斯和高斯处理进行工业物联网异常检测的 LSTM 学习,IEEE Trans.工业信息。 16 (8) (2019)5244–5253。</p> <p>[30] K. Vos,Z. Peng,C. Jenkins,MR Shahriar,P. Borghesani,W. Wang,使用 LSTM/SVM 方法进行基于振动的异常检测,Mech.系统.信号处理。 169(2022)108752。</p> <p>[31] C.-W.张,C.-Y.张,Y.-Y. Lin,一种基于 CNN 和 LSTM 的混合深度学习模型,用于异常行为检测,多媒体工具应用。 (2022) 1–19。</p> <p>[32] S. Lin,R. Clark,R. Birke,S. Schönborn,N. Trigoni,S. Roberts,使用 VAE-LSTM 混合模型进行时间序列异常检测,见:ICASSP 2020 - 2020 IEEE国际声学会议,语音和信号处理,ICASSP,虚拟,巴塞罗那, 2020 年,第 4322–4326 页。</p> <p>[33] Z. Niu,K. Yu,X. Wu,基于 LSTM 的用于时间序列异常检测的 VAE-GAN, Sensors 20 (13) (2020) 3738。</p> <p>[34] A. Deng,B. Hooi,多元时间序列中基于图神经网络的异常检测,载于:AAAI 人工智能会议论文集,卷。 35, (5)2021,第 4027–4035 页。</p>
CRediT 作者贡献声明	
<p>李根:概念化、方法论、软件、验证、形式分析、调查、数据管理、写作 - 初稿、可视化。 Jason J. Jung:概念化、资源、写作审查和编辑、监督、项目管理、资金获取。</p>	
竞争利益声明	
<p>作者声明,他们没有已知的可能影响本文报道的工作的相互竞争的经济利益或个人关系。</p>	
数据可用性	
<p>文章中描述的研究没有使用任何数据。</p>	
致谢	
<p>这项研究得到了韩国政府 (MSIP) 资助的韩国国家研究基金会 (NRF) 的资助 (NRF-2020R1A2B5B01002207)。所有作者都批准了要出版的手稿版本。</p>	
参考	
[1] S. Dwivedi,M. Vardhan,S. Tripathi,使用用于异常检测的 Grasshopper 优化算法构建高效的入侵检测系统,集群计算。 (2021)1–20。	
[2] I. Siniosoglou,P. Radoglou-Grammatikis,G. Efstathopoulos,P. Fouliras,P. Sarigiannidis,智能电网环境的统一深度学习异常检测和分类方法,IEEE Trans.网络.服务.马纳格。 18 (2) (2021)1137–1151。	
[3] K. Choi,J. Yi,C. Park,S. Yoon,时间序列数据异常检测的深度学习:回顾、分析和指南,IEEE Access 9 (2021) 120043–120065。	
[4] KG Ranjan,DS Tripathy,BR Prusty,D. Jena,一种改进的基于滑动窗口预测的波动时间序列异常值检测和校正,Int. J. 数字.建模,电子.网络.设备字段 34 (1) (2021) e2816。	
[5] S. Wang,B. Li,G. Li,B. Yao,J. Wu,基于多维数据清洗和特征重构的短期风电功率预测,Appl.能源292 (2021)116851。	
[6] G. Li,JJ Jung,使用基于熵的动态图嵌入进行多通道脑电图癫痫发作检测,Artif.英特尔.医学。 122 (2021) 102201。	
[7] Z. Chen,D. Chen,X. Zhang,Z. Yuan,X. Cheng,使用变压器学习图结构用于物联网中的多元时间序列异常检测,IEEE Internet Things J. 9 (12) (2022) 9179–9189。	
[8] F. Passerini,AM Tonello,使用电力线调制解调器进行智能电网监控:异常检测和定位,IEEE Trans.智能电网10 (6) (2019) 6178–6186。	

[35] H. Zhao, Y. Wang, J. Duan, C. Huang, D. Cao, Y. Tong, B. Xu, J. Bai, J. Tong, Q. Zhang, 通过图注意力网络进行多元时间序列异常检测, 见: 2020 年 IEEE 国际数据挖掘会议, ICDM, IEEE, 2020 年, 第841-850 页。

[36] G. Li, JJ Jung, 用于多个气象时间序列异常值检测的动态图嵌入, Plos One 16 (2) (2021) e0247119。

[37] T. Höfer, H. Przyrembel, S. Verleger, 群理论的新证据, Paediatr. 佩里纳特, 流行病。 18 (1) (2004) 88-92。

[38] G. Li, JJ Jung, 用于多气候时间序列异常检测的基于熵的动态图嵌入, Sci. 报告 11 (1) (2021) 1-10。

[39] G. Li, T.-H. Nguyen, JJ Jung, 基于车辆边缘计算动态图嵌入的交通事件检测, Appl. 科学。 11 (13) (2021) 5861。

[40] L. Beggel, B. X. Kausler, M. Schiegg, M. Pfeiffer, B. Bischl, 基于 shapelet 学习的时间序列异常检测, Comput. 国家主义者。 34 (3) (2019) 945-976。

[41] M.-S. Zhang, M.-C. Wu, S.-H. Huang, 基于遗传算法的时空关系网络的可解释股票异常检测, IEEE Access 9 (2021) 68302-68319。

[42] 李德, 陈德, 金本, 石L, J. Goh, S.-K. Ng, MAD-GAN: 使用生成对抗网络对时间序列数据进行多变量异常检测, 见: IV Tetko, V. K. rková, P. Karpov, F. Theis (编者), 人工智能和机器学习 - ICANN 2019: 文本和时间序列, Springer International Publishing, Cham, 2019 年, 第 703-716 页。

[43] J. Audibert, P. Michiardi, F. Guyard, S. Marti, MA Zuluaga, USAD: 多变量时间序列上的无监督异常检测, 见: 第 26 届 ACM SIGKDD 知识发现与数据挖掘国际会议论文集, KDD 20, 计算机协会, 美国纽约州纽约市, 2020 年, 第3395-3404 页。

[44] G. Li, X. Zhou, J. Sun, X. Yu, Y. Han, L. Jin, W. Li, T. Wang, S. Li, OpenGauss: 一个自治数据库系统, Proc. VLDB 捐赠。 14 (12) (2021) 3028-3042。

[45] K. Hundman, V. Constantinou, C. Laporte, J. Colwell, T. Soderstrom, 使用 LSTM 和非参数动态阈值检测航天器异常, 见: 第 24 届 ACM SIGKDD 国际知识发现与数据挖掘会议论文集, KDD 18, 计算机协会, 美国纽约州纽约市, 2018 年, 第 387-395 页。

[46] Y. Su, Y. Zhu, C. Niu, R. Liu, W. Sun, D. Pei, 通过随机循环神经网络进行多元时间序列的鲁棒异常检测, 见: 第 25 届 ACM SIGKDD 国际会议论文集关于知识发现和数据挖掘, KDD 19, 计算机协会, 美国纽约州纽约市, 2019 年, 第 2828-2837 页。

[47] J. Li, S. Di, Y. Shen, L. Chen, Fluxev: 一种快速有效的时间序列异常检测无监督框架, 见: 第 14 届 ACM 国际网络搜索和挖掘会议论文集, WSDM 21, 计算机协会, 美国纽约州纽约市, 2021 年, 第 824-832 页。

[48] S. S. Lee, P. Mykland, 金融市场的跳跃: 新的非参数测试和跳跃动态, Rev. Finance. 螺柱。 21 (6) (2008) 2535-2563。

[49] T. T. Huong, T. P. Bac, D. M. Long, T. D. Luong, N. M. Dan, B. D. Thang, K. P. Tran 等人, 使用工业控制系统中的异常检测来检测网络攻击: 联邦学习方法, Comput. 印度 132 (2021) 103509。

[50] D. K. Sharma, T. D. Dhankhar, G. Agrawal, S. K. Singh, D. Gupta, J. Nebhen, J. Razzak, 防止雾中 DDoS 攻击的异常检测框架, 支持物联网网络 Ad Hoc Netw. 121 (2021) 102603。

[51] P. Zhan, S. Wang, J. Wang, L. Qu, K. Wang, Y. Hu, X. Li, IIoT 制造的时间异常检测, J. Intell. 制造商。 32 (6) (2021) 1669-1678。

[52] A. N. Dau, A. Bagnall, K. Kamgar, C.-C. M. Yeh, Y. Zhu, S. Gharghabi, C. A. Ratanamahatana, E. Keogh, UCR 时间序列档案, IEEE/CAA J. Autom. 罪。 6 (6) (2019) 1293-1305。

[53] Z. Xiao, J. Jiao, 少量标记时间序列数据的可解释欺诈检测, 安全。交流。网络。 2021 (2021) 9941464。

[54] I. Benchaji, S. Douzi, B. El Ouahidi, 基于 LSTM 递归神经网络的信用卡欺诈检测模型, J. Adv. 信息。技术。 12 (2) 113-118。

[55] E. D. Andrea, F. Marcelloni, 交通拥堵和事件检测 GPS 轨迹分析, 专家系统。应用。 73 (2017) 43-56。

[56] D. Wijayasekara, O. Linda, M. Manic, C. Rieger, 使用模糊异常检测和语言描述挖掘建筑能源管理系统数据, IEEE Trans. 工业信息。 10 (3) (2014) 1829-1840。

[57] J.-S. Chou, A. S. Telaga, 异常功耗实时检测, Renew. 维持。能源修订版 33 (2014) 400-411。

[58] D. B. Araya, K. Grolinger, H. F. El Yamany, M. M. Capretz, G. Bitsuamlak, 智能建筑集体上下文异常检测框架, 见: 2016 年国际神经网络联合会议, IJCNN, 加拿大温哥华, 2016 年, 第 511 页-518。

[59] S. You, B. H. Cho, Y.-M. 肖恩, D.-W. Seo, I. Y. Kim, 使用个性化异常检测变分自动编码器和耳后脑电图进行半监督自动癫痫发作检测, 计算机。方法计划生物医学。 213 (2022) 106542。

[60] V. Rajinikanth, S. Kadry, D. Taniar, K. Kamalanand, M. A. Elaziz, K. P. Thanaraj, 使用同步提取变换 (SET) 支持的分类技术检测 EEG 信号中的癫痫, J. Ambient Intell. 人性化。计算。 (2022) 1-19。

[61] G. Varone, W. Boulila, M. Lo Giudice, B. Benjdira, N. Mammone, C. Ieracitano, K. Dashtipour, S. Neri, S. Gasparini, F. C. Morabito 等人, 机器学习涉及功能连接特征的方法, 用于对健康对照组的静息脑电图中心因性非癫痫发作进行分类, Sensors 22 (1) (2022) 129。

[62] M. L. Martini, A. A. Valliani, C. Sun, A. B. Costa, S. Zhu, F. Panov, S. Ghatan, K. Rajan, E. K. Oermann, 利用配对立体脑电图和视频记录对癫痫发作进行深度异常检测, Sci. 代表。 11(1) (2021) 1-1。

[63] S. Chaabene, B. Bouaziz, A. Boudaya, A. Hökelmann, A. Ammar, L. Chaari, 使用 EEG 信号进行睡眠检测的卷积神经网络, 传感器 21 (5) (2021) 1734。

[64] L. Erhan, M. Ndubaku, M. Di Mauro, W. Song, M. Chen, G. Fortino, O. Bagdasar, A. Liotta, 传感器系统中的智能异常检测: 多视角综述, Inf. 融合 67 (2021) 64-79。

[65] F. Forooghifar, A. Aminifar, T. Teijeiro, A. Aminifar, J. Jeppesen, S. Beniczky, D. Atienza, 低功耗可穿戴心电图设备癫痫监测的自我意识异常检测, 见: 2021 年 IEEE 第三届人工智能电路与系统国际会议, AICAS, IEEE, 2021 年, 第1-4 页。

[66] R. Jain, H. Shah, 以无线传感器网络为模型的智能城市异常检测, 见: 2016 年信号与信息处理国际会议 (ICONSIP), 印度 Nanded, 2016 年, 第 1-5 页。

[67] R. N. Madurawe, B. I. Jayaweera, T. D. Jayawickrama, J. Perera, R. Withanawasam, 使用图聚类进行股票市场内的共谋集检测, 异常检测, 见: 2021 Moratuwa 工程研究会议 (MERCon), 斯里兰卡, 2021 年, 第 450-455 页。

[68] S. Pan, T. Morris, U. Adhikari, 使用电力系统数据挖掘开发混合入侵检测系统, IEEE Trans. 智能电网 6 (6) (2015) 3104-3113。

[69] J. M. Beaver, R. C. Borges-Hink, M. A. Buckner, 检测恶意 SCADA 通信的机器学习方法的评估, 载于: 2013 年第 12 届机器学习与应用国际会议, 卷。 2, 美国华盛顿, 2013 年, 第 54-59 页。

[70] T. Morris, W. Gau, 用于入侵检测研究的工业控制系统流量数据集, 见: J. Butts, S. Sheno (编辑), 关键基础设施保护 VIII, 施普林格柏林海德堡, 柏林, 海德堡, 2014 年, 第 65-78 页。

[71] T. H. Morris, Z. Thornton, J. Turnipseed, 用于入侵检测系统研究的工业控制系统仿真和数据记录, 载于: 第七届年度东南网络安全峰会, 2015 年, 第 3-4 页。

[72] A. Shoeb, H. Edwards, J. Connolly, B. Bourgeois, S. T. Treves, J. Gutttag, 患者特异性癫痫发作检测, 癫痫行为。 5 (4) (2004) 483-498。

[73] M. K. Siddiqui, R. Morales-Menendez, X. Huang, N. Hussain, 使用机器学习分类器检测癫痫发作的综述, Brain Inform. 7 (1) (2020) 1-18。

[74] M. A. Kramer, E. D. Kolaczyk, H. E. Kirsch, 人类癫痫发作时的紧急网络拓扑, 癫痫研究。 79 (2-3) (2008) 173-186。

[75] A. Schulze-Bonhage, F. Sales, K. Wagner, R. Teotonio, A. Carius, A. Schelle, M. Ihle, 癫痫患者对癫痫发作预测设备的看法, 癫痫行为。 18 (4) (2010) 388-396。

[76] R. G. Andrzejak, K. Lehnertz, F. Mormann, C. Rieke, P. David, C. E. Elger, 脑电活动时间序列中非线性确定性和有限维结构的指示: 对记录区域和大脑状态的依赖性, 物理。修订版 E 64 (6) (2001) 061907。

[77] K. Yoshihara, K. Takahashi, 一种无监督异常检测的简单方法: 网络时间序列数据的应用, PLoS One 17 (1) (2022) e0262463。

[78] 马晓明, 于华, 王宇, 王宇, 利用深度学习理论的大规模交通网络拥堵演化预测, PLoS One 10(3) (2015) e0119044。

[79] T. S. Buda, H. Assem, L. Xu, A. D. E. 早期异常检测的集成方法, 见: 2017 年 IFIP/IEEE 集成网络和服务管理研讨会, JM, 葡萄牙里斯本, 2017 年, 第 442 页-448。

[80] A. Ribes, F. W. Zwiers, J.-M. Azais, P. Naveau, 气候变化检测和归因的新统计方法, Clim. 动态。 48 (1) (2017) 367-386。