



审查

基于深度学习的遥感变化检测 图片:评论

阿伊莎·沙菲克¹, Guo Cao^{1,*}, 齐亚·汗², 穆罕默德·阿萨德³和穆罕默德·阿斯拉姆⁴¹ 南京理工大学计算机科学与工程学院, 南京 210094; ayeshashafique@njust.edu.cn中南大学计算机系, 长沙 410083; zia.official@csu.edu.cn名古屋工业大学² 计算机科学系, 日本爱知县名古屋 466-8555; m.asad@itolab.nitech.ac.jp 西苏格兰大学计算、工程和物理科学学院, 布兰太³ 尔, 格拉斯哥 G72 0LH, 英国; muhammad.aslam@uws.ac.uk *通讯地址: caoguo@njust.edu.cn⁴

摘要:由于遥感 (RS) 技术的快速发展, 如今从不同卫星收集的图像已经广泛可用。这些图像显著增强了变化检测 (CD) 的数据源。CD 是一种识别以不同时间间隔获取的图像中的差异的技术, 并用于许多应用, 例如城市地区开发、灾害管理、土地覆盖对象识别等。近年来, 深度学习 (DL) 技术已得到广泛应用。它在变化检测过程中得到了广泛的应用, 并因其实际应用而取得了巨大的成功。一些研究人员甚至声称深度学习方法优于传统方法并提高了变化检测的准确性。因此, 本综述重点关注针对不同变化检测数据集 (例如 SAR、多光谱、高光谱、VHR 和异构图像) 的监督、无监督和半监督等深度学习技术, 并将重点介绍它们的优缺点。最后, 讨论了一些重大挑战, 以了解变化检测数据集和深度学习模型改进的背景。总的来说, 这次审查将有利于 CD 方法的未来发展。



引文: 沙菲克, A.; 曹, G.; 汗, Z.; 阿萨德, M.; Aslam, M.

基于深度学习的遥感图像变化检测: 综述。

关键词: 变化检测方法; 遥感影像; SAR 图像; 多光谱图像; 高光谱图像; VHR 图像; 异构图像; 深度学习遥感, 2022, 14, 871. <https://doi.org/10.3390/rs14040871>

Academic Editor: Qi Wang

收件日期: 2021 年 12 月 23 日

接受日期: 2022 年 2 月 5 日

发布日期: 2022 年 2 月 11 日

出版商注: MDPI 对于已出版地图和机构隶属关系中的管辖权主张保持中立。

关系。



版权所有: © 2022 作者。

被许可方 MDPI, 瑞士巴塞尔。

本文是一篇开放获取文章

根据条款和

知识共享的条件

归属 (CC BY) 许可证 (<https://creativecommons.org/licenses/by/4.0/>)。

4.0/。

1. 简介和背景随着遥感技术的进

步, 遥感平台收集广泛数据的能力越来越强。这些可用数据已成为通过检测地表变化进行环境监测的关键资源。

变化检测 (CD) 是通过观察不同时期拍摄的一组图像来检测同一地理区域的变化现象[1-3]。由于其广泛应用于火灾探测、环境监测[4]、灾害监测[5]、城市变化分析[6]和土地管理[7]等多种实际应用中, 它引起了广泛的兴趣。因此, CD 越来越受到世界各地研究人员的关注。

RS 数据包含有限的时间、空间和光谱分辨率, 这极大地限制了基于 RS 的 CD 方法。然而, 具有更强大技术能力的传感器的开发已经克服了许多这些限制。因此, 研究人员研究了一套不断扩展的方法、算法和程序来检测变化。在遥感方面, 已经在太空发射了多种类型的卫星, 例如有源或无源、光学或微波传感器, 并且具有高分辨率或低分辨率。

卫星数据集是描述城市土地利用/覆盖类型及其随时间变化的宝贵数据源。检测卫星图像变化的各种方法

已被开发用于发现物体或现象状态的变化[8]。对于 CD，多模态遥感图像，例如合成孔径雷达 (SAR) [9,10]、多光谱 (MS)、或已使用从有源传感器获取的高光谱 (HS) 图像 (SAR)、无源光学传感器 (MS) 等。

在过去的几十年里，已经开发了各种 CD 方法。传统的 CD 方法可以根据分析单元分为两类：

基于像素的 CD (PBCD) 和基于对象的 CD (OBCD)。PBCD 是传统方法通过比较像素来识别变化，因此无法克服限制不同日期或传感器之间的辐射变化和重合失调。因为图像对象之间增加的可变性，PBCD 方法，通常是适用于中低分辨率 RS 图像，在 VHR 中经常无法操作图像。OBCD 解决了这些问题并显著提高了 CD 准确性。针对 VHR 图像 CD 提出了基于 OBCD 的技术，其中图像被分割成不相交和同质的对象，然后比较和分析双时对象。PBCD 和 OBCD 的不同方法如图 1 所示。

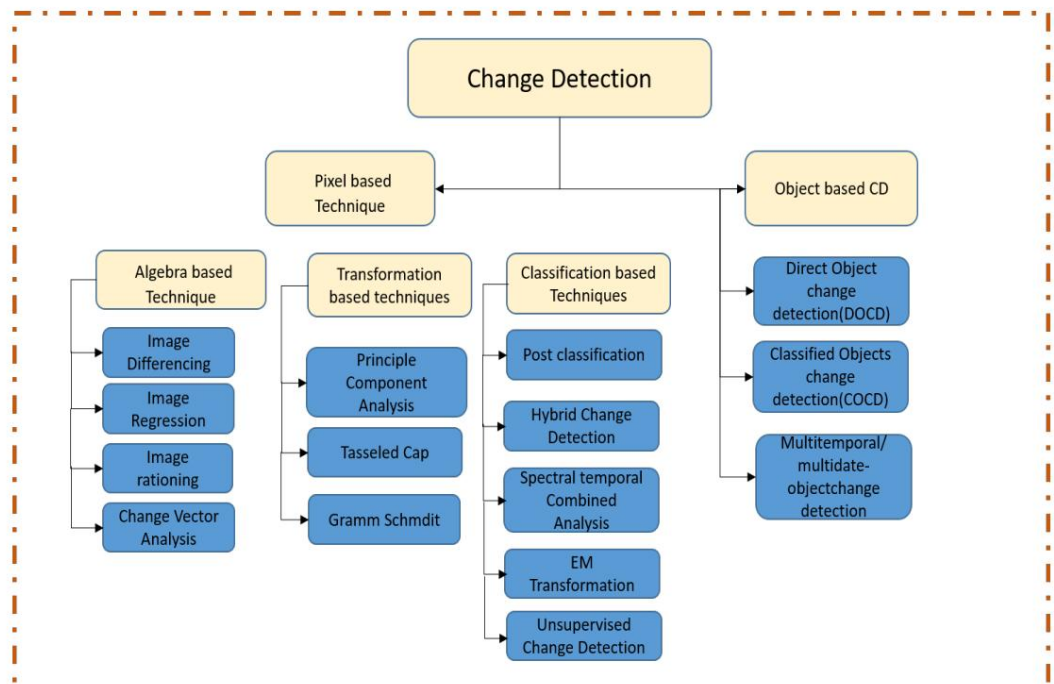


图 1.传统的变更检测方法。

许多传统的变化检测技术，例如图像代数[11]和变换[12]，它们的应用相对有限，并且受到大气条件、季节变化、卫星传感器和太阳高度角的影响，降低了变化检测的准确性[13,14]。虽然具体方法，例如基于对象的图像分析，通过提取几何和纹理特征来减少错误变化，这需要一个烦人且耗时的过程。他们有效地消除了自动化 CD 方法的好处。此外，由于阈值的选择，识别变化区域很困难[15]。提出无监督方法是为了方便通过使用期望最大化算法进行阈值选择来进行变化检测。然而，选择合适的标准来捕获所有变化区域，同时消除不需要的变化区域仍然具有挑战性。此外，基于分类的CD方法[16]将图像的像素转换为土地覆盖类别，而不需要随机噪声改变身份[17-19]。大多数以前的监督或无监督技术都依赖于手工制作的特征表示，其表示能力有限描述复杂且高层的变更信息，导致性能低下在杂乱的土地覆盖下。前面描述的所有分类方法都是

适合训练样本。然而,这些方法不能包含具体的和许多数据集的可靠统计特征,因此不会产生高检测率新数据集的性能。每个方案仅关注该领域的几个方面同时忽视其他人。在缺乏一个清晰明确的定义来整合所有内容的情况下就相关方面而言,RS CD 技术的概念仍然模糊。

深度学习方法自动发现输入数据的表示CD 所需。最近,RS领域的一款基于DL的CD成为了“热点”,引起广泛关注并取得良好效果。近年来,为了识别变化RS图像,DL可以自动导出复杂的、层次的、非线性的特征从原始数据中获取并克服传统变化检测方法的一些局限性。由于深度学习方法具有巨大的建模和学习能力将图像对象与其现实世界地理元素之间的联系表示为尽可能接近,允许更多真实世界的变化信息[20,21]。

1.1.本研究的贡献

过去十年来,文献中发表了各种调查研究,审查用于变化检测的各种机器和深度学习模型以及几乎所有在遥感图像 CD 领域发表的评论被认为表明该领域研究贡献的总体情况。表1总结了这些工作迄今为止已发布。发表在知名期刊上的一篇论文[22]重点关注基于深度学习的遥感方法。评论论文[23]讨论了基于像素的基于对象的变化检测方法并强调了一些问题。在[24]中,作者回顾了基于人工智能的 CD 技术。 [25]的作者回顾了对CD的分析RS 应用的技术,但他们没有强调当前 CD 的挑战深度学习中的方法。一些评论论文[26]重点关注高光谱和多光谱图像 CD,但仍然缺乏对所有 RS 数据集进行评论讨论了深度学习中的变化检测,强调了其挑战。

表 1.关于变化检测的调查论文摘要。

参考	出版商	出版年份	引文
[2]	泰勒和弗朗西斯	1989年	4834
[27]	泰勒和弗朗西斯	2002年	60
[28]	泰勒和弗朗西斯	2004年	3595
[29]	泰勒和弗朗西斯	2012年	510
[23]	爱思唯尔	2013年	1219
[30]	爱思唯尔	2016年	134
[31]	IEEE	2016年	1295
[22]	其他的	2017年	第411章
[20]	IEEE	2017年	第1475章
[32]	爱思唯尔	2018年	124
[33]	IEEE	2019年	90
[21]	ISPRS	2019年	第689章
[26]	MDPI	2019年	11
[34]	IEEE	2020年	48
[24]	MDPI	2020年	76
[25]	爱思唯尔	2020年	8

据我们所知,还没有任何工作探索当前的进展和最常用的遥感数据集,例如 SAR、多光谱、高光谱、VHR 和异质数据集

通过单独使用深度学习来生成 CD 的新图像,并在一个平台上以特定且全面的方式将其按监督、无监督和半监督等类别呈现。没有一篇评论基于深度学习方法单独从数据集的角度讨论 CD。我们详细介绍了用于 CD 的不同传感器的数据,主要包括 SAR、多光谱、高光谱、VHR 和异构图像。我们还在本次审查结束时强调了一些需要解决的挑战。这篇综述将有助于新研究人员了解该领域社区所面临的问题和挑战。此外,本文分析了文献中发现的研究空白,这将帮助未来的研究人员识别和探索 RS CD 领域深度学习的新途径。

1.2. 这项工作的组织

本文综述的概要如下。第2部分解释了纳入和排除标准。第三节重点介绍遥感传感器和数据集分析,涵盖SAR、多光谱、高光谱、VHR和异构图像的数据集。第4节介绍了变更检测架构。第5节介绍了使用基于深度学习的网络对遥感数据集进行变化检测的文献综述。

第6节阐述了评估技术。第7节重点介绍了讨论,最后,第8节总结了本文。

2. 研究纳入/排除标准

首先,设置搜索标准以从所选来源中提取最多的出版物。为了收集更多相关文章,选择标准分为三个部分。第一阶段对文章标题进行验证,剔除重复、不相关的论文。我们研究了第一步收集的文章摘要,在第二阶段,挑选与指定领域相关的论文。在这个过程的最后,我们深入检查了每篇论文并最终确定了本研究的论文。我们回顾了2015年至2021年期间发表的该领域的重要研究论文,主要是2019年和2020年的论文,还有一些2021年的论文。主要关注的是来自最著名出版商的论文,例如Elsevier、IEEE和Remote Sensing。部分最新论文选自IGRASS和ISPRS等会议。我们针对每种类型的数据集回顾了68篇关于深度学习变化检测的论文。我们的重点是对深度学习中CD的RS数据集进行回顾。图2显示了各年度出版物的详细信息。

此外,第5.1-5.5节介绍了数据集和类别讨论。




图 2. 2015 年至 2021 年期刊中逐年发表的论文。

3. 用于变化检测的遥感数据集

3.1.用于收集变化检测数据集的传感器

最近,不同类型的卫星被发射到太空,包括现役卫星无源、光学和微波传感器,以及高分辨率和低分辨率。卫星图像是确定城市土地利用/覆盖形式及其变化的良好数据来源随着时间和空间的变化[35]。卫星上安装了不同的遥感设备来收集有关地球表面上的物体,但与该物体没有直接的物理接触。比较时对于空中和地面平台来说,星载平台是最稳定的载体。那里是传感器与地球表面之间的两种交互模式:主动和被动。有源传感器产生能量来照亮物体并测量观测结果。被动的卫星传感器包括 Landsat、GeoEye、SPOT、EROS 和 WorldView 航天器[36]。由于最近传感器的发展,例如 TerraSAR-X [37]和 COSMO-SkyMed,以亚公制分辨率或非常高的时间分辨率运行,例如 Sentinel-1,以及一系列确保数十年连续测量的系统,我们现在可以考虑在许多民用部门中进行操作应用,例如 M 环境监测以及货物和人员的安全,以及许多其他地球物理科学领域。 SAR 图像的关键属性是其分辨率和地理覆盖范围,以及频率范围、入射角和发射/接收偏振获得的信号。一般来说,在遥感中使用 SAR 图像需要几何和辐射校准,可以按照方法完成由发送数据报道的机构描述。需要进行几何在将 SAR 图像用于遥感之前对其进行辐射校准。

然而,MS RS 在数据可用性方面具有优势。 MS RS 系统使用平行框架传感器用于检测几个波段 (通常是三到六个光谱)的辐射可见光到红外波段。除了这些频段外,还有各种卫星频段传感器捕获一个或两个热带中的图像。因此,MS 卫星传感器更少但更宽的光谱带,无法探测到陆地表面的微小细节并且不允许分离具有微小光谱反射差异的物体[38]。虽然高光谱遥感传感器可以捕获各种窄范围的图像电磁波谱中的光谱带,范围从可见光到近红外,中红外和热红外,HS传感器可以捕获200个波段或更多波段的能量,这意味着它们连续覆盖场景中每个像素的反射光谱。高光谱成像中使用两种不同类型的图像捕获系统:飞机 (AVIRIS)和卫星 (EO-10 上的 Hyperion)。大多数高光谱传感器部署在空中平台上,卫星上的传感器较少[39-42]。随着地球观测技术的进步,更先进的卫星传感器,例如 QuickBird、SPOT 等正在推出,旨在收集 VHR 图片。表2总结了最常用的 RS 卫星及其规格。

表 2.提供了最广泛使用的 RS 卫星及其特性的详细信息[43-45]。

卫星/传感器	国家	年	重访 (日)	空间分辨率 (米)
科斯莫	意大利	2010年	5	15米
Gaofen 3	中国	2016年	5	1-500米
陆地卫星 9	鹿	2020年	16	15米
TerraSAR-X	德国	2007年	2.5-11 天	1-16
点7	鹿	2014年	1-3	1.5米
ERS2	那	1995年	第336圈	6-30 m
雷达卫星	加拿大	2018年	1	3-100米
海伯利安 (EO-1)	鹿	2000年	2-16	30米

表 2. 续

卫星/传感器	国家	年	重访 (日) 2 天	空间分辨率 (米)
阿洛斯	日本	2006年		2.5、10m
图标	鹿	1999年	3	1米、4米
快鸟	鹿	2001年	2.4-5.9	2.61米
环境卫星	那	2002年	35天	300米
地球眼	鹿	2008年	8.3	0.41米
世界观1	鹿	2007年	1.7	0.5米
世界观2	鹿	2009年	1.1	0.46米
世界观3	鹿	2014年	<1	1.24米
世界观4	鹿	2016年	3	0.34米
哨兵-1	那	2014年	12	5-20米
哨兵2号	那	2015年	10	10-60 m
哨兵3号	那	2016年	27	5-40 m
哨兵4号	那	2019年	1	10米
哨兵5号	那	2014年	<1	20米
哨兵6号	那	2020年	9	60米

3.2. 用于变化检测的数据集

本节介绍 CD 常用的不同类型 RS 数据集,例如 SAR、多光谱、高光谱、VHR 和异构图像。

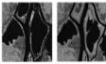
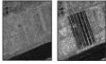
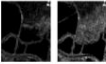
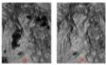
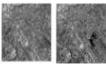
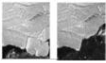

3.2.1. SAR图像

SAR 是一种产生二维图像或三维图像的雷达物体的重建,例如风景[46]。这是一种远程测绘技术具有高空间分辨率的物体或其周围环境的反射率,通过发送并接收电磁 (EM)信号。使用该方法获得的图像可以用于广泛的应用,从基本雷达功能,例如物体检测和地理定位,以估计某些地球物理特性复杂的环境,例如某些尺寸、粗糙度、含水量、密度、等。SAR 数据是从反射反向散射的有源微波传感器捕获的全天候条件下的土地覆盖信息。由于其

不受日照条件影响,SAR 图像为变更检测任务。由于 SAR 常用的频域设备,这种主动传感技术不受阳光的影响,但只有轻微的影响天气。基于航空或卫星传感器的 SAR 系统可快速扫描大片区域使用现场测量无法达到。这种特性使得雷达成像系统是一种特别适合 RS 的仪器[47]。此外,负面的几何畸变和电磁干扰的影响,例如目标重叠,SAR 中必须解决视角收缩和多径效应问题[48]。表3列出 SAR最常用的CD数据集,包括渥太华数据集、伯尔尼数据集[49]、旧金山数据集[50]、Farmland 等。数据集链接如下:

1. Bern数据集开源: <https://github.com/yolalala/RS-source> (22 日访问 2021 年 12 月)。
2. 旧金山数据集开源: <https://github.com/yolalala/RS-source> (已访问 2021 年 12 月 22 日)。
3. 农田数据集开源: <https://share.weiyun.com/5M2gyVd> (22 日访问 2021 年 12 月)。

表 3. SAR 数据集说明。

卫星	区域	数据集名称	图像	像素	日期
雷达卫星合成孔径雷达	加拿大	渥太华		290 × 350	1997 年 5 月至 8 月
雷达卫星2号	中国	黄河		257 × 289	2008年6月 2009年6月
ERS-2	我们	旧金山		256 × 256	2003年8月 2004年5月
陆地卫星 ETM+	墨西哥	墨西哥		512 × 512	2000年4月 2002年3月
ERS-2	瑞士	伯尔尼		301 × 301	1999 年 4 月至 5 月
环境卫星	日本	苏兹伯格		256 × 256	2011年3月
雷达卫星2号	中国	北京		1024 × 1024	2010年10月

多波段、多偏振、多平台SAR图像日益增多
随着 SAR 成像技术的进步,这种技术越来越常见,为 CD 任务提供了更多的数据源。
另一方面,SAR图像总是存在散斑噪声,使得变化检测更加困难
比光学 RS 图像困难。

3.2.2.多光谱图像


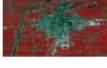


多光谱图像 (MSI) 收集整个电磁频谱的图像数据
在某些波长范围内。 MSI可以提取人眼无法识别的额外信息
无法用其视觉感受器捕获红色、绿色和蓝色[51]。波长可以
通过过滤器分离或使用敏感仪器检测,包括来自可见光范围之外的频率的光,即红外线和紫外线。
MSI 通常通过以下方式获取
一种无源光学传感器,可收集多种光谱中地面物体的信息
乐队。可以廉价地获得空间分辨率从低到高的 MSI,并且
始终如一。还提供了充满活力的纹理、颜色和其他功能。 MSI措施
无论外部光源如何,物体固有的辐射[52-55]。这包括
获取几个宽波长的可见光、近红外和短波红外图像
乐队。不同的材料对不同波长的反射和吸收不同。遥感图像的分辨率各不相同;各种分辨率的应用
场景
多光谱图像略有不同。 MS图像通常用于CD,基于深度学习的CD算法最常用的MS图像来自Landsat
[56-63]
和 Sentinel 系列[64,65]卫星,因为它们的收集成本低,时间成本高
和空间覆盖。此外,其他卫星,例如 QuickBird.SPOT [66-68]、
高分[69,70]和Worldview提供非常高的空间分辨率图像,而其他
提供非常高的空间分辨率航空[71]图像,使CD的发现得以保留
有关更改的更多详细信息。多光谱数据集分为广谱数据集和局部多光谱数据集
区域变化数据集。

3.2.3.广域数据集

它集中于整个大覆盖区域的变化,而忽略了
零星目标的详细信息。多光谱 (MS)数据集由携带卫星的卫星获得
成像光谱仪作为最容易获取和直观的遥感图像。
EROS 数据中心的美国西南部 CD 图像[72]是第一个开源数据集
用于使用变化向量来解释绿化和亮度变化的 CD 任务。

属于它的数据集是美国西南变化检测数据集、MtS-WH、台州数据集[73]、Onera卫星变化检测数据集[74]和NASA地球观测站变化数据集。广域数据集的一些示例在表4。

表 4. 广域数据集说明。

卫星	区域	数据集名称	图像	像素	日期
世界观-2	天使们	我们		322 × 266	1986年–1992年
陆地卫星7号	中国	昆山		400 × 400	2000年3月 2003年2月
图标	中国	MtS-WH		7200 × 6000	2002年2月 2009年6月
哨兵2号	阿联酋	向善		700×700 1200×1200	2015–2018

广域数据集链接如下

1. 美国西南部数据集开源: <https://geochange.er.usgs.gov/sw/changes/> 人为/维加斯 (2021 年 12 月 22 日访问)。
2. MtS-WH数据集开源: 来源: <http://sigma.whu.edu.cn/newspage.php?q=2019-03-26> (2021 年 12 月 22 日访问)。
3. NASA地球观测站数据集开源: <https://earthobservatory.nasa.gov/image/146194/坎昆如何成长为主要度假村> (12 月 22 日访问 2021)。
4. Onera卫星数据集开源: <https://ieee-dataport.org/open-access/oscd-onera-satellite-change-detection> (2021 年 12 月 22 日访问)。




3.2.4. 本地区域数据集

调查城市地区的某些目标至关重要,例如建筑物、河流、道路、HR RS图像是人工神经网络变化的主要数据源目标和细节区域。所属数据集有:SZTAKI数据集、红旗渠数据集、民丰数据集、季节变化检测数据集、HRSCD数据集、建筑CD数据集[75–78]。无论何种应用场景,MSI都有其固有的限制。特征提取方法的准确性不仅会受到雾天等天气情况的影响,而且还会受到拍摄时间差异的影响。结果

这些变化受到相关目标附近的阴影和干扰的影响。一些

表 5 提到了局部区域数据集的示例。

表 5. 局部区域数据集说明。

卫星	区域	数据集名称	图像	像素	日期
福米	中国	斯塔基		952 × 640	2000年 2003年
地理门户	中国	HRSCD		321 × 330	2002年 2005年
世界观-2	中国	土地		322 × 350	2012 年 9 月 19 日 2015 年 2 月 10 日

本地数据集链接如下:

1. HRSCD数据集开源: <https://ieee-dataport.org/open-access/hrscd-high-resolution-semantic-change-detection-dataset>。

2. SZTAK数据集开源: <http://web.eee.sztaki.hu/remotesensing/airchange~基准.htm> (2021 年 12 月 22 日访问)。
- 3.季节变化数据集开源: <https://drive.google.com/file/d/1GX656JqqOyBi-Ef0w65kDGV至nHHRNS9> (2021 年 12 月 22 日访问)。
- 4.构建开源变更数据集: <https://study.Rsgis.whu.edu.cn/pages/download/建筑数据集.html> (2021 年 12 月 22 日访问)。

3.2.5.高光谱图像


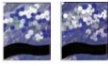
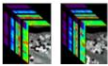
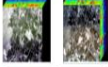


高光谱图像 (HSI) 使用 HSI 传感器捕获。恒指技术目标从地球直接表面捕获数百个光谱通道精确表征各种材料的化学成分。空间和 HSI 的光谱分辨率将它们区分开来。图像的几何关系像素 (彼此之间)由空间分辨率决定,而光谱分辨率确定图像像素内作为波长函数的变化。

大多数 HS 光学无源传感器测量可见光中物体的反射率 (0.4–0.7 μm) 至短波红外 (IR) 光谱 (2.5 μm)。传感器对反射的信号进行采样具有出色的光谱分辨率 (例如 10 nm)的辐射率。这种密集的频谱采样能够准确表示每个像素的反射率,从而精确测量光谱特征[33]。因为多光谱传感器提供粗光谱

在几个不同的频段进行采样,这是开发 CD 算法的早期阶段这些图像主要侧重于识别强烈、突然和突然的变化。HS 中 CD 的目的是检测与显着光谱波动相关的变化,

使用综合光谱采样与微小光谱变化相关的那些 HS 传感器 (通常在 MS 图像中无法检测到)。大多数时候,这些变化仅影响光谱特征的子集。表6 中的一些示例提到了高光谱数据集。

表 6.高光谱数据集说明。

卫星	区域	数据集名称	图像	像素	日期
海伯利安传感器	中国	Jiangsu Province		420 × 140	2006 年 5 月 3 日
海伯利安传感器	鹿	赫米斯顿市		308 × 350	2007 年 4 月 23 日 2004 年 5 月 1 日 2007 年 5 月 8 日
艾维瑞斯	俄勒冈州	赫米斯顿数据集		390 × 200	2007–2015
艾维瑞斯	加利福尼亚州	圣巴巴拉数据集		984 × 740	2013–2014
艾维瑞斯	鹿	加利福尼亚州		147 × 316	2015 年 10 月 21 日 2018 年 6 月 25 日
EO-1	河南	出去		187 × 268	2003 年 3 月 6 日 2006 年 4 月 16 日

HSI 可以提供比 SAR [33]和 MS 图像[79] 更多的光谱信息。作为一个结果,HSI 可以检测到更精细的变化[80],反映不同物质的确切组成对象。尽管 HSI-CD 方法已被使用,但这并不表明高光谱 CD 困难可以得到解决,因为变化检测是一个具有挑战性的过程,

有多种因素会影响。HSI-CD 面临的主要挑战总结如下。

3.2.6.有限的标记数据

由于深度学习模型有数百万个参数,训练起来并不容易他们没有标记数据。此外,对 HSI 数据集中的每个像素进行分类是耗时且需要人类专家[81]。

3.2.7.高维

由于高光谱数据集的高维性,一些 CD 算法很难处理。尽管使用波段选择和特征提取来最小化维度,但也会在一定程度上丢失一些精确的细节信息。不同传感器和平台的发展带来了不同的挑战,例如高维数据集 (高光谱特征和高空间分辨率)、复杂数据结构,计算复杂度高。高维遥感数据 HSI 对训练样本的访问能力有限,这使得深度神经网络,因此,在一般化 HIS 数据分区方面通常不成功。训练阶段[82]。




3.2.8.混合像素问题

混合像素问题通常存在于真实的 HSI-CD 中,这些像素包括几种不同的物质。描述一个特征并不容易 (有时甚至是不可能) 如果粗略地分类为特定类型的物质,则可以准确地混合像素[83]。

3.3.极高空间分辨率 (VHR) 图像

来自多个卫星传感器的 VHR 图像变得越来越普遍,大幅改善 CD 的数据源。VHR由许多卫星传感器收集,包括QuickBird、高分等。VHR 图像可以提供更多信息与中低分辨率图像相比,表面特征和空间分布。遥感 VHR 图像中的 CD 对构建 CD 研究、城市扩张和城市内部变化分析;因此,引起了很多人的兴趣研究人员。表 7 中提到了 VHR 数据集的一些示例

表 7.极高空间分辨率数据集的图示。

卫星	区域	数据集名称	图像	像素	日期
世界观-2	意大利	录像世界查看2		420 × 140	2010年8月 2011年5月
快鸟	意大利	图像对		1400 × 1400	2012年8月 2013年九月
谷歌地球	我们	莱维尔-CD数据集		1024 × 1024	2002年-2018年

尽管利用 VHR 来识别变化是有利的,但存在技术问题由于以下原因而提出挑战。

3.3.1.有限的光谱信息

VHR 传感器采集的图像比中等分辨率传感器采集的图像具有更少的波段。VHR 传感器 WorldView-3 可以提供多达 16 个光谱的图像乐队;仅其他 VHR 图像,例如 QuickBird、IKONOS、Ziyuan-3 和 WorldView-2 涵盖四个频段[84]。很难区分具有等效光谱特征的类别由于类间差异较小,光谱信息有限。研究人员还指出,由于光谱有限,高精度变化检测很困难 VHR 图像的信息[18,85–88]。直接使用传统的基于光谱的CD 诸如变化向量分析之类的方法很困难。因此,不同的特征是经常用于丰富 VHR CD 的光谱信息。

3.3.2.光谱变异性

VHR 图像的光谱变异性很高。例如,建筑物具有复杂的各种屋顶上层建筑,如管道、烟囱、水箱等造成的外观;因此,VHR 图像中的光谱特征显着异质[89,90]。地理物体内的光谱变异性在类内增加

方差,导致基于光谱的图像解释方法的不确定性。天气、太阳角度、物候阶段、潮汐阶段、土壤湿度和水浊度(大气和外部因素)可以导致不变的物体随时间变化光谱特性,将它们错误分类为已改变的[91,92]。此外,临时对象 VHR 图像中可见的图像(例如道路上的汽车)可能会影响基于光谱的效果 VHR 图像中的 CD。

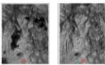
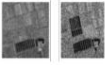

3.3.3.信息丢失

云影/雾霾、地形、树影、建筑物、VHR图像的存在遭受重大信息损失。通过选择无云观测,问题云及其阴影污染是可以避免的[93]。当高大物体进入图像遮挡阳光,出现阴影,导致部分甚至全部损失来自被阴影覆盖的地球表面的信息。地形投射的阴影,另一方面,建筑物和树木在 VHR 图像中似乎不可避免,尤其是在大都市环境中[94]。尽管影子信息在构建过程中很重要检测和高度估计[95,96],这成为较大区域变化的一个问题检测[97]。

3.3.4.异构数据集

不同传感器、分辨率、频率捕获的异构图像(SAR)照明条件和偏振。目前来看,这是一种更加方便快捷的方式一种从多个传感器获取异构图像的适应性方法,以获取更高拍摄频率的多时相图像。然而,异构的CD由于数据处理的技术困难,图像没有得到推广多个传感器数据。相关数据集还不够充分。不同的特点由多个传感器获得的图像中地面物体的表示,特别是从光学和 SAR 传感器捕获的数据使得异构 CD 变得困难[98,99]。然而,计算异构图像之间的差异是很困难的,因为直接比较是不可能的。毕竟,异构图像代表着独特的对象的物理品质并显示出相当不同的统计趋势。在表8中,详细阐述了一些常用的异构图像。

表 8.异构数据集的说明。

卫星	区域	数据集名称	图像	像素	日期
埃TM+	我们	墨西哥		512 × 512	2000年4月 2002年3月
陆地卫星7号	中国	农田		306 × 291	2008年 2009年
陆地卫星7号	中国	Shuguang Village		921 × 593	2008年6月 2012年9月
Gaofen-3	中国	四川		2827 × 1333	2017 年 6 月 24 日
陆地卫星5号	意大利	撒丁岛		412 × 350,300	1995年9月 1996年7月

4. 变化检测架构随着民用遥感技术

的出现,世界已从通过卫星图像进行的持续且不断扩大的监视中受益。该覆盖范围是使用具有不同时间、空间和光谱尺度特性的各种传感器来完成的。这些特性使得表征更广泛的地球表面元素和改变过程成为可能。变更识别还受到数据的可用性和准确性的限制。事实上,遥感数据在 CD 中有广泛的应用,这需要检测输出图像的重大变化。因此,图3展示了基于深度学习的变更检测的一般流程,本节解释了变更检测架构的组件及其交互。

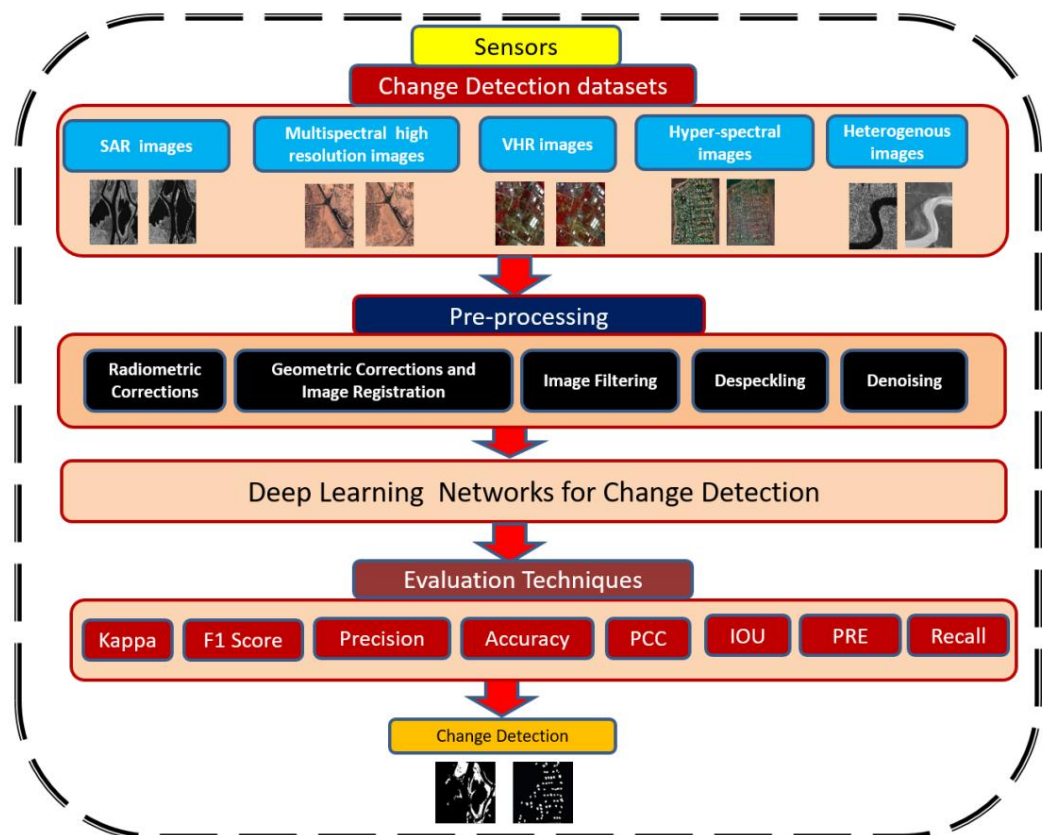


图 3.变更检测架构的工作流程。

4.1.预处理图像预处理

可能对特征提取和图像分析结果的质量产生显著的有益影响。数据收集的数学归一化是许多特征描述符方法中的典型步骤,类似于图像预处理。研究人员创建了许多图像处理方法来解决大气影响问题,例如不需要的噪声或物体。

4.2.数据采集

数据采集是第一步,对于识别变化至关重要。大量图像的采集时间,即季节、月份,是图像采集中需要考虑的关键因素,因为它与物候、气候条件和太阳角度密切相关。

因此,仔细收集多维图像对于减轻这些变量的后果至关重要。然而,数据收集通常受到数据可用性的限制,并且决策通常是目标时间、采集日期和数据可用性之间的权衡。然后捕获的数据被分组为多个子数据集,称为多时相图像,并发送进行预处理[100]。

4.3.几何配准几何配准是一种检测

卫星图像中不必要的部分以分析变化的方法。所有变化检测技术都需要它,因为原始航空图像涉及一定程度的几何失真。传感器位置的变化会导致这种错觉。尽管有些扭曲是可以预测的并且可以很快纠正,但其他扭曲则很复杂且难以从记录中排除。因此,几何校正的目的是补偿畸变并最终创建具有高度几何形状的图像[101,102]。如果图像中不考虑几何失真,则像素的空间坐标将不正确。该方法主要用于识别在多个维度上发生的可能导致像素错误分类的图像变化。几何配准可以使用 RPC、SIFT、DTM、CACO 和 RANSAC 来执行[103,104]。

除了这些方法之外,CD还使用了一种称为 Harris-Laplace 的配准策略[105,106]。为了提高点检测的准确性,该方法使用SIFT对识别的点进行分组和平衡。

4.4.辐射校正

辐射校正对于光学图像更有效。相对辐射校正可用于标准化在不同时期收集的多时相数据,消除错误或失真。尽管比较了多个数据集,但发现图像增强和校正方法发挥着重要作用。它用于校准像素值并补偿误差。该方法显著增强了遥感数据的可解释性和准确性。在比较不同时间的数据集时,辐射数据的校准和调整至关重要。

此步骤采用两种不同的方法:绝对校准,其中数字被转换为相应的地面反射率值;相对校准,这是正确校准偏转灵敏度所必需的[25,107]。卫星图像中使用强度归一化方法来调节亮度和对比度。

可以根据需要调整卫星图像的直方图来进行测试。在数字高程模型 (DEM)中;辐射校正还增加了入射角定向表面积[108]。消除几何畸变的辐射校正消除了产生场景照明和几何校正变化的传感器。

4.5.去斑对数变换是

乘性噪声的通用去噪方法。

然而,SAR 图像包含更显著的噪声,因此需要一种称为去斑的复杂去噪技术。由于采用了精心设计的滤波器,例如 Lee 滤波器、伽马最大后验滤波器和 Kuan 滤波器,去斑成为可能。除了 Landsat 图像之外,SAR 图像也经常用于 CD。该方法提高了基于 SAR 的 CD 技术的性能。在用于去斑的滤波器中,Lee sigma 滤波器产生了最好的结果[109]。在空间域中,使用改进的 Lee sigma 滤波器实现散斑滤波,而在时间域中,通过利用相邻像素之间的时间相似性来提高精度[110]。或者,开发了广泛用于消除高斯噪声的高斯噪声模型[111]。像素值是通过评估整个图像来获得的,而不是观察图像中附近的像素。此外,非线性扩散滤波对于去除 SAR 图像中的散斑噪声也很有用[112]。

4.6.去噪

图像去噪是处理其他任务(例如分割、纹理分析、特征提取等)之前的基本预处理过程。它用于各种降噪任务,同时保留图像信息。此外,使用非局部均值滤波器对 SAR 图像进行去噪[113]。在[114]中,提出了一种实时图像降维滤波器,它使用基于阈值的方法来定位图像边缘。此外,空间滤波器通过在固定窗口上进行平滑来工作,产生

对象周围的伪影以及偶尔的过度平滑,导致视觉模糊。由于其稀疏性、多分辨率和多尺度等特性,小波变换非常适合性能[115]。

5. 使用基于深度学习的网络进行遥感数据集的变化检测

在本节中,我们使用基于深度学习的算法回顾 RS 图像中的各种代表性 CD。我们对 2015 年至 2021 年发表的深度学习领域近 68 篇 CD 论文进行了文献综述。它们在每个部分被分为不同的类别(例如,监督、无监督和半监督)。为了证明几种方法的有效性,我们展示了其中一些方法的实际结果;它们的优点和缺点也在每个部分的末尾和表格中进行了讨论。

5.1. 使用深度学习进行 SAR 图像变化检测

为了展示几种用于 SAR 图像变化检测的深度学习算法的性能,我们以表格形式将综述文献分为不同的基于 DL 的类别,例如监督、无监督和半监督,如表9 所示。

5.1.1. 基于深度学习的SAR图像监督方法Gong等人。 [116]提出了一种利用

深度学习处理多时域 SAR 图像的创新 CD 方法。他们训练了一个深度神经网络,直接从两个源图像生成 CD 图,而无需创建差异图像 (DI); CD 问题被简化为分类问题。为了完成分类,深度架构的学习过程包括无监督特征学习和监督微调。

他们提出的模型由以下三个部分组成:(1)数据预分类,以获得带有标签的高精度数据;(2)构建神经网络,用于学习图像特征并微调神经网络的参数;(3)使用经过训练的深度神经网络对改变和未改变的像素进行分类。与现有方法(例如聚类和阈值技术)相比,他们建议的方法表现良好。

马等人。 [117]提供了一种基于gcForest和多尺度图像融合的SAR图像CD的独特技术。使用gcForest 是因为它提高了准确性并降低了训练难度。因此,所建议的技术使用各种大小的图像块作为gcForest 输入,使其能够学习更多的图像属性,同时减少图像局部信息对分类结果的影响。此外,为了提高灰度值突然变化的像素的检测精度,所提出的技术将差异图像的梯度信息与从训练有素的 gcForest 获取的概率图相结合。结果,提取图像梯度信息可以增加图像边缘信息,并且可以提高边缘检测精度。为了减少计算量和模拟耗时的缺点, Samadi 等人。 [118]使用了 SAR 图像中 CD 的监督深度学习方法。他们提出了一种将形态学图像与两幅原始图像相结合的方法,为 DBN 训练提供合适的数据源。实验结果表明,该方法具有足够的执行时间、理想的性能和优异的精度。

5.1.2. 基于深度学习的SAR图像无监督方法

高等人。 [119]使用深度半 NMF 和 SVD 网络开发了一种独特的 SAR 图像 CD 方法。在他们提出的方法中,预分类是使用深度半NMF完成的,并且很容易获得高精度的标记样本。他们提出了一种基于 SVD 网络的CD 分类模型。从多时相 SAR 图像中,SVD 网络可以学习非线性关系并抑制噪声不变区域。此外,为了提高分类性能,使用两个 SVD 卷积层来获得可靠的特征。建议的方法是无监督的,并且不做出任何严格的假设。

普兰宁西克等人。[120]提出了一种CD算法,该算法利用分数傅立叶变换 (FrFT)的高阶对数累积来提取可调谐Q离散小波变换 (TQWT)中的特征,这些特征被输入到堆叠自动编码器 (SAE)中以区分已更改和未更改的区域。对 SVM 和 SAE进行了比较。实验结果表明,在 TQDWT 和FrFT 中提取特征产生了最显着的结果,并且 SAE 在准确性方面优于 SVM。

[121]中提出的想法是使用收缩自动编码器对 SAR 图像中的 CD 进行深度学习和超像素特征提取。拟议的研究重点是减少散斑噪声导致的性能下降。所提出的策略使用堆叠式收缩自动编码器提取特征。肖等人提出的想法。[122]提供了一种新颖的图像变化检测方法。提出了自组织映射

(SOMDNCD)来产生成功的变化映射,以在降噪和区域边缘的保留之间取得合理的平衡。首先,该方法采用中值滤波器来增强均值比算子产生的差异图像,减少像点噪声对差异图生成的影响。对数比率算子产生比对数比率算子更加多样化的差异图。用于图像时,边缘信息基本保留,漏改率降低。其次,网络根据差异图计算初步变化图,根据变化图的像素是否发生变化对变化图的像素进行分类,并将变化图的像素分为三类:变化、噪声和无变化。

最后,使用类噪声训练集训练 DNN,以去除变化类中的残留噪声并生成最终的变化图。对于不同SAR 数据集中的变化检测任务,Dong 等人。[123]使用多个卷积神经网络,其中两个补丁用作输入。他们开发了一个“暹罗样本”网络,以补丁对作为输入,并考虑到它们之间的各种权衡。Siamese样本网络使用单分支双样本作为判别输入来构建二元分类器(即识别变化的类和未变化的类)。伪暹罗网络、暹罗网络和双通道网络在精度和运行时间之间的平衡比建议的设计更差,并且对抗斑点噪声的能力较弱。此外,与最先进的技术相比,所提出的方法使用简化的算法框架,从而对预分类标签精度的要求较低。

贝尔加马斯科等人。[124]提出了一种卷积自动编码器来检测 SAR图像中的 CD。他们以无人监督的方式培训 CAE。通过使用基于方差的特征选择方法,该策略仅评估CAE收到的信息最丰富的信息。

耿等人。[125]使用显着性引导深度神经网络(SGDNN),这是一种针对五个 SAR 数据集的无监督方法。他们建议的方法可以提取可能发生变化的位置并消除 DI 中的背景像素,从而减少散斑噪声对 SAR的影响。创建分层模糊C均值 (HFCM)聚类,选择变化概率较大且未变化的样本,自动获得伪训练样本。此外,为了提高样本特征辨别力,利用基于非负和 Fisher 约束自动编码器的 DNN 进行最终检测。

法拉哈尼等人。[126]使用了一种基于自动编码器的技术,这是一种深度分析方法,用于实现 SAR的融合特征,“光学”以受益于互补信息,通过减少光谱和辐射来对齐多时相图像差异,并使多时相特征更加相似,以提高 CD 的准确性。

萨哈等人。[127]提出了一种无监督方法LSTM,并提供了一个时间序列分析框架,可以在不知道事件日期或任何像素级标记训练数据的情况下解决时间序列中的CD问题。

舒等人。[128]使用基于补丁的 CD 方法。掩码函数将不规则形状的变化标签转换为规则的映射,使网络能够端到端地学习补丁。首先,SAR 图像用于生成训练样本和设计的掩模。由于存在掩模,基于 U-Net 的网络可以进行端到端学习,同时

忽略不规则形式的标签。新创建的变更图被迭代处理以
获得下一个学习周期中使用的新标签和掩模。学习变化特征
迭代地。通过迭代学习,两阶段更新技术提高了数据多样性
同时抑制噪音。

曲等人。[129]介绍了一种独特的DDNet。空间和频率域元素
DDNet 的一部分被合并以提高分类性能。他们创建了一个多区域
空间域中的卷积模块改进输入图像块并增加
中部地区特色。为了提取频域中的频率信息,他们
使用 DCT 和门控机制。在不同数据集上的实验表明
提出的 DDNet 优于其他几种 CD 方法。

5.1.3.基于深度学习的SAR图像半监督方法

高等人。[130]使用卷积小波神经网络开发了海冰 CD 模型
网络(CWNN)。在海冰变化检测中,利用小波变换来
最大限度地减少 SAR 图像中的散斑噪声。在他们提出的方法中,双树复合体
使用CWNN将小波变换添加到卷积神经网络中
对变化和未变化的像素进行分类。此外,虚拟样品生产方法
用于生成CWNN训练的样本,缓解样本有限的问题。
两种方法的实验结果证明了推荐方法的有效性
SAR 数据集。

王等人。[131]提出了一种用于 SAR 图像 CD 的半监督 DNN,具有像素级和上下文级变化特
征提取的双特征表示。具有标签一致自集成技术的 LCS-EnsemNet 是专门为

SAR图像光盘,解决由于缺乏标记样本而导致的问题。

表 9.基于 SAR 图像数据集的变化检测技术的文献工作总结。

作者	年技巧	模式	优势	坏处
普兰宁西克等人。[120]	2018 堆叠式自动编码器	无监督	高准确率	模型复杂度
龚等人。[116]	2015年深度神经网络	监督	高准确率	计算复杂度高
马等人。[117]	2019 GC森林	监督	抑制噪音	严重依赖 DI 的质量
萨阿迪等人。[118]	2019大北网	监督	减少时间	有限的标签数据
高等人。[119]	2017 NMF SVD	无监督	高性能	非有效样本
吕等人。[121]	2018 无监督收缩自动编码器		高性能	空间信息丢失
肖等人。[122]	2018深度神经网络	无监督	漏检率更低	训练数据有限
贝尔加马斯科等人。[124]	2019年CAE	无监督	不需要标签数据	不完全适合
耿等人。[125]	2019年深度神经网络	无监督	高性能	缺乏注释数据
法拉哈尼,M 等人。[126]	2020年DA方法	无监督	小说	不用于SAR和光学特征融合
萨哈等人。[127]	2020 长短期记忆网络	无监督	不需要任何标记的训练样本复杂	
舒等人。[128]	2021优网	无监督	高准确率	训练样本有限
曲等人。[129]	2021 DDNet	无监督	有效且稳健	缺乏空间特征
高等人。[130]	2019中国CWNN	训练数据的半监督新方法		网络学习的潜力没有完全释放
王等人。[131]	2021 LCS-EnsemNet	半监督高效率		计算负担。
董等人。[123]	2018连体样品	预分类	强散斑噪声消除器	对标记数据的高度依赖

SAR 数据集的计算复杂性和处理时间是整个变化检测过程中需要克服的两个最重要的
障碍。额外的
问题是 SAR 图像中的散斑噪声,它具有乘性特性并且总是
对所有SAR应用造成不利影响。在[116]中,作者提出了
变化检测方法, [119–121],不生成 DI,并被广泛用于
以前的研究。他们提出的方法在 PCC 和
卡帕 (0.98,0.86)。缺点是模型复杂,计算量大
由于各种特征和低效样本而变得复杂。同样,也实现了
PCC (0.98,0.99,0.99)和 kappa (0.91,0.90)的性能更好。然而,缺点
包括更少的训练样本和分类错误。在[121]中,模型性能为

高,但存在空间信息损失。在[123]中,通过从不正确的起始变化图导出,作者获得了训练集的可访问标签。这些方法没有充分利用网络学习和预测的前景。在[125]中,无监督方法显著性引导深度神经网络的新思想取得了良好的性能(PCC 0.99和kappa 0.92),但缺乏注释数据。在参考文献[118]中,作者获得了最高的PCC和kappa结果:0.99、0.96。他们研究的主要优点是显着减少了模拟算法所需的时间,而不会对准确性产生任何负面影响,但生成标签数据具有挑战性。在[130]中,采用了一种新颖的虚拟样本生成方法来生成比传统方法优越且鲁棒的样本,并且缓解了训练样本有限的问题。他们提出的方法优于 PCC 和 kappa: 0.98、0.95。在[126]中,作者提出了一种独特的方法,域适应(DA)技术没有在任何SAR或光学特征融合的研究中使用。然而,模型复杂度较高,其结果评估性能低于以往的研究。在[128]中,PCC和kappa分别为0.99、0.94。主要优点是模型精度和计算时间增加。但训练样本较少,模型可能会导致过拟合。在[129]中,使用双域CNN,包括空间域和频域,通过这种基于学习的算法更有效地检测SAR图像。然而,它们缺乏潜在空间分布特征的数学描述和正则化,这可能会削弱网络的特征表示能力。在[131]中,他们提出的模型显示出很高的准确性,但它有计算负担。在[123]中,作者提出了一种减少散斑噪声的模型,但该网络的性能与大多数现有的深度学习变化检测方法不同。

5.2.使用深度学习的多光谱图像变化检测

5.2.1.基于深度学习的多光谱图像监督方法

多特等人。[132]提出了完全卷积网络的两个 Siamese 扩展,从头开始进行端到端训练,并且在准确性和推理速度上都优于 CD 的最新技术,并且无需进行后处理。这些修改中值得注意的是,将全卷积编码器-解码器范式转换为连体架构,该架构使用跳跃连接来提高输出的空间精度。他们的架构比早期的方法快 500 倍以上。

牟等人。[133]介绍了循环卷积神经网络,这是一种结合了CNN和RNN的独特网络设计。它可以提取联合光谱-空间-时间信息并从双时态多光谱图像中识别变化类型。在实验结果的视觉和定量评估中,所提出的模型效果良好。

张等人。[134]对 MS 图像使用了端到端的 SSJLN,共同学习CD 挑战的光谱空间表示。SSJLN 由三个部分组成:光谱空间联合表示、特征融合和判别学习。

首先,与 Siamese CNN 类似,从网络(S-CNN)获得光谱空间联合表示。其次,提取的特征被融合以表示不同的信息,足以满足变化检测任务。第三,歧视学习旨在更好地研究生成的融合特征的底层信息来描述歧视。

林,Y.等人。[135]提出了一种双边卷积网络来检测双时态多光谱图像的变化。他们用两个对称的 CNN 训练模型,这两个 CNN 能够学习特征表示。他们将外部矩阵乘积应用于输出特征图以获得组合的双线性特征。应用Softmax分类器来生成变化检测结果。

5.2.2.基于深度学习的多光谱图像无监督方法

曹等人。[136]开发了一种在多光谱 RS 数据集中为无监督 CD生成唯一差异图像(DI)的方法。首先,他们使用 DBN以无监督的方式从给定像素的局部邻居学习局部和高级特征。

其次,开发了BP方法,根据选定的训练样本创建DI,强调变化区域和未变化区域之间的差异,同时抑制未变化区域的错误变化。最后,使用简单的聚类分析来创建变化检测图。他们建议的方法在“三 R”数据集上进行了测试,并取得了比传统标准像素级方法更优越的性能。

阿特鲁里等人。[137]提出了多光谱 HR 卫星图像 CD 的 MAU-Net 架构。框架中的每个块都包含以多种分辨率提取特征的过滤器和一个注意层,以帮助网络实现更精细的特征。

MAU-Net的主要优点是特征传播,通过残差连接实现;使用注意力层来识别重要的特征图。Onera 数据集用于比较目的。建议的 MAU-Net 方法在变化检测方面取得了最先进的结果。

龚等人。[138]提出了一个由生成对抗性和判别性分类网络组成的 GDCN。DCN 将输入数据分为三类:更改类、未更改类和伪造类。当网络经过适当的训练以产生最终的 CM 时,DCN 可以将原始图像数据分为两类。建议的方法有效地区分变化像素和未变化像素。

萨哈等人。[139]使用了一种处理多时相图像的新方法,将它们分别输入由可训练的卷积层组成的深度网络。训练过程不使用任何外部标签,分割标签来自最后一层的argmax分类。为了从单个图像中检测对象片段并建立不同的多时间片段之间的对应关系,使用了一种新颖的损失函数。

维拉塔马等人。[140]使用特征级 U-Net在 HR 多光谱图像中创建稳健的土地覆盖变化分割方法。建议的全色锐化是通过应用低通滤波器来消除 IHS 高频图像中的光谱失真而引入的。他们提出的网络由特征级减法块层和 U-Net 分割层组成。特征级减法块层提取所有特征级的动态差异图像 (DI)。即使在几何扭曲和不同角度等噪声下,具有 HRMS 图像的 CD 也优于现有的CD 算法。

赛迪等人。[141]使用端到端模型,构建了一个具有三个并行通道的基于 CNN 的网络:第一个和第二个通道分别从原始的第一次和第二次图像中提取深度特征。第三个通道涉及从差异和“质押”深层特征中提取“变化”深层特征。每个通道还具有三种类型的卷积核:1D、2D 和 3D 扩张卷积核。

CD 图输出还通过计算九个不同的精度指数进行可视化和定量分析。与其他传统方法相比,所提出的模型具有出色的准确性。

罗等人。[142]使用深度卷积生成对抗和 DeepLabv3+ 网络改进了变化检测结果。为了解决 DL 网络需要大量样本且 CD 样本难以获得的问题,他们使用非生成式和 DCGAN 生成式方法进行数据增强。DCGAN 网络数据成功补充了样本数据集。然后,为了制作RS图像CD,使用了SP-DeepLabv3+。通过用子像素卷积替换反卷积层来升级网络,这提高了网络的总体精度。通过亚像素卷积,他们的网络预测 RS 图像变化检测。最后,他们的网络的泛化性能在不同的数据集 (例如 Google Earth、Landsat 8 和 OSCD)上进行了测试,结果表明所提出的网络在泛化方面表现良好。

5.2.3. 基于深度学习的多光谱图像半监督方法

阿尔瓦雷斯, J. 等人。[143]提出了一种用于多光谱图像的自监督条件生成对抗网络,经过训练仅生成未更改样本的分布。他们的主要想法是通过以下方式学习未改变样本的分布:

监督生成器的对抗性训练。他们的实验结果表明所提出的模型相对于几种 CD 方法的有效性。

张等人。 [144]提出了一种新的基于FDCNN的CD方法,其中子VGG16用于从RS图像中学习深度特征,FD-Net用于生成特征差异图,FF-Net 用于通过用小特征训练来融合这些图像像素级样本的数量。此外,为了减少训练时间并提高网络性能,他们创建了一个用于训练的变化幅度引导损失函数基于交叉熵损失函数,它允许使用先验知识来减少伪变化并使获得最终的二进制变化图变得更容易。

在这里,我们提出了一些优点和缺点,请参见表10。在[134]中,作者通过使用端到端的方法实现了最高准确度 0.99 和精确度 0.97 SSJLN 模型。这些模型用于规避 DI 的影响,并且进行了一些尝试已经被用来以端到端的方式解决CD任务[132–134,137,138]。然而,缺点是这些端到端 CNN 模型需要大量训练数据。为了解决这些问题,使用了GDCN。生成器恢复实际数据输入噪声给出更多训练样例,提高判别分类能力网络的性能,并达到 0.95 的准确率。此外,性能是受聚类算法的影响。在[140]中,作者处理了复杂的变化,扭曲和各种角度观看困难以提供特征级 U-Net,包括特征级减法块和 U-Net 分割层。全色锐化方法除了控制微小的变化之外,还用于提高几何和空间分辨率变化。在[145]中,提出了一种半监督方法来解决缺乏正确标记数据的问题,并获得了 0.84 的准确度。在[142]中,作者利用了非生成式和 DCGAN 生成技术用于样本增强,以解决深度学习问题需要大量样本和变化检测样本的学习网络,很难获得。他们的模型使用不同的数据集具有 0.95 的准确度。在[141]中,使用端到端 CNN 模型;它不需要任何预处理,就实现了精度高 (OA = 0.99,KC = 0.80) ,但该模型非常耗时。很相似 [135],他使用了监督技术。生成标记数据具有挑战性;因此,无监督方法通常优于监督方法。

表 10.基于多光谱的变化检测技术的文献工作总结
图像数据集。

作者	年技巧	模式	优势	坏处
多特等人。 [132]	2018年FCNN	监督	端到端训练	海量训练数据
牟等人。 [133]	2018年RCNN	监督	端到端	模型无法提取所有深层特征。
张等人。 [134]	2019 SSJLN	监督	高性能	海量训练数据
林,Y 等人。 [135]	2020 BCNN	监督	端到端训练	生成标记数据具有挑战性
曹等人。 [136]	2017年大北网	监督	高准确率	处理时间
阿特鲁里等人。 [137]	2018 MAU-Net	监督	端到端	性能低下
龚等人。 [138]	2019 DCN,GDCCN	监督	减少训练样本问题	模型复杂度
萨哈等人。 [139]	2020 深度联合分割 无监督		不需要任何标记的训练像素	耗时
维拉塔马等人。 [140]	2020优网	无监督	解决光谱失真问题	计算复杂度
赛迪等人。 [141]	2020 美国有线电视新闻网	无监督	端到端	耗时
罗等人。 [142]	2020 DCGAN,DeepLabv3+	无监督	高性能	海量训练数据
张等人。 [144]	2020年FDCNN	预训练	鲁棒性和泛化能力强 需要大量像素级训练样本	
阿尔瓦雷斯,J 等人。 [145]	2020 S2-cGAN	半监督提取多种分辨率的特征		模型复杂度

5.3.使用深度学习进行高光谱图像变化检测
5.3.1.高光谱图像中基于深度学习的监督方法

Syedi,S.等人。 [146]提出了一种有监督的CD方法来提高效率
通过结合相似性和基于距离的方法来改进现有的 CD 方法。他们的

该方法的准确率超过 96%,误报率低于0.03,曲线下面积约为 0.986。

范迪诺,J.等人。[147]引入了堆叠自动编码器来从多类 CD 的遥感 HS 数据集中提取特征。他们的实验结果表明了他们的方法在提取融合信息的相关特征时的有效性。

混合亲和力矩阵可以同时有效地管理多源数据,从而可以学习 GETNET 中光谱之间的代表性特征。它不仅提供了更丰富的跨通道梯度信息,也是多源信息融合同时处理的有效方法。

侯等人。[148]提出了深度学习算法来识别 HRRS 图像上的 CD,并创建了一个 W-Net 架构,该架构使用跨步卷积、串联和快速连接技术来识别变化特征提取和分类。然后,使用 W-Net 作为生成器,开发了 GAN 来训练显示分布的映射函数。W-Net和CDGAN都取得了成功的成果,CDGAN在性能上可以超越W-Net。与以前的方法相比,他们提出的技术可以从双源图像中获得最终的 CM。

Moustafa 等人使用不同的高光谱图像数据集。[149]提出了称为注意力残差循环U-Net (Att R2U-Net)的CD架构。该模型使用了U-Net 的四种不同变体:循环 U-Net、注意力 U-Net 和注意力残差循环U-Net。注意力循环 (即残差模型)分配的参数最多,并且在二元和多重变化方面表现最佳。循环U-Net,即残差U-Net模型,以其优异的性能适用于HSI的二分类和多分类CD。

这项研究支持这样的观点:DNN与 HSI 数据结合时可以学习复杂的特征并提高 HSI CD 性能。

5.3.2.高光谱图像中基于深度学习的无监督方法

童等人。[150]开发了一种独特的策略来解决当源图像中训练样本很少时的多CD问题。使用无监督的二进制 CD来创建二进制 CM。之后,使用主动学习对源图像进行分类,然后使用迁移学习方法获得目标图像的分类图。最后,分类后比较创建了多重CM。

宋等人。[151]提出了Re3FCN,它使用LSTM和3D卷积神经网络;该方法综合了基于深度学习的 FCN 和卷积 LSTM的优点。使用每个端路的SCA 值计算训练样本,并将 PCA 和 SCA 方法结合起来以提供高度准确和可靠的样本。该策略有利于在没有训练数据的情况下执行CD。此外,Re3FCN (1)从多时相图像中提取光谱-空间-时间信息; (2)通过用卷积层替换全连接层,有效识别二元和多类变化,同时保留空间结构输入; (3) 端到端训练。

萨哈等人。[152]提出了一种用于超维图像的无监督 CD 方法,该方法利用未经训练的深度模型作为深度特征提取器。在超维图像中,他们提出的方法有效地区分变化的像素和未变化的像素。本文通过使用源自未经训练的模型的 DCV 将更改的像素聚类到各个组中,增强了多 CD 的方法。

赛迪等人。[153]介绍了一种由DTW算法和CNN组成的网络。他们使用 DTW 和 Otsu 的阈值技术找到了一个二进制 CD,并使用 CNN 获得了多个 CD。他们提出的方法比以前的方法有几个优点,包括 (1)二进制和多 CD 的准确性高; (2)利用空间和光谱特征生成多个CM; (3)误报率低; (4)无监督框架,无需训练每个数据集。

5.3.3. 高光谱图像中基于深度学习的半监督方法

袁, Y. 等人。 [154] 专注于半监督 CD 方法来识别噪声条件下 HS 图像的变化, 因此提出了一种新的距离度量学习框架。使用常规进化框架来识别“嘈杂”环境中的变化, 而不消除任何噪声带, 这些噪声带受大气 (或水) 的影响, 并且在其他文献中总是手动消除。他们采用了半监督的拉普拉斯正则化度量学习方法, 利用大量未标记的数据来解决不适定样本问题。他们在两个多时相 HS 数据集上执行了他们提出的方法, 事实证明它们在理想和噪声条件下效果最好。

王等人。 [155] 为 HS 影像 CD 提供了 GETNET 网络。他们的研究提供了三个重要贡献: (1) 引入了混合亲和矩阵, 可以同时有效地管理多源数据, 从而可以学习 GETNET 中光谱之间的代表性特征; (2) 设计二维卷积神经网络来学习判别特征并提高泛化能力; (3) 开发了新的高光谱图像 CD 数据集用于客观比较。

黄, F. 等人。 [156] 提出了一种基于张量和 DL 的 HS 图像 CD 解决方案。他们使用基于张量的信息模型来建立高光谱遥感图像中变化的特征。他们还设计了基于三阶张量的玻尔兹曼人工神经网络机。使用多层 Tensor3-RBM, 训练未标记的数据, 将 BP 神经网络替换为 STM, 并使用多层深度置信网络来提高准确性。他们的实验结果表明, 张量遥感深度信念网络具有更高的变化检测能力。

深度学习技术有可能用于解决基于 HSI 的挑战, 但不同的研究仍然存在一些局限性。我们在表 11 中简要介绍了研究的优点和缺点。就准确性而言, 循环残差 U-Net 表现出最出色的性能, 为 0.99 [149]。之前的一些方法也具有较好的性能, 如参考文献 [146-150, 155, 156] 所示。然而, 参考。 [148] 显示了最低的性能 0.64 kappa 和漏报率 (MAR) 为 0.30。较低的性能涉及有限的训练数据、未使用数据增强以及未用作骨干的预训练模型。

此外, 他们提出的方法直接从两个图像中获得最终的变化。在 [156] 中, 由于 DBN 深度网络和 TFS-Cube 张量模型的广泛使用, TFS-Cube 比其他方法消耗更多的时间。可以通过增强计算机硬件的性能 (例如添加 GPU 模块) 或简化算法流程来减少 TRS 时间的 DBN 消耗。在 [155] 中, 通过各种 CD 技术生成的伪训练集对于训练网络是必要的。

算法的性能会受到伪训练集中固有噪声的影响。CNN 训练有几个优点, 其中之一是它只需要输入图像。在 [148] 中, 作者提出的方法完全受到监督, 因此由于人工注释的困难而缺乏吸引力。在 [150] 中, 作者使用了新颖的方法, 改进了多重变化检测问题, 并提高了准确性。然而, 所建议的方法的缺点是多时相图像预计具有相同的土地覆盖类型。因此, 无法识别目标图像中新的土地覆盖类型。在 [151] 中, 没有足够的训练数据来验证这些网络在空间分辨率为 30 m 的低分辨率 HSI 中的使用。

表 11.基于高光谱的变化检测技术的文献工作总结
图像数据集。

作者	年技巧	模式	优势	坏处
赛迪,S 等人。 [146]	2017 基于相似性的方法 监督		高准确率	阈值化样本数据需求
范迪诺,J 等人。 [147]	2018 SAE ELM 或 SVM	监督	二进制和多类 CD	培训充足问题
侯等人。 [148]	2019年W网	监督	更好的性能	训练依赖于大量手动注释的数据
穆斯塔法等人。 [149]	2021 ARR-U-Net	监督	二进制和多类 CD	计算复杂度
童等人。 [150]	2020 AL TL	无监督	多张CD	无法检测目标图像中的新土地覆盖类型。
萨哈等人。 [152]	2021年深度CVA	无监督	更好的性能	耗时且模型复杂
赛迪等人。 [153]	2020 3D CNN	无监督	多类CD	海量训练数据
袁,Y 等。 [154]	2015 SSDM-CD	半监督高性能		不适用于空间信息
黄,F 等人。 [156]	2019年TDL	半监督更好的表现		仅使用光谱特征
王等人。 [155]	2019 获取网	半监督端到端二维		训练难度
宋,A 等人。 [151]	2020 Re3FCN,CD	预训练	高语义分割结果	训练数据不足

5.4.使用深度学习进行 VHR 图像变化检测

5.4.1.基于深度学习的 VHR 图像监督方法

彭等人。 [157]提出了更先进的U-Net++设计。 U-Net++ 模型的密集跳跃连接用于学习多个特征图的多尺度特征图语义层。他们采用了残差块策略来促进深度 FCN 网络梯度收敛,这对于获取更全面的信息也很有用。此外,MSOF 方法用于集成多尺度侧输出

创建最终变化图之前的特征图。他们使用加权二元交叉熵损失和骰子系数损失成功地减少了类别不平衡的影响。方等人。 [158]使用双时态 VHR 图像并构建了混合 DLSF。网络提供两种并发流:DLSFF 和基于 Siamese 的 CD。拟议的系统使用独特的变更图引用来学习跨域翻译,以隐藏未更改区域的差异,并强调两个区域中已更改区域的差异域,分别。然后它专注于检测变化区域。陈等人。 [159]提出了两种基于 MFCU 的独特的深度暹罗卷积神经网络无监督和监督变化检测。 DMSCN 根据以下生成的数据进行训练无监督变化检测中的自动预分类。 DSMS-FCN 能够处理任何大小的图像,并且在监督中不需要滑动补丁窗口变化检测,因此准确性和推理时间可能会大大提高。为了解决定位不准确的问题,使用FC-CRF修改DSMS-FCN发现。 FC-CRF 与 DSMS-FCN 集成,使用 DSMS-FCN 的输出作为一元势。静,R等人。 [160]为 CD 开发了一种独特的深度学习架构,该架构由子网和 LSTM 子网组成,使用空间、光谱和多相信息增加 VHR RS 图像中的 CD 功能。实验表明, LSTM子网络提取的多相信息对于改善

CD 结果的准确性。

5.4.2.基于深度学习的 VHR 图像无监督方法

检测超高分辨率 (VHR) 的变化极具挑战性,因为季节变化、成像条件等的影响。Javed 等人。 [161]提出了一种基于对象的 VHR 图像 CD 方法。他们生成了 MBI 特征图像并使用了三个 PBCD的不同方法并提出了用于检测建筑物的D-S理论理论光盘。科雷亚等人。 [162]采用了CD方法VHR图像。综合技术,它由两个原则组成,处理捕获的多光谱和多时态数据通过不同的传感器。(i) 图像的光谱、辐射和几何均质化通过不同的传感器获得;(ii) 通过以下特征检测大量变化确保不同时间和传感器之间的同质性。主要思想是对图像进行变换使用转换转化为一些共同特征。以本文为例,流苏

caps 变换用于图像变换。使用各种多光谱传感器数据进行的实验来评估该算法。

萨哈等人。[163]介绍了一种针对 VHR 图像 CD 的深度变化向量分析 (DCVA),该分析是通过将 CVA 与预训练的深度卷积神经网络相结合而开发的。深层特征是从预先训练的多层 CNN 中提取的。通过组合 CNN 不同层的特征形成特征炒作向量,以确保在多个抽象级别捕获空间上下文。对变化前和变化后图像的深度变化向量进行像素比较,生成深度变化向量,然后对其进行分析,以从多时相 VHR 图像中提取二进制和多重变化信息。

赵等人。[164]提出了一种注意力门生成对抗性适应网络 (AG-GAAN)。AG-GAAN 的贡献如下: (1)该方法可以自动检测多个变化; (2)它包含用于空间约束的注意力门机制,并以更精细的轮廓加速变化区域识别; (3)引入领域相似性损失来提高模型的可区分性,使模型能够更准确地映射出真实的变化。

5.4.3. 基于深度学习的 VHR 图像半监督方法

萨哈等人。[165]使用了图卷积网络 (GCN),该网络最近在半监督单数据分析中表现出了良好的性能,以提高变化检测性能。为了将地块处理成可以由 GCN 处理的图形表示,应用了一种新颖的图形构建方法。GCN 仅针对标记的地块优化其损失函数。迭代训练方法有助于将标签信息从标记节点传播到未标记节点,从而允许检测未标记数据的变化。建议的方法仅基于分析的双时场景,不需要其他数据集或预训练网络。

庞等人。[166]提出了一种新颖的基于暹罗相关性和注意力的 CD 网络 (SCA-CDNet),用于双时态 VHR 图像。在第一阶段,数据增强成功地防止了过度拟合并提高了训练模型的泛化能力。其次,利用 ResNet 提取图像的多尺度特征,充分利用网络当前的预训练权重,使后续的模型训练变得更加容易。第三,正在开发一种新颖的相关模块,以一致地叠加上述双时态特征并提取降维的变化特征。第四,在相关性模块和解码器模块之间包含注意力模型,使网络更加关注对变化分析有巨大影响的区域或通道。

第五,开发了一种新颖的加权交叉熵损失函数,使训练集中于错误检测,提高训练模型的最终精度。

帕帕多玛拉基等人。[167]提出了一种使用全卷积 LSTM 网络的独特模型,并提出了一种类似 U-Net 的架构 (LU-Net),该架构通过在每个编码级别之上分层集成全卷积 LSTM 块来建模空间特征表示的时间关系,并使用一个额外的解码分支,对各种输入日期中呈现的可用语义类别执行语义分割,从而形成多任务框架。

在参考文献[166]中,作者提出的方法在准确度 $OA=0.990$ 上表现出优异的性能。 $F1 = 0.91$, $Pre = 0.92$, $IOU = 0.83$ 。之前的一些方法已经表现出良好的性能[157-159,162],但也存在一些挑战。上述所有深度学习算法都有一个共同点:它们都需要大量的训练数据,如表12所示。在深度学习中,众所周知,如果训练数据不足,对新图像的泛化会受到很大影响。在[162]中,作者在最后提到了一些解决论文局限性的未来想法,例如将集群与特定类型的变化相关联,以及特征选择以进一步区分不同的变化。提出了一种具有新颖深度监督的改进 U-Net++ 模型,以捕获具有挑战性的场景中的细微变化。据作者称,该模型仅关注变化/不变信息,这对于某些实际应用来说是不够的[157]。

表 12.基于 VHR 图像数据集的变化检测技术的文献工作总结。

作者	年技巧	模式	优势	坏处
彭等人。 [157]	2019优网++	监督	端到端	需要大量的训练样本
方等人。 [158]	2019 DLSF	监督	检测性能高	不关注光谱信息的变化。
陈等人。 [159]	2019 暹罗CRNN	监督	高性能	大量标记样本
静,R等人。 [160]	2020 TriSiamese LSTM	监督	提高准确性	计算复杂度
贾韦德等人。 [161]	2020 D-S 理论	无监督	低误报	建筑物变化的漏检
科雷亚等人。 [162]	2018 年辐射变化树无监督		很好的表现	大量训练样本
萨哈等人。 [163]	2019多层CNN	无监督	减少对改变样本的依赖需要大量的像素级样本。	
赵等人。 [164]	2020年AG-GO	无监督	提高检测精度	模型受到危险环境的巨大挑战
帕帕多玛拉基特等人。 [167]	2021 路网	无监督	方法新颖	性能低下
萨哈等人。 [165]	2020年GCN	半监督消除了许多冗余特征		耗时
庞等人。 [157]	2021 SCA-CDNet	预训练	提高准确性	不足以满足某些实际应用
吉等人。 [168]	2019 Mask R-CNN,CNN	自学成才	减少训练样本的需求	时间复杂度

5.5.使用深度学习进行异构图像变化检测

5.5.1.基于深度学习的异构图像监督方法

杨等人。 [169]提供了一种基于深度典型相关分析（DCCA)的独特的跨传感器CD方法。使用整个区域的样本进行训练后，DCCA 变换允许对齐两个异构多光谱的光谱数据集 ;然后,使用任何变化检测方法。常用的实验跨传感器图像数据集表明,建议的策略优于以前的方法。此外,DCCA 的参数形式通常比

KCCA 的非参数形式。

王等人。 [170]使用了基于深度暹罗卷积网络和混合卷积特征提取模块（OB-DSCNH)的监督CD方法多传感器数据集。建议的方法可以从输入中提取层次特征比比较方法更抽象、更有弹性的图像配对。埃贝尔等人。 [171]提出了一种新颖的暹罗网络并提出了一种新的双峰网络基于融合的 CD 模型,结合了来自 SAR 和光学传感器的数据。

5.5.2.基于深度学习的异构图像无监督方法

刘等人。 [172]提出了 SCCN 来减少 1D 和 2D CNN 的局限性对于CD。他们建议的 SCCN 模型完全是无监督的,没有标记像素。SCCN 有一个卷积层和每一侧的多个耦合层将两个输入图像（馈送到每一侧)放入具有更一致特征的特征空间中两个输入图像的表示。最后直接生成差异图该特征空间使用像素级欧几里得距离。开发了耦合功能驱动网络参数学习。他们使用 DAE 逐层预训练网络同时考虑两个输入图像的噪声模型以给出正确的网络参数和不变标签的初始化。提出的想法牛等人。 [173]使用cGAN来转换异构SAR和光学图像进入一个他们的信息更一致地表达的空间,允许直接比较。所提出的框架包括一个基于 cGAN 的翻译网络，尝试以 SAR 图像作为目标和近似值平移光学该网络可减少 SAR 图像与翻译图像之间的像素差距。两个网络交替更新。经过充分训练后,两人翻译并且估计的图像可以被认为是同质的,允许直接比较最终变更图。詹等人。 [174]提出了一种对数变换特征的独特方法学习（LTFL)网络将SAR图像转换为光学图像。修改后的然后可以使用图像对来使用联合特征来学习高级特征表示萃取。预分类结果将是原始数据,用于挑选标记样本,用于训练初级神经网络分类器。当这个分类器经过充分训练后,它将

标记每个位置,从而识别地面上的变化。为了解决异构 RS 图像对之间的二元分类问题,Touati 等人。[175]提出了一种堆叠稀疏自动编码器无监督方法并训练了时间图像特征。

构建的异常检测模型根据其在潜在空间中的表示来重建输入,以识别新的未见过的图像对的像素。首先,使用堆叠隐藏表示在这个正常的紧凑空间中对探测(新)图像(即,作为输入请求的双时态异构图像对)进行编码。使用 L2 范数在残差法线空间中计算重建误差,其中适度的重建误差将非变化模式区分为属于法线类。相反,变化模式以高重构错误为特征,属于异常类。

通过使用高斯混合对重建误差进行分组,在残差空间中生成已更改/未更改的分类图。

江等人。[176]使用了一种新的 DHFF 方法来检测异质图像的变化。建议的深度同质特征融合方法考虑了同质变换,它将异构图像转换为与 IST 问题相同的特征空间。与传输图像风格的标准 IST 方法相比,所提出的 DHFF 方法测量并在其他新特征子空间中实现特征同质性,使用 IIST 策略来满足同质图像中 CD 的特征同质性要求。

普雷克斯尔等人。[177],使用无监督的 CD 方法和扩展的 DCVA,其中使用不同的空间分辨率和光谱带获得变化前和变化后的图像。

孙,Y 等人。[178]开发了一种专注于异构图像中图像相似性测量的 CD 方法。该方法基于非局部补丁相似性为每个补丁生成一个图形,以在异构数据之间创建链接,然后通过评估一个图像的图形结构仍然与另一幅图像的图形结构相对应的程度来测量变化水平。在同一域中比较图结构,避免异构数据的泄漏,从而产生更稳健的变化检测结果。

实验表明,所建议的基于非局部补丁相似性的异构 CD 方法效果良好。

为了检测异构 RS 图像的变化,Li 等人。[179]提出了 SSPCN 分析,高维特征空间中的两个异构图像,完全无监督,没有明确标记的示例。该方法采用基于分类的方法建立伪标签,并为每个样本提供一个权重以反映样本的难易程度。然后,SPL 最初用于学习简单的样本,然后逐渐融入更详细的数据。在训练过程中,根据网络参数动态调整样本权重。最后,使用经过训练的卷积神经网络构建二进制变化图。

杨等人。[180]开发了一种新的 SAR 图像选择性对抗适应方法。主要贡献是从不同源领域转移知识以帮助识别目标领域中的变化。在他们提出的方法中,他们首先使用鉴别器来选择适合目标域的样本,然后使用另一个鉴别器通过对抗性学习来最小化域差异。

5.5.3. 基于深度学习的异构图像半监督方法

吴等人。[181]提出了一种基于 GCN 和多尺度面向对象分析的半监督 CD 策略,以更好地解决 CD 问题(同构和异构)。他们提出的方法首先进行图像分割,然后将图像块构建成图,并使用 GCN 来检测哪些块发生了变化。

江等人。[176]使用了一种新的 DHFF 方法来检测异构图像的变化。建议的深度同质特征融合方法考虑了同质变换,它将异构图像转换为与 IST 问题相同的特征空间。与转移图像风格的标准 IST 方法相比,所提出的 DHFF 方法测量并实现特征同质性

使用IST策略生成新的特征子空间来满足特征同质性均匀图像中 CD 的要求。

萨哈等人。[182]提出了一种独特的 CD 自我监督学习方法双颞叶场景;他们使用了不同的自监督学习文献概念,例如如深度聚类、增强视图、对比学习和 Siamese 网络,而仅利用可用的目标未标记场景。他们提出的方法可以训练网络可以有效地利用这些概念并适当地修改它们以适应目标多传感器双时态数据。

各种方法在[169,172–176,178,179]中显示出高性能。然而,有仍然存在一些局限性,如表13所示。在[172]中,作者展示了该方法的优于现有的几种方法。此类方法依赖于预分类并且不需要标记数据。然而,它仍然无法利用巨大的目前可用且可用于改进的遥感数据量表现。此外,该方法的局限性在于它只考虑不变的像素。在[173]中,接收像素作为输入的完全链接层减少了像素方面的方差他们的网络。这些类型的模型网络不获取邻域信息围绕一个像素,它们有许多可学习的参数 接受的连接层一个像素作为输入。此外,训练样本的选择取决于朴素现有的方法。因此,后续过程可能会因此产生的错误而受到损害。

表 13.基于异构的变化检测技术的文献工作总结
图像数据集。

作者	年技巧	模式	优势	坏处
杨等人。[169]	2018年DCCA	监督	DCCA 的训练速度通常比 KCCA 更快 计算成本高	
王等人。[170]	2020 OB-DSCNH	监督	高准确率	没有考虑中心像素及其邻域是否不属于同一类别
埃贝尔等人[171]	2021连体网监测		新颖的数据	耗时且性能低下
刘等人。[172]	2016年SCCN,DAE	无监督	高性能	空间复杂度
牛等人。[173]	2018年cGAN	无监督	更高的准确度	大量可学习参数
詹等人。[174]	2018年LTFL	无监督	检测精度高	人工操作成本高
图阿蒂等人。[175]	2020年DSRM	无监督	更好的性能	需要大量的训练样本
萨哈等人。[182]	2021 直流,AV,CL,SN	自我监督	更好的性能	耗时
杨等人。[180]	2021年南非航空展	无监督	新颖、高性能	训练有难度
李等人。[179]	2021年上海交通大学	无监督	更高的准确性	伪标签的生成在某些情况下不成立
Prexl 等人[177]	2021 年扩展 DCVA 无监督		更好的性能	不新颖
孙等人。[178]	2021 补丁相似度	无监督	更好的性能	当地面要素覆盖很大面积时很复杂
吴等人。[181]	2021年GCN	半监督/图框架		耗时
江等人。[176]	2020 DHFF 是	预训练	高性能	计算复杂度

在[169]中,关键的限制是高计算成本。在[174]中,尽管他们检测精度高,实际操作中需要人工操作成本较高监督模式或复杂的筛选过程来选择训练样本无监督模式。在[178]中,建议的技术自适应地学习更鲁棒的距离引起的概率网络。这种局部结构一致性使用了以下事实
异质图像共享相同地面的相同结构信息
目的;即成像模态不变。主要关注局部结构的变化。
在[179]中,所提出的方法有一些局限性。在伪标签的生成中,假设多时相图像有微小的变化,并且这个假设确实
在某些情况下不成立。

一个有趣的、也是新的方向涉及行星 CD,其中(根据据我们所知)只有少数作者开展了工作。在这里,我们解释一下他们的工作:

克纳等人。[183]深入开发了行星 CD 的监督方法。对于行星变化检测,他们使用带有各种监督分类器的卷积自动编码器来检测各种 RS 数据集
中的表面特征变化,其中一个小的
标记训练样本的数量。尽管图像质量、照明、成像传感器、表面特性和共同配准存在显著差异,但他们提出的方法
可以使用相对较小的训练数据集以高精度检测有意义的变化。

萨哈等人。[184]提出了一种基于补丁级无监督CD深度迁移的方法用于行星探索。他们提出的方法可以确定一对双时态补丁是否发生变化,此外,他们提出了一种使用伪未变化对来确定区分变化和未变化的阈值的技术

补丁。

6. 评估指标

CD 算法处理关于变化率的极其不平衡的数据与未更改区域相关的区域。最常用的评价 CD 中的技术是准确率、F1、精确度和召回率、总体误差、正确百分比分类 (PCC)、PRE (代表预期一致性) 和 kappa, 如图所示方程 (1) - (10)。

所有评价指标的计算公式为:

$$\text{精度} = TP / (TP + FP) \quad (1)$$

TP: 被识别为变化的像素。TN: 识别为未更改的像素。FP: 在该算法中, 未更改的像素被错误地识别为更改。FN: 改变像素错误地归类为未更改。准确率和召回率是评估结果的两个标准检索系统的效率。精度是通过除以正确的数量来计算的通过检索到的实例总数获得的实例。灵敏度定义为精度计算为参考更改像素的比率。它也称为召回或 TPR。特异性定义了未改变像素的准确性。它也称为 TNR。中华民国使用灵敏度和特异性测量绘制曲线。此外, 该模型的性能由 ROC 曲线下面积 (AUC) 决定。最佳灵敏度特异性为 1.0, 最差为 0.0。Kappa 通常用于评估分类 kappa 值越大, 表明性能越好。F1 是谐波准确率和召回率之间的平均值。它同时考虑误报和漏报并且在不平衡数据下表现良好。准确性: 它衡量有多少正数和负面观察被正确分类[185]。

$$\text{灵敏度/召回率} = TP / (TP + FN) \quad (2)$$

$$\text{特异性} = TN / (TN + FP) \quad (3)$$

$$F1Score = F1 = 2 * (\text{精度} * \text{召回率}) / (\text{精度} + \text{召回率}) \quad (4)$$

$$\text{准确率} = \text{正确预测} / \text{总预测} = (TP + TN) / (TP + TN + FP + FN) \quad (5)$$

$$Kappa = (PCC - PRE) / (1 - PRE) \quad (6)$$

$$PCC = (TP + TN) / (TP + TN + FP + FN) \quad (7)$$

$$PRE = ((TN + FP) \cdot (TN + FN)) / (TP + TN + FP + FN)^2 + ((TN + FP) \cdot (TN + FN)) / (TP + TN + FP + FN)^2 \quad (8)$$

$$\text{准确度} = (TP + TN) / (TP + TN + FP + FN) \quad (9)$$

$$IOU = TP / (TP + FP + FN) \quad (10)$$

定量结果

为了评估不同评估矩阵的性能, 我们提出了一些以之前的结果为例, 该结果基于使用深度学习的变化检测不同数据集的方法。表14和图4显示了使用 SAR 的结果数据集。结果通过 FCM、NLMFCM、DBN、SCCN、小波融合、gcForest, 以及提出的方法。不同类型的评估矩阵用于显示性能, 例如 FN、FP、OE、PCC 和 K。同样, 表15列出了通过使用不同的评估矩阵 (例如精度、

召回率、F1 分数和 OA;图5展示了 VHR 图像的视觉比较。

表16给出了使用不同评估矩阵 (例如OA、精度、召回率、F1分数和k)对高光谱图像的定量结果;图6展示了高光谱图像的视觉比较。表17列出了使用不同评估矩阵 (例如OA、灵敏度、MD、FA、F1、BA、精度、特异性和KC)的多光谱图像的定量结果。图7展示了多光谱图像的视觉比较。同样,表18给出了定量结果,图8显示了使用不同评估矩阵 (例如 FA、MA、OE、OA 和 KC)对异质图像进行的视觉比较。




图 4.使用农田 C 的各种方法对 CD 结果进行视觉比较: (a)参考、(b) FCM、(c) NLMFCM、(d) DBN、(e) SCCN、(f)小波融合、(g) gcForest, (h)提出的方法。




图 5.使用各种 DL 方法对区域 6 进行 CD 结果的视觉比较: (a)图像 T1, (b)图像 T2, (c)参考变化图, (d) CDNet, (e) FC-EF, (f) FC-Siam-conc、(g) FC-Siam-diff、(h) FC-EF-Res、(i) FCN-PP 和(j) U-Net++。更改的部分以白色标记,未更改的部分以黑色标记。




图 6. 高光谱赫斯顿图像的 CD 结果(a)地面实况, (b) U-Net, (c) RU-Net, (d) Att U-Net, (e) R2U-Net 和(f) Att R2U-网络。




图 7. 多光谱 Saclay 图像的 CD 结果(a) CVA-SVM, (b) MAD-SVM, (c) PCA-SVM, (d) IR-MAD-SVM, (e) SFA-SVM, (f) 3D-CNN, 以及(g)提议的方法。黑色、红色和蓝色表示 TP 和 TN、FN 和 FP 像素。




图 8.异质图像的 CD 结果。(a,b)不同观察获得的图像次, (c)参考图像。(d) PCC, (e) SCCN, (f) ASDNN, (g)基于 FL, (h) LTFL。

表 14. SAR 图像的定量结果[117]。

方法	纤维网	FP	你是	PCC	K
流式细胞仪	12,126	813	12,939	85.47	34.95
NLMFCM	第687章	第668章	第1355章	98.48	86.36
数据库网络	第697章	第841章	1538	98.27	84.29
SCCN	第768章	第779章	第1547章	98.26	84.38
小波融合	931	第1377章	2308	97.41	75.76
GC森林	124	第685章	809	99.09	91.41
提议的方法	163	630	第793章	99.11	91.66

表 15.VHR图像的定量结果[157]。

方法	精确	记起	F1-分数	哦
CD网	0.7395	0.6797	0.68 82	0.9105
FC-EF	0.8156	0.7613	0.7711	0.9413
暹罗FC	0.8441	0.8250	0.8250	0.9572
FC-暹罗-diff	0.8578	0.8364	0.8373	0.9575
FC-EF-Res	0.8093	0.7881	0.7861	0.9436
FCN-PP	0.8264	0.8060	0.8047	0.9536
优网++	0.8954	0.8711	0.8756	0.9673

表 16.高光谱图像的定量结果[149]。

方法	哦	精确	记起	F1-分数	K
优网	0.945470	0.935675	0.951087	0.942151	0.950427
鲁网	0.989402	0.948417	0.923722	0.935821	0.945470
那个U网	0.986232	0.900143	0.908169	0.893870	0.930937
R2 U-网	0.953387	0.978676	0.920067	0.919009	0.900139
那个R2U-Net	0.991611	0.958538	0.946333	0.952342	0.957096

表 17.多光谱图像的定量结果[157]。

方法	OA 灵敏度 MD FA F1 BA						精密度特异性KC		
脑血管病协会	94.09	19.50			80.50	4.16 13.15 57.67	9.92	95.84	0.104
疯狂的	91.05	42.48			57.52	7.81 17.88 67.34	11.32	92.19	0.148
主成分分析	92.55	19.25			80.75	5.72 10.61 56.77	7.32	94.28	0.075
红外MAD	91.1	40.56			59.44	7.70 17.31 66.43	11点	92.30	0.142
国家安全局	92.48	31.06			68.94	6.07 15.94 62.49	10.72	93.93	0.128
3D-CNN	98.15	29.19			70.81	0.23 42.02 64.48	74.96	99.77	0.413
建议方法	99.18	75.40			24.60	0.25 80.99 87.58 87.46 99.75		0.805	

表 18.异质图像的定量结果[174]。

方法	但	和	你是	哦	肯尼迪
PCC	2947	第1187章	4134	95.86	0.4651
SCCN	2094	第538章	2632	97.36	0.6532
亚斯德尼神经网络	1939年	第525章	2464	97.53	0.6695
基于FL	2027年	627	2654	97.34	0.6434
LTFL	1104	第841章	1945年	98.05	0.6950

7. 讨论

CD 的深度学习方法在遥感、基于深度学习的技术已被证明是非常成功的。然而,有过程中存在的问题较多,具体如下:

7.1.训练样本

尽管深度学习算法可以从原始数据中学习高度抽象的特征表示遥感图像检测和识别的成功取决于大量的训练样本。然而,因为收集标记的高分辨率图像是

具有挑战性,(经常)缺乏高质量的培训。在这些条件下,以更少的适当数量保留深度学习算法的表示学习性能训练样本仍然是一个重大问题。为了正确训练系统,深度学习研究人员采用各种策略,包括迁移学习[186-192]、数据增强、GAN [148,155]、 AE 和 SSAE [193]。虽然这些技术可以缓解一些问题由于样本不足,需要进一步改进。一种深度学习方法[194]涉及信任监督 CD 的小型训练数据集。这种方法似乎是非常有趣,因为它最大限度地减少了标记训练数据的要求。

7.2.先验知识

由于变化位置和方向模糊,变化地图上的总面积大于变化检测中的变化区域。由于缺乏先验信息,传统的无监督方法无法快速解决这个问题。因此,弱和使用半监督方法,但需要进行高级研究以提高其表演。

7.3.图像配准

近年来,深度学习RS图像配准已成为一个活跃的研究领域。深度学习在图像配准方面的主要限制是缺乏可用的公共资源训练数据集,这应该是遥感界未来的努力。有许多挑战需要解决,特别是在遥感器数据集中。由于

由于不同分辨率、不同时间（或不同方式）获取的遥感图像的多样性，建立庞大的图像配准公共训练数据集将是一项重要的挑战和艰巨的任务[163]。例如，来自流动站、卫星或机载传感器的非最低点图像配准[50]仍然是未解决的挑战。使用稳健的预测算法来处理配准错误是该问题的一种可能的解决方案。已经提出了一些算法来减少配准错误[195]。此外，遥感图像（例如多时相图像）的准确配准非常具有挑战性。为了更好地了解如何最大程度地减少残余重合失调对变化检测过程的影响，请参阅。[196]研究了影响多时相 VHR 数据集的配准噪声行为。需要对稳健可靠的注册方法进行更多研究。

7.4. RS图像复杂性由于可

见光、微波、红外等多种辐射和散射特性，遥感数据十分复杂；图像行为随地面特征的不同而变化很大。与自然场景图像相比，高分辨率遥感图像在单个场景中包含各种颜色、大小、旋转和位置的物体。

相比之下，其他类别的独特场景可能在很多方面彼此相似。

RS 图像的复杂性极大地增加了使用深度学习从场景和对象中学习稳定且有辨别力的表示的挑战。遥感社区认识到，远距离观测的基本问题永远无法解决。例如，将数据与噪声分离以恢复一组特定的地球物理特征，以及精确的传感器校准是持续存在的问题。技术发展增强了观测的信息内容，但数据永远不足以唯一地识别所有感兴趣的地球物理特征；随着科学的进步，所需的“可观察物”的清单也在不断扩大。因此，RS 仍然是一个根本上不适定的问题，必须通过理论模型、先验知识和辅助观察来正确表征和限制。这些是制定新的科学目标时需要考虑的关键因素。在[197,198]中，作者提出了一些克服RS问题的挑战和一些有用的建议，这对研究人员很有帮助。

7.5. 多重变化图大多数CD算法仅

识别二值变化而忽略了遥感图像中的多重变化检测，大多数研究集中在二值CD上，并且仅区分是否存在变化。在多个 CD 上的工作有限，其中变更类进一步细分为几种变更类型。很少有研究，例如[149,150,152,153,163]，关注多个变化图。此外，超维图像用于二进制 CD；据我们所知，只有一项研究使用了超维图像，即[152]，用于多类CD。因此，有必要进行进一步的研究。学者们应该引入一种针对不同数据集上的多个变化图的新方法，因为过去一些研究人员只使用多个CD的高光谱图像，因此还需要在其他RS图像上进行更多的实验，例如VHR图像和超维图像。

八、结论

我们回顾了文献中一些最著名的 RS 数据集和用于变化检测的最新 DL 算法，这些算法取得了出色的性能。此外，还进行了更深入的回顾，以描述和讨论 DL 算法在其类别中的使用，例如有监督变化检测方法、无监督变化检测方法和半监督方法；我们还介绍了它们的优点和缺点，这使我们的研究与以前的评论不同。对DL中用于变化检测的系统分析和常用网络表明，变化检测已经取得了很大的进步，但由于缺乏训练数据、先验知识、图像复杂性等，CD仍然存在许多挑战。即使这些

挑战已被克服,由于不断变化的需求和多样化的数据,仍然有许多RS数据集中尚未关注的核心问题,例如异构数据,多分辨率图像,以及高分辨率和大尺寸图像的全局信息。因此,强烈建议进一步研究更加关注这些挑战。

作者贡献:所有作者都对本文做出了重大贡献。评价由 AS 在 GCZK 和 MA (Muhammad Asad) 的监督下创建和编写; MA (穆罕默德·阿斯拉姆)帮助审查相关文献。总体框架所有贡献者都讨论了本文的内容。AS和GC创建了整体框架审查、检查文章并监督整个研究的各个阶段。所有作者都读过并同意手稿的出版版本。

基金资助:本研究得到江苏省自然科学基金项目的部分资助基金BK20191284和国家自然科学基金项目61801222。

致谢:作者衷心感谢学术编辑和审稿人提供的有益评论和建设性想法。

利益冲突:作者声明不存在利益冲突。

缩写

本手稿中使用了以下缩写:

远视过程调用	有理多项式系数
DTM	数字地形模型
SIFT	尺度不变特征变换
PSOSAC	粒子群优化样本共识
CACO	连续蚁群优化
RANSAC	随机样本共识
DCGAN	深度卷积生成对抗网络
SSJLN	谱空间联合学习网络
HRMS	高分辨率多光谱
SCCN	对称卷积耦合网络
DHFF	深度同质特征融合
MFCU	多尺度特征卷积单元
DSMS-CN	深度连体多尺度卷积网络
FCN	全卷积网络
DLSF	基于对偶学习的Siamese框架
FC-CRF	全连接条件随机场
KCCA	核典型相关分析
CVD	深度变化向量
是	图像风格迁移
DHFF	深度同质特征融合
SSPCN	空间自定进度卷积网络
声压级	自定进度的学习
真阳性率	真阳性率
总氮比	真阴性率
鹏	接收器工作特性

参考

1. 瓦尔盖斯, A.; 古比, J.; 拉马斯瓦米, A.; Balamuralidhar, P. ChangeNet:用于视觉变化检测的深度学习架构。欧洲计算机视觉会议 (ECCV) 研讨会论文集, 德国慕尼黑, 2018 年 9 月 8 日至 14 日。
2. Singh, A. 回顾文章使用遥感数据的数字变化检测技术。国际。 J. 遥感。 1989, 10, 989–1003。
[\[交叉参考\]](#)
3. 西萨拉赫, H.; 戈尔丁, SE; 雷兹吉, A.; 努尔·埃尔·伊斯兰, B.; Ait-Aoudia, S. 什么是遥感变化检测技术? 走向概念框架。国际。 J. 遥感。 2020, 41, 1788–1812。
[\[交叉参考\]](#)
4. 刘, R.; 库弗, M.; Persello, C. 采用基于 CNN 的变化检测方法的贫民窟的时间动态。偏僻的 Sens. 2019, 11, 2844. [\[交叉引用\]](#)

5. 黄X.; 曹Y., Li, J. 一种利用时间序列多视图高分辨率光学卫星图像监测新建建筑区域的自动变化检测方法. 遥感环境. 2020, 244, 111802. [\[交叉引用\]](#)
6. 李Z., 沉H., 程Q., 刘Y., 你的. 基于深度学习的不同传感器中高分辨率遥感图像云检测. ISPRS J. 摄影图. 遥感. 2019, 150, 197–212. [\[交叉参考\]](#)
7. Rußwurm, M.; Korner, M. 使用长短期记忆网络对中等分辨率多光谱卫星图像进行作物识别的时间植被建模. IEEE 计算机视觉和模式识别研讨会会议记录, 美国夏威夷檀香山, 2017 年 7 月 21–26 日; 第 11–19 页。
8. 博伊德, DS; Foody, GM 对近期基于遥感和 GIS 的生态信息学研究进行了概述. 生态. 通知. 2011 年, 6, 25–36. [\[交叉参考\]](#)
9. 苏迈亚, M.; Kumari, RSS Gabor 滤波器, 通过 KI 阈值对 SAR 图像进行变化检测. 光学 2017, 130, 114–122. [\[交叉参考\]](#)
10. 尚R.; 袁Y., 焦L., 孟Y., Ghalamzan, AM 用于合成中变化检测的自定进度学习算法
孔径雷达图像. 信号处理. 2018, 142, 375–387. [\[交叉参考\]](#)
11. 布鲁佐内, L.; Prieto, DF 自动分析差异图像以进行无监督变化检测. IEEE 传输. 地理学. 遥感. 2000, 38, 1171–1182. [\[交叉参考\]](#)
12. Celik, T. 使用主成分分析和 k 均值聚类对卫星图像进行无监督变化检测. IEEE 地球科学. 遥感快报. 2009, 6, 772–776. [\[交叉参考\]](#)
13. 刘S.; 布鲁佐内, L.; 博沃洛, F.; Du, P. 多时相高光谱图像中的分层无监督变化检测. IEEE 跨. 地理学. 遥感. 2014, 53, 244–260。
14. 费拉里斯, V.; 多比根, N., 魏, Q., Chabert, M. 检测不同空间和光谱的光学图像之间的变化
决议: 基于融合的方法. IEEE 传输. 地理学. 遥感. 2017, 56, 1566–1578. [\[交叉参考\]](#)
15. 刘S.; 杜Q., 董X., 萨马特, A.; 布鲁佐内, L.; Bovolo, F. 多尺度形态压缩变化向量分析
无监督的多重变化检测. IEEE J. Sel. 顶部. 应用. 地球观测. 遥感. 2017, 10, 4124–4137. [\[交叉参考\]](#)
16. 吴C.; 杜B., 崔X.; 张L. 基于迭代慢特征分析和的分类后变化检测方法
贝叶斯软融合. 遥感环境. 2017, 199, 241–255. [\[交叉参考\]](#)
17. 高F.; 张L., 王J., Mei, J. 利用纹理信息和支持向量机对复杂地形受损区域遥感图像进行变化检测. 国际电路与系统会议 (CAS 2015) 论文集, 法国巴黎, 2015 年 8 月 9–10 日; 第 9–10 页。
18. 沃尔皮, M.; 图亚, D.; 博沃洛, F.; 卡内夫斯基, M.; Bruzzone, L. 使用上下文对 VHR 图像进行监督变化检测
信息和支持向量机. 国际. J. 应用程序. 地球观测. 地理信息. 2013, 20, 77–85. [\[交叉参考\]](#)
19. 博沃洛, F.; 布鲁佐内, L.; Marconcini, M. 基于半监督 SVM 的无监督变化检测新方法和相似性度量. IEEE 传输. 地理学. 遥感. 2008, 46, 2070–2082. [\[交叉参考\]](#)
20. 朱XX.; 图亚, D.; 穆, L., 夏, GS.; 张L., 徐, F. Fraundorfer, F. 遥感深度学习: 综合
审查和资源清单. IEEE 地球科学. 遥感杂志. 2017 年, 5, 8–36. [\[交叉参考\]](#)
21. 马L.; 刘Y., 张X.; 叶Y., 尹, G.; Johnson, 文学学士 遥感应用中的深度学习: 荟萃分析和评论.
ISPRS J. 摄影图. 遥感. 2019, 152, 166–177. [\[交叉参考\]](#)
22. 鲍尔, JE.; 安德森, DT; Chan, CS, Sr. 遥感深度学习的综合调查: 理论、工具和社区面临的挑战. J. 应用程序. 遥感. 2017, 11, 042609. [\[交叉引用\]](#)
23. 侯赛因, M.; 陈, D., 程, A., 魏, H., Stanley, D. 遥感图像的变化检测: 从基于像素到
基于对象的方法. ISPRS J. 摄影图. 遥感. 2013, 80, 91–106. [\[交叉参考\]](#)
24. 石W.; 张, M., 张, R., 陈, S., Zhan, Z. 基于人工智能的变化检测: 最先进的技术和挑战。
遥感. 2020, 12, 1688. [\[交叉引用\]](#)
25. 阿法克, Y.; Manocha, A. 遥感应用变化检测技术分析: 综述. 生态. 通知. 2021, 63, 101310. [\[交叉引用\]](#)
26. Kwan, C. 使用多光谱和高光谱图像进行实际变化检测应用的方法和挑战。
信息 2019, 10, 353. [\[交叉引用\]](#)
27. 科平, P.; 兰宾, E.; 容克希尔, J.; Muys, B. 自然生态系统监测中的数字变化检测方法: 综述。
分析-多时相遥感图像 2002, 3–36. [\[交叉参考\]](#)
28. 卢D.; 莫塞尔, P.; 布隆迪齐奥, E.; Moran, E. 变更检测技术. 国际. J. 遥感. 2004, 25, 2365–2401. [\[交叉参考\]](#)
29. 陈, G.; 海伊, GJ.; 卡瓦略, LM; Wulder, MA 基于对象的变化检测. 国际. 遥感杂志, 2012, 33, 4434–4457. [\[交叉参考\]](#)
30. 秦R.; 田, J., Reinartz, P. 3D 变化检测 - 方法和应用. ISPRS J. 摄影图. 遥感. 2016, 122, 41–56. [\[交叉参考\]](#)
31. 张L.; 张L., Du, B. 遥感数据深度学习: 最新技术教程. IEEE 地球科学。
遥感杂志. 2016 年, 4, 22–40. [\[交叉参考\]](#)
32. 钟Y.; 马, A., Soon-Ong, Y.; 朱, Z.; 张丽. 光学遥感图像处理中的计算智能. 应用。
软计算. 2018, 64, 75–93. [\[交叉参考\]](#)
33. 刘S.; 马里内利, D.; 布鲁佐内, L.; Bovolo, F. 多时相高光谱图像变化检测综述: 当前
技术、应用和挑战. IEEE 地球科学. 遥感杂志. 2019, 7, 140–158. [\[交叉参考\]](#)

- 34.赫利菲,L.; Mignotte, M. 用于遥感图像变化检测的深度学习:综合回顾和荟萃分析。IEEE 访问2020, 8, 126385–126400。[交叉参考]
35. Tsagakatakis, G.; 艾迪尼, A.; 福蒂亚杜, K.; 詹诺普洛斯, M.; 彭塔里, A.; Tsakalides, P. 深度学习方法调查遥感观测增强。传感器2019, 19, 3929。[交叉引用]
36. Giardino, M.J. 美国宇航局遥感对考古学贡献的历史。J.阿切尔.科学。2011, 38, 2003–2009。[交叉参考]
37. 马蒂斯, S.; 克斯滕, J.; Twele, A. 基于 TerraSAR-X 的全自动洪水服务。ISPRS J.摄影图.遥感, 2015, 104, 203–212。[交叉参考]
38. 刘, S.; 杜, Q.; 童, X.; 萨马特, A.; Bruzzone, L. 通过光谱空间频带扩展对多光谱遥感图像进行无监督变化检测。IEEE J. Sel.顶部.应用.地球观测.遥感.2019, 12, 3578–3587。[交叉参考]
39. 亚当, T.; 赫鲁斯卡, J.; 帕多瓦, L.; 贝萨, J.; 佩雷斯, E.; 莫赖斯, R.; Sousa, J.J. 高光谱成像:基于无人机的传感器的评论, 农业和林业数据处理和应用.遥感. 2017, 9, 1110。[交叉引用]
40. Ortenberg, F. 高光谱传感器特性:机载、星载、手持式和卡车安装,高光谱数据与激光雷达的集成.基础知识、传感器系统、光谱库和植被数据挖掘; CRC Press:美国佛罗里达州博卡拉顿, 2018 年;第 41–69 页。
41. 卢, B.; 道, P.D.; 刘, J. 嘿。; 尚杰. 高光谱成像技术及其在农业中的应用的最新进展。遥感. 2020, 12, 2659。[交叉引用]
42. Seydi, S.T.; Hasanlou, M. 高光谱变化检测中全色锐化的灵敏度分析.应用.土工垫. 2018, 10, 65–75。[交叉参考]
43. 朱, L.; 索马莱宁, J.; 刘, J.; 希普帕, J.; 卡蒂宁, H.; Haggren, H. 评论:遥感传感器.多用途地理空间数据的应用; IntechOpen:英国伦敦, 2018 年;第 19–42 页。
44. 吉, C.; 李, X.; 魏, H. Li, S. 用于光合和非光合植被分数反演的不同多光谱传感器的比较.遥感. 2020, 12, 115。[交叉引用]
45. 托特, C.; Jó'zów, G. 遥感平台和传感器:一项调查。ISPRS J.摄影图.遥感. 2016, 115, 22–36。[交叉参考]
46. 基尔希特, M.; Rinke, C. 根据合成孔径雷达 (SAR) 图像对建筑物和植被进行 3D 重建.在 MVA 会议记录,日本千叶,1998 年 11 月 17 日至 19 日;第 228–231 页。
47. Ferro-Famil, L.; Pottier, E. 合成孔径雷达成像.地表微波遥感;爱思唯尔:阿姆斯特丹, 荷兰, 2016 年;第 1–65 页。
48. 查特吉, A.; 穆克吉, J.; 艾卡特, S.; Misra, A. 双极化合成的稻田半监督分类使用深度学习的孔径雷达 (SAR) 图像.国际. J. 遥感. 2021, 42, 1867–1892。[交叉参考]
49. 刘, L.; 贾, Z.; 杨, J. Kasabov, 基于数学形态学和K-means的NK SAR图像变化检测聚类算法。IEEE 访问2019, 7, 43970–43978。[交叉参考]
50. 高, F.; 董, J.; 李, B.; 徐, Q. Xie, C. 基于邻域比率和极限学习机的合成孔径雷达图像变化检测。J.应用程序.遥感. 2016, 10, 046019。[交叉引用]
51. Schowengerdt, R.A. 遥感:图像处理模型和方法;爱思唯尔:荷兰阿姆斯特丹, 2006 年。
52. 哈根, 北卡罗来纳州; Kudenov, M.W. 快照光谱成像技术回顾.选择.工程师. 2013, 52, 090901。[交叉引用]
53. Anees, A.; 阿里亚尔, J.; 奥莱利, M.M.; 大风, T.J.; Wardlaw, T. 一种强大的多内核变化检测框架,用于使用 Landsat 7 ETM+ 数据检测叶甲虫落叶。ISPRS J.摄影图.遥感. 2016, 122, 167–178。[交叉参考]
54. 戴, X.L.; Khorram, S. 基于人工神经网络的遥感变化检测.摄影图.工程师.遥感. 1999, 65, 1187–1194。
55. 吴, C.; 杜, B.; 张, L. 多光谱图像中变化检测的慢速特征分析。IEEE 传输.地理学.遥感. 2013, 52, 2858–2874。[交叉参考]
56. 布鲁佐内, L.; Cossu, R. 用于检测土地覆盖转变的 RBF 神经网络方法.遥感图像和信号处理VII; SPIE:美国华盛顿州贝灵厄姆, 2002 年;第 4541 卷,第 223–231 页。
57. 阿布埃尔加西姆, A.A.; 罗斯, W.; 戈帕尔, S.; Woodcock, C. 使用自适应模糊神经网络进行变化检测:环境海湾战争后的损失评估.遥感环境. 1999, 70, 208–223。[交叉参考]
58. Zhu, Z. 使用陆地卫星时间序列进行变化检测:频率、预处理、算法和应用的回顾。ISPRS J.摄影图.遥感. 2017, 130, 370–384。[交叉参考]
59. 卡马鲁丁, M.K.A.; 堪萨斯州吉达多; 缅甸州托里曼; 朱希尔, H.; 奥马尔, R.; 阿卜德·瓦哈卜, N.; 易卜拉欣, S.; 阿旺, S.; 莫鲁德, K.N.A. 使用 GIS 和遥感技术对马来西亚登嘉楼州肯逸湖盆地的土地利用/土地覆盖变化进行分类.国际. J. 工程.技术. 2018 年 7 月 12 日至 15 日。[交叉参考]
60. 费尔德伯格, J.; 内塔尼亚胡, 新斯科舍省; Shoshany, M. 一种基于神经网络的线性特征变化检测技术及其在地中海地区的应用。IEEE 国际地球科学和遥感研讨会论文集,比利时布鲁塞尔, 2002 年 7 月 11–16 日;第 2 卷,第 1195–1197 页。
61. 戈什, A.; 苏布迪, B.N.; Bruzzone, L. 集成吉布斯马尔可夫随机场和 Hopfield 型神经网络,用于遥感多时相图像中的无监督变化检测。IEEE 传输.图像处理. 2013, 22, 3087–3096。[交叉参考]
62. 戈什, S.; 帕特拉, S.; Ghosh, A. 一种基于改进自组织的无监督上下文敏感变化检测技术特征图神经网络.国际. J. 大约.原因. 2009, 50, 37–50。[交叉参考]

63. 韩, M.; 张, C.; 周宇. 基于熵的遥感图像逐对象联合分类变化检测
通过模糊 ARTMAP 进行查询. 地理信息科学. 遥感. 2018, 55, 265–284. [\[交叉参考\]](#)
64. 波门特, A.; 皮基亚尼, M.; Del Frate, F. 基于深度特征的 Sentinel-2 变化检测. IGARSS 2018-2018 IEEE 国际地球科学与遥感研讨会论文集, 西班牙巴伦西亚, 2018 年 7 月 22-27 日; 第 6859–6862 页。
65. 阿拉比, MEA; 卡鲁伊, MS; Djerriri, K. 通过深层暹罗网络进行光学遥感变化检测. IGARSS 2018-2018 IEEE 国际地球科学与遥感研讨会论文集, 西班牙巴伦西亚, 2018 年 7 月 22-27 日; 第 5041–5044 页。
66. 张, NB; 韩, M.; 姚, W.; 陈, LC; Xu, S. 使用 SPOT-5 检测城市地区土地利用和土地覆盖的变化
图像和部分 Lanczos 极限学习机. J. 应用程序. 遥感. 2010, 4, 043551.
67. 内穆尔, H.; Chibani, Y. 通过模糊积分进行神经网络组合, 用于遥感图像中的鲁棒变化检测。
EURASIP J. Adv. 信号处理. 2005, 2005, 413784. [\[交叉引用\]](#)
68. 内穆尔, H.; Chibani, Y. 用于遥感图像变化检测的模糊神经网络架构. 国际. J. 遥感. 2006, 27, 705–717. [\[交叉参考\]](#)
69. 范, J.; 关联. ; Han, M. 一种基于权重聚类稀疏自动编码器的新型联合变化检测方法. IEEE J. Sel. 顶部. 应用. 地球观测. 遥感. 2019, 12, 685–699. [\[交叉参考\]](#)
70. 白, T.; 孙, K.; 邓, S. Chen, Y. 高分辨率卫星图像中面向对象变化检测的四种机器学习方法的比较. MIPPR 2017: 遥感图像处理、地理信息系统及其他应用; SPIE: 美国华盛顿州贝灵厄姆, 2018 年; 第 10611 卷, 第 14 页. 106110G。
71. 雷, T.; 张, Y.; 吕, Z.; 李, S.; 刘, S. 阿拉斯加州南迪 使用深层双时态图像绘制山体滑坡库存图
卷积神经网络. IEEE 地球科学. 遥感快报. 2019, 16, 982–986. [\[交叉参考\]](#)
72. 汉, P.; 苹果. ; 李, Q.; 冷, P.; 公共汽车. ; Li, K. 使用双感兴趣区域网络的航空图像变化检测. 神经计算 2019, 349, 190–201. [\[交叉参考\]](#)
73. 吴, C.; 张, L. Du, B. 用于场景变化检测的内核慢特征分析. IEEE 传输. 地理学. 遥感, 2017, 55, 2367–2384. [\[交叉参考\]](#)
74. Daudt, RC; 勒索克斯, B.; 鲍尔奇, A.; Gousseau, Y. 使用卷积神经网络进行多光谱地球观测的城市变化检测. IGARSS 2018-2018 IEEE 国际地球科学与遥感研讨会论文集, 西班牙巴伦西亚, 2018 年 7 月 22-27 日; 第 2115–2118 页。
75. 龚, M.; 詹, T.; 张, P. Miao, Q. 用于多光谱变化检测的基于超像素的差异表示学习
遥感图像. IEEE 传输. 地理学. 遥感. 2017, 55, 2658–2673. [\[交叉参考\]](#)
76. 吉, S.; 魏, S. Lu, M. 用于从开放航空和卫星图像中提取多源建筑物的全卷积网络
数据集. IEEE 传输. 地理学. 遥感. 2018, 57, 574–586. [\[交叉参考\]](#)
77. 列别捷夫, M.; 维齐尔特, YV; 维戈洛夫, O.; 克尼亚兹, V.; Rubis, AY 使用条件对抗网络对遥感图像进行变化检测. 2018 年 SPRS TC II 中期研讨会 “走向摄影测量 2020” 会议记录, 意大利加尔达湖滨, 2018 年 6 月 4-7 日; 第 42 卷。
78. 贝内德克, C.; Szirányi, T. 通过多层条件混合马尔可夫模型对光学航空图像进行变化检测. IEEE 传输. 地理学. 遥感. 2009, 47, 3416–3430. [\[交叉参考\]](#)
79. 巴兹, Y.; 梅尔加尼, F.; Al-Sharari, HD 具有水平集的多光谱遥感图像中的无监督变化检测方法. IEEE 传输. 地理学. 遥感. 2010, 48, 3178–3187. [\[交叉参考\]](#)
80. 图克斯伯里, 美联社; 康伯, AJ; 新泽西州泰特; 兰姆, A.; Fisher, PF 遥感光学图像变化的关键综合
检测技术. 遥感环境. 2015, 160, 1–14. [\[交叉参考\]](#)
81. 克沙瓦, N.; 芥末, JF 光谱分解. IEEE 信号处理. 马格. 2002, 19, 44–57. [\[交叉参考\]](#)
82. 王, Q.; 张, F. Li, X. 高光谱波段选择的最佳聚类框架. IEEE 传输. 地理学. 遥感 2018, 56, 5910–5922. [\[交叉参考\]](#)
83. 加米西, P.; 横屋, N.; 李, J.; 廖, W.; 刘, S. 普拉扎, J.; 拉斯蒂, B.; Plaza, A. 高光谱图像和信号处理的进展: 对现有技术的全面概述. IEEE 地球科学. 遥感杂志. 2017 年, 5, 37–78. [\[交叉参考\]](#)
84. 达拉-穆拉, M.; 普拉萨德, S.; 帕西菲奇, F.; 甘巴, P.; 查努索, J.; Benediktsson, JA 多式联运的挑战和机遇
和遥感数据融合. 过程. IEEE 2015, 103, 1585–1601. [\[交叉参考\]](#)
85. 莫梅尼, R.; 阿普林, P.; Boyd, DS 通过星载图像绘制复杂的城市土地覆盖: 空间的影响
分辨率、光谱带集和分类方法. 遥感. 2016, 8, 88. [\[交叉引用\]](#)
86. 龚, J.; 刘, C.; 黄, X. 从高分辨率遥感图像中提取城市信息的进展. 科学. 中国地球科学. 2020, 63, 463–475. [\[交叉参考\]](#)
87. 刘, D.; 托曼, E.; 富勒, Z.; 陈, G. 伦敦, A.; 张, X.; 赵, K. 整合历史地图和航空图像来表征长期土地利用变化和景观动态: 通过随机森林进行基于对象的分析. 生态. 印度语. 2018, 95, 595–605. [\[交叉参考\]](#)
88. 黄, X.; 温, D. 李, J. 秦 R. 使用高分辨率对中国特大城市微妙的城市变化进行多层次监测
多视角卫星图像. 遥感环境. 2017, 196, 56–75. [\[交叉参考\]](#)
89. 佩萨雷西, M.; 华东, G.; 布莱斯, X.; 埃利希, D.; 费里, S.; 格根, L.; 哈尔基亚, M.; 考夫曼, M.; 肯珀, T.; 卢, L. 等人. 来自光学 HR/VHR RS 数据的全球人类住区图层: 概念和初步结果. IEEE J. Sel. 顶部. 应用. 地球观测. 遥感. 2013, 6, 2102–2131. [\[交叉参考\]](#)

90. 布鲁佐内, L.; Bovolo, F. 超分辨率遥感变化检测系统设计的新颖框架
图片。过程。IEEE 2012, 101, 609–630。[交叉参考]
91. 卢, M.; 陈, J.; 唐, H.; 拉奥, Y.; 杨, P. Wu, W. 通过集成基于对象的数据混合模型进行土地覆盖变化检测
Landsat 和 MODIS。遥感环境。2016, 184, 374–386。[交叉参考]
92. 叶 S.; 陈, D. Yu, J. 结合变化向量分析和后分类的有针对性的变化检测程序
方法。ISPRS J. 摄影图。遥感。2016, 114, 115–124。[交叉参考]
93. 塔塔尔, N.; 萨达特塞雷什特, M.; 阿雷菲, H.; Hadavand, A. 一种强大的基于对象的阴影检测方法, 用于城市地区和水体上空
的无云高分辨率卫星图像。副词。太空
研究中心。2018, 61, 2787–2800。[交叉参考]
94. 莫维亚, A.; 贝纳特, A.; Crosilla, F. RGB VHR 图像中的阴影检测和去除, 用于土地利用无监督分类。
ISPRS J. 摄影图。遥感。2016, 119, 485–495。[交叉参考]
95. 利亚西斯, G.; Stavrou, S. 用于阴影检测和建筑物高度估计的卫星图像分析。ISPRS J. 摄影图。遥感。2016, 119, 437–450。[交叉参考]
96. 黄 X.; 张, L. 用于从多光谱 GeoEye-1 图像中自动提取建筑物的多方向和多尺度形态索引。摄影图。工程师。遥感。2011, 77, 721–732。[交叉参考]
97. 宋 H.; 黄, B.; 张, K. 通过形态学在高分辨率卫星图像中进行阴影检测和重建
过滤和基于示例的学习。IEEE 传输。地理学。遥感。2013, 52, 2545–2554。[交叉参考]
98. Mercier, G.; 莫泽, G.; Serpico, S.B. 用于异构遥感图像变化检测的条件联结函数。IEEE 传输。地理学。遥感。2008, 46, 1428–1441。[交叉参考]
99. Prendes, J. 多传感器图像的新统计模型及其应用于变化检测。博士论文, 大学
巴黎-萨克雷, 萨克雷, 法国, 2015。
100. 普伦德斯, J.; 查伯特, M.; 帕斯卡, F.; 吉罗斯, A.; Tournet, J.Y. 一种新的多元统计模型, 用于对同质和异构传感器采集的图像进行变化检测。IEEE 传输。图像处
理。2014, 24, 799–812。[交叉参考] [考研]
101. 奎罗斯-内托, 太平绅士; 坎波斯, MFM; 纳尔逊, BW; de Souza Pio, JL 使用互信息对 Landsat-TM 图像进行自动几何和辐射配准。收录于 GeoInfo 会议记录, 巴
西圣保罗, 2004 年 11 月 22–24 日; 第 343–360 页。
102. 吴, Y.; 马, W. 龚, M.; 苏, L. Jiao, L. 一种基于快速样本一致性的图像配准新型点匹配算法。
IEEE 地球科学。遥感快报。2014 年, 12, 43–47。[交叉参考]
103. 费茨利斯, 阿拉巴马州; 普罗科, A.; 库特鲁姆巴斯, KD; 迈克尔, D.; Kontoes, CC 一种无人机和广域卫星图像之间近实时变化检测的方法。ISPRS J. 摄影图。
遥感。2016, 119, 165–186。
[交叉参考]
104. 吴, Y.; 马, W. 苗, Q. Wang, S. 多传感器遥感图像的多模态连续蚁群优化
通过本地搜索进行注册。群进化。计算。2019, 47, 89–95。[交叉参考]
105. 张 X.; 冷, C.; 洪, Y. 裴, Z.; 程, L. Basu, A. 多模态遥感图像配准方法和
进步: 一项调查。遥感。2021, 13, 5128。[交叉引用]
106. 曹 G.; 周 L.; 一种基于条件随机的高分辨率遥感图像变化检测新方法
场模型。国际。遥感杂志, 2016, 37, 1173–1189。[交叉参考]
107. 富兰克林, SE; Giles, PT 航空和卫星遥感图像的辐射处理。计算。地理学。1995, 21, 413–423。
[交叉参考]
108. 阿贾迪, OA; 迈耶, FJ; Webley, PW 使用多尺度驱动方法检测合成孔径雷达图像的变化。
遥感。2016, 8, 482。[交叉引用]
109. 伊伊诺, S.; 伊藤, R. 土井, K.; 今泉, T.; Hikosaka, S. 使用 SAR 基于 CNN 生成高精度城市分布图
用于短期变化监测的卫星图像。国际。J. 图像数据融合 2018, 9, 302–318。[交叉参考]
110. 纳斯里, M.; Nezamabadi-pour, H. 使用新的自适应阈值函数在小波域中进行图像去噪。神经计算 2009, 72, 1012–1025。[交叉参考]
111. 戈利拉尔兹, NA; 高, H. Demirel, H. 使用哈里斯鹰元启发式优化算法对卫星图像进行去噪
改进的自适应广义高斯分布阈值函数。IEEE 访问 2019, 7, 57459–57468。[交叉参考]
112. 冯, W.; Chen, Y. 使用经过训练的非线性扩散滤波来减少散斑。J. 马斯。成像可见度。2017, 58, 162–178。[交叉参考]
113. 德瓦帕尔, D.; 库马尔, S.; Jojy, C. 一种使用非局部均值滤波去斑点 SAR 图像的新方法。J. 印度社会学会。偏僻的
Sens. 2017, 45, 443–450。[交叉参考]
114. Reich, S.; 沃格特, F.; Dellen, B. 实时边缘保留去噪滤波器。在 VISIGRAPP 会议记录 (4: VISAPP) 中,
葡萄牙马德拉, 2018 年 1 月 27 日至 29 日; 第 85–94 页。
115. 艾丽莎, P.; Sheela, KG 图像去噪技术 - 概述。IOSR J. Electr. 交流。工程师。2016, 11, 78–84。[交叉参考]
116. 龚, M.; 赵, J. 刘, J. 苗, Q. Jiao, L. 基于深度神经网络的合成孔径雷达图像变化检测。
IEEE 传输。神经网络。学习。系统。2015, 27, 125–138。[交叉参考]
117. 马 W.; 杨, H. 吴, Y. 熊, Y. 胡, T. 焦 L.; Hou, B. 基于多粒度级联森林的变化检测和
SAR 图像的多尺度融合。遥感。2019, 11, 142。[交叉引用]
118. 萨马迪, F.; 阿克巴里扎德, G.; Kaabi, H. 使用深度置信网络进行 SAR 图像变化检测: 一种基于形态图像的新训练方法。IET 图像处理。2019, 13, 2255–
2264。[交叉参考]

- 119.高,F.;刘X.董,J.钟,G.;基于深度半 NMF 和 SVD 网络的 SAR 图像变化检测。遥感. 2017, 9, 435. [\[交叉引用\]](#)
120. Planin i v c,P.; Gleich, D. 使用对数累积量和堆叠自动编码器检测 SAR 图像中的时间变化。IEEE 地球科学。遥感快报. 2018, 15, 297–301. [\[交叉参考\]](#)
- 121.Lv ,N.;陈,C.;邱,T. Sangaiah,AK 基于收缩自动编码器的深度学习和超像素特征提取 SAR 图像中的变化检测。IEEE 传输.工业信息通报. 2018, 14, 5530–5538. [\[交叉参考\]](#)
- 122.肖,R.;崔,R.林,M.陈L.;倪,Y. Lin, X. SOMDNCD:基于自组织图和深度神经网络的图像变化检测。IEEE 访问2018, 6, 35915–35925. [\[交叉参考\]](#)
- 123.董H.;马,W.吴,Y.龚,M.; Jiao, L. 用于合成孔径雷达图像变化检测的局部描述符学习卷积神经网络。IEEE 访问2018, 7, 15389–15403. [\[交叉参考\]](#)
- 124.贝加马斯科,L.;萨哈,S.;博沃洛,F.; Bruzzone, L. 基于卷积自动编码器特征提取的无监督变化检测.国际光学与光子学学会《遥感图像与信号处理第二十五届会议记录》,法国斯特拉斯堡,2019 年 10 月 7 日;第 11155 卷,p. 1115510。
- 125.耿,J.;最大限度。;周X; Wang, H. 用于 SAR 图像变化检测的显着性引导深度神经网络。IEEE 传输.地理学。遥感. 2019, 57, 7365–7377. [\[交叉参考\]](#)
- 126.法拉哈尼,M.; Mohammadzadeh, A. 多传感器多时态无监督变化检测的域适应遥感图像.国际. J. 遥感. 2020, 41, 3902–3923. [\[交叉参考\]](#)
- 127.萨哈,S.;博沃洛,F.; Bruzzone, L. 使用无监督 lstm 进行图像时间序列变化检测。IEEE 地球科学.遥感快报. 2020. [\[交叉引用\]](#)
- 128.舒,Y.;李,W.杨,M.程,P. Han, S. 基于补丁的 SAR 图像变化检测方法和标签更新策略。遥感. 2021, 13, 1236. [\[交叉引用\]](#)
- 129.曲X.;高,F.董,J.杜,Q. Li,使用双域网络的合成孔径雷达图像中的 HC 变化检测。IEEE 地球科学.遥感快报. 2021. [\[交叉引用\]](#)
- 130.高,F.;王X.;高,Y.董,J. Wang, S. 基于卷积小波神经网络的 SAR 图像海冰变化检测网络。IEEE 地球科学.遥感快报. 2019, 16, 1240–1244. [\[交叉参考\]](#)
- 131.王R.;王L.;魏X.陈JW; Jiao, L. 用于 SAR 图像变化检测的动态图级神经网络。IEEE 地理学.遥感快报. 2021. [\[交叉引用\]](#)
- 132.Daudt ,RC;勒索克斯,B.; Boulch, A. 用于变化检测的全卷积暹罗网络。2018 年第 25 届IEEE 国际图像处理会议 (ICIP) 会议记录,希腊雅典,2018 年 10 月 7–10 日;第 4063–4067 页。
- 133.Mou ,L.; Zhu,XX 用于多光谱图像中土地覆盖变化检测的循环卷积神经网络。IGARSS 2018-2018 IEEE 国际地球科学与遥感研讨会论文集,西班牙巴伦西亚,2018 年 7 月 22–27 日;第 4363–4366 页。
- 134.张W.;卢X.多光谱图像变化检测的光谱空间联合学习.遥感. 2019, 11, 240. [\[交叉参考\]](#)
- 135.林,Y.;李,S.方,L.; Ghamisi, P. 使用双线性卷积神经网络进行多光谱变化检测。IEEE 地球科学。遥感快报. 2019, 17, 1757–1761. [\[交叉参考\]](#)
- 136.曹,G.;王,B.泽维尔,HC;杨,D. Southworth, J. 一种基于深度神经网络的新型差分图像创建方法用于遥感图像的变化检测.国际.遥感杂志, 2017, 38, 7161–7175. [\[交叉参考\]](#)
- 137.阿特鲁里,明尼苏达州; Kudipudi, S. MAU-Net:多光谱高分辨率卫星图像的变化检测。
- 138.龚,M.杨,Y.詹,T.牛X. Li,S. 用于多光谱变化检测的生成判别分类网络图像。IEEE J. Sel.顶部.应用.地球观测.遥感. 2019, 12, 321–333. [\[交叉参考\]](#)
- 139.萨哈,S.;穆,L.邱,C.;朱XX;博沃洛,F.; Bruzzone, L. 多时态高分辨率图像的无监督深度联合分割。IEEE 传输.地理学.遥感. 2020, 58, 8780–8792. [\[交叉参考\]](#)
- 140.维拉塔马,W.;李,J. Sim, D. 基于特征级 U-Net 的多光谱图像变化检测。IEEE 访问2020, 8, 12279–12289. [\[交叉参考\]](#)
- 141.Seydi ,ST;哈桑卢,M.; Amani, M. 用于土地覆盖/土地利用变化的新的端到端多维 CNN 框架多源遥感数据集中的检测.遥感. 2020, 12, 2010. [\[交叉引用\]](#)
- 142.罗X.;李,X.吴,Y.侯W.;王,M.金,Y.徐文.基于亚像素卷积的高分辨率遥感图像变化检测方法研究。IEEE J. Sel.顶部.应用.地球观测.遥感.2020 , 14, 1447–1457. [\[交叉参考\]](#)
- 143.霍尔加多·阿尔瓦雷斯,JL;拉万巴赫什,M.; Demir, B. S2-cGAN:二进制的自监督对抗性表示学习多光谱图像中的变化检测。arXiv 2020, arXiv:2007.02565。
- 144.张,M.; Shi,W.一种基于特征差异卷积神经网络的变化检测方法。IEEE 传输.地理学.遥感. 2020, 58, 7232–7246. [\[交叉参考\]](#)
- 145.阿尔瓦雷斯,JLH;拉万巴赫什,M.; Demir, B. S2-cGAN:用于多光谱图像中二进制变化检测的自监督对抗性表示学习。IGARSS 2020-2020 IEEE 国际地球科学和遥感研讨会论文集,美国夏威夷威可洛亚,2020 年 9 月 26 日至 10 月 2 日;第 2515–2518 页。
- 146.Seydi ,ST; Hasanlou,M.一种新的基于土地覆盖匹配的高光谱图像变化检测.欧元.遥感杂志, 2017, 50,517–533. [\[交叉参考\]](#)

- 147.洛佩斯-范迪尼奥,J.;加里亚,AS;赫拉斯,DB; Argüello, F. 用于高光谱图像中多类变化检测的堆叠自动编码器。IGARSS 2018-2018 IEEE 国际地球科学与遥感研讨会论文集,西班牙巴伦西亚,2018 年 7 月 22-27 日;第 1906-1909 页。
- 148.侯,B.;刘,Q.;王,H. Wang, Y. 从 W-Net 到 CDGAN:通过深度学习技术进行双时态变化检测。IEEE 传输。地理学。遥感。2019, 58, 1790–1802。[交叉参考]
- 149.穆斯塔法,MS;穆罕默德,SA;艾哈迈德,S.; Nasr,AH 基于 UNet 神经网络修改的高光谱变化检测网络。J.应用程序。遥感。2021, 15, 028505。[交叉引用]
- 150.童X.;潘,H.;刘,S.;李,B.;罗X.;谢H.; Xu,X.一种基于不确定区域分析和改进的迁移学习的高光谱变化检测新方法。IEEE J. Sel.顶部。应用。地球观测。遥感。2020, 13, 2056–2069。[交叉参考]
- 151.宋,A.;金,Y. Han, Y. 使用超高分辨率卫星图像进行基于对象的变化检测的不确定性分析深度学习网络。遥感。2020, 12, 2345。[交叉引用]
- 152.萨哈,S.;康德曼,L.;宋,Q. Zhu,XX 使用未经训练的模型进行超维图像变化检测。IEEE J. Sel. 顶部。应用。地球观测。遥感。2021, 14, 11029–11041。[交叉参考]
- 153.Seydi ,ST; Hasanlou,M.基于光谱分解和卷积神经网络的二值和多重高光谱变化检测的新结构。测量2021, 186, 110137。[交叉引用]
- 154.袁,Y.;吕,H.;卢欣.多时相高光谱图像半监督变化检测方法。神经计算2015, 148, 363–375。[交叉参考]
- 155.王Q.;袁,Z.;杜,Q. Li, X. GETNET:用于高光谱图像变化检测的通用端到端 2-D CNN 框架。IEEE 传输。地理学。遥感。2018, 57, 3–13。[交叉参考]
- 156.黄F.;于,Y. Feng, T. 基于张量和深度学习的高光谱遥感图像变化检测。J. 维斯。交流。图像代表。2019, 58, 233–244。[交叉参考]
- 157.彭,D.;张,Y. guan, H.使用改进的 UNet++ 对高分辨率卫星图像进行端到端变化检测。偏僻的 Sens. 2019, 11, 1382。[交叉引用]
- 158.方,B.;潘,L.; Kou, R. 基于双学习的孪生框架,使用双时态 VHR 光学遥感图像进行变化检测。遥感。2019, 11, 1292。[交叉引用]
- 159.陈,H.;吴,C.;杜,B.;张L. Wang, L. 通过深度连续卷积多层循环神经网络对多源 VHR 图像进行变化检测。IEEE 传输。地理学。遥感。2019, 58, 2848–2864。[交叉参考]
- 160.Jing ,R.;刘,S.;龚,Z.;王,Z.;关,H.;高塔姆,A.;赵,W. 基于对象的 VHR 遥感变化检测基于 Trisiamese-LSTM 的图像。国际。J. 遥感。2020, 41, 6209–6231。[交叉参考]
- 161.贾维德,A.;荣格,S.;李,WH; Han, Y. 通过融合像素级变化检测结果进行基于对象的建筑变化检测从形态建筑索引生成。遥感。2020, 12, 2952。[交叉引用]
- 162.索拉诺-科雷亚,YT;博沃洛,F.; Bruzzone, L. 一种对不同多光谱传感器采集的多时相 VHR 图像进行无监督变化检测的方法。遥感。2018, 10, 533。[交叉引用]
- 163.萨哈,S.;博沃洛,F.; Bruzzone, L. 用于 VHR 图像中多重变化检测的无监督深度变化矢量分析。IEEE 传输。地理学。遥感。2019, 57, 3677–3693。[交叉参考]
- 164.赵W.;陈X.;葛,X. Chen, J. 使用对抗网络进行双时态遥感中的多重变化检测 IEEE 地球科学。遥感快报。2020。[交叉引用]意象。
- 165.萨哈,S.;穆,L.;朱XX;博沃洛,F.; Bruzzone, L. 使用图卷积网络进行半监督变化检测。IEEE 地球科学。遥感快报。2020, 18, 607–611。[交叉参考]
- 166.庞S.;张,A.;郝,J.;刘,F. Chen, J. SCA-CDNet:用于双时态 VHR 图像的稳健的基于暹罗相关性和注意力的变化检测网络。国际。J.遥感。2021年, 1-22。[交叉参考]
- 167.帕帕多玛拉基,M.;瓦卡洛普卢,M.; Karantzas, K.用于城市变化检测的耦合语义分割和全卷积 LSTM 网络的深度多任务学习框架。IEEE 传输。地理学。遥感。2021。[交叉引用]
- 168.吉S.;沉,Y.;卢,M.;张,Y.使用卷积神经网络从大规模航空图像中构建实例变化检测网络和模拟样本。遥感。2019, 11, 1343。[交叉引用]
- 169.杨,J.;周,Y.;曹,Y. Feng, L. 使用深度典型相关分析的异构图像变化检测。2018 年第 24 届国际模式识别会议 (ICPR) 论文集,中国北京,2018 年 8 月 20-24 日;第 2917-2922 页。
- 170.王,M.;坦克.;贾X.;王X; Chen, Y. 具有混合卷积特征提取模块的深度暹罗网络基于多传感器遥感图像的变化检测遥感。2020, 12, 205。[交叉引用]
- 171.玉宝,P.;萨哈,S.; Zhu,XX 融合多模态数据进行监督变化检测。国际。拱。摄影图。遥感争端。信息。科学。2021, 43, 243–249。[交叉参考]
- 172.刘,J.;龚,M.;秦K.;张,P.一种基于异构光学变化检测深度卷积耦合网络和雷达图像。IEEE 传输。神经网络。学习。系统。2016, 29, 545–559。[交叉参考]
- 173.牛X.;龚,M.;詹,T. Yang,Y.用于异构图像变化检测的条件对抗网络。IEEE 地理学。遥感快报。2018, 16, 45–49。[交叉参考]
- 174.詹,T.;龚,M.;蒋X; Li, S. 基于对数的变换特征学习,用于异构图像中的变化检测。IEEE 地球科学。遥感快报。2018, 15, 1352–1356。[交叉参考]

- 175.图阿蒂,R.;米尼奥特,M.; Dahmane, M. 用于异构图像中无监督变化检测的异常特征学习:深度稀疏残差模型。IEEE J. Sel.顶部。应用。地球观测。遥感. 2020, 13, 588–600。[交叉参考]
- 176.江X.;李,G.刘,Y.张,XP; He,Y.通过深度同质特征融合进行异构光学和 SAR 遥感图像的变化检测。IEEE J. Sel.顶部。应用。地球观测。遥感. 2020, 13, 1551–1566。[交叉参考]
- 177.Prexl, J.;萨哈,S.; Zhu,XX 使用超分辨率和无监督学习减轻变化检测的空间和光谱差异。2021 年 IEEE 国际地球科学与遥感研讨会 IGARSS 会议记录,虚拟, 2021 年 7 月 11-16 日;第 3113-3116 页。
- 178.孙Y.;雷,L.;李,X.孙,H.; Kuang,G.基于非局部斑块相似性的异构遥感变化检测。模式识别。 2021, 109, 107598。[交叉引用]
- 179.李H.;龚,M.;张,M. Wu, Y. 用于异构图像变化检测的空间自定步调卷积网络。IEEE J. Sel.顶部。应用。地球观测。遥感.2021, 14, 4966–4979。[交叉参考]
- 180.杨,M.;焦L.;侯,B.;刘,F. Yang, S. 基于选择性对抗适应的跨场景变化检测框架遥感图像。IEEE 传输。地理学。遥感. 2020, 59, 2188–2203。[交叉参考]
- 181.吴J.;李,B.秦,Y.倪,W.张,H.毛皮.; Sun,Y.用于同质和异构遥感图像变化检测的多尺度图卷积网络。国际。J.应用程序。地球观测。地理信息。 2021, 105, 102615。[交叉引用]
- 182.萨哈,S.;埃贝尔,P.; Zhu,XX 自监督多传感器变化检测。arXiv 2021, arXiv:2103.05102。
- 183.克纳,HR;吉隆坡瓦格斯塔夫;布埃,BD;灰色,PC;贝尔,JF; Amor,HB 通过卷积自动编码器和迁移学习实现行星表面的广义变化检测。IEEE J. Sel.顶部。应用。地球观测。遥感.2019, 12, 3900–3918。[交叉参考]
- 184.萨哈,S.; Zhu,XX 补丁级无监督行星变化检测。IEEE 地球科学。遥感快报。 2021。[交叉引用]
- 185.林,K.;金,D. Kim,CS 使用卷积神经网络集合对高分辨率卫星图像进行变化检测。2018 年亚太信号与信息处理协会年度峰会和会议(APSIPA ASC) 会议记录,美国夏威夷州檀香山,2018 年 11 月 12 日至 15 日;第 509–515 页。
- 186.马尔马尼斯,D.;达特库,M.;埃施,T.; Stilla, U. 使用 ImageNet 预训练网络进行深度学习地球观测分类。IEEE 地球科学。遥感快报。 2015, 13, 105–109。[交叉参考]
- 187.杨J.;赵,Y.陈,JCW; Yi, C. 使用两通道深度卷积神经网络进行高光谱图像分类。2016 年 IEEE 国际地球科学与遥感研讨会 (IGARSS) 论文集,中国北京, 2016 年 7 月 10-15 日;第 5079–5082 页。
- 188.里索耶维奇,V.;莫米克,S.; Babi'c, Z. Gabor 航空图像分类描述符。在国际自适应和自然计算算法;施普林格:柏林/海德堡;德国,2011;第 51–60 页。
- 189.查特菲尔德,K.;西蒙尼扬,K.;维达尔迪,A.; Zisserman, A. 细节中的魔鬼回归:深入研究卷积网络。arXiv 2014, arXiv:1405.3531。
- 190.盛,G.;杨,W.徐,T. Sun, H. 使用基于稀疏编码的多特征进行高分辨率卫星场景分类组合。国际。J. 遥感. 2012, 33, 2395–2412。[交叉参考]
- 191.李SH;陈,CS;梅奥,SJ; Remagnino, P.深度学习如何提取和学习叶子特征以进行植物分类。模式识别。 2017,71,1-13。[交叉参考]
- 192.李SH;陈,CS;威尔金,P.; Remagnino, P. Deep-plant:利用卷积神经网络进行植物识别。2015 年 IEEE 国际图像处理会议 (ICIP) 会议记录,加拿大魁北克市,2015 年 9 月 27-30 日;第 452–456 页。
- 193.陶,C.;潘,H.;李,Y. Zou, Z. 使用堆叠稀疏自动编码器进行高光谱无监督光谱空间特征学习图像分类。IEEE 地球科学。遥感快报。 2015, 12, 2438–2442。
- 194.萨哈,S.;班纳吉,B.; Zhu,XX 信任用于监督变化检测的小型训练数据集。arXiv 2021, arXiv:2104.05443。
195. Schaum, A.高光谱图像的局部协方差均衡:目标检测的优点和局限性。2005 年 IEEE 航空航天会议论文集,美国蒙大拿州 Big Sky,2005 年 3 月 5-12 日; 2001-2011 页。
- 196.马尔凯西,S.;博沃洛,F.; Bruzzone, L. 一种对 VHR 中的变化检测的配准噪声具有鲁棒性的上下文相关技术多光谱图像。IEEE 传输。图像处理。 2010, 19, 1877–1889。[交叉参考] [考研]
- 197.杜博维克,O.;舒斯特,G.;徐,F.胡,Y.博施,H.;兰德格拉夫,J.; Li, Z. 卫星遥感面临的巨大挑战。正面。遥感. 2021, 2, 1。[交叉引用]
198. Wilson, R.遥感的复杂性:文献综述、综合和立场文件。2011 年 6 月 2 日。在线提供: <https://ieeexplore.ieee.org/document/9069898> (2021 年 12 月 22 日访问)。