

中图法分类号: TP319.4 文献标识码: A 文章编号: 1006-8961(2023)06-1685-13

论文引用格式: Nie J T, Zhang L, Wei W, Yan Q S, Ding C, Chen G C and Zhang Y N. 2023. A survey of hyperspectral image super-resolution method. Journal of Image and Graphics, 28(06):1685-1697(聂江涛, 张磊, 魏巍, 闫庆森, 丁晨, 陈国超, 张艳宁. 2023. 高光谱图像超分辨率重建技术研究进展. 中国图象图形学报, 28(06):1685-1697)[DOI:10.11834/jig.230038]

高光谱图像超分辨率重建技术研究进展

聂江涛¹, 张磊^{1*}, 魏巍¹, 闫庆森¹, 丁晨², 陈国超¹, 张艳宁¹

1. 西北工业大学计算机学院, 西安 710072; 2. 西安邮电大学计算机学院, 西安 710061

摘要: 不同于传统图像(如灰度图像、RGB图像等)专注于保存目标场景的空间信息, 高光谱图像蕴含丰富的空—谱信息, 不仅可以保存目标的空间信息, 还可以保存具有高可辨性的光谱信息。因此高光谱图像广泛应用于多种计算机视觉和遥感图像任务中, 如目标检测、场景分类和目标追踪等。然而, 在高光谱图像获取以及重建过程中仍然存在许多问题与瓶颈。如传统高光谱成像仪器在成像过程中通常会引入噪声, 且获得的图像往往具有较低的空间分辨率, 极大地影响了高光谱图像的质量, 对后续数据分析任务造成了极大的困难。近年来, 高光谱图像超分辨率重建技术研究得到了极大的发展, 现有超分辨率重建方法可以大致分为两类, 一类为空间超分辨率重建方法, 可以通过直接提升高光谱图像的空间分辨率来获得高质量高光谱图像; 另一类为光谱超分辨率重建方法, 可以通过提升高空间分辨率图像的光谱分辨率来生成高质量高光谱图像。本文从高光谱图像超分辨率重建领域的新设计、新方法和应用场景出发, 通过综合国内外前沿文献来梳理该领域的主要发展, 重点论述高光谱图像超分辨率重建领域的发展现状、前沿动态、热点问题及趋势。

关键词: 高光谱图像(HSI); 超分辨率重建; 单图超分辨; 融合超分辨; 光谱超分辨

A survey of hyperspectral image super-resolution method

Nie Jiangtao¹, Zhang Lei^{1*}, Wei Wei¹, Yan Qingsen¹, Ding Chen², Chen Guochao¹, Zhang Yanning¹

1. School of Computer Science, Northwestern Polytechnical University, Xi'an 710072, China;

2. School of Computer Science, Xi'an University of Posts & Telecommunications, Xi'an 710061, China

Abstract: Computer vision-oriented hyperspectral images (HSIs) are featured to enrich spatial and spectral information compared to gray and RGB images. It has been developing in such domains like target detection, scene classification, and tracking. However, the HSI imaging technique is challenged for its distortion problems (e. g., low spatial resolution, noise). HSI-related super-resolution (SR) methods are proposed to reconstruct high-quality HSIs in terms of a high spectral resolution and spatial resolution (HR). Current HSI SR methods can be segmented into two categories: spatial SR and spectral SR. The spatial SR method is oriented to reconstruct the target HR HSI via improving the spatial resolution of low-resolution (LR) HSI. It can be subdivided into single image SR and fusion based SR methods further. Single image based SR method can be used to reconstruct the target HSI via directly improving the spatial resolution of LR HSI. However, due to much more spatial information is sacrificed, single image based SR method is challenged to reconstruct effective HSIs.

收稿日期: 2023-01-17; 修回日期: 2023-02-28; 预印本日期: 2023-03-06

* 通信作者: 张磊 nwpuzhanglei@nwpu.edu.cn

基金项目: 国家自然科学基金项目(62101454, 62071387, U19B2037); 中央高校基本科研业务费专项资金资助; 深圳市基础研究资助项目(JCYJ20190806160210899)

Supported by: National Natural Science Foundation of China (62101454, 62071387, U19B2037); Fundamental Research Funds for the Central Universities; Shenzhen Fundamental Research Program (JCYJ20190806160210899)

Therefore, to fuse these high quality spatial information into the LR HSIs, extra high spatial homogeneous information is introduced (e. g. , multispectral image (MSI), RGB). In this way, the spatial resolution of LR HSI can be improved greatly (e. g. , 8 times, 16 times, and 32 times SR). The other HSI SR method is focused on the spectral super-resolution method, which can improve the spectral resolution of high spatial resolution images (e. g. , MSI, RGB) and generate the target hyperspectral image. The literature review is focused on the growth of HSI SR methods in relevance to three aspects single image-based, fusion-based, and spectral super-resolution contexts. Each of these three category for HSI SR methods can be further subdivided into two aspects of traditional optimization framework and deep learning based methods. For single image HSI SR, due to the SR problem being an illness inverse problem, traditional optimization framework based single image HSI SR methods is used to develop effective image priors to restrain the SR process. Image priors like low-rank, sparse representation, and non-local features are commonly used in single based HSI SR method, but it still challenged for such problems of manpower and restrictions. For the traditional fusion based method, the core element is to balance the spatial-spectral correlation between HR MSI and LR HSI. It is feasible to split these two images into key components and then re-combine the effective parts of each image. Therefore, multiple schemes are introduced (e. g. , non-negative matrix factorization, coupled tensor factorization) to leverage the key information from HR MSI and LR HSI. In addition, to increase the effectiveness of these decomposition methods, some constraints are required to be introduced (e. g. , sparse, low-rank). For the traditional spectral resolution method, it is essential to learn how to reconstruct the spectral characteristics from RGB/MSI images. When paired RGB and HSI exist, a promising way is feasible to construct a dictionary (e. g. , sparse dictionary learning) that the mapping relation can be recorded between RGB/MSI images and HSIs. The dictionary learning based spectral super-resolution methods have been developing as well, but it is often challenged to realize more generalization ability for applications. In recent years, deep learning based methods have facilitated much more computer vision tasks, and is beneficial for exploiting the inherent spatial-spectral relations of HSIs. For the single image HSI SR methods, a deep convolution neural network (DCNN) is utilized to learn the mapping process from LR HSI to HR HSI. The DCNN is capable to learn deep image prior from plenty of training samples, which has better representation ability than the heuristic handcrafted image priors (e. g. , low-rank, sparse) to some extent. However, the performance of this kind of method is often restricted by the amount and variety of training samples. Therefore, it is necessary to reconstruct HR HSI from LR HSI in an unsupervised manner, but the robustness of the unsupervised method is still a challenging problem to be resolved. For the deep learning based HSI fusion methods, to extract spatial-spectral information from MSIs and HSIs, an effective design of DCNN frameworks (e. g. , multi-branch, multi-scale, 3D-CNN) are concerned about. However, such problems (e. g. , noise, unknown degeneration, unregistered) are challenged for effective generalization ability of DCNN-based HSI fusion method. To resolve these problems, unsupervised and alternative learning methods are introduced to improve fusion-based generalization ability. The DCNN-unfolding is proposed and the optimal interpretability is demonstrated, and its registration strategy is introduced to improve the robustness further. For the spectral super resolution method, DCNN is demonstrated to model the mapping scheme between RGB/MSI and HR HSI. However, there still some barriers are required to be resolved for DCNN-based spectral super resolution method. For example, most existing spectral super resolution methods can generate HSI only according to its fixed spectral interval or spectrum range. A spectral super resolution framework is required to be linked with generalization ability well in the future. In this study, we will summarize the developing of the HSI SR scope from the perspective of new designs, new methods, and new application scenes.

Key words: hyperspectral image (HSI); super-resolution reconstruction; single image super-resolution; fusion based super-resolution; spectral super-resolution

0 引言

本文主要介绍高光谱图像超分辨率重建领域的新设计、新方法和应用场景,通过综合国内外前沿文

献从两方面介绍该领域的主要发展。一方面介绍面向空间超分辨率重建方法的研究现状;另一方面介绍面向光谱超分辨率重建方法的发展。

不同于灰度图像和 RGB 图像等传统图像(如图 1(a)所示)对光谱信息进行离散采样,高光谱图

像(如图1(b)所示)不仅可以保存目标的空间信息,还可以保存具有高可辨性的连续光谱信息。如图2所示,传统高光谱图像成像设备主要采用推扫式相机,每次获得一个光谱波段的信息,或者获得空间维度中一条线上的光谱信息。该高光谱相机可以获取目标场景完整的光谱信息,但需要改变相机的角度扫描全场景,这一过程通常需要耗费大量成像时间。并且,由于该类高光谱成像设备的感光元件需要更强的能量感应,其原件尺寸往往较大,因此所获得高光谱图像的空间分辨率通常较低。针对该问题,研究者提出了大量高光谱图像超分辨率算法来提升高光谱图像的空间分辨率。现有面向空间的高光谱图像超分辨率重建算法大致分为两类,一类为单图超分辨率重建方法;另一类为基于融合的高光谱图像超分辨率重建方法。相比于单图超分辨率重建方法,基于融合的方法可以借鉴高空间分辨率多光谱图像中的结构信息,从而重建出更高分辨率的图像。除此之外,盲高光谱图像超分方法也是研究者主要关注方向之一,其目的是当降质模型未知时也可以有效重建出目标图像,该类方法具有更好的迁移性,在真实数据上可以取得更好的效果。

由于上述传统高光谱图像成像时主要采用推扫的方式,虽然可以同时保留完整的空-谱信息,但是成像时间较长。相比于高光谱相机,拍摄自然图像的相机可以更快地捕捉目标图像的空间特征且具有较高的空间分辨率,如RGB相机以及多光谱相机,但是该类图像的光谱分辨率往往较低。因此研究者提出通过提升RGB图像或者多光谱图像的光谱分辨率来获得同时具有高空间分辨率、高光谱分辨率的图像。现有光谱超分辨率重建方法通常基于深度网络来学习低光谱图像到高光谱图像的重建过程。但由于光谱变换的复杂性,端到端的深度光谱超分辨率重建网络往往具有较大的局限性,因此如何构建动态网络来灵活地重建目标高光谱图像是当前的一个研究热点。

本文首先介绍面向空间的高光谱图像超分辨率重建方法,包含基于单图的以及基于融合的高光谱图像超分辨率重建方法,每类方法按照实现方式的不同进行系统性介绍。然后对光谱超分辨率重建方法进行详细介绍及总结。最后对比国内外研究发展现状,并对高光谱图像超分辨率重建技术的发展趋势进行展望。

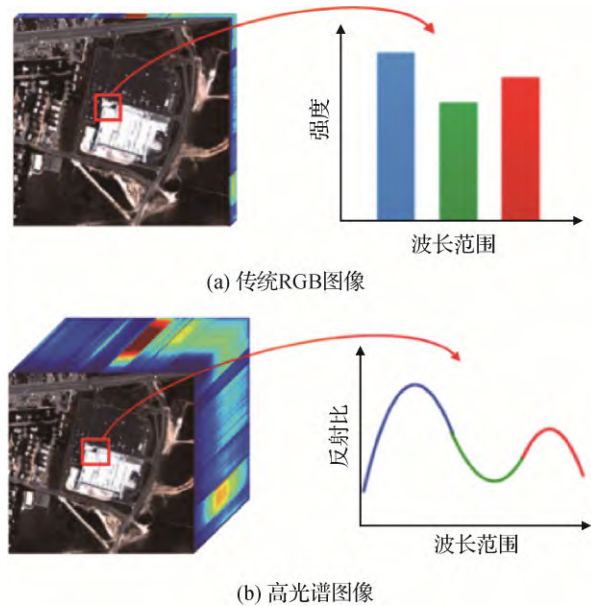


图1 传统RGB图像及高光谱图像


Fig 1 Traditional RGB image and hyperspectral image
((a) traditional RGB image; (b) hyperspectral image)

图2 高光谱图像推扫式成像过程

Fig. 2 The generating process of hyperspectral image

1 面向空间的超分辨率重建方法

1.1 单图超分辨率重建方法

为获得高空间分辨率的高光谱图像,最为直接的方式为直接对低空间分辨率高光谱进行空间维度的分辨率重建。如图3所示,低空间分辨率高光谱图像可以看做是原始高质量高光谱图像经过一系列降质(如模糊、噪声以及空间降采样)得到的。本文定义低空间分辨率的高光谱图像为 $X \in \mathbf{R}^{B \times m \times n}$, 高

空间分辨率的高光谱图像为 $Z \in \mathbf{R}^{B \times M \times N}$, 其中 B 、 $M(m)$ 和 $N(n)$ 分别指高光谱图像的波段数、长和宽, 其中 M 远大于 m 、 N 远大于 n 。基于最大后验概率模型, 单图超分辨率重建问题可以简单转化为优化一个目标函数。具体为

$$\min_z \|D(Z) - X\|^2 + \lambda \mathcal{R}(Z) \quad (1)$$

式中, $D(\cdot)$ 为空间降质函数, $\mathcal{R}(\cdot)$ 为高空间分辨率高光谱图像中的先验信息, λ 为平衡系数。由于超分辨率重建问题为一个病态的逆问题, 其解空间往往无穷大, 导致直接优化式(1)具有很大难度。基于传统优化方式的单图超分辨率重建方法主要通过引入强有力的图像先验来约束解空间, 降低求解难度。而基于深度学习的单图超分辨率重建方法主要通过大量成对的仿真数据来构建训练集, 并通过训练的方式从数据中学习低分辨率图像到高分辨率图像的重建过程。




图3 低空间分辨率高光谱图像生成

Fig. 3 The generating of low resolution hyperspectral image

1.1.1 基于传统优化的单图超分辨率重建方法

在早期算法中, 最直接的高光谱单图超分辨率重建方法主要通过插值的方式提升低分辨率高光谱图像的空间分辨率。该类方法主要利用相邻像素的信息来重建目标像素。常用的插值法主要包括最近邻插值、双线性插值和双三次插值等, 其中双三次插值相对于其他插值算法能更好地保留空间和光谱信息。而基于插值的方法虽然实现简单, 但是存在超分辨率图像模糊的问题, 且无法保证光谱一致性, 难以得到理想的高质量高光谱图像。

不同于简单地对空间信息插值, 基于稀疏编码的高光谱图像单图超分辨率重建方法主要通过学习的方法生成稀疏字典, 并将其用于提升低分辨率图像的空间信息。提出了许多基于稀疏编码的新方法, 以更好地建立低分辨率和高分辨率高光谱图像之间的关系。Huang 等人(2014b)提出了一个基于

多字典稀疏表示的超分辨率重建映射模型, 在学习和类别分配过程中利用稀疏表示充分挖掘高光谱图像的空-谱关系, 可以有效地抑制噪声影响, 具有较好的鲁棒性。并且进一步提出了一种联合低秩和成组稀疏建模先验的高光谱超分辨率重建方法, 在超分辨率重建的过程中同时对降质模型进行建模, 在空间模糊降质未知的情况下具有较好的适应性。Gou 等人(2014)在高光谱图像优化过程中引入了非局部自相似性和局部内核约束正则化项, 并提出了一个具有局部和非局部先验的耦合字典学习模型, 可以有效挖掘高光谱图像中的空-谱间的局部与非局部关系, 有效提升了重建效果。考虑到光谱的稀疏性和空间光谱块的高相似性, Li 等人(2016)提出了一种同时结合图像的稀疏先验和非局部自相似性的高光谱单图超分辨率方法, 在保持光谱一致性的基础上充分利用高光谱图像自身的空间信息。

传统方法虽然在单图高光谱图像超分辨率重建问题上取得了一定效果, 但是往往过于依赖高光谱图像的先验信息, 并且使用的先验大多都是启发式的人工先验, 该类先验的表征能力较弱, 当面临一些具有挑战性的任务时, 这些先验可能会失去约束能力, 使方法无法取得令人满意的效果。除此之外, 基于传统优化方式的方法需要针对不同的图像和设备进行最优参数调整, 严重限制了这些方法的性能和适用性。

1.1.2 基于深度学习的单图超分辨率重建方法

近来深度学习已经成为图像处理和计算机视觉领域最热门的技术之一, 提出了许多基于深度学习的高光谱单图超分辨率重建方法, 极大地提升了高光谱图像的重建质量。

如图4所示, 一种最为直接的方式是利用深度卷积网络构建单图超分辨率重建方法, 该类方法可以通过深度卷积神经网络从大量成对的数据中学习从低空间分辨率高光谱图像到高分辨率高光谱图像重建过程。

在早期实验过程中, 基于深度学习的方法往往缺乏大规模数据集用来训练。Yuan 等人(2017)考虑到可用来训练的高光谱数据较少, 通过迁移学习的方法将在大量自然图像训练好的卷积网络迁移到高分辨率高光谱图像上, 然后通过非负矩阵分解来分析低分辨率和高分辨率高光谱图像之间的光谱特异性, 提升超分辨率重建性能。而遥感图像独特的空间纹理特征




图4 基于卷积神经网络的高光谱超分方法示意图

Fig. 4 A simple flowchart of convolution neural network based hyperspectral image super resolution method

是自然图像不具有的,所以使用自然图像模型参数进行迁移仍具有局限性。

为了同时探索空间和光谱信息,Hu等人(2020)提出一个内融合网络来联合学习高光谱图像中的空一谱信息以及不同图像间的光谱信息差异,使模型可以更好地保留图像的光谱信息。然而高光谱图像是一个3维张量,现有大部分基于2D卷积的神经网络无法充分提取高光谱图像的光谱维特征,容易造成光谱失真。不同于2维卷积,3维卷积可以同时提取空间和光谱信息,越来越多的研究工作开始使用3维卷积进行高光谱单图超分辨率重建。基于使用3维卷积替代2维卷积的想法,Mei等人(2017)提出了基于3维卷积的高光谱超分辨率方法,通过3维卷积在光谱维的滑动平移学习高光谱图像光谱间的关系,对光谱信息有效进行提取。为了进一步解决重建图像的光谱扭曲问题,Li等人(2020a)提出一个具有光谱注意力机制的3维生成对抗网络。然而,3维卷积通常具有较高的计算和存储复杂度。受启发于Xie等人(2018)提出的可分离3维卷积模型,Li等人(2020c)提出一个包含2维卷积和可分离3维卷积的混合卷积模块,在减少参数量和计算量的同时,充分提取空间和光谱特征。Li等人(2021b)通过探索2维卷积和3维卷积之间的关系,提出一种新的高光谱图像超分辨率重建方法,并通过共享空间信息的方式降低了模型结构冗余,进一步提升了模型的有效性。Liu等人(2021)使用分组卷积来避免全卷积造成的光谱扭曲问题,并且提出一种新的光谱注意力机制来更好地利用高光谱图像中的光谱先验信息。综上,针对单图超分辨率重建任务的深度学习模型设计主要聚焦于高光谱图像的空一谱信息提取上,即如何有效提取和利用高光谱图像中的光谱信息,同时保证模型的计算量和参数量在可接受范围内。

由于高光谱单图超分辨率重建是一个严重病态的逆问题,且低分辨率高光谱图像的空间信息损失较为严重,特别是超分辨率倍数较大时(如8、16以及32倍),即使引入强大的图像先验进行约束或者增加训练数据数量,超分辨率重建的结果仍然无法进一步提高。因此,在实际应用中,高光谱单图超分辨率重建方法只能在超分辨率倍率较小的情况下取得较好的结果。

1.2 融合超分辨率重建方法

由于低分辨率高光谱图像中损失的空间信息过多,直接对其进行空间超分辨率重建并不能获得较好的效果。因此,有研究者提出利用额外的高空间分辨率多光谱图像 $Y \in \mathbf{R}^{b \times M \times N}$ 对低空间分辨率高光谱图像做空间信息补充。如图5所示,在仿真实验中,高空间分辨率多光谱图像通常假设为目标高分辨率高光谱图像在光谱维降质得到,其具有与低空间分辨率高光谱图像一致的空间信息,但分辨率更高。与式(1)相同,该类方法也可简单转化为求解一个基于最大后验概率的目标函数。具体为

$$\min_Z \|D(Z) - X\|^2 + \|P(Z) - Y\|^2 + \lambda \mathcal{R}(Z) \quad (2)$$

式中, $P(\cdot)$ 为光谱域降质函数。




图5 高光谱图像的空间降质过程以及光谱降质过程

Fig. 5 The spatial degeneration and spectral degeneration on hyperspectral image

解决基于融合的高光谱图像超分辨率重建方法的关键在于如何联合挖掘低空间分辨率高光谱图像与多光谱图像之间的空一谱关系。基于传统优化方式的重建方法着重于利用图像先验信息约束重建图像的空一谱信息表示,进而重建出高质量的高光谱图像;基于深度学习的重建方法大多是从网络结构

出发,构建更适合挖掘低空间分辨率高光谱图像与多光谱图像之间空一谱信息的网络模型。

1.2.1 基于传统优化的融合超分辨率重建方法

与基于单图的高光谱图像超分辨率重建算法类似,基于传统优化方式的融合超分辨率重建算法同样着重于挖掘有效的图像先验信息来约束融合超分辨率重建这一病态逆问题。Yokoya 等人(2012)提出基于耦合矩阵分解的方式,分别从高光谱图像和多光谱图像中提取出端元和丰度(如图6所示)的信息,并通过结合这两部分信息的方式来生成既有高光谱分辨率也有高空间分辨率的高光谱图像。但是,由于缺乏对所提取分度及端元的约束,因此无法保证该部分信息的准确性,从而导致其重建性能的下降。




图6 高光谱图像端元-丰度分解融合

Fig. 6 The illustration of endmember-abundance decomposition of the hyperspectral image

Lanaras 等人(2015)提出通过引入一些关于光谱矩阵的基本物理特性(如丰度值非负、丰度值和为1等)作为约束来提升丰度及端元分解的准确性。为了更好地提升融合重建性能,Dong 等人(2016)提出了基于非负字典学习的方法来挖掘高光谱图像的空一谱稀疏性,并引入了空间域的非局部相似性作为约束重建图像的图像先验,对保证重建图像的质量做出了极大贡献。为了使稀疏分解更加有效,Li 等人(2021c)提出了一个自适应的稀疏分解方法,并通过交替优化的方式来更精确地估计重建过程中的系数,以此提升重建效果以及其模型的适应性。除

了稀疏先验之外,低秩先验也是高光谱图像融合超分辨率重建方法中采用的一种有效的图像先验约束。Wu 等人(2020)提出联合挖掘高光谱图像空一谱域的低秩特性来约束重建图像,使重建的高光谱图像具有更好的空间效果并避免光谱扭曲。Xue 等人(2021)引入一个子空间聚类的方法来发掘观测图像与目标高光谱图像在子空间中的低秩特性,对有效重建目标图像起到了极大的作用。Liu 等人(2020)提出挖掘高光谱图像的超像素低秩特性,以此来约束重建结果。

上述方法大多是基于矩阵分解的方式,但是由于高光谱图像是一个3维数据,将其转换为2维矩阵往往会损失其中的信息。因此有大量方法基于张量分解的方式来有效分离高光谱图像中的有效信息。该类方法将低分辨率高光谱图像以及高分辨率多光谱图像进行分解,并从中提取有用的空一谱信息进行融合,以此来重建目标高分辨率高光谱图像。Kanatsoulis 等人(2018)提出一个基于耦合张量分解的方法来克服矩阵分解方法信息损失的问题。Li 等人(2018)基于该张量分解方式提出一个基于耦合稀疏张量分解的高光谱图像融合超分辨率重建方法,如图7所示,提升了重建高光谱图像的质量。




图7 高光谱图像张量分解(Li等,2018)

Fig. 7 The illustration of tensor decomposition of the hyperspectral image (Li et al., 2018)

在此基础上,Dian 等人(2019a)提出引入一个基于子空间的低张量多秩约束来提升张量分解的精度,该方法可以有效挖掘数据中的光谱波段之间的相关性以及非局部相似性。Xu 等人(2019)提出一个基于张量乘法的稀疏张量表示方法来挖掘高光谱图像中的非局部相似性,对高光谱图像的空一谱相关性挖掘有极大的促进。Dian 等人(2019b)提出一个低张量秩的方法,主要通过构建高度相关的4维数据张量,并在此数据上挖掘数据的相关性以及非

局部相似性,进而更好地重建目标高分辨率高光谱图像。同样,Wan等人(2020)提出通过构建4维数据张量以及引入非负先验约束等方式来挖掘高光谱数据中空一谱相关性。为了更好地探索高光谱图像和多光谱图像之间的空一谱相关性,Xu等人(2020a)提出了基于耦合张量CP(canonical polyadic)分解方式的融合超分辨率重建方法,可以更有效地将高光谱图像张量进行分解,方便后续的空一谱信息提取。He等人(2022)提出基于耦合张量环分解的高光谱图像融合超分辨率重建方法,通过挖掘图像中的低秩特性来有效重建目标图像。此外,为了更好地挖掘高光谱图像的高阶相关性,Xu等人(2020b)提出一个方法来学习高阶耦合张量环表示,并引入图一拉普拉斯约束来使重建图像可以更好地保留原始光谱信息,缓解重建图像中的光谱扭曲。

综上所述,基于传统优化方式的融合超分辨率重建方法大致可以分为基于矩阵分解的方法与基于张量分解的方法。这两类方法的成功离不开对图像先验信息的挖掘与运用。但是,现有图像先验大多是启发式人工先验(如低秩、稀疏等),该类先验对目标高光谱图像表征能力有限,会限制现有方法在一些具有挑战性任务上的表现。

1.2.2 基于深度学习的融合超分辨率重建方法

随着深度学习的发展,通过深度网络挖掘低分辨率高光谱图像与高分辨率多光谱图像之间的空一

谱相关性来提升超分重建的性能是一种较受欢迎的方式。Han等人(2018)提出一个高光谱图像融合超分辨率重建网络,并将观测图像沿光谱维度拼接在一起,直接输入重建网络,通过这种方式该网络可以联合提取输入数据中的空一谱信息。进一步地,Han等人(2019)提出一个可端到端训练的融合超分辨率网络,可以通过构建一个多层次以及多尺度信息提取网络来充分挖掘高光谱图像中的空一谱相关性。考虑到高光谱图像是一个3维张量,Palsson等人(2017)提出构建一个3D卷积网络来提取高光谱与多光谱数据间的空一谱相关性。然而,随着网络架构设计越来越复杂,参数量以及计算量也随之增加。受到基于小波分解的融合算法启发,Zhu等人(2021)提出一个轻量化的网络来渐进地从观测图像中重建出目标高分辨率高光谱图像。

现有网络模型往往通过堆叠模块来构建可端到端训练的结构,这种模型通常缺乏可解释性。不同于传统方法利用启发式先验来约束重建结果,Dian等人(2018)提出利用深度学习的方式隐式地学习有益于重建的先验信息。Wei等人(2020)构建了一个可端到端学习的轻量化模型,如图8所示,该模型基于传统优化框架,将参数转化成可学习的网络参数,使网络整体具有可解释性。Xie等人(2022)通过将近端梯度求解算法利用深度模型展开的方式提出一个具有可解释性的网络模型,引入传统图像先验低

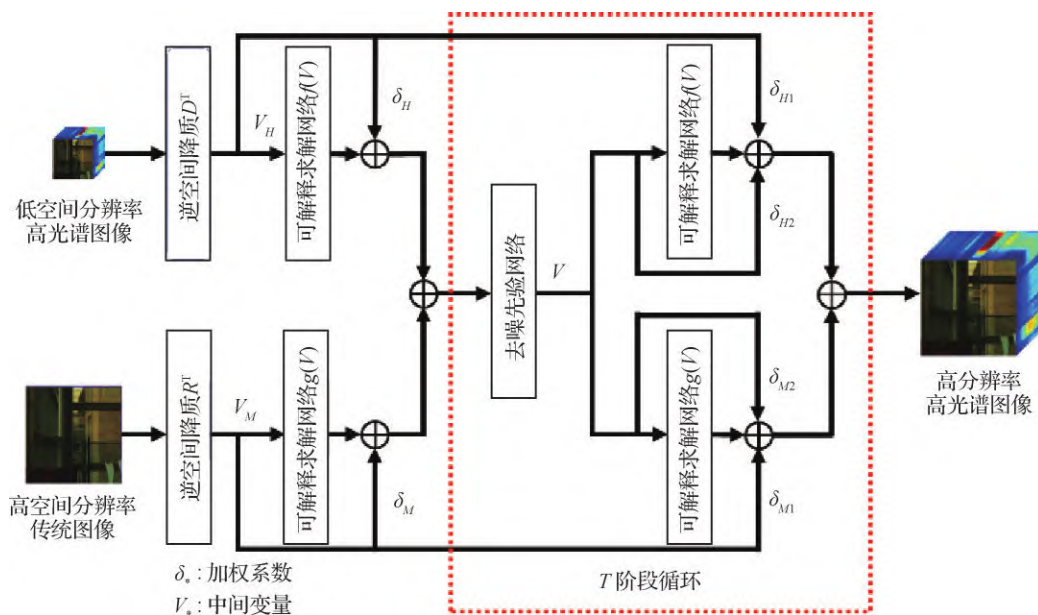


图8 一个可解释的高光谱图像融合网络(Wei等,2020)

Fig. 8 An interpretable hyperspectral image fusion network (Wei et al., 2020)

秩先验对重建结果进行约束。Ma 等人(2021)同样基于深度学习展开近端梯度求解算法,并利用 Transformer 以及 3D 卷积神经网络来学习高光谱融合重建所需的先验。构建可解释融合网络有利于基于传统模型设计和构建深度融合超分模型,对模型的构建与改进有较好的指导作用。

由于高光谱图像数据集规模通常较小,无法提供足量的训练数据,使网络无法得到充分训练。针对这一问题,Qu 等人(2018)基于深度卷积神经网络提出一个无监督的方法重建目标高光谱图像,该方法基于光谱解混模型并引入了迪利克雷分布对所提取特征进行约束。Wei 等人(2021)提出基于深度图像先验的循环递归模型,无监督地从观测图像中重建出目标光谱图像,该方法采用的深度图像先验对高光谱图像中的噪声具有较强的鲁棒性。此外,该方法通过循环递归的方式渐进地重建目标图像并通

过像素级权重引导重建过程,使重建结果可以更快地收敛到目标图像。考虑到传统优化模型的灵活性,Liu 等人(2022a)提出一个基于自编码网络的无监督超分辨率重建方法,该网络结合了矩阵非负分解算法。更进一步地,考虑到真实应用场景中降质条件难以获知这一问题,Zhang 等人(2021)结合深度图像先验提出一个无监督盲超分辨率方法,在重建过程中对空一谱降质模型进行估计,使模型可以更好地适应不同的降质影响。Xie 等人(2022)针对盲超分问题,提出利用额外的模型对降质进行估计,然后将估计到的降质用到原先的重建框架中以提升盲场景下的重建质量。Zhang 等人(2020a)提出一个基于无监督迁移学习的方法,如图9所示,一方面解决由降质未知造成的重建性能下降的问题,另一方面解决不同数据集之间差异造成的模型泛化性差的问题。

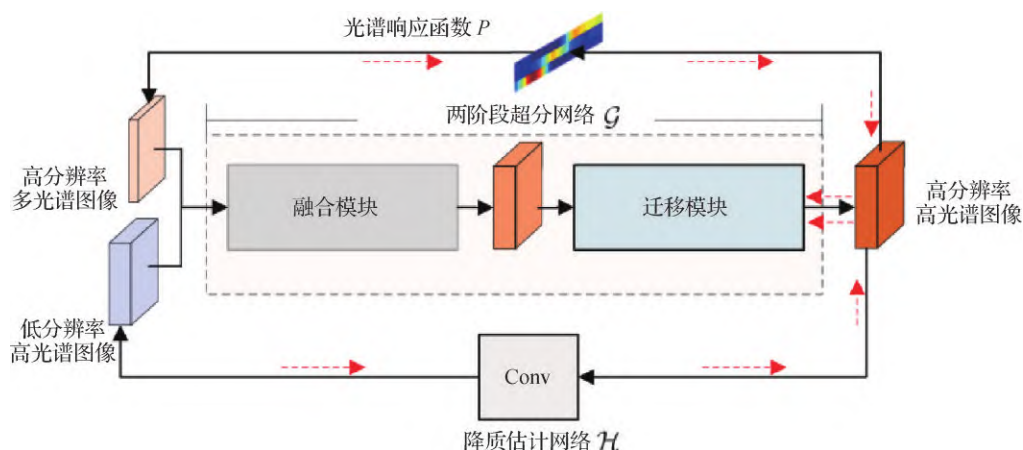


图9 一个自适应的高光谱图像融合网络(Zhang等,2020a)

Fig. 9 An adaptive hyperspectral image fusion network (Zhang et al., 2020a)

除此之外,面向融合的高光谱超分辨率重建方法通常假设观测到的低空间分辨率高光谱图像与高空间分辨率多光谱图像具有一致的空间场景。然而由于这两幅图像通常由不同的成像设备获取,不可避免地会使这两幅图像在空间信息上失配,如平移、旋转、扭曲等。考虑到上述问题,Zhou 等人(2020)提出将图像配准方法引入到现有融合方法中,缓解因失配造成的重建性能损失。Nie 等人(2020)提出一个端到端的无监督深度方法来解决失配情况下高光谱图像的融合问题,该方法主要通过引入空间变换网络来对观测图像进行配准,然后使用配准后的图像构建无监督约束,有效提升了在失配图像上的

融合效果。Qu 等人(2021)基于挖掘失配图像之间的互信息并通过引入迪利克雷分布来缓解因观测图像失配而带来的重建效果影响。

基于融合的高光谱超分辨率重建方法可利用相应高空间分辨率多光谱图像中的空间信息来对低分辨率高光谱图像的空间信息进行重建,使其可以重建更高分辨率的图像。然而,基于融合的超分辨率重建方法仍面临许多挑战,如在空一谱降质均未知时如何保证重建结果的准确性、如何有效联合挖掘失配图像高光谱—多光谱数据对之间的关键信息等问题。

2 面向光谱的超分辨率重建方法

不同于面向空间的超分辨率重建方法通过提升低空间分辨率高光谱图像的空间分辨率来获得高分辨率高光谱图像。如图10所示,面向光谱的超分辨率重建方法可以通过提升RGB或者多光谱图像的光谱分辨率来获得目标高空间分辨率高光谱图像。并且,不同于面向空间的高光谱图像超分辨率重建方法存在复杂的空间退化,光谱超分辨率问题中的降质因素相对简单。RGB/多光谱图像可以看做是高光谱图像经过光谱降质得到,而这一光谱降质通常是已知的,即光谱响应函数。通过光谱超重建出高的光谱分辨率的同时,RGB/多光谱数据中的高空间分辨率信息也可以有效保留。面向光谱的超分辨率重建方法也可大致分为基于传统优化的方法与基于深度学习的方法。

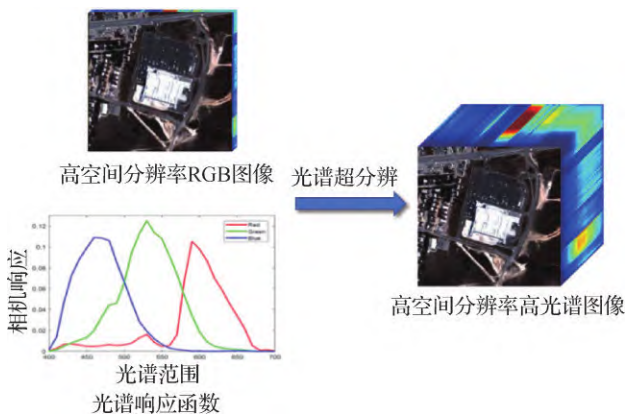


图10 光谱超分辨率重建
Fig. 10 Spectral super-resolution

2.1 基于传统优化的光谱超分辨率重建方法

光谱超分辨率重建方法的关键在于挖掘RGB图像/多光谱图像与目标高光谱图像之间的光谱相关性。因此,基于传统优化的光谱超分辨率重建方法多采用字典学习的方式来实现RGB图像/多光谱图像到高光谱图像的映射。Arad和Ben-Shahar(2016)通过构建稀疏字典的方式从高光谱图像中学习光谱先验,并根据此先验来引导RGB图像/多光谱图像到高光谱图像的映射。Yi等人(2019)提出通过增广的多光谱/高光谱图像对来挖掘光谱相关性,并通过光谱字典学习的方式提升光谱重建的准确性,同时为了更好地保留空间特性,引入了空间一致

性约束以及高光谱图像低秩先验。Fotiadou等人(2019)在稀疏字典的基础上考虑了不同成像光谱响应函数对光谱重建的影响,增强了所提模型的适应能力,使其可以处理不同源域的RGB/多光谱图像。Gao等人(2021)考虑了一个复合场景,即高光谱图像和多光谱图像存在部分重合场景时,可以联合融合超分辨方法与光谱超分辨方法重建目标高光谱图像。具体而言,提出了一个联合稀疏低秩学习方法,通过从融合区域学习高光谱—多光谱低秩字典信息来促进无重叠区域高光谱图像的光谱重建。

2.2 基于深度学习的光谱超分辨率重建方法

早期基于深度学习的光谱超分辨率重建方法通常利用不同的网络结构挖掘成对的RGB/多光谱数据与高光谱数据之间的空—谱关系,并学习如何将RGB/多光谱数据映射到对应的高光谱数据。Zhao等人(2020)提出一个多层级的回归网络用以从RGB图像中重建出光谱信息,进而重建出目标高光谱图像。Hang等人(2021)提出将高光谱图像的物理特性引入光谱超分辨率重建网络的训练过程,一方面利用精心设计的深度网络挖掘高光谱图像的光谱相关性,另一方面利用光谱反向映射约束光谱超分过程。Yan等人(2020)提出挖掘高光谱图像中目标的类别信息以及位置信息来缓解RGB图像中目标特性相近时无法有效重建光谱信息这一问题。Li等人(2021)提出构建联合的2D—3D残差注意力网络来有效挖掘训练数据中的空—谱关系,并通过结构张量约束来促进对RGB/多光谱图像中高频细节信息的保留。Zhang等人(2020b)构建了一个多分支网络,如图11所示,充分挖掘训练数据中的空—谱相关性,并利用混合函数的方式动态地重建每个像素点的光谱信息,进而更有效且精准地重建目标高光谱图像。

为了使光谱超分辨率重建方法更具适应性, Li等人(2020b)提出将光谱敏感先验信息引入光谱重建网络,通过构建自适应加权注意力网络来有效地根据相机光谱响应函数重建出目标高光谱图像。Fu等人(2022)提出一个基于光谱响应函数最优选择的光谱超分辨方法,通过从数据集中选择最适合重建的图像来完成光谱维信息重建。Li等人(2022)进一步引入结构信息一致性模块将高光谱图像的结构张量先验信息融入RGB图像,并通过光谱梯度约束损失来减少光谱扭曲现象。Liu等人

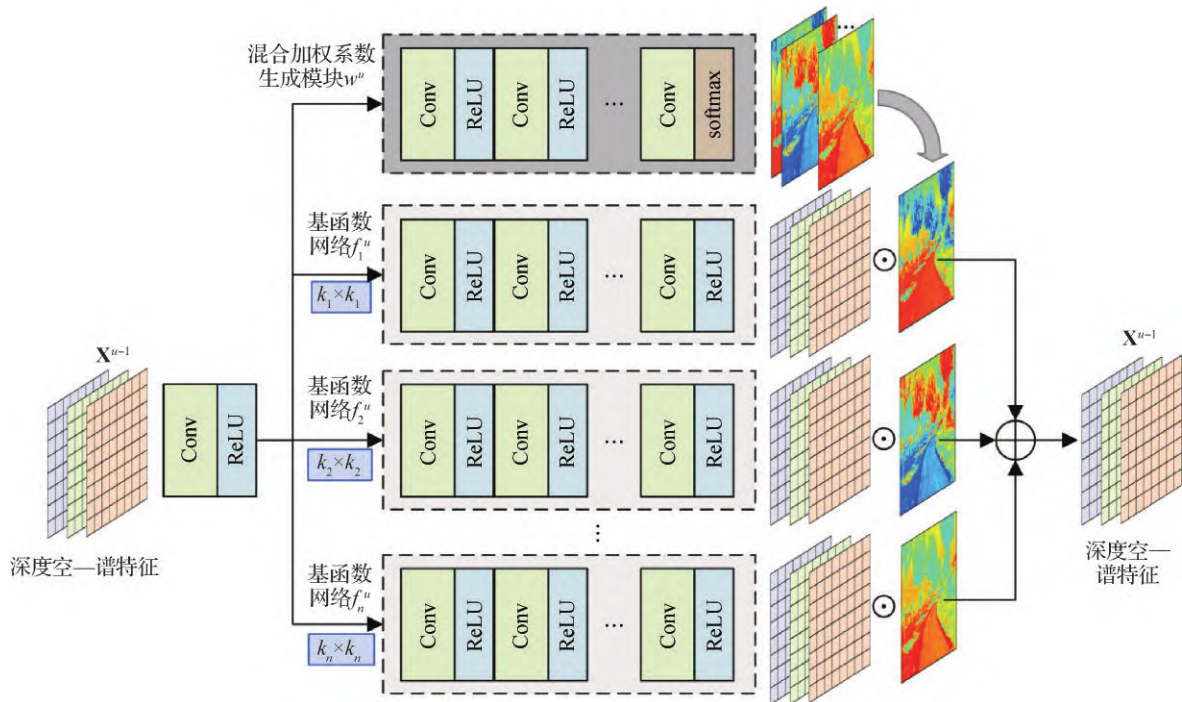


图 11 基于动态混合函数光谱超分辨率重建(Zhang等,2020b)

Fig. 11 Function-mixture based spectral super-resolution (Zhang et al., 2020b)

(2022b)提出基于对抗学习的方式,从RGB图像生成目标高光谱图像,具体而言,该方法利用空间判别网络以及光谱判别网络来提升重建高光谱图像的质量。Mei等人(2020)提出一个统一的架构来同时解决空间超分问题以及光谱超分问题。

相比于面向空间的高光谱图像超分辨率重建方法,光谱超分辨率重建方法可以更好地保留RGB/多光谱图像中的空间信息,使重建图像具有更好的视觉效果。然而,上述方法在光谱维度上的信息丢失也是极大的,造成精确重建光谱还是十分具有难度,因此如何有效重建光谱信息,避免光谱扭曲是该类方法的关键。除此之外,光谱超分辨率重建方法在实际应用中存在一些亟待解决的问题,如源相机的不同使得光谱不同进而影响光谱重建,以及如何重建不同光谱波段的高光谱图像。

3 结 语

本文对高光谱图像超分辨率重建算法领域的发展进行总结。按重建信息(如空间信息、光谱信息)的不同,将高光谱图像超分辨率算法大致分为面向空间的超分辨率方法以及面向光谱的超分辨率方法,面向空间的超分辨率方法又细分为单图超分辨

以及融合超分辨重建方法。为了详细介绍这3类方法,将其分为基于传统优化的方法以及基于深度学习的方法。由于超分辨率重建问题是一个典型的病态逆问题,传统方法在解决该问题时通常通过引入强有力的图像先验信息(如稀疏、低秩等)来约束重建结果,但基于启发式的人工先验通常具有局限性。而基于深度学习方法可以从大量成对数据中挖掘有效的先验信息用于重建,但是对训练数据的大量需求使得训练基于深度学习的方法代价高昂。针对上述问题,研究人员提出了多种解决方案。如将深度先验与传统优化方法相结合,利用深度学习方式为传统优化方式注入强有力的先验信息,以及通过构建无监督学习、迁移学习等方法来缓解深度学习对数据量的需求等。总的来说,针对高光谱图像超分辨率重建中存在的问题进行了细致的研究与探讨,提出了多种解决方案,使高光谱超分辨率重建领域的新方法层出不穷。但是,在高光谱图像超分辨率重建任务中仍存在许多问题需要继续探讨。面对单图超分辨率重建任务,如何有效提升在高超分辨重建倍率下的表现以及含有复杂降质任务时的性能是比较值得研究的问题。对于融合超分辨率重建任务,如何提升所提方法在不同场景下的泛化性能是一个值得研究的方向,如盲超分问题以及失配情况下的

融合超分问题。对于光谱超分任务,构建可控模型来重建不同光谱分辨率的高光谱图像是一个值得研究的方向。

综上所述,高光谱超分辨重建算法领域在近年来取得了蓬勃的发展,但是需要解决的新问题也不断涌现,在高光谱超分辨重建领域未来的工作中,应当把握热点方向,为解决高光谱图像中的新问题提出合理的解决方案。

致 谢 本文由中国图象图形学学会成像探测与感知专业委员会组织撰写,该专委会链接为 <http://www.csig.org.cn/detail/2445>。

参考文献(References)

- Arad B and Ben-Shahar O. 2016. Sparse recovery of hyperspectral signal from natural RGB images//Proceedings of the 14th European Conference on Computer Vision. Amsterdam, the Netherlands: Springer: 19-34 [DOI: 10.1007/978-3-319-46478-7_2]
- Dian R and Li S L. 2019a. Hyperspectral image super-resolution via subspace-based low tensor multi-rank regularization. IEEE Transactions on Image Processing, 28(10): 5135-5146 [DOI: 10.1109/TIP.2019.2916734]
- Dian R, Li S T and Fang L Y. 2019b. Learning a low tensor-train rank representation for hyperspectral image super-resolution. IEEE Transactions on Neural Networks and Learning Systems, 30(9): 2672-2683 [DOI: 10.1109/TNNLS.2018.2885616]
- Dian R, Li S T, Guo A J and Fang L Y. 2018. Deep hyperspectral image sharpening. IEEE Transactions on Neural Networks and Learning Systems, 29(11): 5345-5355 [DOI: 10.1109/TNNLS.2018.2798162]
- Dong W S, Fu F Z, Shi G M, Cao X, Wu J J, Li G Y and Li X. 2016. Hyperspectral image super-resolution via non-negative structured sparse representation. IEEE Transactions on Image Processing, 25(5): 2337-2352 [DOI: 10.1109/TIP.2016.2542360]
- Fotiadou K, Tsagkatakis G and Tsakalides P. 2019. Spectral super resolution of hyperspectral images via coupled dictionary learning. IEEE Transactions on Geoscience and Remote Sensing, 57(5): 2777-2797 [DOI: 10.1109/TGRS.2018.2877124]
- Fu Y, Zhang T, Zheng Y Q, Zhang D B and Huang H. 2022. Joint camera spectral response selection and hyperspectral image recovery. IEEE Transactions on Pattern Analysis and Machine Intelligence, 44(1): 256-272 [DOI: 10.1109/TPAMI.2020.3009999]
- Gao L R, Hong D F, Yao J, Zhang B, Gamba P and Chanussot J. 2021. Spectral superresolution of multispectral imagery with joint sparse and low-rank learning. IEEE Transactions on Geoscience and Remote Sensing, 59(3): 2269-2280 [DOI: 10.1109/TGRS.2020.3000684]
- Gou S P, Liu S Z, Yang S Y and Jiao L C. 2014. Remote sensing image super-resolution reconstruction based on nonlocal pairwise dictionaries and double regularization. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 7(12): 4784-4792 [DOI: 10.1109/JSTARS.2014.2328596]
- Han X H, Shi B X and Zheng Y Q. 2018. SSF-CNN: spatial and spectral fusion with CNN for hyperspectral image super-resolution//Proceedings of the 25th IEEE International Conference on Image Processing (ICIP). Athens, Greece: IEEE: 2506-2510 [DOI: 10.1109/ICIP.2018.8451142]
- Han X H, Zheng Y Q and Chen Y W. 2019. Multi-level and multi-scale spatial and spectral fusion CNN for hyperspectral image super-resolution//Proceedings of 2019 IEEE/CVF International Conference on Computer Vision Workshop. Seoul, Korea (South): IEEE: 4330-4339 [DOI: 10.1109/ICCVW.2019.00533]
- Hang R L, Liu Q S and Li Z. 2021. Spectral super-resolution network guided by intrinsic properties of hyperspectral imagery. IEEE Transactions on Image Processing, 30: 7256-7265 [DOI: 10.1109/TIP.2021.3104177]
- He W, Chen Y, Yokoya N, Li C and Zhao Q B. 2022. Hyperspectral super-resolution via coupled tensor ring factorization. Pattern Recognition, 122: #108280 [DOI: 10.1016/j.patcog.2021.108280]
- Hu J, Jia X P, Li Y S, He G and Zhao M H. 2020. Hyperspectral image super-resolution via intrafusion network. IEEE Transactions on Geoscience and Remote Sensing, 58(10): 7459-7471 [DOI: 10.1109/TGRS.2020.2982940]
- Huang H J, Christodoulou A G and Sun W D. 2014a. Super-resolution hyperspectral imaging with unknown blurring by low-rank and group-sparse modeling//Proceedings of 2014 IEEE International Conference on Image Processing. Paris, France: IEEE: 2155-2159 [DOI: 10.1109/ICIP.2014.7025432]
- Huang H J, Yu J and Sun W D. 2014b. Super-resolution mapping via multi-dictionary based sparse representation//Proceedings of 2014 IEEE International Conference on Acoustics, Speech and Signal Processing. Florence, Italy: IEEE: 3523-3527 [DOI: 10.1109/ICASSP.2014.6854256]
- Kanatsoulis C I, Fu X, Sidiropoulos N D and Ma W K. 2018. Hyperspectral super-resolution: a coupled tensor factorization approach. IEEE Transactions on Signal Processing, 66(24): 6503-6517 [DOI: 10.1109/TSP.2018.2876362]
- Lanaras C, Baltsavias E and Schindler K. 2015. Hyperspectral super-resolution by coupled spectral unmixing//Proceedings of 2015 IEEE International Conference on Computer Vision. Santiago, Chile: IEEE: 3586-3594 [DOI: 10.1109/ICCV.2015.409]
- Li J, Yuan Q Q, Shen H F, Meng X C and Zhang L P. 2016. Hyperspectral image super-resolution by spectral mixture analysis and spatial-spectral group sparsity. IEEE Geoscience and Remote Sensing Letters, 13(9): 1250-1254 [DOI: 10.1109/LGRS.2016.2579661]
- Li J J, Cui R X, Li B, Song R, Li Y S, Dai Y C and Du Q. 2020a.

- Hyperspectral image super-resolution by band attention through adversarial learning. *IEEE Transactions on Geoscience and Remote Sensing*, 58 (6) : 4304-4318 [DOI: 10.1109/TGRS. 2019. 2962713]
- Li J J, Du S C, Song R, Wu C X, Li Y S and Du Q. 2022. HASIC-net: hybrid attentional convolutional neural network with structure information consistency for spectral super-resolution of RGB images. *IEEE Transactions on Geoscience and Remote Sensing*, 60: #5522515 [DOI: 10.1109/TGRS.2022.3142258]
- Li J J, Wu C X, Song R, Li Y S and Liu F. 2020b. Adaptive weighted attention network with camera spectral sensitivity prior for spectral reconstruction from RGB images//*Proceedings of 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*. Seattle, USA: IEEE: 1894-1903 [DOI: 10.1109/CVPRW50498.2020.00239]
- Li J J, Wu C X, Song R, Xie W Y, Ge C R, Li B and Li Y S. 2021a. Hybrid 2-D - 3-D deep residual attentional network with structure tensor constraints for spectral super-resolution of RGB images. *IEEE Transactions on Geoscience and Remote Sensing*, 59 (3) : 2321-2335 [DOI: 10.1109/TGRS.2020.3004934]
- Li Q, Wang Q and Li X L. 2020c. Mixed 2D/3D convolutional network for hyperspectral image super-resolution. *Remote Sensing*, 12(10): #1660 [DOI: 10.3390/rs12101660]
- Li Q, Wang Q and Li X L. 2021b. Exploring the relationship between 2D/3D convolution for hyperspectral image super-resolution. *IEEE Transactions on Geoscience and Remote Sensing*, 59(10): 8693-8703 [DOI: 10.1109/TGRS.2020.3047363]
- Li S T, Dian R, Fang L Y and Bioucas-Dias J M. 2018. Fusing hyperspectral and multispectral images via coupled sparse tensor factorization. *IEEE Transactions on Image Processing*, 27 (8) : 4118-4130 [DOI: 10.1109/TIP.2018.2836307]
- Li X S, Zhang Y Q, Ge Z X, Cao G, Shi H and Fu P. 2021c. Adaptive nonnegative sparse representation for hyperspectral image super-resolution. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 14: 4267-4283 [DOI: 10.1109/JSTARS.2021.3072044]
- Liu D H, Li J and Yuan Q Q. 2021. A spectral grouping and attention-driven residual dense network for hyperspectral image super-resolution. *IEEE Transactions on Geoscience and Remote Sensing*, 59(9): 7711-7725 [DOI: 10.1109/TGRS.2021.3049875]
- Liu J J, Wu Z B, Xiao L, Sun J and Yan H. 2020. A truncated matrix decomposition for hyperspectral image super-resolution. *IEEE Transactions on Image Processing*, 29: 8028-8042 [DOI: 10.1109/TIP.2020.3009830]
- Liu J J, Wu Z B, Xiao L and Wu X J. 2022a. Model inspired autoencoder for unsupervised hyperspectral image super-resolution. *IEEE Transactions on Geoscience and Remote Sensing*, 60: #5522412 [DOI: 10.1109/TGRS.2022.3143156]
- Liu L Q, Li W Y, Shi Z W and Zou Z X. 2022b. Physics-informed hyperspectral remote sensing image synthesis with deep conditional generative adversarial networks. *IEEE Transactions on Geoscience and Remote Sensing*, 60: #5528215 [DOI: 10.1109/TGRS.2022. 3173532]
- Ma Q, Jiang J J, Liu X M and Ma J Y. 2021. Learning a 3D-CNN and transformer prior for hyperspectral image super-resolution [EB/OL]. [2023-01-02]. <https://arxiv.org/pdf/2111.13923.pdf>
- Mei S H, Jiang R T, Li X and Du Q. 2020. Spatial and spectral joint super-resolution using convolutional neural network. *IEEE Transactions on Geoscience and Remote Sensing*, 58 (7) : 4590-4603 [DOI: 10.1109/TGRS.2020.2964288]
- Mei S H, Yuan X, Ji J Y, Zhang Y F, Wan S and Du Q. 2017. Hyperspectral image spatial super-resolution via 3D full convolutional neural network. *Remote Sensing*, 9(11): #1139 [DOI: 10.3390/rs9111139]
- Nie J T, Zhang L, Wei W, Ding C and Zhang Y N. 2020. Unsupervised deep hyperspectral super-resolution with unregistered images//*Proceedings of 2020 IEEE International Conference on Multimedia and Expo (ICME)*. London, UK: IEEE: 1-6 [DOI: 10.1109/ICME46284.2020.9102881]
- Palsson F, Sveinsson J R and Ulfarsson M O. 2017. Multispectral and hyperspectral image fusion using a 3-D-convolutional neural network. *IEEE Geoscience and Remote Sensing Letters*, 14 (5) : 639-643 [DOI: 10.1109/LGRS.2017.2668299]
- Qu Y, Qi H R and Kwan C. 2018. Unsupervised sparse dirichlet-net for hyperspectral image super-resolution//*Proceedings of 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*. Salt Lake City, USA: IEEE: 2511-2520 [DOI: 10.1109/CVPR.2018. 00266]
- Qu Y, Qi H R, Kwan C, Yokoya N and Chanussot J. 2021. Unsupervised and unregistered hyperspectral image super-resolution with mutual Dirichlet-net. *IEEE Transactions on Geoscience and Remote Sensing*, 60: #5507018 [DOI: 10.1109/TGRS. 2021. 3079518]
- Wan W, Guo W H, Huang H Y and Liu J. 2020. Nonnegative and nonlocal sparse tensor factorization-based hyperspectral image super-resolution. *IEEE Transactions on Geoscience and Remote Sensing*, 58(12): 8384-8394 [DOI: 10.1109/TGRS.2020.2987530]
- Wei W, Nie J T, Li Y, Zhang L and Zhang Y N. 2020. Deep recursive network for hyperspectral image super-resolution. *IEEE Transactions on Computational Imaging*, 6: 1233-1244 [DOI: 10.1109/TCI.2020.3014451]
- Wei W, Nie J T, Zhang L and Zhang Y N. 2021. Unsupervised recurrent hyperspectral imagery super-resolution using pixel-aware refinement. *IEEE Transactions on Geoscience and Remote Sensing*, 60: #5500315 [DOI: 10.1109/TGRS.2020.3039534]
- Wu R Y, Ma W K, Fu X and Li Q. 2020. Hyperspectral super-resolution via global-local low-rank matrix estimation. *IEEE Transactions on Geoscience and Remote Sensing*, 58(10): 7125-7140

[DOI: 10.1109/TGRS.2020.2979908]

- Xie Q, Zhou M H, Zhao Q, Xu Z B and Meng D Y. 2022. MHF-Net: an interpretable deep network for multispectral and hyperspectral image fusion. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 44 (3) : 1457-1473 [DOI: 10.1109/TPAMI.2020.3015691]
- Xie S, Sun C, Huang J, Tu Z W and Murphy K. 2018. Rethinking spatiotemporal feature learning: speed-accuracy trade-offs in video classification//*Proceedings of the 15th European Conference on Computer Vision*. Munich, Germany: Springer: 318-335 [DOI: 10.1007/978-3-030-01267-0_19]
- Xu Y, Wu Z B, Chanussot J, Comon P and Wei Z H. 2020a. Nonlocal coupled tensor CP decomposition for hyperspectral and multispectral image fusion. *IEEE Transactions on Geoscience and Remote Sensing*, 58(1): 348-362 [DOI: 10.1109/TGRS.2019.2936486]
- Xu Y, Wu Z B, Chanussot J and Wei Z H. 2019. Nonlocal patch tensor sparse representation for hyperspectral image super-resolution. *IEEE Transactions on Image Processing*, 28 (6) : 3034-3047 [DOI: 10.1109/TIP.2019.2893530]
- Xu Y, Wu Z B, Chanussot J and Wei Z H. 2020b. Hyperspectral images super-resolution via learning high-order coupled tensor ring representation. *IEEE Transactions on Neural Networks and Learning Systems*, 31(11): 4747-4760 [DOI: 10.1109/TNNLS.2019.2957527]
- Xue J Z, Zhao Y Q, Bu Y Y, Liao W Z, Chan J C W and Philips W. 2021. Spatial-spectral structured sparse low-rank representation for hyperspectral image super-resolution. *IEEE Transactions on Image Processing*, 30: 3084-3097 [DOI: 10.1109/TIP.2021.3058590]
- Yan L B, Wang X H, Zhao M, Kaloorazi M, Chen J and Rahardja S. 2020. Reconstruction of hyperspectral data from RGB images with prior category information. *IEEE Transactions on Computational Imaging*, 6: 1070-1081 [DOI: 10.1109/TCI.2020.3000320]
- Yi C, Zhao Y Q and Chan J C W. 2019. Spectral super-resolution for multispectral image based on spectral improvement strategy and spatial preservation strategy. *IEEE Transactions on Geoscience and Remote Sensing*, 57(11): 9010-9024 [DOI: 10.1109/TGRS.2019.2924096]
- Yokoya N, Yairi T and Iwasaki A. 2012. Coupled nonnegative matrix factorization unmixing for hyperspectral and multispectral data fusion. *IEEE Transactions on Geoscience and Remote Sensing*, 50(2): 528-537 [DOI: 10.1109/TGRS.2011.2161320]
- Yuan Y, Zheng X T and Lu X Q. 2017. Hyperspectral image superresolution by transfer learning. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 10 (5) : 1963-1974 [DOI: 10.1109/JSTARS.2017.2655112]
- Zhang L, Lang Z Q, Wang P, Wei W, Liao S C, Shao L and Zhang Y N. 2020b. Pixel-aware deep function-mixture network for spectral super-resolution. *Proceedings of the AAAI Conference on Artificial Intelligence*, 34 (7) : 12821-12828 [DOI: 10.1609/aaai.v34i07.6978]
- Zhang L, Nie J T, Wei W, Li Y and Zhang Y N. 2021. Deep blind hyperspectral image super-resolution. *IEEE Transactions on Neural Networks and Learning Systems*, 32 (6) : 2388-2400 [DOI: 10.1109/TNNLS.2020.3005234]
- Zhang L, Nie J T, Wei W, Zhang Y N, Liao S C and Shao L. 2020a. Unsupervised adaptation learning for hyperspectral imagery super-resolution//*Proceedings of 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition*. Seattle, USA: IEEE: 3070-3079 [DOI: 10.1109/CVPR42600.2020.00314]
- Zhao Y Z, Po L M, Yan Q, Liu W and Lin T Y. 2020. Hierarchical regression network for spectral reconstruction from RGB images//*Proceedings of 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*. Seattle, USA: IEEE: 1695-1704 [DOI: 10.1109/CVPRW50498.2020.00219]
- Zhou Y, Rangarajan A and Gader P D. 2020. An integrated approach to registration and fusion of hyperspectral and multispectral images. *IEEE Transactions on Geoscience and Remote Sensing*, 58 (5) : 3020-3033 [DOI: 10.1109/TGRS.2019.2946803]
- Zhu Z Y, Hou J H, Chen J, Zeng H Q and Zhou J T. 2021. Hyperspectral image super-resolution via deep progressive zero-centric residual learning. *IEEE Transactions on Image Processing*, 30: 1423-1438 [DOI: 10.1109/TIP.2020.3044214]

作者简介

聂江涛,男,博士研究生,主要研究方向为图像处理和异源图像融合。E-mail: niejiangtao@mail.nwpu.edu.cn

张磊,通信作者,男,教授,主要研究方向为图像处理、小样本学习和视频分析。E-mail: nwpuzhanglei@nwpu.edu.cn

魏巍,男,教授,主要研究方向为图像质量提升、机器学习与模式识别。E-mail: weiweinwpu@nwpu.edu.cn

闫庆森,男,教授,主要研究方向为图像HDR重建、机器学习与模式识别。E-mail: qingsenyan@gmail.com

丁晨,男,讲师,主要研究方向为图像处理、机器学习与模式识别。E-mail: dingchen@xupt.edu.cn

陈国超,男,硕士研究生,主要研究方向为高光谱图像超分辨率重建。E-mail: guochaocen@163.com

张艳宁,女,教授,主要研究方向为遥感图像分析、计算机视觉和模式识别。E-mail: ynzhang@nwpu.edu.cn