



审查

# 基于深度学习的变化检测调查 高分辨率遥感图像

Huiwei Jiang <sup>1,2</sup> , Min Peng <sup>3</sup>, Yuanjun Zhong <sup>4,\*</sup>, Haofeng Xie <sup>2</sup>, Zemin Hao <sup>3</sup>, Jingming Lin <sup>2</sup>, Xiaoli Ma <sup>4</sup>  
and Xiangyun Hu <sup>2,5</sup>

<sup>1</sup> 国家测绘中心, 北京 100830; huiwei\_jian@whu.edu.cn 武汉大学遥感与信息工程学院, 武汉市珞喻

<sup>2</sup> 路129号 430079; xiehaofeng@whu.edu.cn (HX); linjingming@whu.edu.cn (JL); huxy@whu.edu.cn (XH)

<sup>3</sup> 沈阳岩土勘察研究院有限公司, 沈阳 110004; minpeng@whu.edu.cn (议员); haozemin@whu.edu.cn (ZH)

<sup>4</sup> 广东省国土资源厅测绘院, 广州市黄埔区光埔中路13号 510663; xiaoli.ma1010@gmail.com 武汉大学人工智能测绘研究院, 武汉市珞喻路129号 430079

<sup>5</sup>

\*通讯地址: yuanjun.zhong.gd@gmail.com; 电话: +86-20-8770-2345; 传真: +86-20-8770-3807

**摘要:** 基于遥感影像的变化检测在遥感分析领域发挥着重要作用, 在资源监测、城市规划、灾害评估等领域得到广泛应用。由于人工智能 (AI) 技术的爆发式发展引起了广泛的兴趣, 基于深度学习框架的变化检测算法使得借助海量数据检测更细微的变化 (例如小型建筑物的改动) 成为可能。遥感数据, 特别是高分辨率 (HR) 数据。尽管方法有很多, 但我们仍然缺乏对最新深度学习方法在变化检测方面的最新进展的深入回顾。为此, 本文的主要目的是回顾现有的基于深度学习的HR 遥感图像变化检测算法。本文首先描述了变化检测框架, 并从所采用的深层网络架构的角度对方法进行了分类。



Citation: Jiang, H.; Peng, M.; Zhong, Y.; Xie, H.; Hao, Z.; Lin, J.; Ma, X.; Hu,

X. 基于深度学习的高分辨率遥感图像变化检测综述。

遥感. 2022, 14, 1552. [https://](https://doi.org/10.3390/rs14071552)

[doi.org/10.3390/rs14071552](https://doi.org/10.3390/rs14071552)

然后, 我们回顾了深度学习在各种粒度结构中应用变化检测的最新进展。此外, 本文还提供了来自不同传感器的HR 数据集的摘要, 以及与变化检测相关的信息, 以供研究人员使用。同时, 研究了该任务的代表性评估指标。最后, 总结了使用 HR 遥感图像进行变化检测的挑战, 为了提高模型的性能必须解决这些挑战。此外, 我们还提出了该领域未来研究的有前景的方向。

学术编辑: Filiberto Pla

收稿日期: 2022 年 2 月 27 日

接受日期: 2022 年 3 月 21 日

发布日期: 2022 年 3 月 23 日

**关键词:** 深度学习; 变化检测; 高分辨率; 遥感图像

出版商注: MDPI 对于已出版地图和机构隶属关系中的管辖权主张保持中立。

关系。

## 一、简介

基于遥感 (RS) 技术的变化检测用于利用同一地理位置的两个或多个图像来发现和识别地面物体的差异 [1]。遥感技术的发展引起了许多研究人员的兴趣, 并在灾害监测 [2,3]、资源调查 [4-6] 和城市规划 [7,8] 等许多领域得到了应用。

在过去的几十年里, 通过多时相图像进行变化检测根据要求和条件受到了深入的审查, 并且人们为开发各种变化检测方法付出了巨大的努力, 包括传统方法 [9,10] 和基于深度学习的方法方法 [11]。在深度学习盛行之前, 变化检测问题主要通过手工特征来解决



版权所有: © 2022 作者。

被许可方 MDPI, 瑞士巴塞尔。

本文是一篇开放获取文章

根据条款和

知识共享的条件

归属 (CC BY) 许可证 ([https://](https://creativecommons.org/licenses/by/4.0/)

[creativecommons.org/licenses/by/](https://creativecommons.org/licenses/by/4.0/)

4.0/).

深度学习中,变化检测问题主要是通过从复杂的特征提取器中导出的手工特征来解决的。随着自动化应用的日益广泛

为了利用遥感图像进行变化检测,研究人员从复杂的特征提取器中获得了巨大的效果。随着自动开发各种变化检测方法,利用遥感图像选择变化检测具有挑战性,研究人员在这方面付出实际中最适合的方法,以及传统方法的局限性正在开发各种变化检测方法。然而,选择最有挑战性的变得越来越明显。一方面,遥感数据源不适合实际应用,传统方法的局限性日益凸显。图像日益多样化,图像空间分辨率逐渐提高,图像清晰度越来越明显。一方面,遥感数据来源日益丰富。尾巴正在逐渐丰富,多样化提取的特征表现力较差,图像空间分辨率逐渐提高,图像细节传统方法特征显著降低变化检测精度,且正在逐步丰富。传统提取的特征表达能力差。

易受季节变化、光照条件等因素影响,方法特点明显降低变化检测精度,且易受

卫星传感器和太阳高度角。另一方面,虽然有些方法会受到季节变化、光照条件、卫星传感器等因素的影响,结合形状和纹理特征来减少虚假变化,这是耗时的和太阳高度角的。另一方面,虽然有些方法可以减少虚假变化,但是,手工制作的特征在很大程度上依赖于特定的领域知识,这严重降低了变更检测技术的自动化能力。此外,手工制作的特征严重依赖于特定的领域知识,这严重降低了变更检测技术的自动化能力。此外,手工制作的特征严重依赖于特定的领域知识,这严重降低了变更检测技术的自动化能力。一般来说,经验特征在表示图像方面较强,并且经验特征通常不是最优的,并且经验特征

最近,基于深度学习 (DL-based) 的方法引起了广泛关注。图像表示能力较弱。

它们在图像分类等多个领域取得了优于传统方法的成功。最近,基于深度学习 (DL-based)的方法引出了语义分割[12]、语义分割[13]、对象跟踪[14]和自然语言亲和性,它们在图像等各个领域都取得了超过传统方法的成功。基于手动技术、基于深度学习的分类[12]、语义分割[13]、对象跟踪[14]和自然语言的分类方法相比,深度学习可以给定数据中学习特征并显著降低处理需求[15]。与基于手动技术的传统方法相比,DL专家征并显著降低需求。

由于其非线性特征和融入专家领域知识的出色特征提取,可以处理复杂的场景。此外,基于深度学习的方法可以提供准确的理解能力[16,17],并且由于其非线性表征和出色的特征提取,它们实现了远远超出传统复杂场景方法的性能[16,17],并且它们取得了远远超出传统方法的性能。

由于这些优点,基于 DL 的方法的使用呈指数级增长。

解决遥感问题,例如,在图像分割中[18,19],物体检测问题,例如,在图像分类中[18,19],物体检测[20,21],姿态估计[22,23],场景直立[24]和图像分割[25]。

[25].同时,DL方法的高判别性特征可以用来解决同时,DL方法的高判别性特征可以用来解决变化检测问题。已经进行了大量研究来解决变化检测问题。已经进行了大量研究来解决变化检测问题。通过需要更多有用的信息,使用基于 DL 的技术检测问题通过学习有关更改的更多有用信息,使用基  
图 1 通过精心设计的损失函数说明了数量的增加。图 1 说明过去三十年发表的专注于遥感的论文。可以看出,近三十年来发表的论文主要关注遥感。从上可以看出从图中可以,看出数量多数研究者已经关注了变化检测,并且从图中可以看出,大多数研究者已经关注了该领域的出版物数量逐年增加。值得一提的是,该领域的出版物逐年增加。值得一提的是,出版物涉及深度学习的变化检测的出版物显着增加自 2016 年以来,涉及深度学习的变化检测的出版物显着自 2016 年起,遥感显示基于深度学习的变化检测方法迅速超越数字显示基于深度学习的变化检测遥感检测应用程序。




图1 1990年至2020年发表文献统计。数据由先进

在 Web of Science 上搜索 (allintitle: ((TS = ( “深度学习” )) OR TS = ( “神经网络” )) AND TI = ( “更改检测” ) , allintitle2: TI = ( “更改检测” ) )。

一般来说,最流行的变化检测解决方案是使用来自同一传感器的双时态遥感图像。双时态数据主要包括合成孔径雷达 (SAR) [26,27]和光学图像。在上述两类数据中,光学图像最常用于变化检测,因为它们可以提供丰富的光谱和空间信息。根据光谱分辨率,光学图像可分为高光谱图像、多光谱图像和全色图像三种类型。然而,为了保留图像的光谱信息,同时尽可能提高空间分辨率,在实际应用中通常将多光谱和全色图像融合在一起。为了说明使用不同数据源进行变化检测的过程,我们进行了简单的统计分析。图2统计了2015年至2020年4月基于深度学习的相关变化检测数据源的分布情况,包括SAR、多光谱和高光谱图像。显然,SAR和多光谱图像一直是最常用的数据类型。然而,散斑噪声给SAR变化检测的研究带来了比光学噪声更多的挑战。

此外,侧视几何结构和不同的微波散射贡献模式也引入了典型问题,例如停留和阴影。特别是在密集的城市地区,建筑物经常被部分遮挡,不同建筑物的信号常常混合在一起,这使得它们难以解释[26,28]。事实上,多光谱图像的比例应该更大,因为很多文献中默认的数据源是高分辨率卫星图像,属于多光谱图像。

不过,这次我们只根据“航空”和“卫星”关键词进行搜索。

同时,随着遥感信息技术的快速发展,高光谱图像越来越受到人们的关注,它不仅具有较高的光谱分辨率,而且空间分辨率不断提高。与高光谱图像相比,多光谱数据能够以更经济、更稳定的方式获得,具有相对更高的时间分辨率和更广泛的空间分辨率。通过提高空间分辨率,可以在更精细的尺度上观察地球[29]。地面物体的精细结构信息,即使尺寸很小,也可以反映在高分辨率 (HR)或极高分辨率 (VHR)图像中[30];这里,分辨率主要指空间分辨率。此外,HR 或 VHR 图像的颜色、纹理和其他特征非常丰富。因此,多光谱图像已成为许多遥感应用 (尤其是变化检测)的主要数据源。本文的主要目的是总结基于深度学习的变化检测方法,特别是使用 HR 遥感图像的变化检测方法。我们特别关注对地观测卫星,例如最常用的高分系列[31,32]、Worldview系列[33]、ZY系列[31,33]、Quickbird [33]和VHR航空影像基于深度学习的变化检测方法中的数据源,由于其可访问性。

目前,虽然存在许多变更检测评论,但大多数都主要集中在传统的变更检测方法上[10,34–36]。最近,一些研究人员回顾了深度学习变化检测[37–39]。本次调查的目的是对基于深度学习的HR图像变化检测方法进行总结和分类,以辅助相关研究。拟议的调查与已发布的调查不同。我们主要关注 HR 遥感数据集,而不是混合所有可用的数据集,这使得初学者很难找到直接的方法来开始他们的研究。

此外,我们的综述概述了使用 HR 遥感图像的最先进的变化检测方法,包括对完整变化检测工作流程的每个组成部分的详细分析。

本文的主要贡献有四个方面。

- (1)我们对基于HR遥感图像的深度学习的变化检测进行了系统回顾,涵盖了最流行的特征提取网络以及该框架各部分的构造机制。
- (2)我们根据检测单元分析变化检测算法的粒度,这使得我们能够独立于特定应用而应用合理的方法。

经济稳定的方式,具有相对较高的时间分辨率和更广泛的空间分辨率。通过提高空间分辨率,可以在更精细的尺度上观察地球[29]。地面物体的精细结构信息,即使尺寸很小,也可以反映在高分辨率 (HR)或超高分辨率 (VHR)图像中[30];这里,分辨率主要指空间分辨率。此外,HR 或 VHR 图像的颜色、纹理和其他特征非常丰富。因此,多光谱图像已成为许多遥感应用 (尤其是变化检测)的主要数据源。本文的主要目的是总结基于深度 (3)的变化检测方法。我们提出了用于共 31 HR 遥感图像学习变化检测的流行数据集,特别是使用 HR 遥感图像。特别是,我们详细关注地球物体,并研究了该任务的代表性评估指标。

服务卫星,如高分系列[31,32]、Worldview系列[33]、ZY系列[31,33], (4)我们对未来利用远程技术进行变化检测的研究提出了几点建议。Quickbird [33] 和 VHR 航空图像,它们是最常用的传感数据源。基于深度学习的变化检测方法,由于其可访问性。




图 2. 2015 年至 2020 年不同图像源的分布。数据由先进的在 Web of Science 上搜索。(a)光学图像论文总数比例图来自各种来源。(b)多源相关论文数量年度统计柱状图。图片。(allintitle 例如:(((TS = ( “深度学习” )) OR TS = ( “神经网络” )) AND TI = ( “变化检测” ))) AND (TS = ( “合成孔径雷达” ) OR TS = ( SAR)))。

本文的内容整理如下。首先,变革的框架介绍了基于深度学习的检测以及每个部分最常用的策略在第 2 节中。然后,在第 3 节中,我们根据以下内容回顾变更检测方法:检测单元。随后,我们列出了公开可用的数据集和标准第 4 节中用于变更检测的评估指标。最后,在第 5 节中,我们概述了审查的结论并为进一步的研究提供了一些有希望的方向。

## 2. 基于深度学习的变化检测算法

神经网络 (NN)的不断发展和完善已经开启为过去十年中的变化检测任务提供了新的机会。近年来,人们在利用深度学习方法进行遥感变化检测方面做出了巨大的努力。大量研究表明这些方法优于传统方法。传统方法,因为他们从大量的数据中学习代表性和区分性特征样本数组。

### 2.1. 变更检测框架

由于变化检测的输入是多时相数据,因此基于深度学习的变化检测方法从数据收集开始,在两个或多个相同位置采集数据期间。

因此,应首先对输入图像进行配准,以确保输入图像的一致性地理信息。应该指出的是,尽管有更好的配准算法,错误仍然可能发生。然后,可以通过考虑颜色、纹理和梯度以及空间几何的特征提取器来确定代表性特征。图像之间的关系。之后,变化特征由区分特征并用于定位和确定变化信息的强度,这称为特征融合。上述两个步骤可以一起定义为改变信息提取。最后,通过改变来执行优化过程评价标准以获得最终的变化图。至于变革的实施检测,当前基于深度学习的变化检测方法旨在解决几个问题或所有子问题,即特征提取、特征融合和优化。整体



改变信息意图是最后根据历史评价标准进行干扰处理,得到最终的意图。图4为干扰性检测原理,当前基网不受攻击的变化性检测能力与主网在相同干扰或全部攻击下是否更能检测出异常(主网基网和变化性检测性检测技术)的对比结果可以归结为变化信息提取、网络优化和准确性评估,如图3所示。

变化检测技术的总体框架可以概括为变化信息提取、网络优化和准确性评估,如图3所示。信息提取、网络优化和准确性评估,如图3所示。

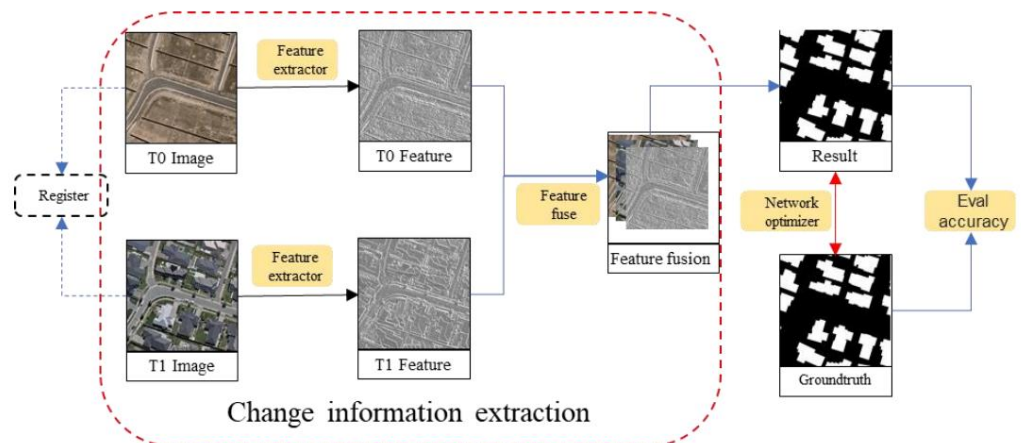


图 1 展示了检测到的整体框架,其中黄色填充的圆角矩形框定了本文检测的一般框架,其中黄色填充的圆角矩形说明本文的范围。

## 2.2.2 主站数据提取与网络各

具有多个隐藏层的深度神经网络具有多个隐藏层的深度神经网络具有多个隐藏层的深度神经网络  
建立生物神经网络系统 DNN 网络因其具有生物神经网络的特征识别能力而广泛应用于模式识别任务中。

任务的辨别力和强大的特征表征能力。

一般来讲,使用多传感器(MLE)和/或使用多里感转换器(MLP)感知的使用多传感器,转换输入将特征向量源转换为特征空间以是解分类。例如,从受限特征空间放入变化特征空间以获得分类。例如,具有可见层和隐藏层的受限玻尔兹曼机(RBM)[41]可以从复杂场景中提取有效信息。具有可见层和隐藏层的受限玻尔兹曼机(RBM)[41]可以从复杂场景中提取有效信息。

就使用无提取判别性特征的深层架构而言。(例如基于卷积神经网络(CNN)和具有非提取判别性特征(例如边缘、纹理或颜色)的深层架构而言,主要线条种类主要有五类:基于五种形变类型(基于自监督神经网络)(基于非神经网络)、基于卷积神经网络(NN)、生成对抗神经网络(GAN)、基于生成器-判别器网络(N)和变压器为基础的框架结构[4]。所有文献基于卷积神经网络(CNN)和网络(GAN)和基于图方法[图4显示的方法]更复杂的基于图网络的分布。

用于开发检测的通用神经网络架构[图5显示]分布。




图 4.常用于变革的网络架构的百分比分布

根据用于变更或检测的网络架构的交集生成分布图条。常用于变更反检测的网络架构的百分比分布。数保探数据网通与Web Science高级科学数据集在2016年。

### 2.2.1. 编码器-解码器和自动编码器 (AE) 模型

作为一种典型且流行的网络结构,编码器-解码器模型由模型系列,例如 AE 模型,它学习从输入空间到模型的特征映射

遥感. 2022, 14, 1552

## 2.2.1. 编码器-解码器和自动编码器 (AE) 模型

6 共 31

作为一种典型且流行的网络结构,编码器-解码器模型由一系列模型组成,例如AE模型,它们学习从输入空间到输出空间的特征映射。该模型由输入层、隐藏层和输出层(输出空间)组成。该模型由输入层、隐藏层和输出层组成,如下所示

如图5a所示,编码器将输入向量  $x$  压缩到隐藏层中,如图 5a 所示。编码器将输入向量  $x$  压缩到隐藏层,定义为

$$h = f(W \cdot x + b), \quad (1) \quad (1)$$

其中  $h \in R^n$  表示隐藏层的输出,  $f(\cdot)$  是一个非线性函数,例如 logistic sigmoid 函数  $(1 + \exp(-x))$ ,  $W \in R^{n \times m}$  表示权重矩阵,  $x \in R^m$  代表输入。编码器,  $\epsilon$  代表输入。




图 5(a) 自动编码器和 (b) 堆叠自动编码器的架构。

解码器将隐藏层重构为输出层,公式为

$$x = f(W \cdot h + b), \quad (2) \quad (2)$$

其中  $x \in R^m$  表示重构输出,  $W \in R^{m \times n}$  表示权重矩阵,  $h \in R^n$  表示隐藏层的输出,  $b$  表示解码器,  $\epsilon$  表示编码器,  $b$  表示隐藏层和输出层的偏差。自动编码器与特定的编码器-解码器模型具有相同的输入和输出。

自动编码器与特定的编码器-解码器具有相同的输入和输出。理论上,自动编码器可以降低特征的维度。与校长相比,主成分分析 (PCA) 算法,其性能较好,主要得益于神经网络学习特征的能力。AE 模型通常通过最小化来训练神经网络学习特征的能力很强。AE 模型通常使用距离度量 (例如欧几里得距离) 通过重建损失函数使用距离度量 (例如 Eu-) 最小化重建损失函数,其目的是关闭输入和输出单元。这些模型广泛用于 cliche 模型的距离旨在接近输入和输出单元。这些模型是流行的图像到图像转换问题 [42] 和序列到序列 lar 用能图像到图像翻译问题 [42] 和自然语言处理 (NLP) [43] 中的序列到序列问题。鉴于其强大的学自然语言处理 (NLP) 中的序列模型 [43]。鉴于其强大的学习能力改进 (例如,堆叠 AE [44]、堆叠去噪 AE [45]、堆叠渔民关系 AE [46] 及其改进 AE [47] 经常发表 [44]、堆叠去噪 AE [45]、堆叠稀疏 AE [47]、去噪 AE [48]、模糊 Fisher 作为不同网络中的组件。堆叠式自动编码器 (SAE) 和堆叠 AE 模型是 AE 和堆叠神经网络。通常作为不同网络中的组件。堆叠自动编码器 (SAE) 是下一个隐藏层的神经输入。图 5b 给出了 SAE 网络的简单表示,每个隐藏层的输出服务于采用卷积网络的变化检测任务,AE 模型被广泛使用作为下一个隐藏层的输入。图 5b 给出了 SAE 的简单表示。作为无监督任务中的特征提取器,因为它们可以避免对于使用卷积网络的变化检测任务,AE 模型广泛需要大量的手动注释 [50]。上述大多数自动编码器合和复杂的场景中用作特征提取器,因为它们可以避免基于问题的方法可以获得各种特征,但在混需要大量的手动注释 [50]。上述大多数自动编码器 无法提取最佳的识别特征,进而区分场景而无需基于方法可以获得各种特征,但在混合复杂的场景中,它们正在彻底挖掘场景类信息。如果没有彻底挖掘场景类信息,就无法提取最佳的识别特征,进而区分场景。

## 2.2.2. 递归神经网络 (RNN) 和长短期记忆 (LSTM)

## 2.2.2. 递归神经网络 (RNN) 和长短期记忆 (LSTM)

与顺序数据相关的字段,例如语音 [51]、文本 [52]、视频 [53] 和时间序列 [54]。如图 6a 所示, RNN 可以展开为串联链

单元 (即 RNN 单元)。

RNNs能够有效地捕获顺序关系,并且已经广泛应用于与顺序数据相关的领域,例如语音[51]、文本[52]、视频[53]。并且RNNs能够有效地捕获顺序关系并且已经被广泛使用时间-序列[54]。如图6a所示,RNN可以展开为与顺序数据相关的一系列串联字段,例如语音[51]、文本[52]、视频[53]和连接单元(即RNN单元)。

遥感, 2022, 14, 1552

时间序列[54]。如图 6a 所示,RNN 可以展开为串联单元链(即 RNN 单元)。

7 共 31




图 6. (a) RNN 的架构; (b) LSTM。

图 6: (a) RNN 的结构; (b) LSTM。

感知图像以检测变化[56-59]。ishing 梯度意味着 RNN 很难训练，为了解决这个问题，长但是，随着序列（时间）长度的增加，van 的问题，然而，由于 van 问题，导致模型难以收敛。

ishing 梯度意味着 RNN 很难训练。为了缓解这个问题,长[46,57,58,61]通过门机制,有输入门、输出门和遗忘门,来缓解梯度消失 (LSM) 问题。图 6b 显示了典型的 LSTM 单元在短期记忆中的 LSTM 门被引入到图 6b 所示的简单 RNN 中的隐藏层单元中。门单元在电路中起到类似于“开关”的作用,其中 RNN [46,57,58,61] 通过门机制,有输入门、输出门和遗忘门 [46,57,58,61] 单元。门机制,每个输入门、输出门和遗忘门,用于控制信息传输的开启和关闭。LSTM 的核心如图 6b 所示。单元的作用类似于电路中的“开关”,单元的状态,是由门控制的。门的主要作用是决定用什么来控制信息传输的开启和关闭。LSTM 的核心是从记忆中保留什么和省略什么。因此,LSTM 网络一直处于  $\alpha$ -cell 状态,由门控制。门控制的主要作用是决定什么。细胞状态,由门控制。门的主要功能是决定采用何种方式从 HR 遥感数据中获取变化信息。在变化检测中记忆中要保留什么以及要省略什么。因此,LSTM 网络被应用于变化检测。细胞状态包含学习到的多时相图像的

作中[61],神经网络包含输入和输出层,并随着网络的变化能够在网络的不同数据域上进行训练,并利用这些信息进行预测。此外,模型和状态信息能够具有足够的灵活性以从不同数据进行训练时利用它们[62]。神经网络架构并非设计为长期城市动态变化的 RNN 的替代方案,因为神经网络通常仅能捕捉短期变化 [52]。作者提供了一种基于 RNN 的框架来监测四个城市年际之间的动态变化。总的来说,RNN 通过知识迁移的思想实现知识迁移思想的启发,[52]中的作者提出了一种基于 RNN 的方法来监测四个城市年份之间的动态变化。然而,在模型训练的初始阶段,监测四个城市年份之间的动态变化时具有一定的优势。总体而言,RNN 在面临时间跨度大且规格不一的数据集时具有一定的优势。

在面对长时间规格检测问题时,基于长期城市的方法具有一定的优势[56]。

采样不足,并且在长期城市变化检测中表现出优越性[56]。

### 2.2.3.3 卷积神经网络 (CNN)

CNN 是由卷积层组成的经典前馈神经网络,由卷积层组成。卷积神经网络 (CNN) 是一种由卷积层组成的经典前馈神经网络,流行于生物视觉[63]。从图4中我们可以看出CNNs是生物视觉生物视觉,使其能够有效获取高通量流行的网络架构的特征。如图7所示,该网络被设计为通过其空间感受野进行输入[64]。




图7.简单卷、单卷和网络加密的架构。

图 7.简单卷积神经网络和全连接神经网络的主要优点

卷积网络 (FCN)的优点是它们可以避免将高维特征扩展到向量中导致空间信息丢失的问题,同时通过权重共享和稀疏性显著减少所需的训练参数[65]。因此,由于CNN可以处理高维数据[66-68],数据

来源可以是高光谱图像、SAR 图像、街景图像或其他图像。



与全连接神经网络相比,全连接神经网络的主要优点

卷积网络 (FCN)的特点是它们可以避免将高维特征扩展到向量中导致空间信息丢失的问题,同时通过权重共享和稀疏性显著减少所需的训练参数

遥感. 2022, 14, 1552

[65].因此,由于CNN可以处理高维数据[66-68],因此数据源可以是高光谱图像、SAR图像、街景图像或其他图像。

CNN强大的学习能力使其在研究高维信息时比传统方法更能够获得准确丰富的特征,当CNN强大的学习能力使其更能够获得准确丰富的特征时

训练样本充足。CNN 及其改进在高维信息的研究中比传统方法具有显著的特点,当

对于遥感图像应用的贡献,例如场景分类[69],物体训练样本是足够的。CNN 及其改进取得了重大进展

检测[70]和变化检测[71]。经典的CNN及其扩展架构对遥感图像应用的贡献,例如场景分类[69]、物体分类

包括 AlexNet [12]、VGGNet [72]、ResNet [73]、UNet [74] 和 DenseNet [75]、检测 [70] 和变化检测 [71]。经典的 CNN 及其扩展架构 HRNet [23],可以用作特征提取器。

包括 AlexNet [12]、VGGNet [72]、ResNet [73]、UNet [74] 和 DenseNet [75],以及通过VGG网络的知识传输可以传输不同领域的数据集HRNet [23],它可以用作特征提取器。

(例如, CV 域图像到 RS 域图像) [76]。通过使用 CNN HR 遥感

实现图像分类,同时实现高分辨率图像分割的准确性(例如, CV 域图像到 RS 域图像) [76]。通过使用 CNN HR 遥感

通过改进 UNet [77] 进行优化。该模型能够实现图像分类取得较好的分类效果,同时高分辨率图像分割的准确性

使用 ResNet [78] 的 LiDAR。通过允许 CNN 导出高维特征,通过改进 UNet [77] 进行优化。该模型

从高分辨率影像的光谱信息来看,遥感的精度

一般来说,大多数端到端 CNN 网络仅在输出层进行训练,以改进变化检测[79]。

监督学习。然而,深度卷积网络无法有效地学习有用的信息。一般来说,大多数端到端CNN网络仅在输出层进行

由于隐藏层不可见且缺乏监督,因此具有监督学习的特点。然而,深度卷积网络无法有效学习有用的信息

网络无法有效地学习最有用的特征,尤其是在深层网络中,由于隐藏层不可见和缺乏监督,特征

这会导致梯度消失问题,影响后续的预测。网络内无法有效地学习最有用的特征,尤其是在深度网络中,

深度超不是仅仅依赖于输出层逐渐追踪的梯度,这会导致梯度消失问题,影响后续的预测。反而

视觉可以提高特征提取器的学习能力,从而有助于导出更多仅依靠输出层逐渐跟踪的梯度、深度监督

有效提高特征提取器的学习能力,从而帮助导出更有效的特征

信息[17,80,81]。

#### 2.2.4.生成对抗网络 (GAN)

GAN 是一个新的生成模型家族,于 2014 年推出[82]。

如图 8 所示,模型由两个独立的模型组成,于 2014 年推出[82]。

生成器 (Generator) 和判别器 (Discriminator),它们在游戏中相互竞争以达到动态平衡。判别器) ,它们在游戏中相互竞争以达到动态平衡。

生成器的学习产生类似于“真实”样本的假数据,其目的生成器的学习产生类似于“真实”样本的假数据,其目的

的生成用噪声  $z$  映射到目标分布的函数,而是生成用噪声  $z$  映射到目标分布的函数,而判别器

鉴别器学习区分虚假数据和真实数据。基本的 GAN 的工作原理是学习区分虚假数据和真实数据,基本的 GAN 的工作原理是学习区分虚假数据和真实数据

数据,生成器和判别器充当对手,生成器和判别器充当对手,前者试图

前者试图最小化以下功能,后者则试图最小化其他功能。通过最小化以下功能,后者是其他功能。通过不断的

不断的对抗性学习,判别器的判别能力不断增长学习,判别器的判别能力变强,同时数据

更强,而生成器生成的数据将变得更类似于真实的数据,生成器生成的数据将变得更类似于真实的数据。

数据。

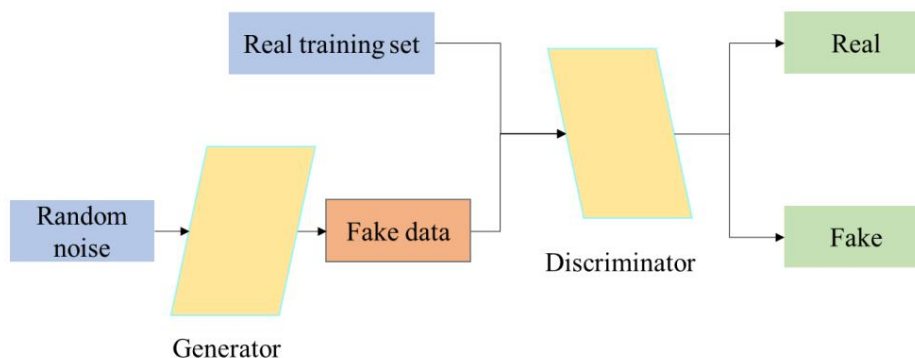


图 8.GAN 的结构。

最小最大损失给出如下:

$$\min_G \max_D f(D, G) = \mathbb{E}_x[\log(D(x))] + \mathbb{E}_z[\log(1 - D(G(z)))], \quad (3)$$

其中  $x$  是给定的训练数据,  $G(z)$  是给随机噪声的映射函数

向量  $z$ ,  $D(x)$  表示训练数据中的  $x$  是真还是假的概率,  $D(G(z))$

是鉴别器对假生成样本为真实样本的概率的估计,  $G$  和



D 是同时训练的,  $E_x$ 是所有真实数据样本的期望值,  $E_z$ 是生成器的所有随机输入的期望值。

GAN 可以使用少量标记数据 (即真实数据)进行训练,并可以提供有效的判别模型来检测变化。在两部分对抗中,梯度消失和模式崩溃的问题变得更加明显,这使得它们在遥感图像中的应用不如传统方法有效[83]。

因此,自从GAN发明以来,研究人员努力以各种方式改进/修改它们,例如DCGAN [84]、InfoGAN [85]、CycleGAN [86]、WGAN [87]、Self-Attention GAN [88] 和 BigGAN [89]。GitHub 资源[90]中列出了更多有关 GAN 的作品。

如上所述,变化检测是通过多时态数据的联合分布捕获变化或不同信息 (DI)图的分布的过程,这补充了GAN的功能。因此,GAN 可以用来探索所需的潜在分布 (变化图或 DI)与多时态数据的联合分布之间的关系。

在变化检测中,所有生成的图像应该显示出与预期的差异改变区域。同时,没有改变的领域不应表现出差异。

GAN 在变化检测方面有两个主要优势。一方面,虽然数据限制是深度学习的主要问题,但 GAN 可以学习生成大量伪数据,从而增强网络的泛化能力。具体来说,GAN 可以用有限的标记样本从大量未标记数据中提取有用且有判别性的特征,从而降低成本并确保半监督变化检测的良好性能[91]。另一方面,受域适应和迁移学习技术的启发,GAN 可以将源域中的图像映射到目标域中的虚拟图像。

当将 GAN 应用到对象检测、图像分割和变化检测领域时,发现它们更适合变化检测,主要是因为相似的场景降低了 GAN 产生不需要的错误结果的风险[83]。在变化检测中,天气、季节和其他因素可能会导致伪变化,而GAN 可以将其排除[92,93]。

与其他生成模型 (例如变分自动编码器 (VAE))相比,GAN 对重建约束没有要求,因此排除了模糊变化或 DI 图。此外,与对每个像素进行二元分类的CNN相比,GAN对像素中的噪声不敏感,因为它恢复了差分信息的完整分布。

#### 2.2.5. 基于变压器的网络

Transformer 于 2017 年首次推出,最初用于序列到序列的学习[15]。它们可以轻松提供远程依赖建模,因此已广泛用于自然语言处理 (NLP),并开始在计算机视觉领域显示出前景[94,95]。基于变压器的网络可以利用卷积和变压器的优势来有效地对上下文信息进行建模。

它们也可以被视为一种有效的基于注意力的工具,可以增加模型的接收范围,从而提高表示变化检测特征的能力[96]。Transformer 的架构是按照编码器-解码器架构构建的,如图9所示。获得输入图像的标记集 (特征序列)后,我们使用 Transformer 编码器对这些标记之间的上下文进行建模。随着

对于输入图像的上下文丰富的标记,变换器解码器适合将概念的代表投影回像素空间以获得像素级特征。虽然Transformer结构在NLP中得到了广泛的应用,但其在视觉领域 (Vision Transformer, ViT) 的应用仍然有限。

输入图像的上下文丰富的标记,变换器解码器适合将概念的表达投影回像素空间以获得像素级特征。虽然Transformer结构在NLP中得到了广泛的应用,其在视觉领域的应用(Vision Transformer,ViT)仍然有限。




图9. 变压器的架构。  
图9. 变压器的架构。

## 2.3. 变更信息提取

### 2.3. 变更信息提取

在早期的变化检测应用中,最传统、最经典的方法是代数分析方法(如差分[97]、回归[98]等)。遵循将变化视为相异性的思想,通过测量来生成变化图。代数分析方法(如差分[97]、回归[98]等)。遵循将变化视为相异性的思想,通过测量来生成变化图。将变化视为相异性的基本思想,变化图是通过测量图像对之间的像素级相似性来生成的。这种方法确定图像对之间的像素级相似性。该方法的优点是计算要求低,缺点是手工制作的特征计算要求低,缺点是手工特征无法有效区分变化。他们通过以下方式识别显著不同的像素特征来区分变化。他们通过变化特征识别显著不同的像素,然后通过阈值处理获得二元掩模。改变变化概率。改变通过阈值处理获得二元掩模。变化特征测量每个检测单元(例如,像素、块或对象)的变化概率。从多时相图像中提取的信息变化为后续的研究奠定了基础。生成时相图像最终变化图。后模态DIP和最终变化图奠定了基础。毫无疑问,令人满意的变化检测方法很大程度上取决于适当距离的制定。

衡量变化信息的指标。总体而言,变化信息函数目前许多研究者都致力于提高变化的鲁棒性。

包含两个部分:特征提取和特征相似度。

通过改进特征提取和特征相似度策略进行鲁棒性。

通过改进特征提取和特征相似度策略进行鲁棒性。变化检测的性能主要依赖于变化信息的识别。

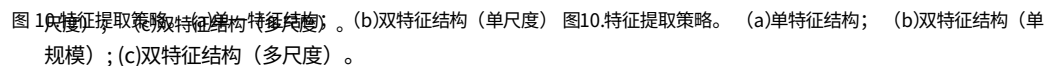
通过改进特征提取和特征相似度策略进行鲁棒性。变化检测的性能主要依赖于变化信息的识别。

### 2.3.1. 特征提取策略

2.3.1. 特征提取策略使用 DCNN 进行变化检测的第一个例子。自从

随后,DCNN得到了广泛的应用,在这些应用中,主要有两种,如图10所示。由于特征提取策略的类型:单分支结构和双分支结构,如图10所示。

特征提取策略的类型:单分支结构和双分支结构,如图10所示。



与单分支结构不同,双特征结构是后期融合,其中结果特征是从两个独立策略的融合结果中一个提取的,其中结果特征是从两个独立策略的融合结果中提取的。-悬垂分支,如图10b、c所示。本质上,它是悬垂分支,如图10b、c所示。本质上,它是一个暹罗神经网络。

SiamNet网络架构包含具有单特征直接性检测任务。首先,两个分支分别从两个输入中提取特征,其中分支分别从两个输入中提取特征,具有相同的结构和共享/不共享参数。然后,仅合并两个分支和共享/无共享参数。然后,仅在网络的卷积层完成后才合并两个分支。双流结构网络的卷积层完成后。双流结构利用不同的网络分支来实现差异化的特征提取,以获得使用不同的网络分支来完成差异化的特征提取,以获取更有针对性的功能。大量证据表明,后期融合策略取得了更好的效果。

包含更有针对性的功能。大量证据表明,后期融合策略的性能优于之前的图像级特征融合方法。比之前的图像级特征融合方法有更好的性能。

一般来说, Siamese 网络的两个分支共享权重。也就是说, 网络使用相同的方法从两个输入中提取特征, 如图 11a 所示。共享参数可能会阻止每个分支达到各自的最佳权重, 因此其他小组建议使用伪 Siamese 作为替代品, 如图 11b 所示。具有两个并行编码流的 Siamese 网络 (如 [81] 所示) 具有两个共享共享权重的并行编码流的连体网络具有更少的参数并且收敛速度更快 [81]。Chen [100] 验证了 Siamese 网络的效率接近伪 Siamese 网络, 但计算成本较低。



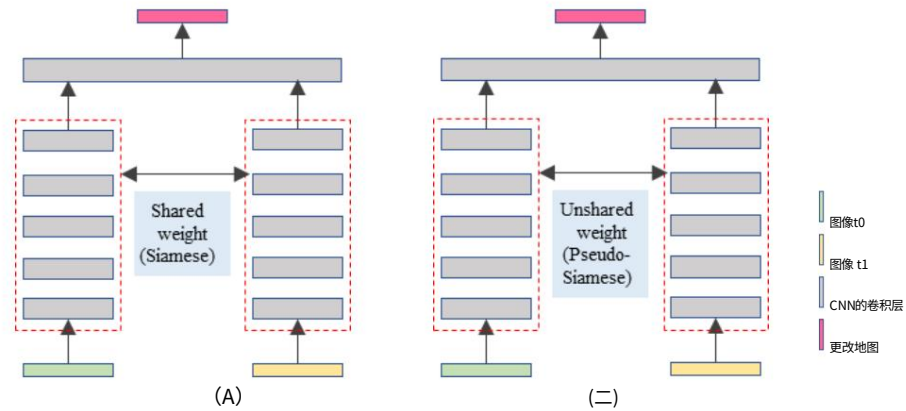


图1.具有不同权重结构的特征提取。(a)共享权重(孪生网络);(b)非共享权重(伪孪生网络)。

### 2.3.3.3 特征融合策略

变化检测通过相似性来看待变化,直接用于测量它们,并旨在对未变化的特征进行分组的距离度量。在学习区分特征,将未变化的特征分组并分离变化的部分。以前,变更检测受到很大限制和单独的更改部分。此前,变化检测已经极大地限制了其手工制作的性能。受到 CNN 模型成功的启发,通过其手工制作的性能的表现。受到 CNN 模型在图像分类方面成功的启发,我们生成了一个高度抽象且具有判别力的特征图。我们通过学习过滤器生成了高度抽象和区分的特征图。测量特征之间距离的最流行方法学习过滤器。测量特征之间距离的最流行的方法是欧几里得距离[101-105]和余弦相似度[106,107]。欧几里得距离[101-105]和余弦相似度[106,107]。距离度量度的适用性会严重影响模型的性能,而这取决于指标会严重影响模型的性能,这取决于相应的任务。例如,欧氏距离和余弦相似度适用于响应任务。例如,欧几里得距离和余弦相似度分别适用于人脸识别和文本处理。实验表明,欧几里得分别是识别和文本处理。实验表明,欧氏距离,也称为均方误差 (MSE)距离,比余弦距离表现更好。方差,也称为均方误差 (MSE)距离,在测量变化时比余弦相似度表现更好[108]。其他距离例如曼哈顿距离[109]、Minkowski距离[92]和 Mahalanobis 距离[92]。为了重用前Minkowski 距离[92]。为了重用 Mahalanobis 距离[92]。为了训练好的深度CNN,引入了预训练的权重来解决变化检测问题。最简单、最可靠的方法是距离度量直接测量经典特征提取网络的变化[103,110],例如 AlexNet [111] 或者 VGG 模型 [72]。它是在大型辅助数据集 [111] 上进行预训练的。阈值化,执行一个步骤来设计最终执行阈值步骤来设计最终的变化图;例如 OSTU [112]。如果没有微调学习,如何区分就不足以描述变化。曾经,没有微调学习的模型没有足够的判别力来描述深度度量学习方法已成功用于学习更多判别变化。

原生特征,例如使用深度 Siamese 学习参数化嵌入空间。深度度量学习方法已成功用于学习更深度卷积网络[13]。抑制变化区域的特征并犯罪特征,例如使用深度 Sia 学习参数化嵌入空间,尽可能有效地保留不变的特征。各种损失函数已经成为全卷积网络的主要特征[13]。抑制用于变化检测的变化区域的特征,例如对比损失[104,113]和三元组损失[114]。

并尽可能有效地保留不变的,各种损失函数已经有了Triplet loss 对比损失获得更好的结果,因为 Triplet loss 利用了优势。研究用于变化检测,例如对比损失[104,113]和三元组损失[114]。Triplet loss 获得了比 contrastive loss 更好的结果,因为 triplet loss 在对比损失函数中采用了像素之间更大的空间关系的优势[115]。为了避免必须基于具有共享权重的双分支设置相似性,其中特征相关对比度损失函数中的参数,在两幅图像之间引入特征融合[116]方法可以得到充分利用。使用决策网络可以消除基于具有共享权重的双分支来学习图像相似度,其中特征阈值处理过程在变化图中。与已开发的表示法相比,可以充分利用两幅图像之间的相关性。使用决策网络可以消除使用学习距离度量,例如具有完全连接层的距离度量[79]。基于度量的方法单独处理多时相图像,忽略相关决策网络可以在时间信息中包含超越距离的更复杂的相似性函数[115]。

指标。然而,基于度量的方法单独处理多时相图像,ig- 2.3.3.3.特征融合策略关注时间信息内的相关性[115]。

将Siamese网络结构与特征融合操作结合起来,得到差异图,融合使用阈值算法生成变化图。

特征融合能够将来自两个分支的有意义的信息组合起来生成单个融合特征,这对于后续应用更加有利,因为它包含更丰富的信息。换句话说,引入特征融合来在双分支的基础上学习图像相似性,从而无需对变化图应用额外的阈值处理过程。目前,特征融合领域的大部分研究主要集中在两个操作上:特征聚合和注意力机制。

特征聚合。单分支结构通过差分、求和或串联直接融合图像级别的特征。双分支结构的特征融合方法可以大致分为单尺度融合[59,104,117-120]或多尺度融合[32,33,121],分别如图10b,c所示。

单尺度融合仅用于融合两个分支特征的顶层。  
多尺度融合以deep-to-shadow的方式进行密集特征融合,每个尺度的特征变换方法相同,采用差分、求和或级联,与单尺度融合类似。

之前的许多工作表明,深层网络的浅层特征包含更详细的信息,例如图像纹理和对象边界,但缺乏语义线索。随着层数的增加,层次特征将变得更加抽象(由于池化序列等) [103]。一般来说,越深的层语义信息越多,但细节越少。多尺度融合策略可以通过将分层特征图与更广泛的上下文和更精细的空间细节相结合来弥补不同级别特征图之间的差距。

多尺度特征融合结构和跳跃连接结构已被证明是将浅层空间信息映射到深层语义特征的可行方案。

它们都可以适应单分支[122]和双分支[123]特征提取网络。遥感图像中变化的物体通常是不规则的、不同尺度的。多尺度特征融合结构是解决该问题的有效技术,用于导出各种尺度的特征。连接[2,32,120,122]、求和[123]和差分[33,80,121,123,124]的基本操作可分别用于获取全局信息、未更改信息和已更改信息。跳过连接[80]桥接高级特征和低级特征,以获得更好的图像分割网络结果[74,125]。需要注意的是,数学变换的结果,例如差、求和、堆叠、集中或其他逻辑运算,可以被视为跳跃连接的结束元素[31,123]。

注意机制。由于语义上的差异,通过简单的逻辑运算进行特征聚合往往会导致特征混乱。在过去的十年中,注意力机制发挥了越来越重要的作用,并使各种计算机视觉应用受益,例如图像分类、对象提取和语义分割。

通过注意力机制,网络可以自动强调与通道或位置中的图像/特征相关的重要信息,从而显着提高网络的效率和准确性。在变化检测中,注意力机制可以增强变化特征的表示,抑制双时态图像中不相关变化的特征。基于注意力的融合策略在从Siamese结构中学习的两个特征之间建立了一座信息桥梁,以实现信息融合。因此,最终的特征不是从两个特征分支单独获得的,而是从它们的相互作用中获得的[100]。

事实上,这两种特征融合方法通常同时使用并相互补充。可以通过多尺度特征融合结构提取图像的多尺度特征表示。这对于处理各种尺寸的地面物体特别有效。注意力机制使得网络更加关注变化的区域,提高了特征提取的效率。

在深度学习领域一直很难理解如何在不使用池化的情况下获得更大的感受野,从而导致图像信息的部分丢失。

除了这两种策略之外,还有一些专注于全局或局部特征的方法

可用并且对于提取更好的变化信息至关重要[114,120],例如金字塔池化模块 (PPM) [126]、多孔空间金字塔池化 (ASPP) [127]、扩张卷积[128]和初始架构[129],它可以通过不同的感受野捕获多尺度信息。

#### 2.4. 优化策略目前,二元交叉

熵损失在基于深度学习的二元分类中最为普遍。由于它计算两个分布之间的相似度,因此更适合二进制变化检测。

然而,类不平衡[130]是使用深度学习方法进行分类时的一个常见问题,其中某些类的数量远远多于其他类的数量,这与遥感图像变化检测的情况类似。使用很少变化的像素进行训练会导致网络倾向于特定类别。引入加权交叉熵损失作为平衡不同类样本比例关系的改进。基于两个不平衡样本的比例,可以构建分布权重[17]或权重矩阵[33]来控制交叉熵损失。除此之外,还提出了焦点损失和骰子损失[17]来解决不平衡问题。一般来说,这两种损失通常同时发生以实现互补优势,因为焦点损失是没有空间关系的像素损失,而骰子损失是包括空间依赖性的区域损失。Xian [120]提出了一种可分离损失函数来优化网络。分别针对变化的像素和未变化的像素计算损失,以减弱不平衡标签的影响。可分离损失的主要理论是,变化区域的特征应该被推开,而不变区域应该尽可能接近。受此启发,对比损失函数[131]被用来通过扩大变化对之间的度量并同时减少未变化图像对之间的度量来评估两幅图像之间的相似性。与二元交叉熵的改进类似,Zhan 优化了权重对比损失[104]。

此外,基于数据的过采样方法,例如数据增强[132-134],提供了另一种解决数据不平衡问题的有效方法,并已广泛应用于深度学习中以提高深度模型的鲁棒性。

此外,一些研究人员使用后处理通过 k 最近邻[104]、模糊 c 均值聚类[121]或多尺度分割[31,110]更新初始结果来获得更好的变化图。

无监督学习。目前,可用于遥感变化检测的开放注释数据集非常少,这严重限制了深度学习模型,尤其是 FCN 的实际适用性。值得一提的是,可以使用生成对抗网络 (GAN) 将简单分布生成的随机噪声转换为新的图像标签对。这种有前景的无监督学习方法在许多应用中取得了巨大的成功。然而,尽管它们具有出色的生成数据的能力,但 GAN 很难生成密集注释的图像来训练 FCN 模型,而且很少有人关注这项研究。此外,Kullback-Leibler (KL) 散度损失[135]对于无监督学习来说是有意义的。

弱监督学习。与需要大量注释数据集的监督学习和导致模型性能较差的无监督学习相比,弱监督学习 (SSL) 提供了一种方法来提高基于深度学习的模型的鲁棒性和泛化性能。它可以使用不完整、不准确或不精确的标签来挖掘可辨别的特征,而不是大量准确标记的信息[136]。半监督学习通常是弱监督学习,它从不完整的样本 (包括标记和未标记的数据集) 中学习来训练模型。许多研究人员在视觉任务中采用了这种方法[124,137,138],包括变化检测[29]。当涉及到不精确的监督时,标签是粗粒度的,例如图像级标签[139-141]。监督方法的不准确性与给定样本并不总是与真实情况相符这一事实有关,



遥感. 2022, 14, 1552

[124,137,138],包括变化检测[29]。说到监管不严,标签是粗粒度的,例如图像级标签[139-141]。监督方法的不准确性与给定样本并不总是与真实情况相符有关,该过程通常称为使用噪声标签进行学习,这更接近行业中深度学习的背景。目前关于噪声学习的研究主要是通常所说的带有噪声标签的学习过程,这更接近于背景

关注分类问题[142],很少关注行业内复杂的变化深度学习。目前关于噪声学习的研究主要关注分类问题[142],很少关注复杂的变化检测问题。

### 3. 变化检测的粒度分析

近几十年来,随着遥感图像空间分辨率的提高,许多针对航空和卫星图像变化的深度学习方法被提出。这些提出了许多用于航空和卫星图像变化检测的深度学习方法。根据检测单元的粒度,我们可以大致分类。根据检测单元的粒度,我们可以将这些方法大致分为两大类:场景级方法(SLCD)和区域级方法(RLCD)。这两个类别不一定是相互独立的方法(RLCD)。这两个类别不一定相互独立,有时,相同的变化检测过程可能存在于不同的方法中。图12显示了用于变化检测的方法的分类。图12显示了使用HR遥感图像进行变化检测的方法分类。采用HR遥感图像。

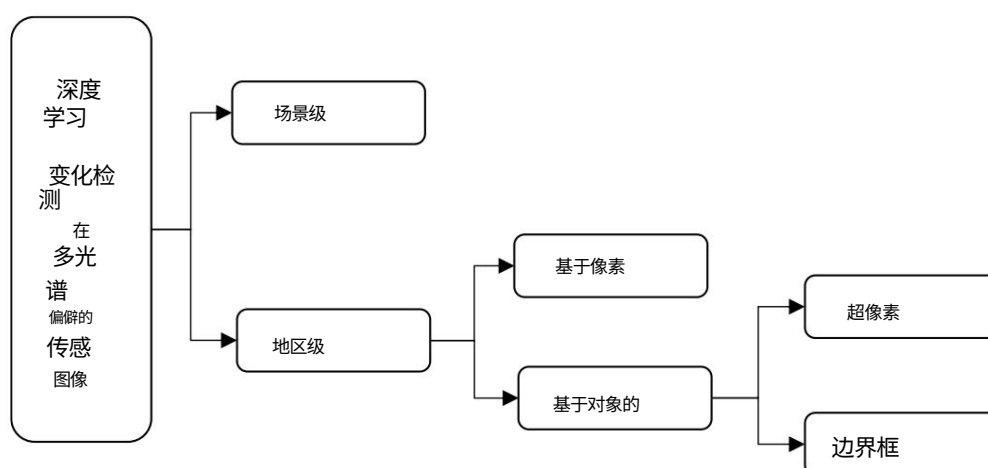


图 12: 高分辨率遥感图像变化检测方法的分类。

#### 3.1. 场景级变化检测

随着覆盖地球表面的高分辨率图像的不断增多,面对,景观的上下文和纹理信息变得越来越丰富,现在可以实现场景级别的土地利用分析,例如场景分类[142]。现在可以实现场景级别的土地利用分析,例如[145]、场景分割[138,146,147]和场景变化检测[148-150]。场景分类[143-145]、场景分割[138,146,147]和场景变化检测。尽管单图像分类由于其广泛性而得到适用性,特别是在自然图像中,很少有研究关注像素和对象级别的场景变化去检测,或关注变化类型的多时相图像中的保护。对于多时相图像,大多数工作都集中在变化然而,像素级或对象级变化检测方法在像素和对象级别进行检测,或进一步识别变化类型。用于土地利用变化分析,造成这种情况的主要原因可能是场景中的对象不会直接影响土地利用类别,例如植被生长和个体建筑物的拆除/建造,土地利用类别,例如从住宅区到工业区。因此,它不直接影响土地利用类别,即它们在场景内的变化对于改进场景尺度的变化检测方法并不至关重要。检测场景变化,改进土地利用类别,例如从住宅区改为工业区。使用多时相图像并识别现场的土地利用转变(“从-到”),改进场景尺度的变化检测方法至关重要。检测规模是城市发展分析和监测的一个新领域[151]。为了通过多时相图像进行场景变化并识别土地利用转变(“从-到”),在住宅区和商业区的外观可以通过遥感指示场景级变化检测(SLCD),即场景变化检测[151]。例如,住宅区和商业区的外观可以通过遥感指示场景级变化检测(SLCD),即场景变化检测[151]。在遥感图像中,旨在分析和识别任何给定条件下的土地利用变化从语义角度看同一区域的多时相遥感图像。这里,“场景”是指从大比例尺遥感影像中裁剪出来的图像,包括独特的土地覆盖信息[145]。

在SLCD方法中,使用两个输入图像的特征来生成DI图,然后使用决策方法(例如阈值分割或决策网络)将输入块分为两类(变化和无变化[152])。决策方法将变化检测作为二元分类任务进行,具有两个输出:变化或无变化。因此,SLCD的两个挑战是找到一种有效的方法来提取图像的显着特征,并寻求最佳的变换特征空间来探索时间相关性。

与大多数计算机视觉任务一样,提取多时间图像的判别特征是一个重要且具有挑战性的步骤。在深度学习发展之前,人们付出了巨大的努力来导出有区别的视觉特征,包括手工制作的局部特征,例如尺度不变特征变换(SIFT) [153]和使用视觉词袋编码局部特征(BoVW) [154]。考虑到手工特征的弱点,一些研究人员转向无监督学习技术,例如稀疏编码[155]。从未标记数据自动生成的特征成功应用于场景分类,然后引入变化检测。然而,基于无监督学习的图像场景的代表性特征尚未得到充分利用,限制了它们区分遥感图像中不同场景类别的能力。至于从两个特征进行场景分类的决策方法,支持向量机(SVM) [156]是最常见和有效的分类器[157]。

随着大量带注释样本的收集、机器学习理论的发展和计算能力的增强,深度学习模型(例如自动编码器、CNN和GAN)已经证明了它们在学习生产性特征方面的强大能力[145]。这种决定性的优势已经扩展到场景分类和遥感图像的变化检测[108]。

SLCD最简单的方法,即后分类方法,将场景变化检测任务视为一个独立的分类,忽略时间相关性信息,从而遭受错误累积。换句话说,它几乎没有考虑多时相图像的时间相关性。一些研究人员已经开始考虑多时相图像场景之间的时间相关性,开发了深度典型相关分析(DCCA)正则化[149]和一种称为软DCCA [158]的改进方法。然而,这些仅专注于从两个输入中学习相关特征,并且无法优化以提高特征表示能力。

学习到的全连接层可用于对双时态场景之间的相似性进行建模,并提高特征表示的可靠性[159]。

### 3.2.区域级变化检测在变化检测任务

中,图像中的像素和对象是分析的两个主要类别。人们已经研究了区域级(包括基于像素和基于对象)的方法,其中变化检测可以被视为密集的二进制分割任务[17]。准备好图像后,全卷积网络(FCN)可以将每个区域(像素或对象)的分割结果分类为有变化或无变化。

一般的方法是为每个区域分配一个变化分数,其中变化的区域比未变化的区域具有更高的分数。在某种程度上,这种方法允许端到端的变化检测并避免错误的累积。此外,它在检测速度方面提供了巨大的优势,这有助于大规模数据处理。

由于大多数变化检测应用涉及识别多时相遥感图像中特定区域或目标的变化,因此区域级变化检测方法比场景级变化检测方法更流行。

#### 3.2.1.基于块/超像素的变化检测块和超像素是遥感图

像处理应用中最常见的检测单元。首先构建补丁或超像素,然后通过投票生成DI图作为伪训练集,可用于学习

改变中心像素的类型[152,160,161]。补丁是规则的图像网格单元,而超像素是不规则的相邻像素簇。

仅当输入对全局发生变化时才执行基于补丁/超像素的变化检测(PBCD)。将多级连体网络中的网络通道特征连接起来后,生成的向量用于训练两层决策网络。该网络将变化检测作为具有两个输出的二元分类任务来处理:分别为变化和无变化的 1/0 [105]。每个补丁或超像素都通过卷积网络来生成固定维度的表示。由于超像素的形状不规则,需要将其特征转换为一维特征,从而导致空间信息的丢失。除此之外,矩形框中过多的干扰信息也严重影响了分类结果。

为了解决这个问题,使用了基于补丁的深度学习框架,该框架是一种训练像素及其邻居形成固定大小为  $3 \times 3$ 、 $5 \times 5$ 、 $7 \times 7$  等的补丁的算法。将 patch 大小转化为向量作为模型输入,根据空间邻近原则,根据其邻域值预测 patch 中心像素的变化类别。例如,相对而言,深度信念网络(DBN) [160]和多层感知器(MLP)是在基于补丁的变化检测中使用一维神经网络模型的最简单方法。在这些方法中,补丁被展平为一维向量作为输入;然后,使用贪婪逐层预训练来初始化权重,并使用标记的补丁样本进行微调。然而,不利的是,这两种具有完全连接层的架构存在大量可学习参数,而用于变化检测的带注释训练示例数量有限,导致过度拟合和计算成本增加。此外,上述网络的另一个缺点是它们将空间特征压缩为一维向量,导致图像的二维空间属性被忽略。

另一个可能影响模型性能的因素是补丁的大小,它会影响感受野的大小。找到获得最佳性能的合适尺寸通常具有挑战性。如果补丁大小太小,则上下文信息不足的小感受野可能会限制变化检测的性能。网络无法彻底学习变化信息和封闭字段,从而无法正确检测变化。此外,由于相邻字段之间的显著重叠,该方法可能会降低计算效率并增加存储器消耗。

此外,在不丢失空间信息的情况下[116],基于补丁的注意力机制可以有效克服PBCD方法预测类别的不确定性。

然而,遥感应用中的图像明显比自然图像大,但遥感图像中每个类别都有较小的物体。几乎每张图像都包含各种对象类别,并且在全局级别对场景信息进行分类并不容易。换句话说,典型的基于注意力的过程不适合大规模遥感图像的语义学习,因为斑块描述符提供了有限的局部上下文基本信息。

因此,PBCD方法的主要局限性可以列出如下:首先,很难找到合适的补丁大小,这显着影响DNN的性能;其次,像素块中的冗余信息会导致过度拟合并增加计算成本。

### 3.2.2. 基于像素的变化检测通常,基于

像素的变化检测方法从各个像素及其周围的像素提取特征,并预测二进制掩模,逐像素分类为变化或未变化。值得注意的是,编码器-解码器架构由于其高度灵活性和优越性,在基于像素的变化检测中变得越来越流行。正如我们之前提到的,光谱空间信息对于变化检测很重要。然而,大多数算法会比较光谱或文本值



单个像素不考虑相邻像素之间的关系并忽略空间环境。

FCN [13]使用全卷积 (FC) 层而不是CNN 中的全连接层来生成像素级预测。此后,FCN及其变体为细粒度变化检测提供了一种有效的方法,例如FC-EF [162]、FC-Siam- conc [162]和FC-Siam-diff [162]以及W-Net [163]。最常用的编码器-解码器 CNN SegNet 通过 VGG16 进行了改进,通常用于图像的语义分割。然而,当直接应用于变化检测时,如果没有跳过连接,它的准确率会很低。尽管简单的连接可以帮助恢复丢失的空间信息,但满足变化检测任务的需求仍然具有挑战性,特别是对于各种尺寸的物体。因此,UNet++ [17]采用了一系列嵌套和密集的跳跃连接来实现多尺度特征提取并减少尺度方差引起的伪变化。这是利用UNet++ 进行遥感图像像素级分割潜力的一条有前途的途径,它具有捕获细粒度细节的优势。为了充分利用多时相遥感图像之间的时空依赖性,提出了BiDateNet [115]以更好地区分时空特征。在 BiDateNet 中, LSTM 卷积块被添加到跳跃连接中,以使用 U-Net 架构检测双时态遥感图像之间的时间模式。此外,一些研究[114,164]采用ASPP [46]来提取多尺度特征,这将改善变化检测。

此外,注意力机制改进了CNN 模型中使用的平均或最大池化,使模型能够评估不同位置和范围的特征的影响。注意力机制已在计算机视觉研究中使用多年,因此难怪许多出版物将这种机制应用于变化检测[165]。卷积块注意模块 (CBAM) [166]用于使不同阶段的特征在通道和空间方面更容易识别[167]。

自注意力[52]是一种链接序列中不同位置以估计该序列中每个位置的特征的机制。它可以对双时态遥感数据之间的远程相关性进行建模。非局部神经网络[35]已经在各种任务中发展了自注意力,例如视频分类和对象识别。

### 3.2.3.基于对象的变化检测

基于对象的方法以对象而不是像素作为分析单位。对象是一组局部像素簇,其中所有像素都被分配相同的分类标签。基于对象的方法有效地利用了图像中的同质信息,并消除了图像噪声、边界 [168]和未对准的影响。由于基于对象的方法可能带来的好处,它们在土地覆盖绘图中很普遍。在各种出版物中,它们取得了比基于像素的方法更好的性能。

这一成功导致它们在对象级研究中得到普遍使用,例如对象检测和实例分离。近年来,基于对象的变化检测技术也被开发用于检测变化的对象。理论上,该方法可以减少基于像素的方法的预测中经常出现的错误检测变化的数量。该方法生成对象级预测,例如各种变化对象的掩模或边界框。这些方法大致分为两类。

第一个执行基于超像素的变化检测并输出掩模。第二组变化检测方法基于对象检测框架,用于以边界框的形式查找变化的对象。这两个类别可以使用分类后比较方法,该方法将变化检测视为对图像/框进行分类。在此任务中,在两个分类图像/框之间进行土地覆盖类别比较,其中不同的类别发生变化。

基于超像素。该方法适用于通过图像分割获得的同质像素组,利用光谱纹理和几何特征,例如图案和区域。使用超像素对象可以消除变化检测结果中的一些“椒盐”噪声。有时,多分辨率生成的超像素

分割用于将结果细化到对象级别[31]。然而,无论超像素的形成如何,手动执行的不适当的比例设置都会增加额外的误差。例如,随着分割规模的扩大,对象的清洁度会降低。计算量和小观察范围是极限分割(近似基于像素的方法)的两个主要限制因素。因此,对象级变化检测的重点是突破先验参数的约束,收集自适应对象。并非以这种方式生产的每个物体都具有相同的尺寸;因此,过度分割和分割不足会导致更差的变化检测结果[34]。

候选边框。在该方法中,将变化对象作为对象检测(OD)的目标。常用的OD方法,例如SSD [169]、Faster R-CNN [170]和YOLO1-5 [171-175],具有用于变化检测的潜力。

该方法将遥感图像中的“变化区域”作为检测目标,而“未变化区域”作为背景。OD方法应用于高分辨率遥感图像变化检测[176]。一组正方形区域和具有特定变化类型的相交区域的检测结果混合在一起。

特征提取网络可以是单分支或双分支网络。对于单分支网络,首先合并或减去多时相图像,然后将结果输入到OD网络以确定变化[176]。双分支网络分别生成每个图像的基本特征和代表性特征,然后融合每个分支的特征[177]或提议区域[178]来预测类别分数和差异置信度。此外,基于对象的实例分割(例如使用Mask R-CNN的实例分割)可以用作检测变化的基础,从而生成初始化的对象实例[179]。事实上,获取物体的位置是确定变化物体位置的第一步。

#### 4. 相关数据集和评估指标

近几十年来,人们提出了多种检测变化的方法,但选择正确的方法很困难。因此,必须采用适当的指标来在相同的数据中使用。在这里,我们列出了一些公开可用的基准测试数据集,并给出了一些标准评估指标,用于比较算法的性能,以便在进一步的研究中应用。

##### 4.1. 用于变化检测的热门数据集

下面,我们总结了一些用于变化检测的流行和公开的高分辨率光学遥感数据集。目的是激发读者对利用高分辨率光学遥感图像进行变化检测的兴趣,并促进变化检测的初步实验。通过考虑必要的变化检测任务,我们将数据集分为以下三类。

##### 4.1.1. 二进制变化检测数据集

DSIFN-CD [80]由3940对双时态图像组成,其中394对是从手动标记图像中裁剪出来的,3940对是通过数据增强生成的。该数据集涵盖了不同土地覆盖类别的变化,由六对高分辨率(2 m)卫星图像获得,每对覆盖中国一个城市。

SZTAKI AirChange Benchmark Set (SZTAKI) [180]的空间分辨率为1.5 m,具有13个 $952 \times 640$ 像素的航拍图像对。该数据集由三个区域(例如,Szada、Tiszadob和Archive)组成,分别包含7.5和1个图像对。在早期的CD研究中,这是最常用的数据集,具有各种变化类型,包括新建城区、建筑作业、种植森林、新耕地和建筑完工前的基础工作。

Onera卫星变化检测(OSCD) [152]包含2015年至2018年间获取的24对卫星图像的集合,覆盖世界城市地区(包括亚洲、巴西、欧洲、中东和美国)10 m分辨率。每个

其中大约有  $600 \times 600$  像素。该数据集主要关注人类活动引起的城市变化,例如城市增长和城市衰退。

航空图像变化检测 (AICD) [181] 是一个包含 500 对航空图像的二进制 CD 合成数据集,这些图像对是从具有 5 个不同视点的 100 张原始图像生成的。此外,某种人造变化对象 (例如建筑物、树木或浮雕) 被添加到每个图像以生成图像对。

季节变化 CDD [182] 由 16,000 对 Google Earth (GE) 图像组成,每对图像具有  $256 \times 256$  像素,空间分辨率为 0.03–1 m/像素,从七对  $4725 \times 2700$  季节变化遥感图像中收集。与合成图像的数据集 AICD 相比,CDD 包含大量反映真实变化的变化信息。

换句话说,该数据集更关注与物体的出现和消失相关的变化,而不是由于自然因素 (例如季节差异、亮度等) 造成的差异。

SYSU-CD 数据集 [167] 是现有变化检测数据集的大型汇编,具有不同的空间分辨率、变化类型和数据量。该数据集包含 20000 对 2007 年至 2014 年拍摄的 20000 对大小为  $256 \times 256$  像素、空间分辨率为 0.5 m 的正射航拍图像,此外还包含密集的高层建筑。

卫星-无人机异构图像变化检测 (HTCD) [183] 是 2008 年卫星和 2020 年无人机拍摄的组合数据集。原始卫星图像来自 Google Earth,空间分辨率为 0.5971 m,无人机图像的空间分辨率为 7.465 厘米来自开放航空地图。它们的大小分别为  $11 \text{ K} \times 15 \text{ K}$  像素和  $1.38 \text{ M} \times 1.04 \text{ M}$  像素 (分为 15 个块)。该数据集主要关注覆盖基希讷乌及其周边地区的城市人造物体 (如建筑物、道路和其他人造设施) 的变化,面积约为 36 平方公里。

#### 4.1.2. 语义变化检测数据集

高分辨率语义变化检测 (HRSCD) [184] 由 291 对  $10,000 \times 10,000$  像素的航空图像组成,分辨率为每像素 0.5 m,于 2005/2006 和 2012 年获取。该数据集提供了二进制变化图和土地-覆盖地图 (例如,人造表面、农业区、森林、湿地和水)。

语义变化检测 (SECOND) [185] 是一个基于双任务的语义变化检测数据集,包括一个变化类别和六个土地覆盖类别 (例如,非植被地表、树木、低植被、水、建筑物和游乐场)。它包含 4662 对航拍图像,尺寸为  $512 \times 512$  像素。

超高分辨率 UCD (Hi-UCD) [186] 通过注释双时态航空图像中的九个土地覆盖类别来关注城市变化。该数据集包含 2017 年至 2018 年的 359 对图像对,2018 年至 2019 年的 386 对图像对,2017 年至 2019 年的 548 对图像对。数据集中的每个图像对 (包括图像、语义图和变化图) 都具有空间分辨率 0.1 m,大小为  $1024 \times 1024$  像素。

#### 4.1.3. 建筑物变化检测数据集

WHU-CD [187] 是一个公共建筑变化检测数据集。它包含一对高分辨率 (0.075 m) 航拍图像,尺寸为  $32,507 \times 15,354$  像素,覆盖了 2012 年和 2016 年新西兰基督城地区。

学习、视觉和遥感实验室 (LEVIR-CD) [115] 是一个公共的、大规模的建筑物变化检测数据集。它包含 637 对高分辨率 (0.5 m)  $1024 \times 1024$  像素的 Google 地球 (GE) 图像,覆盖 2002 年至 2018 年的 20 个不同区域。

AIST 建筑变化检测 (ABCD) 数据集 [188] 由 22,171 对航空图像组成,其中 10,777 对固定比例 ( $160 \times 160$  像素) 和 11,394 调整大小 ( $120 \times 120$  像素)。这些图像是从几对海啸前和海啸后图像中裁剪出来的,覆盖了 66 平方公里的海啸灾区。海啸前的图像于 2000 年 8 月获取,分辨率为每像素 0.4 m,而海啸后的图像则以每像素 0.4 m 的分辨率获取。



于 2011 年 3 月 11 日采集,分辨率为每像素 0.12 m,并重新采样为 0.4 m 每个像素。

S2Looking 数据集[189]包含从侧视中提取的 5000 个图像块对农村地区卫星图像。双时态图像跨度1-3年,分辨率为 0.5–0.8 m/像素。

xBD [190]是迄今为止第一个也是最大的建筑损坏评估数据集,包含22,068张卫星图像和 850,736个建筑多边形,覆盖面积45,000平方公里 灾难 (例如地震、洪水、火山爆发、野火和自然灾害)前后 风)。每幅图像的大小为 1024 × 1024 像素,分辨率为 0.3 m/像素。

表1变化遥感影像数据集基本信息  
检测。用于变化检测的开放数据集非常少,其中一些已经 空间分辨率低。也就是说,可以用于基于DL的公共数据集 变化检测有很大的局限性。这会对基于深度学习的变更产生不利影响 检测方法有以下两种方式。一、模型容易出现过拟合 当数据量超过模型参数数量且数据量不足时 带注释的数据集可供学习,严重限制了深度学习的实际适用性 楷模。其次,一些可用数据集的图像空间分辨率较低,例如 如SZTAKI、DSIFN和OSCD,这样不仅排除了许多小变化的对象,而且还排除了 使得许多人造物体 (例如建筑物和道路)的边界变得不清晰。 结果,不明确的划分导致模型含糊不清。

表 1.用于变化检测任务的流行高分辨率遥感数据集摘要。

数据集	课程	传感器	图像对	图片大小	解决 (米)	真实的	时期 (年)
斯塔基	2	天线	13	952 × 640	1.5	√	-
CDD	2	卫星	16,000	256 × 256	0.03–1	√	-
OSCD	2	卫星	24	600 × 600	10	√	2
A B C D	2	天线	8506/8444	160 × 160/ 120 × 120	0.4	√	11
人工智能CD	2	天线	500	800 × 600	0.5	✗	-
莱维尔-CD	2	卫星	第637章	1024 × 1024	0.5	√	6
武汉大学CD	2	天线	1	32,507 × 15,354	0.075	√	4
中山大学CD	2	天线	20,000	256 × 256	0.5		7
HRSCD	1+5	天线	第291章	10,000 × 10,000	0.5	√	6, 7
第二	1+6	天线	4662	512 × 512	-	√	-
嗨UCD	1+9	天线	1293	1024 × 1024	0.1	√	1, 2
双干扰素	2	卫星	3940	512 × 512	2	√ 5, 8, 10, 15, 17	
S2寻找	2	卫星	5000	1024 × 1024	0.5–0.8	√	1–3
HTCD	2	卫星, 天线	1	11K × 15K 0.59710.007465 √			12

每个数据集的文献引用总数如图13 所示,反映了 每个数据集的重要性。统计分析基于Google的工作 学者。该图说明 WHU-CD 是最流行的数据集,并且应用程序 LEVIR-CD 的数量急剧增加。

每个数据集的文献引用总数如图 13 所示,反映了每个数据集的重要性。统计分析基于谷歌学术的工作。从图中可以看出,WHU-CD 是最受欢迎的数据集,LEVIR-CD 的应用急剧增加。

遥感. 2022, 14, 1552

22 共 31

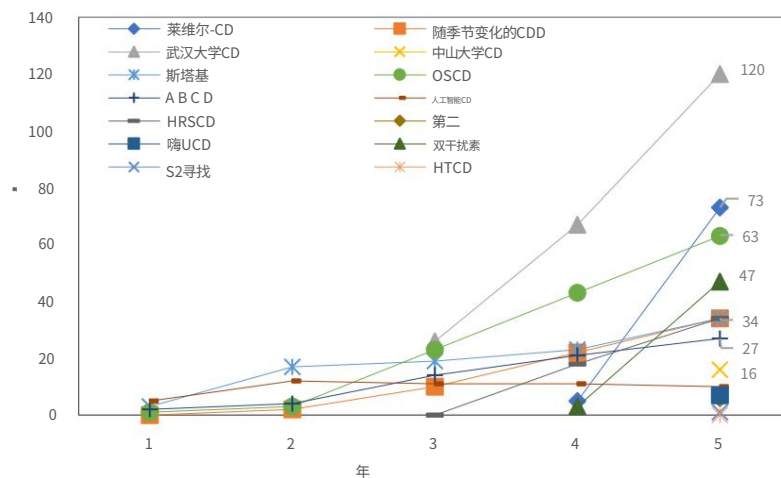


图 13 每个数据集的文献引用总数

图 13. 每个数据集的文献引用总数。

#### 4.2. 评估指标

#### 4.2. 评估指标

#### 众所周知,变化检测算法的性能评估

众所周知,变化检测算法的性能评估是一个关键问题。在这里,我们介绍了一些常用的评估指标。

节奏是一混淆矩阵[191,192]通常用于定量分析评估指标。

考虑到敏感性和特异性,混淆矩阵[191,192]通常用于二元分类准确性的定量分析。它也适用于考虑敏感性和特异性,分类的准确性。它还适用于通过可能的已更改和未更改状态进行二进制更改检测。的定义通过可能的已更改和未更改状态进行二进制更改检测。混淆矩阵的定义如表2所示。FP (假阳性)和FN (假阴性)指的是分别被错误地分类为已更改和未更改的像素。TP (真正)和TN (真负)分别代表变化的像素和未变化的像素。 (真阳性)和TN (真负)分别表示正确检测到的变化像素和未变化像素。

表 2. 二进制变化检测的混淆矩阵。

表 2. 二进制变化检测的混淆矩阵。

检测	参考	
	改变了	没有改变
检测到了	改变了	没有改变
改变了	城市	纤维网
没有改变	纤维网	总氮

最广泛使用的绩效衡量标准定义如下:

$$OA = \frac{TP + TN}{TP + FP + TN + FN}, \quad (4)$$

$$精度 = \frac{城市}{TP + FP}, \quad (5)$$

$$回想一下 = \frac{城市}{TP + FN}, \quad (6)$$

$$F1 = \frac{2 * 精度 * 召回率}{精度 + 召回率}, \quad (7)$$

$$借条 = \frac{城市}{TP + FP + FN}, \quad (8)$$

总体准确率 (OA)是预测结果的通用评价指标。精确衡量实际发生更改的检测的比例,召回率衡量该比例正确检测到的变化的数量,F1 指的是召回率和精度。一般来说,精度越高表明错误预测结果越少,召回率越高表明错过的变化更少。IoU 或杰卡德指数定义为

预测分割图与地面实况的交集和统一。作为对于指标来说,其值越大,预测结果越好。一般来说,在二进制CD任务中,除了OA之外的所有指标都只计算由于平衡问题而换了班级。

除此之外,还有一些具有特殊应用的指标,例如分离的Kappa (SeK)、平均精度 (AP) 和轨迹误差矩阵 (TEM)。

SeK [120]的提出是为了减轻不同变化中不平衡的影响类别。

AP计算精确率-召回率曲线下的平均值,通常是用作对象级别的精确度和召回率的指标。

美联社=
$$\frac{1}{0} p(r)博士,$$

(9)

这里,p和r分别指对象级精度和召回率。

TEM 能够评估多时间变化检测的结果[193]。这TEM由两个指标组成 (例如二元分类和变化检测),而分类指标用于评估检测到的变化/未变化是否正确。另一个指示器显示使用参考数据检测到的更改路径。一些研究将可能的变革路径分为六个子组[4,194],如表 3 所列。

表 3.轨迹误差矩阵 (TEM) 中的子组。

团体	分类结果	参考	检测到
S1	正确的	未更改 已更改 未	不变
S2		更改 未更	改变了
S3		改 已更改	不变
S4	不正确		改变了
S5			不变
S6		改变了	改变了 不正确的轨迹

5.结论

在本文中,我们对基于深度学习的变化检测进行了全面的回顾使用高分辨率图像进行学习,涵盖了最流行的特征提取深度神经网络及其构建机制。此外,根据检测单元分析了变化检测算法的粒度,即

使我们能够独立于其特定应用而应用合适的方法。

本文提到的相关变化检测方法表明深度学习技术成功地促进了变化检测的发展,并已取得了重大进展。然而,变化检测仍然面临许多挑战由于需求的多样性和数据的复杂性。此外,多源遥感数据的数据融合和多尺度问题也是需要解决的问题遥感应用中应引起重视。值得一提的是,它可以应对不同地面目标的不同困难。例如,高层建筑的位移是图像捕捉的最大挑战之一从不同的角度来看[165],异质外观[195]也是一个突出的问题。因此,对变化检测未来研究方向提出几点建议强烈建议使用遥感数据来更多地关注这些挑战。首先,生成大量标记样本用于变化检测很重要当训练具有足够高泛化能力的大型模型来处理各种复杂的场景。其次,为了处理变更检测的困难,领域知识 (遥感图像的时空光谱特征,地理信息和其他与地球科学相关的知识)必须融入

学习框架增强了方法的可靠性。第三,当大量标记样本的数据缺乏且具有挑战性时,小样本集学习对于算法的开发很有用。

作者贡献: Conceptualization,YZ,HJ 和 XH;写作 初稿准备、 HJ,MP,HX,ZH,JL 和 XM;写作 审查和编辑,HJ,YZ,HX 和 XH;监督, YZ 所有作者均已阅读并同意稿件的出版版本。

基金资助:本研究得到国家自然科学基金项目 (批准号:92038301和41771363)的资助,并得到国土资源部广东省测绘院、沈阳岩土勘察研究院有限公司的资助。有限公司

致谢 :作者衷心感谢学术编辑和审稿人提出的有益评论和建设性建议。

利益冲突 :作者声明不存在利益冲突。

参考

1. Singh, A.使用遥感数据的数字变化检测技术。国际。 J. 遥感. 1989, 10, 989–1003. [\[交叉参考\]](#)
2. 郑Z.;钟,Y.王.J.马,A.张L.利用基于对象的深层语义变化检测框架构建快速灾害响应的损害评估:从自然灾害到人为灾害。遥感环境。 2021, 265, 112636. [\[交叉参考\]](#)
3. 莫亚,L.;穆哈里,A.;阿德里亚诺,B.;越村,S.;马斯,E.马瓦尔-佩雷斯,LR; Yokoya, N. 使用相位相关和基于 1 的稀疏模型检测城市变化以进行早期灾害响应 :以 2018 年印度尼西亚苏拉威西岛地震海啸为例。遥感环境。 2020, 242, 111743–111756. [\[交叉参考\]](#)
4. 刘,R.库弗,M.; Persello, C. 采用基于 CNN 的变化检测方法的贫民窟的时间动态。遥感. 2019, 11, 2844. [\[交叉引用\]](#)
5. 布鲁佐内,L.; Serpico, SB 用于检测多时相遥感中土地覆盖转变的迭代技术 图片。IEEE 传输.地理学.遥感. 1997, 35, 858–867. [\[交叉参考\]](#)
6. 德贝姆,PP;小德卡瓦略,OA;丰特斯·吉马良斯,R.; Trancoso Gomes,RA 使用陆地卫星数据和卷积神经网络对巴西亚马逊地区森林砍伐的变化检测。遥感. 2020, 12, 901. [\[交叉引用\]](#)
7. 张Z.;沃塞耳曼,G.;格克,M.;图亚,D.; Yang,MY 使用多模态遥感数据进行变化检测 暹罗CNN。arXiv 2018, arXiv:1807.09562。
8. 陈杰;刘,H.;侯,J.杨,M. Deng, M.通过结合粗略定位和联合分割改进VHR 遥感图像中的建筑物变化检测。ISPRS 国际。J.地理信息。 2018, 7, 213. [\[交叉引用\]](#)
9. 秦R.;田,J. Reinartz, P. 3D 变化检测 - 方法和应用。ISPRS J.摄影图.遥感. 2016, 122, 41–56. [\[交叉参考\]](#)
10. 班恩,Y.; Yousif, O. 变更检测技术 :回顾。在 多时相遥感中。遥感与数字图像处理; Ban,Y.,Yousif,O.,编;遥感与数字图像处理;施普林格:Cham,瑞士,2016;第 20 卷,第 19–43 页。
11. 刘T.;杨,L. Lunga, D. 使用深度学习方法和基于对象的图像分析进行变化检测。遥感。环境。 2021, 256, 112308. [\[交叉引用\]](#)
12. 克里热夫斯基,A.;苏茨克维尔,I.; Hinton,GE ImageNet 使用深度卷积神经网络进行分类。交流。ACM 2012, 60, 84–90. [\[交叉参考\]](#)
13. 朗,J.;谢尔哈默,E.; Darrell, T. 用于语义分割的全卷积网络。计算机视觉和模式识别会议 (CVPR) 会议记录,美国马萨诸塞州波士顿,2015 年 6 月 8–10 日;第 3431–3440 页。
14. 陈L.-C.;杨,Y.王,J.徐,W. Yuille, AL 对尺度的关注 :尺度感知语义图像分割。计算机视觉和模式识别会议 (CVPR) 会议记录,美国内华达州拉斯维加斯,2016 年 6 月 27–30 日;第 3640–3649 页。
15. 瓦斯瓦尼,A.;沙泽尔,N.;帕尔玛,N.;乌什科雷特,J.;琼斯,L.;戈麦斯,AN;凯撒,L.; Polosukhin,I.《注意力就是你所需要的》。arXiv 2017, arXiv: 1706.03762。
16. 陈L.-C.;朱,Y.帕潘德里欧,G.;施罗夫,F.; Adam,H. 用于语义图像分割的带空洞可分离卷积的编码器-解码器。欧洲计算机视觉会议 (ECCV) 会议记录,德国慕尼黑, 2018 年 9 月 8 日至 14 日;第 833–851 页。
17. 彭,D.;张,M. Wanbing, G.使用改进的 UNet++ 进行高分辨率卫星图像的端到端变化检测。遥感. 2019, 11, 1382. [\[交叉引用\]](#)
18. 徐X.;李,W.兰,Q.杜,Q.高,L.;张波. 基于卷积神经网络的多源遥感数据分类 网络。IEEE 传输.地理学.遥感. 2018, 56, 937–949. [\[交叉参考\]](#)
19. 李,Y.;张,H.薛,X.蒋,Y. Shen, Q. 遥感图像分类的深度学习 :一项调查。威利跨学科牧师。数据最小值知道。迪可夫。 2018 年 8 月,e1264. [\[交叉参考\]](#)



- 20.邓Z.;孙,H.;周,S.赵,J.雷,L.; Zou, H. 遥感图像中卷积的多尺度目标检测神经网络. ISPRS J.摄影图.遥感, 2018,145,3-22. [\[交叉参考\]](#)
- 21.张Z.;江,R.我是.;张,S.张,Y. VHR 光学遥控器中目标检测的旋转不变特征学习通过双网感知图像. IEEE 接入2020, 8, 20818–20827. [\[交叉参考\]](#)
- 22.纽厄尔,A.;杨,K. Deng, J. 用于人体姿势估计的堆叠沙漏网络.欧洲计算机视觉会议 (ECCV) 会议记录,荷兰阿姆斯特丹,2016 年 10 月 11-14 日;第 483–499 页。
- 23.孙K.;肖,B.;刘,D.; Wang, J. 用于人体姿势估计的深度高分辨率表示学习.计算机视觉和模式识别 (CVPR) 会议论文集,美国加利福尼亚州长滩,2019 年 6 月 16 日至 20 日。
- 24.朱Q.;孙,X.;钟,Y.张丽.高分辨率遥感图像场景理解:综述. IEEE 国际地球科学与遥感研讨会 (IGARSS) 会议记录,日本横滨,2019 年 7 月 28 日至 8 月 2 日;第 3061–3064 页。
- 25.迈克尔,K.;阿恩特伯勒,S.; Robert, J.使用深度卷积神经网络对城市遥感图像中的小物体进行语义分割和不确定性建模.计算机视觉和模式识别研讨会会议记录 (CVPRW),美国内华达州拉斯维加斯,2016 年 6 月 26 日至 7 月 1 日;第 680–688 页。
- 26.龚,M.;赵,J.刘,J.苗,Q. Jiao L. 基于深度神经网络的合成孔径雷达图像变化检测网络. IEEE 传输.神经网络.学习.系统. 2016, 27, 125–138. [\[交叉参考\]](#)
- 27.高,F.;董,J.李,B. Xu, Q. 基于 PCANet 的合成孔径雷达图像自动变化检测. IEEE 地球科学.遥感快报. 2016, 13, 1792–1796. [\[交叉参考\]](#)
- 28.姚S.;沙赫扎德,M.; Zhu, XX 使用 OSM 建筑物足迹在单个 SAR 图像中估计建筑物高度. 2017 年联合城市遥感活动 (JURSE) 会议记录,阿拉伯联合酋长国迪拜,2017 年 3 月 6-8 日;第 1-4 页。
- 29.彭,D.;布鲁佐内,L.;张,Y.关,H.丁,H. Huang, X. SemiCDNet:一种用于高分辨率遥感图像变化检测的半监督卷积神经网络. IEEE 传输.地理学.遥感. 2021, 59, 5891–5906. [\[交叉参考\]](#)
30. Jacobsen, K.用于地形测绘的超高分辨率光学卫星的特性. ISPRS-国际摄影测量、遥感和空间信息科学档案馆;哥白尼有限公司:德国哥廷根,2011 年;第 XXXVIII-4/W19卷,第 137–142 页. [\[交叉参考\]](#)
- 31.王M.;坦克.;贾X.;王X; Chen, Y. 具有混合卷积特征提取模块的深度连体网络基于多传感器遥感图像的变化检测.遥感. 2020, 12, 205. [\[交叉引用\]](#)
- 32.鲍,T.;傅,C.;方,T. Huo, H. PPCNET:用于高分辨率遥感图像变化检测的组合补丁级和像素级端到端深度网络. IEEE 地球科学.遥感快报. 2020, 17, 1797–1801. [\[交叉参考\]](#)
- 33.张,M.; Shi, W. 基于特征差异卷积神经网络的变化检测方法. IEEE 传输.地理学.遥感. 2020, 58, 7232–7246. [\[交叉参考\]](#)
- 34.侯赛因,M.;陈,D.程,A.魏,H. Stanley, D. 遥感图像的变化检测:从基于像素到基于对象的方法. ISPRS J.摄影图.遥感. 2013, 80, 91–106. [\[交叉参考\]](#)
- 35.博沃洛,F.; Bruzzone, L. 数据融合中的时间变量:变化检测视角. IEEE 地球科学.遥感杂志. 2015年, 3,8-26. [\[交叉参考\]](#)
- 36.图克斯伯里,美联社;康伯,AJ;新泽西州泰特;兰姆,A.; Fisher,PF 遥感光学图像变化的关键综合检测技术.遥感环境. 2015,160,1-14. [\[交叉参考\]](#)
- 37.你,Y.;曹,J.周文.基于遥感影像的多源变化检测方法综述多目标场景.遥感. 2020, 12, 2460. [\[交叉引用\]](#)
- 38.石W.;张,M.张,R.陈,S. Zhan, Z. 基于人工智能的变化检测:最先进的和挑战.遥感. 2020, 12, 1688. [\[交叉引用\]](#)
- 39.赫利菲,L.; Mignotte, M. 用于遥感图像变化检测的深度学习:综合回顾和荟萃分析. IEEE 访问2020, 8, 126385–126400. [\[交叉参考\]](#)
- 40.兰,G.;约书亚,B.;亚伦,C.深度学习;麻省理工学院出版社:美国马萨诸塞州剑桥,2016 年。
- 41.费舍尔,A.; Igel, C. 受限玻尔兹曼机简介.模式识别、图像分析、计算机视觉和应用进展论文集 (CIARP),阿根廷布宜诺斯艾利斯,2012 年 9 月 3-6 日;第 14-36 页。
- 42.刘,M.-Y.;布劳埃尔,T.; Kautz, J. 无监督图像到图像翻译网络.神经信息处理系统国际会议 (NIPS) 会议记录,美国加利福尼亚州长滩,2017 年 12 月 4-9 日。
- 43.巴齐奥蒂斯,C.;安德鲁索普洛斯,I.;康斯塔斯,I.; Potamianos, A. SEQ 3:用于无监督抽象句子压缩的可微分序列到序列到序列自动编码器.计算语言学协会北美分会会议记录:人类语言技术 (NAACL),美国明尼苏达州明尼阿波利斯,2019 年 6 月 6 日至 7 日。
- 44.扎巴尔扎,J.;任,J.郑,J.赵,H.清,C.;杨,Z.杜,P. Marshall, S. 新颖的分段堆叠自动编码器,用于有效高光谱成像中的降维和特征提取.神经计算2016, 185, 1–10. [\[交叉参考\]](#)
- 45.努尔迈尼,S.;达玛瓦胡尼,A.;萨克蒂·穆克蒂 (Sakti Mukti)AN;明尼苏达州拉赫马图拉;菲尔道斯,F.; Tutuko, B. 基于深度学习的堆叠用于 ECG 心跳分类的去噪和自动编码器.电子学2020, 9, 135. [\[交叉引用\]](#)
- 46.刘,G.;李,L.焦L.;董,Y. Li, X. 用于 SAR 变化检测的 Stacked Fisher 自动编码器.模式识别. 2019, 96, 106971. [\[交叉参考\]](#)
- 47.龚,M.;杨,H.张鹏. 基于深度学习的三元变化特征学习与变化特征分类 SAR 图像中的检测. ISPRS J.摄影图.遥感. 2017, 129, 212–225. [\[交叉参考\]](#)

- 48.叶X.;王L.;邢,H.; Huang, L. 使用堆叠自动编码器对图像中的混合噪声进行去噪。2015 年 IEEE 国际信息与自动化会议 (ICIA) 论文集, 中国丽江, 2015 年 8 月 8-10 日; 第 2720–2724 页。
- 49.邵Z.;邓,J.;王L.;范,Y. 新斯科舍省苏马里; Cheng, Q. 基于模糊自动编码的遥感图像云检测。遥感. 2017, 9, 311. [\[交叉引用\]](#)
- 50.艾尔,V.;阿维德,A.;霍利特,TB;卡洛,JT; Abayowa, B. 自动编码器与预训练的 CNN 网络:应用深度特征来加速实时视频流中计算成本高昂的对象检测。目标和背景签名 IV 会议记录, 德国柏林, 2018 年 9 月 10 日至 11 日; p. 107940Y。
- 51.安贝尔卡,A.;阿瓦萨莫尔,P.;德什穆克,G.; Dave, P. 使用循环神经网络进行语音识别。收录于 2018 年 3 月 1-3 日在印度哥印拜陀举行的融合技术当前趋势国际会议 (ICCTCT) 会议记录; 第 1-4 页。
- 52.刘,P.;邱X. Huang,X. 用于多任务学习的文本分类的循环神经网络。第二十五届国际人工智能联合会议 (IJCAI) 论文集, 美国纽约州纽约市, 2016 年 7 月 9-15 日; 第 2873–2879 页。
- 53.钟,Y.;李,H. Dai, Y. 使用深度 RNN 进行开放世界立体视频匹配。在欧洲会议记录中计算机视觉 (ECCV), 德国慕尼黑, 2018 年 9 月 8 日至 14 日。
- 54.Hewamalage ,H.;伯格梅尔,C.; Bandara, K. 用于时间序列预测的循环神经网络:当前状态和未来方向。国际。J. 预测。2021, 37, 388–427. [\[交叉参考\]](#)
- 55.石W.;张,M.;柯,H.;方X.;詹,Z. Chen, S. 深度卷积神经网络的滑坡识别及其变化检测。IEEE 传输。地理学。遥感. 2020, 59, 4654–4672. [\[交叉参考\]](#)
- 56.穆,L.;布鲁佐内,L.; Zhu, X. 通过循环卷积神经网络学习光谱-空间-时间特征, 用于多光谱图像中的变化检测。IEEE 传输。地理学。遥感. 2019, 57, 924–935. [\[交叉参考\]](#)
- 57.刘R.;程,Z.;张L. Li, J. 基于信息传递和注意力机制的遥感图像变化检测。IEEE 访问2019, 7, 156349–156359. [\[交叉参考\]](#)
- 58.Lyu ,H.;卢,H. Mou, L. 从土地覆盖变化的循环神经网络中学习可转移的变化规则检测。遥感. 2016, 8, 506. [\[交叉引用\]](#)
- 59.陈H.;吴,C.;杜,B.;张L. Wang, L. 通过深度连体卷积多层循环神经网络进行多源 VHR 图像的变化检测。IEEE 传输。地理学。遥感. 2020, 58, 2848–2864. [\[交叉参考\]](#)
- 60.奥尔多涅斯,FJ; Roggen, D. 用于多模式可穿戴活动识别的深度卷积和 LSTM 循环神经网络。传感器2016, 16, 115. [\[交叉引用\]](#) [\[考研\]](#)
- 61.宋,A.;崔,J.;韩,Y. Kim, Y. 使用循环 3D 全卷积网络进行高光谱图像变化检测。遥感. 2018, 10, 1827. [\[交叉引用\]](#)
- 62.Lyu ,H.; Lu, H. 通过循环神经网络学习可转移的变化检测方法。2016 年 IEEE 国际地球科学与遥感研讨会 (IGARSS) 论文集, 中国北京, 2016 年 7 月 10-15 日; 第 5157–5160 页。
- 63.萨里古尔,M.;厄齐尔德勒姆,BM; Avci,M. 差分卷积神经网络。神经网络。2019, 116, 279–287. [\[交叉参考\]](#) [\[考研\]](#)
64. Minaee,S.;博伊科夫,YY;波里克利,F.;广场,AJ;科塔纳瓦兹,N.; Terzopoulos, D. 使用深度学习进行图像分割:A 民意调查。IEEE 传输。模式识别。马赫。英特尔。2021 年, 抢先体验。 [\[交叉参考\]](#) [\[考研\]](#)
- 65.韩,Y.;唐,BP; Deng,L. 一种具有扩大感受野的增强卷积神经网络, 用于行星齿轮箱的故障诊断。计算。《工业》2019 年, 107, 50–58. [\[交叉参考\]](#)
- 66.李,H.; Kwon, H. 基于上下文深度 cnn 的高光谱分类。在《国际地球科学学报》和遥感研讨会 (IGARSS), 中国北京, 2016 年 7 月 10-15 日; 第 3322–3325 页。
- 67.马志尼,D.;布泽利,M.;帕伊,DP; Schettini, R. 用于街景高效语义分割的 CNN 架构。国际消费电子会议 (ICCE) 会议记录, 德国柏林, 2018 年 9 月 2-5 日。
- 68.谢里夫扎德,F.;阿克巴里扎德,G.; Kaviani,YS 使用新型混合 CNN-MLP 分类器对 SAR 图像中的船舶进行分类。J. 印度社会委员会。遥感. 2019, 47, 551–562. [\[交叉参考\]](#)
- 69.皮雷斯-德利马,R.; Marfurt, K. 用于遥感场景分类的卷积神经网络:迁移学习分析。遥感. 2020, 12, 86. [\[交叉引用\]](#)
- 70.雷,J.;罗X.;方,L.;王,M. Gu, Y. 用于遥感图像中目标检测的区域增强卷积神经网络。IEEE 传输。地理学。遥感. 2020, 58, 5693–5702. [\[交叉参考\]](#)
- 71.曹C.;德拉吉切维奇,S.; Li, S. 用卷积神经网络方法检测土地利用变化。环境2019 年6 月 25 日。 [\[交叉参考\]](#)
- 72.西蒙尼扬,K.; Zisserman, A. 用于大规模图像识别的超深卷积网络。在诉讼程序中国际学习表征会议 (ICLR), 美国加利福尼亚州圣地亚哥, 2014 年 5 月 7-9 日。
- 73.他,K.;张,J.;任,S. Sun, J. 用于图像识别的深度残差学习。计算机会议论文集视觉与模式识别 (CVPR), 美国内华达州拉斯维加斯, 2016 年 6 月 27-30 日; 第 100-1 页770–778。
- 74.Ronneberger ,O.;费舍尔,P.; Brox, T. U-Net:用于生物医学图像分割的卷积网络。医学图像计算和计算机辅助干预国际会议 (MICCAI) 论文集, 德国慕尼黑, 2015 年 10 月 5-9 日; 第 234–241 页。

75. 黄, G.; 刘, Z.; 范德马滕, L.; Weinberger, K. 密集连接的卷积网络。在诉讼程序中  
计算机视觉和模式识别会议 (CVPR), 美国夏威夷檀香山, 2017 年 7 月 21-26 日; 第 4700-4708 页。
76. 刘, X.; 池, M.; 张, Y. 通过微调 VGG 深度网络对高分辨率遥感图像进行分类。IEEE 国际地球科学与遥感研讨会 (IGARSS) 会议记录, 西班牙巴伦西亚, 2018 年 7 月 22-27 日; 第 7137-7140 页。
77. 郭, Y.; 廖, J.; Shen, G. 用于高分辨率图像分类的嵌入胶囊的深度学习模型。IEEE J. Sel.  
主题应用地球观测。遥感. 2020, 14, 214-223。[交叉参考]
78. 王, A.; 王, M.; 吴, H.; 江, K.; Iwahori, Y. 一种新颖的 LiDAR 数据分类算法, 结合了 capsnet 和 resnet。  
传感器 2020, 20, 1151。[交叉引用]
79. 王, Q.; 袁, Z.; 杜, Q.; Li, X. GETNET: 用于高光谱图像变化的通用端到端 2-D CNN 框架  
检测。IEEE 传输。地理学。遥感. 2018, 57, 3-13。[交叉参考]
80. 张, C.; 岳, P.; 塔佩特, D.; 蒋, L.; 上官, B.; 黄, L.; Liu, G. 一种用于高分辨率双时态遥感图像变化检测的深度监督图像融合网络。ISPRS J. 摄影图。遥感. 2020, 166, 183-200。[交叉参考]
81. 李, K.; 李, Z.; Fang, S. 用于高分辨率卫星图像变化检测的 Siamese NestedUNet 网络。控制、机器人与智能系统国际会议 (CCRIS) 论文集, 中国厦门, 2020 年 10 月 27 日; 第 42-48 页。
82. 古德费洛, J.; 普杰-阿巴迪, J.; 米尔扎, M.; 徐, B.; 沃德-法利, D.; 奥扎尔, S.; 考维尔, A.; Bengio, Y. 生成对抗网络。交流。ACM 2014, 63, 139-144。[交叉参考]
83. 李, X.; 罗, M.; 吉, S.; 张, L. Lu, M. 评估基于图像级域传输的生成对抗网络, 用于多源遥感图像分割和目标检测。国际。J. 遥感. 2020, 41, 7343-7367。[交叉参考]
84. 雷德福, A.; 梅斯, L.; Chintala, S. 具有深度卷积生成对抗的无监督表示学习  
网络。arXiv 2015, arXiv:1511.06434。
85. 陈, X.; 段, Y.; 豪霍夫特, R.; 舒尔曼, J.; 苏茨克维尔, J.; Abbeel, P. InfoGAN: 可解释的表示学习  
信息最大化生成对抗网络。arXiv 2016, arXiv:1606.03657。
86. 朱, J.-Y.; 帕克, T.; 伊索拉, P.; Efros, A. 使用循环一致对抗网络进行不成对的图像到图像转换。  
2017 年 IEEE 国际计算机视觉会议 (ICCV) 会议记录, 意大利威尼斯, 2017 年 10 月 22-29 日; 第 2242-2251 页。
87. Arjovsky, M.; 钦塔拉, S.; Bottou, L. Wasserstein GAN。arXiv 2017, arXiv:1701.07875。
88. 张, H.; 古德费洛, J.; 梅塔克斯, D.; Odena, A. 自注意力生成对抗网络。arXiv 2018, arXiv:1805.08318。
89. 布洛克, A.; 多纳休, J.; Simonyan, K. 用于高保真自然图像合成的大规模 GAN 训练。第七届国际学习表征会议 (ICLR) 会议记录, 美国路易斯安那州新奥尔良,  
2018 年 5 月 6-9 日。
90. GAN\_Zoo。在线提供: <https://github.com/hindupuravinash/the-gan-zoo> (2022 年 3 月 20 日访问)。
91. 江, F.; 龚, M.; 詹, T.; Fan, X. 基于半监督 GAN 的多光谱多重变化检测框架  
图片。IEEE 地球科学。遥感快报. 2019, 17, 1223-1227。[交叉参考]
92. 赵, W.; 穆, L.; 陈, J.; 男生。; Emery, WJ 结合度量学习和对抗网络进行季节性不变变化检测。IEEE 传输。地理学。遥感. 2019, 58, 2720-2731。[交叉参考]
93. 李, X.; 杜, Z.; 黄, Y.; Tan, Z. 基于深度翻译 (GAN) 的光学和 SAR 遥感变化检测网络  
图片。ISPRS J. 摄影图。遥感. 2021, 179, 14-34。[交叉参考]
94. 卡里恩, N.; 马萨, F.; 西尼夫, G.; 乌苏尼尔, N.; 基里洛夫, A.; Zagoruyko, S. 使用 Transformer 进行端到端目标检测。欧洲计算机视觉会议 (ECCV) 会议记录, 在  
线, 2020 年 8 月 23-28 日; 第 213-229 页。
95. 张, Y.; 刘, H.; Hu, Q. TransFuse: 融合 Transformers 和 CNN 进行医学图像分割。arXiv 2021,  
arXiv:2102.08005。
96. 陈, H.; 齐, Z.; Shi, Z. 使用 Transformer 进行遥感图像变化检测。arXiv 2021, arXiv:2103.00208。[交叉参考]
97. 柯, L.; 林, Y.; 曾, Z.; 张, L.; 孟, L. 具有显着性测试的自适应变化检测。IEEE 访问 2018, 6, 27442-27450。  
[交叉参考]
98. 里德, MK; Liu, J. 城市环境变化检测四种算法的比较。遥感环境. 1998 年,  
63, 95-100。[交叉参考]
99. 刘, T.; 李, Y.; 曹, Y.; Shen, Q. 使用双通道卷积神经网络进行多时相合成孔径雷达图像的变化检测。J. 应用程序。遥感. 2017, 11, 042615。[交叉引用]
100. 陈, P.; 郭, L.; 张, X.; 秦, K.; 马, W. Jiao, L. 用于遥感图像变化检测的注意力引导连体融合网络。遥感. 2021, 13, 4597。[交叉引用]
101. 亚当, WH; 康斯坦丁诺斯, GD; Iasonas, K. 使用局部注意掩模的分段感知卷积网络。IEEE 国际计算机视觉会议 (ICCV) 会议记录, 意大利威尼  
斯, 2017 年 10 月 22-29 日; 第 5048-5057 页。
102. 文, Y.; 张, K.; 李, Z.; Qiao, Y. 一种用于深度人脸识别的判别特征学习方法。欧洲计算机视觉会议 (ECCV) 会议记录, 荷兰阿姆斯特丹, 2016 年 10 月 8-16 日; 第  
499-515 页。
103. 拉拉比, M.; 刘, Q.; Wang, Y. 基于卫星图像变化检测的卷积神经网络特征。首届国际模式识别研讨会 (IWPR) 会议记录, 日本东京, 2016 年 7 月 11-13 日。
104. 詹, Y.; 傅, K.; 严, M.; 孙, X.; 王, H. Qiu, X. 基于深度连体卷积网络的光变化检测  
航拍图像。IEEE 地球科学。遥感快报. 2017, 14, 1845-1849。[交叉参考]

- 105.法伊兹,R.;巴万,V.;贾里德,VC;约翰,K.; Andreas, S. 具有多级特征的暹罗网络,用于卫星图像中基于补丁的变化检测。IEEE 全球信号与信息处理会议 (GlobalSIP) 会议记录,美国加利福尼亚州阿纳海姆,2018 年 11 月 26 日至 29 日;第 958–962 页。
- 106.孙Y.;陈,Y.王X; Tang,X.联合识别验证的深度学习人脸表示。第 27 届神经信息处理系统国际会议 (NIPS)会议记录,加拿大魁北克省蒙特利尔,2014 年 12 月 8-13 日;第 1988-1996 页。
- 107.穆勒,J.; Thyagarajan, A. 用于学习句子相似性的暹罗循环架构。摘自第 30 届 AAAI 人工智能会议论文集,美国亚利桑那州凤凰城,2016 年 3 月 5 日;第 2786–2792 页。
- 108.郭E.;傅X.朱,J.邓,M.刘,Y.朱Q. Li, H. 学习衡量变化:全卷积连体度量用于场景变化检测的网络。arXiv 2018, arXiv:1810.09111。
- 109.任,C.;王X;高,J.周X; Chen, H. 使用生成对抗性的卫星图像无监督变化检测网络。IEEE 传输。地理学。遥感. 2021, 59, 10047–10061。[交叉参考]
- 110.櫻田K.; Okatani, T. 使用 CNN 特征和超像素分割对街道图像对进行变化检测。英国机器视觉会议 (BMVC) 会议记录,英国斯旺西,2015 年 9 月 7-10 日;第 1-12 页。
- 111.鲁萨科夫斯基,O.;邓,J.苏,H.克劳斯,J.;萨西什,S.;马,S.黄,Z.卡帕西,A.;科斯拉,A.;伯恩斯坦,M.;等人。ImageNet 大规模视觉识别挑战赛。国际。J. 计算机。视觉。2015, 115, 211–252。[交叉参考]
112. Otsu, N. 灰度直方图的阈值选择方法。IEEE 传输。系统。曼赛博恩。1979, 9, 62–66。[交叉参考]
- 113.刘,J.;龚,M.;秦K.;张,P.基于异构光学和雷达图像的变化检测的深度卷积耦合网络。IEEE 传输。神经网络。学习。系统。2018, 29, 545–559。[交叉参考]
- 114.张,M.;徐,G.陈,K.严,M. Sun, X. 基于三元组的航空遥感图像变化语义关系学习检测。IEEE 地球科学。遥感快报。2019, 16, 266–270。[交叉参考]
- 115.陈H.; Shi, Z. 基于时空注意力的方法和遥感图像变化检测的新数据集。遥感. 2020, 12, 1162。[交叉引用]
- 116.旭峰,H.;梁,T.贾,Y.苏坎坦卡,R.; Berg,AC MatchNet:统一特征和度量学习以实现基于补丁的匹配。计算机视觉和模式识别会议 (CVPR) 会议记录,美国马萨诸塞州波士顿,2015 年 6 月 7-12 日;第 3279–3286 页。
- 117.陈,J.;袁,Z.;彭,J.陈L.;黄,H.朱,J.林,T. Li, H. DASNet:用于高分辨率卫星图像变化检测的双注意力全卷积连体网络。arXiv 2020, arXiv:2003.03608。[交叉参考]
- 118.梅斯基塔,DB;桑托斯,RFD;马夏雷特,DG;坎波斯,MFM; Nascimento,ER 全卷积连体自动编码器无人机航拍图像中的变化检测。IEEE 地球科学。遥感快报。2019, 17, 1455–1459。[交叉参考]
- 119.刘,J.;陈,K.徐,G.孙,X.;严,M.刁,W.; Han, H. 用于光学航空图像变化检测的基于卷积神经网络的迁移学习。IEEE 地球科学。遥感快报。2020, 17, 127–131。[交叉参考]
- 120.向S.;王,M.蒋X;谢G.;张,Z. Tang, P. 使用遥感图像的双任务语义变化检测生成变革现场模块。遥感. 2021, 13, 3336。[交叉引用]
- 121.陈H.;吴,C.;杜,B.张 L. 用于多时相VHR 图像变化检测的深度连体多尺度卷积网络。第十届多时相遥感图像分析国际研讨会(MultiTemp) 会议论文集,中国上海,2019 年 8 月 5-7 日。
- 122.郑Z.;万,Y.张,Y.向S.;彭,D.;张,B. CLNet:用于光学遥感图像变化检测的跨层卷积神经网络。ISPRS J.摄影图。遥感。2021, 175, 247–267。[交叉参考]
- 123.宋L.;夏,M.金,J.钱,M.张,Y.SUACDNet:基于暹罗U型的注意力变化检测网络结构。国际。J.应用程序。地球观测。地理信息。2021, 105, 102597。[交叉引用]
- 124.郭H.;施Q.马里诺尼,A.;杜,B.张,L.深层建筑足迹更新网络:一种从双时态遥感图像更新现有建筑足迹的半监督方法。遥感环境。2021, 264, 112589。[交叉引用]
- 125.周Z.;拉赫曼·西迪奎,MM;泰巴赫什,N.; Liang, J. UNet++:用于医学图像分割的嵌套 U-Net 架构。医学图像分析深度学习和临床决策支持多模态学习 (DLMIA) 论文集,西班牙格拉纳达,2018 年 9 月 20 日;第 3-11 页。
- 126.赵H.;石,J.;齐,X.王X; Jia, J. 金字塔场景解析网络。计算机视觉会议论文集和模式识别 (CVPR),美国夏威夷州檀香山,2017 年 7 月 21-26 日;第 100-1 页6230–6239。
- 127.陈,L.-C.;帕潘德里欧,G.;科基诺斯,I.;墨菲,K.; Yuille,AL DeepLab:使用深度卷积网络、空洞卷积和全连接 CRF 进行语义图像分割。arXiv 2016, arXiv:1606.00915。[交叉参考][考研]
- 128.Yu, F.; Koltun, V. 通过扩张卷积进行多尺度上下文聚合。国际学习表征会议 (ICLR) 会议记录,波多黎各圣胡安,2016 年 5 月 2-4 日;第 1-13 页。
- 129.塞格迪,C.;魏,L.杨清,J.;塞尔马内特,P.;里德,S.;安格洛夫,D.;埃尔汗,D.;范霍克,V.; Rabinovich, A. 深入研究卷积。2015 年 IEEE 计算机视觉和模式识别会议 (CVPR) 会议记录,美国马萨诸塞州波士顿,2015 年 6 月 7-12 日;第 1-9 页。
- 130.布达,M.;梅基,A.; Mazurowski,马萨诸塞州对卷积神经网络中类别不平衡问题的系统研究。神经网络。2018, 106, 249–259。[交叉参考][考研]
- 131.阮,TL; Han, D. 使用多时态无人机图像检测路面变化卷积连体网络。可持续发展2020, 12, 2482。[交叉引用]



132. 李X.;段,H.;惠,Z.;王,F.-Y. 使用图像生成进行数据增强以进行变化检测。2021 年 IEEE 第一届数字孪生和并行智能国际会议 (DTPI) 论文集, 中国北京, 2021 年 7 月 15 日至 8 月 15 日; 第 188–191 页。
133. 陈H.;李,W. Shi, Z. 遥感图像中建筑物变化检测的对抗性实例增强。IEEE 跨. 地理学. 遥感. 2022, 60, 1–16. [\[交叉参考\]](#)
134. 肖顿,C.; Khoshgoftaar,TM 一项关于深度学习图像数据增强的调查。J. 大数据2019, 6, 60. [\[交叉引用\]](#)
135. 李X.;袁,Z.; Wang, Q. 用于高光谱图像变化检测的无监督深度噪声建模。遥感. 2019, 11, 258. [\[交叉引用\]](#)
136. 李YF;郭LZ; Zhou,ZH 走向安全的弱监督学习。IEEE 传输. 模式肛门. 马赫. 英特尔. 2021, 43, 334–346. [\[交叉参考\]](#)
137. 易卜拉欣,MS;瓦赫达特,A.;兰吉巴尔,M.; Macready,WG 具有自校正网络的半监督语义图像分割。计算机视觉和模式识别会议 (CVPR) 会议记录, 美国华盛顿州西雅图, 2018 年 6 月 13 日至 19 日; 第 12712–12722 页。
138. Kerdegari, H.; 拉扎克,M.;阿吉里乌,V.; Remagnino, P. 使用半监督 GAN 进行城市场景分割。在诉讼程序中 遥感图像和信号处理 XXV, 法国斯特拉斯堡, 2019 年 9 月 9 日至 11 日。
139. 江X.; Tang, H. 用于弱监督变化检测的密集高分辨率连体网络。2019 年第六届系统与信息学国际会议 (ICSAI) 论文集, 中国上海, 2019 年 11 月 2–4 日; 第 547–552 页。
140. 汗,SH;他,X. 波里克利,F.;本纳蒙,M.;索赫尔,F.; Togneri, R. 学习弱监督的深度结构化网络 变化检测。arXiv 2016, arXiv:1606.02009。
141. 安德马特,P.; Timofte, R. 用于变更细分和分类的弱监督卷积网络。亚洲计算机视觉会议 (ACCV) 会议记录, 日本京都, 2020 年 11 月 30 日至 12 月 4 日; 第 103–119 页。
142. 宋H.;金,M. 帕克,D. 闪亮的。;李,J.-G. 使用深度神经网络从噪声标签中学习: 一项调查。arXiv 2020, arXiv:2007.08199. [\[交叉参考\]](#) [\[考研\]](#)
143. 程,G.;韩,J. Lu, X. 遥感图像场景分类: 基准和最新技术。过程。IEEE 2017, 105, 1865–1883. [\[交叉参考\]](#)
144. 王S.;关,Y. Shao, L. 用于遥感场景分类的多粒度规范外观池。IEEE 跨. 图像处理. 2020, 29, 5396–5407. [\[交叉参考\]](#)
145. 程,G.;谢X. 韩,J. 郭L.;夏,G.-S. 遥感图像场景分类遇到深度学习: 挑战, 方法. 基准和机遇。IEEE J. Sel. 主题应用地球观测. 遥感. 2020, 13, 3735. [\[交叉引用\]](#)
146. Hazel,GG 用于多光谱场景分割和异常检测的多元高斯 MRF。IEEE 传输. 地理学. 遥感. 2000, 38, 1199–1211. [\[交叉参考\]](#)
147. 陈,C.; Fan, L. 使用 U-net++ 进行数据增强的遥感图像场景分割。2021 年计算机工程与人工智能国际会议 (ICCEAI) 论文集, 中国上海, 2021 年 8 月 27–29 日; 第 201–205 页。
148. 吴,C.;张L. 张,L. 多时相超高分辨率遥感图像的场景变化检测框架。信号处理2016, 124, 184–197. [\[交叉参考\]](#)
149. 王,Y.;杜,B. 茹,L. 吴,C.; Luo, H. 通过深度卷积典型相关分析神经网络进行场景变化检测。IEEE 国际地球科学与遥感研讨会 (IGARSS) 会议记录, 日本横滨, 2019 年 7 月 28 日至 8 月 2 日; 第 198–201 页。
150. 吴,C.;张L. Du, B. 用于场景变化检测的内核慢速特征分析。IEEE 传输. 地理学. 遥感. 2017, 55, 2367–2384. [\[交叉参考\]](#)
151. 黄X.;刘,H.;张丽. 利用高分辨率遥感影像对中国大城市地区城中村进行时空检测与分析。IEEE 传输. 地理学. 遥感. 2015, 53, 3639–3657. [\[交叉参考\]](#)
152. Daudt, RC;索克斯,BL;鲍尔奇,A.; Gousseau, Y. 使用卷积神经网络进行多光谱地球观测的城市变化检测。IEEE 国际地球科学与遥感研讨会 (IGARSS) 会议记录, 西班牙巴伦西亚, 2018 年 7 月 22–27 日; 第 2115–2118 页。
153. Lowe,DG 来自尺度不变关键点的独特图像特征。国际. J. 计算机. 视觉. 2004, 60, 91–110. [\[交叉参考\]](#)
154. 杨,J.;蒋,Y.-G.;豪普特曼,AG; Ngo,C.-W. 评估场景分类中的视觉词袋表示。多媒体信息检索国际研讨会论文集, 德国巴伐利亚奥格斯堡, 2007 年 9 月 24–29 日; 第 197–206 页。
155. 伯恩哈德,S.;约翰,P.; Thomas, H. 高效稀疏编码算法。神经信息处理系统会议 (NIPS) 论文集, 英国温哥华, 2007 年 12 月 4–7 日; 第 801–808 页。
156. Burges,CJC 用于模式识别的支持向量机教程。数据最小值知道。迪可夫。1998, 2, 121–167. [\[交叉参考\]](#)
157. 张L.;张L. 陶,D.;黄X. 结合多种特征进行高光谱遥感图像分类。IEEE 传输. 地理学. 遥感. 2012, 50, 879–893. [\[交叉参考\]](#)
158. 张X.;向,T. Hospedales,TM 通过软去相关实现可扩展且有效的深度 CCA。arXiv 2017, arXiv:1707.09669。
159. Ru, L.;杜,B. Wu, C. 基于相关性融合的多时态场景分类和场景变化检测。IEEE 传输. 图像处理. 2021, 30, 1382–1394. [\[交叉参考\]](#) [\[考研\]](#)

160. 龚, M.; 詹, T.; 张, P. Miao, Q. 用于多光谱遥感图像变化检测的基于超像素的差异表示学习。IEEE 传输。地理学。遥感. 2017, 55, 2658–2673。[交叉参考]
161. 雷, Y.; 刘, X.; 石, J.; 雷, C.; Wang, J. 具有用于变化检测的深度特征的多尺度超像素分割。IEEE 访问。2019年7月36600–36616。[交叉参考]
162. Daudt, R.C.; 索克斯, B.L.; Boulch, A. 用于变化检测的全卷积连体网络。第 25 届 IEEE 国际图像处理会议 (ICIP) 会议记录, 希腊雅典, 2018 年 10 月 7-10 日; 第 4063–4067 页。
163. 侯, B.; 刘, Q.; 王, H. Wang, Y. 从 W-Net 到 CDGAN: 通过深度学习技术进行双时态变化检测。IEEE 传输。地理学。遥感. 2020, 58, 1790–1802。[交叉参考]
164. 丁, Q.; 邵, Z.; 黄, X. Altan, O. DSA-Net: 一种新颖的深度监督注意力引导网络, 用于在高分辨率遥感图像中构建变化检测。国际。J. 应用程序。地球观测。地理信息。2021, 105, 102591。[交叉引用]
165. 姜, H.; 胡, X.; 李, K.; 张, J.; 龚, J.; 张, M. PGA-SiamNet: 基于金字塔特征的注意力引导孪生网络用于遥感正射影像建筑物变化检测。遥感. 2020, 12, 484。[交叉引用]
166. 桑, 贤, W.; 钟, 灿, P.; 俊, 杨, L.; Kweon, J.S. CBAM: 卷积块注意力模块。在诉讼程序中欧洲计算机视觉会议 (ECCV) 德国慕尼黑, 2018 年 9 月 8 日至 14 日; 第 3–19 页。
167. 石, Q.; 刘, M.; 李, S.; 刘, X.; 王, F.; 张, L. 基于深度监督注意力度量的网络和用于遥感变化检测的开放航空图像数据集。IEEE 传输。地理学。遥感. 2022, 60, 1–16。[交叉参考]
168. Fisher, P. 像素: 圈套和错觉。国际。J. 遥感. 1997, 18, 679–685。[交叉参考]
169. 刘, W.; 安格洛夫, D.; 埃米尔汗, D.; 塞格迪, C.; 里德, S.; 傅, C.-Y.; Berg, A.C. SSD: 单次多盒探测器。欧洲计算机视觉会议 (ECCV) 会议记录, 荷兰阿姆斯特丹, 2016 年 10 月 8–16 日; 第 21–37 页。
170. 任, S.; 他, K.; 吉尔希克, R.; Sun, J. Faster R-CNN: 利用区域提议网络实现实时目标检测。arXiv 2015, arXiv:1506.01497。[交叉参考][考研]
171. 雷德蒙, J.; 迪夫瓦拉, S.; 吉尔希克, R.; Farhadi, A. 你只看一次: 统一的实时对象检测。arXiv 2015, arXiv:1506.02640。
172. 雷德蒙, J.; Farhadi, A. YOLO9000: 更好、更快、更强。arXiv 2016, arXiv:1612.08242。
173. 雷德蒙, J.; Farhadi, A. YOLOv3: 渐进式改进。arXiv 2018, arXiv:1804.02767。
174. 博赫科夫斯基, A.; 王, C.-Y.; Liao, H.-Y.M. YOLOv4: 目标检测的最佳速度和准确性。arXiv 2020, arXiv:2004.10934。
175. 乔切, G. 约洛夫 5. 在线提供: <https://github.com/ultralytics/yolov5> (2022 年 3 月 10 日访问)。
176. 王, Q.; 张, X.; 陈, G.; 戴, F.; 龚, Y. Zhu, K. 基于 Faster R-CNN 的高分辨率遥感图像变化检测。遥感快报。2018, 9, 923–932。[交叉参考]
177. 张, L.; 胡, X.; 张, M.; 舒, Z.; Zhou, H. 使用双相关注意力引导检测器进行对象级变化检测。ISPRS J. 摄影图。遥感. 2021, 177, 147–160。[交叉参考]
178. 汉, P.; 苹果。; 李, Q.; 冷, P.; 公共汽车。; Li, K. 使用双感兴趣区域网络的航空图像变化检测。神经计算 2019, 349, 190–201。[交叉参考]
179. 吉, S.; 沉, Y.; 卢, M.; 张, Y. 使用卷积神经网络从大规模航空图像中构建实例变化检测网络和模拟样本。遥感. 2019, 11, 1343。[交叉引用]
180. 贝内德克, C.; Sziranyi, T. 通过多层条件混合马尔可夫模型对光学航空图像进行变化检测。IEEE 传输。地理学。遥感. 2009, 47, 3416–3430。[交叉参考]
181. 布尔迪斯, N.; 马罗, D.; Sahbi, H. 用于航空图像变化检测的约束光流。2011 年 IEEE 国际地球科学与遥感研讨会论文集, 加拿大不列颠哥伦比亚省温哥华, 2011 年 7 月 24–29 日; 第 4176–4179 页。
182. 列别杰夫, 马萨诸塞州; 维齐尔, Y.V.; 维戈洛夫, O.V.; 弗吉尼亚州克尼亚兹; Rubis, A.Y. 使用条件对抗网络进行遥感图像变化检测。ISPRS 国际。拱。摄影图。遥感争端。信息。科学。2018, 42, 565–571。[交叉参考]
183. 邵, R.; 杜, C.; 陈, H.; Li, J. SUNet: 卫星和无人机异构遥感图像的变化检测使用双通道全卷积网络。遥感. 2021, 13, 3750。[交叉引用]
184. 罗德里戈, C.D.; 伯特兰, L.S.; 亚历山大, B.; Yann, G. 用于大规模语义变化检测的多任务学习。arXiv 2018, arXiv:1810.08452。
185. 杨, K.; 夏, G.-S.; 刘, Z.; 杜, B.; 杨, W. 佩里洛, M.; 张, L. 用于语义变化检测的非对称连体网络在航拍图像中。IEEE 传输。地理学。遥感. 2022, 60, 1–18。[交叉参考]
186. 田, S.; 马, A.; 郑, Z.; Chung, Y. Hi-UCD: 遥感图像中城市语义变化检测的大规模数据集。arXiv 2020, arXiv:2011.03247。
187. 吉, S.; 魏, S. Lu, M. 用于从开放航空和卫星图像数据集中提取多源建筑物的全卷积网络。IEEE 传输。地理学。遥感. 2019, 57, 574–586。[交叉参考]
188. 藤田, A.; 樱田, K.; 今泉, T.; 伊藤, R.; 彦坂, S.; Nakamura, R. 通过卷积神经网络从航空图像中检测损坏。2017 年第十五届 IAPR 国际机器视觉应用会议 (MVA) 会议记录, 日本名古屋, 2017 年 5 月 8–12 日; 第 5–8 页。
189. 沉, L.; 卢, Y.; 郝, C.; 魏, H.; 谢, D.; 岳, J.; 陈, R.; 张, Y.; 张, A.; 吕, S. 等人。S2Looking: 用于建筑物变化检测的卫星侧视数据集。arXiv 2021, arXiv:2107.09244。[交叉参考]

190. Ritwik, G.; 理查德, H.; 桑德拉, S.; 尼拉夫, P.; 布莱斯, G.; 吉加尔, D.; 埃里克, H.; 豪伊, C.; Matthew, G. 创建 xBD: 用于评估卫星图像建筑物损坏的数据集。IEEE/CVF 计算机视觉和模式识别(CVPR) 研讨会论文集, 美国加利福尼亚州长滩, 2019 年 6 月 16 日至 21 日; 第 10-17 页。
191. 奥洛夫森, P.; Foody, 总经理; 赫罗德, M.; 斯特曼, SV; 伍德科克, CE; 乌尔德, 马萨诸塞州 估算面积和评估土地变化的准确性。遥感环境。2014, 148, 42–57。[交叉参考]
192. 奥洛夫森, P.; Foody, 总经理; 斯特曼, SV; Woodcock, CE 在土地变化研究中更好地利用准确性数据: 使用分层估计估计准确性和面积并量化不确定性。遥感环境。2013, 129, 122–131。[交叉参考]
193. 李, B.; Zhou, Q. 使用轨迹误差矩阵进行多时相土地覆盖变化检测的精度评估。国际。J. 遥感。2009, 30, 1283–1296。[交叉参考]
194. 普拉托莫, J.; 库弗, M.; 科利, D.; Martinez, J. 应用轨迹误差矩阵评估时间可转移性 OBIA 用于贫民窟检测。欧元。遥感杂志, 2018, 51, 838–849。[交叉参考]
195. 龚, J.; 胡, X.; 庞, S. Wei, Y. 根据图像和足迹图进行建筑物变化检测的屋顶切割引导定位。摄影图。工程师。遥感。2019, 85, 543–558。[交叉参考]