



ScienceDirect提供内容列表

信息科学

期刊主页: www.elsevier.com/locate/ins



使用集成和稳健的高光谱异常检测
合作代表

Shaoxi Wang^A, Xintao Hu^A, Jialong Sun^B, Jinzhuo Liu^{C,d,e}

^A 西北工业大学微电子学院, 西安 710072
^B 西北工业大学计算机学院, 西安 710072
^C 云南大学软件学院, 昆明 650106
^d 云南省软件工程重点实验室, 昆明 650106
^e 云南大学网络空间工程研究中心, 昆明 650106

文章信息

文章历史:
2020 年 12 月 12 日收到
2022 年 10 月 7 日收到修订版
2022 年 12 月 29 日接受
2023 年 1 月 2 日上线

关键词:
异常检测 (AD)
合作代表
高光谱图像 (HSI)
机器学习

抽象的

在本文中,我们提出了一种基于集成和鲁棒的异常检测方法
基于协作表示的检测器。用于估计背景数据的聚焦像素是从图像中随机采样的。弱化异常值的贡献

在选定的像素中,我们通过采用稳健的范数为异常值分配较低的权重
回归。因此,估计结果对异常值的存在不太敏感,
正如实验结果所证明的那样。但由于算法性能不稳定
像素采样的随机性。为了消除不稳定性并提高检测性能,采用了集成学习方法。我们重复建模背景

基于随机像素选择,检测结果是所有批次的集合。
我们表明,在大多数数据集中,所提出的方法优于传统算法。此外,用于检测的批处理过程可以通过应用
并行计算来促进性能利用率的未来进步。

2023 Elsevier Inc. 保留所有权利。

一、简介

高光谱图像 (HSI)在过去三十年中因其在区分物体中的应用而脱颖而出。
自然地面物体的光谱异常。高光谱图像由高光谱探测器捕获,
包含二维几何空间图像和高光谱分辨率的光谱信息。不同的地面物体
具有独特的特征,这些特征反映在相应的光谱信息中。因此,光谱信息可以视为地物的特征,用于区分某类地物和其他地物。

使高光谱图像成为最重要的情报资源。高光谱图像的重要性已在各种遥感应用中得到重视,例如[1-5]中的对象分类、高光谱图像

[6,7]中的分解,[8]中的异常检测, [9,10]中的变化检测,等等。最著名和最广泛使用的之一
应用是异常检测,一种将感兴趣的对象与背景分开的方法,这种方法通常很少见
在数据中。异常检测一直是系统健康监测、目标检测和故障中研究的主要课题
检测,仅举几例。

通讯作者。
邮箱地址: shxwang@nwpu.edu.cn (王胜), hxt_tg@mail.nwpu.edu.cn (胡X), jlsun@mail.nwpu.edu.cn (孙杰), jinzhuo.liu@hotmail.com (J. Liu)。

<https://doi.org/10.1016/j.ins.2022.12.096>
0020-0255/ 2023 Elsevier Inc. 保留所有权利。

努力提出一种高性能、鲁棒性强的异常检测方法,保证该算法在存在异常值 (即干扰异常检测性能的噪声)的情况下能够正确运行。基于传统的异常检测算法,人们提出了各种鲁棒性增强方法,例如

作为自适应 Reed-Xiao (RX) [11],用于高光谱的压缩列稳健主成分分析 (CCRPCA) 异常检测 [12]、低秩表示和对一 (LRRSTO) [13]和鲁棒非线性异常检测 (RNAD) [14]。然而,这些算法的时间消耗要么比传统算法长,要么在它们的算法中没有提到。作品。一些相关工作带来了新的视角和新颖的方法,例如背景联合稀疏表示 (BJSR) [15], [16]中基于图的异常检测, [17]中通过谱分解和基于字典的低秩分解的检测算法,以及基于背景估计和自适应加权的异常检测算法 [18]中提出了稀疏表示。为了开发一种高效、鲁棒的异常检测算法,该算法保持低时间消耗和复杂性,我们采用“2;1-范数”方法来增强检测的鲁棒性,假设背景

高光谱数据呈正态分布。 2;1-范数回归的引入受到[19]的启发,其中 Nie 提出了一种有效的算法来加速联合 2;1-范数回归问题的权重矩阵求解进度。通过在背景建模中引入 2;1-范数回归和随机抽样策略,我们成功地改进了 [20]中提出的传统 CRD 算法的鲁棒性,复杂度和时间消耗保持在五个真实高光谱数据集的实验结果证明,水平较低,性能有所提高。这所提出的方法可以有效增强存在情况下高光谱异常检测的鲁棒性和准确性异常值。

本文的其余部分结构如下。在第二部分中,我们回顾了异常检测领域的相关工作。第三部分详细描述了所提出的基于 2;1-范数回归和随机背景建模的鲁棒异常检测算法。数据集描述、实验结果和结论显示在

以下部分。

2.相关工作

全局/本地 RX (GRX/LRX) 和基于协作表示的检测器 (CRD) 是高光谱异常检测领域的里程碑。RX 算法在[21]中介绍,其中提出了令人信服的理论 and 实践理由一般似然比检验 (GLRT) 的术语。它假设背景像素和异常像素服从具有相同协方差但均值不同的高斯分布。每个像素分别测试判断是否遵循背景分布。偏离背景分布的像素可以被视为异常。

CRD 是一种流行的异常检测方法。它通过两个窗口的框架展示了当地的特色。对两个移位窗口之间的每个周围像素 (其矩阵表示为Xw)进行采样以估计中心要测量的像素 y。原始版本采用岭回归来找到权重向量a:

$$\arg \min_{\mathbf{a}} \|\mathbf{y} - \mathbf{X}\mathbf{w}\mathbf{a}\|_2^2 + \lambda \|\mathbf{a}\|_2^2$$

81P

这里 k 控制权重值的惩罚。然后,对a求导并将其设置为零,我们可以通过以下方式计算a

$$\mathbf{a} = (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^T \mathbf{y}$$

82P

然后,它计算实际像素 (y)和协作表示像素之间的欧几里得距离 $\|\mathbf{y} - \mathbf{X}\mathbf{w}\mathbf{a}\|_2^2$ (Xwa^2)以确定异常情况。

应用CRD存在挑战:

- 外窗和内窗的尺寸很难确定,因为它与具体的尺寸有关。
- 异常物体。如果数据集同时包含大异常和小异常,固定的窗口大小可能会导致较差的结果表现。
- 如果某些异常的辐射强度严重偏离平均值,则低偏差异常可能会被错误分类。
- 上面的估计过程应用于图像中的每个像素,大部分是评估矩阵逆,其复杂度为 $O(N^3)$ 。因此,将CRD应用到高速场景是一个挑战。

该方法采用随机采样来估计一次性计算中的背景。在下一节中,我们将介绍其详细信息。

3. 方法

在这里,我们提出了一种全局协作表示来对我们随机选择的背景像素进行建模 (如算法 1 所示)。然后通过将每个像素分别分配给训练好的模型来找出异常像素。我们的

该方法概述如图2所示。这里 3-D 高光谱图像表示为 $X \in \mathbb{R}^{1/4 \times 1/2 \times n}$; $x_2; \dots$ 图像波段的数量, n 是图像像素的数; $x_n \in \mathbb{R}^n$, 其中 p 代表量。(下面的 ECRD1 代表我们提出的方法。)

3.1.强大的协作表示

为了解决客观问题,我们引入 $2;1$ -范数。 $2;1$ -范数涉及矩阵 $W \in \mathbb{R}^{m \times n}$ 的范数

$$\|W\|_{2;1} = \sum_{i=1}^m \sqrt{\sum_{j=1}^n W_{ij}^2}$$

83P

然后对 W 求导至方程: 3.我们有

$$\frac{\partial \|W\|_{2;1}}{\partial W} = \frac{1}{2} \sum_{j=1}^n \frac{W_{ij}}{\sqrt{\sum_{i=1}^m W_{ij}^2}};$$

84P

其中 W_{ij} 是矩阵 W 的第 i 行向量的 2 -范数。 4 可以写成矩阵方程形式

$$\frac{\partial \|W\|_{2;1}}{\partial W} = \frac{1}{4} RW;$$

85P

其中 $R \in \mathbb{R}^{m \times m}$ 是对角矩阵, 第 i 个对角元素 R_{ii} 等于 $1/\|W_i\|_2$ 。

异常更有可能是少数,因此像素的总体通常模拟背景对象
众多的算法。与传统的对像素邻域进行采样的 CRD 方法不同,我们只采样了几个
从整个图像 X 中随机抽取 $X_s \in \mathbb{R}^{p \times s}$ 像素,以减少异常规模的影响。然后可以通过联合 $2;1$ -范数最小二乘回归用参数矩阵 W (大小为 $s \times n$) 来估计全局背景表示。
目标可描述如下:

$$W_c = \arg \min_W \|X_s W\|_{2;1} + \lambda \|W\|_{2;1};$$

86P

其中 λ 是拉格朗日乘子。第一项限制了原始图像和估计图像之间的差异。
同时,由于 $2;1$ -范数具有行旋转不变性,并且 $2;1$ -范数中异常值的权重小于
在 2 -范数中,背景估计变得稳健。此外,第二个正则化项的约束使得
权重矩阵 W 行稀疏,在背景估计过程中更加关注 X_s 中的关键样本。这种约束可以解释为对采样像素应用特征选择,这进一步提高了鲁棒性。

考虑方程的导数。 6 W 并将其设置为零,我们有

$$X_s^T D X_s - \lambda \sum_{j=1}^n X_{sj} W_{kj} = 0;$$

87P

在等式中。 7 对角矩阵 D 的第 i 个元素为 $1/\|W_i\|_2$ 。至此,协同背景表示 W 可解:
参数矩阵 W 可解:

$$W = \frac{1}{4} X_s^T D X_s \times kH;$$

88P

然后我们有一个对异常值不敏感的背景估计 $X_s W_c$ 。

3.2.像素分数提升

我们对每个像素 i 与背景的偏差进行评分

$$S_i = \frac{\|X_i - X_s W_c\|_2}{\|X_s W_c\|_2};$$

89P

由于采样的随机性,算法性能不稳定。采样的背景像素越多,检测结果越好,异常像素也越少。在大多数情况下, X_s 仅包含少量异常,并且

因此,我们可以通过重复随机背景建模、评分和计算来提高检测性能
平均尝试次数:

$$S_i = \frac{1}{T} \sum_{t=1}^T \frac{\|X_i - X_s^t W_c^t\|_2}{\|X_s^t W_c^t\|_2};$$

90P

结果,可以获得稳定的性能。

¹ 我们方法的源代码可以在 <https://github.com/hxt-tg/ensemble-and-robust-crd> 访问。

4. 实验结果

4.1.验证方法

我们的新颖方法和对比方法的所有实现都使用 MATLAB R2019a,并在禁用并行计算的 AMD Ryzen7 2700 CPU 上运行。我们采用接受者操作特征 (ROC)曲线[22]和ROC曲线下面积 (AUC)来衡量上述方法的性能。如果一个探测器比另一个探测器更好,那么它就会比另一个探测器更高。并且相应的AUC值也会更大。

算法1:ERCRD算法流程

```
Data: Image matrix  $\mathbf{X} \in \mathbb{R}^{p \times n}$ , number of sampling points  $s \in \mathbb{R}$ , number of repeats  $\mathbf{T} \in \mathbb{R}$ 
Result: Scoring vector  $\mathbf{S} \in \mathbb{R}^n$ 
Initialize scoring matrix  $\mathbf{S} \leftarrow \mathbf{0}$ ;
for  $r \leftarrow 1$  to  $\mathbf{T}$  do Ensemble
    Randomly sample pixels  $\mathbf{X}_s \in \mathbb{R}^{p \times s}$  from image  $\mathbf{X}$ ;
    Calculate the diagonal matrix  $\mathbf{D}$ , where the  $i$ -th element
         $\mathbf{D}_i = 1/||(\mathbf{X} - \mathbf{X}_s \mathbf{W})^i||_2$ ;
    Calculate the diagonal matrix  $\mathbf{H}$ , where the  $i$ -th element  $\mathbf{H}_i = 1/||\mathbf{W}^i||_2$ ;
    Calculate the parameter matrix  $\widehat{\mathbf{W}} = (\mathbf{X}_s^\top \mathbf{D} \mathbf{X}_s + \lambda \mathbf{H})^{-1} \mathbf{X}_s^\top \mathbf{D} \mathbf{X}$ ;
    Calculate the global background representation  $\mathbf{X}_s \widehat{\mathbf{W}}$ ;
    for  $i \leftarrow 1$  to  $n$  do
        Add the  $\ell_2$ -norm score of  $(\mathbf{X} - \mathbf{X}_s \widehat{\mathbf{W}})^i$  to  $\mathbf{S}(i)$ ;
    end
end
Average scoring matrix  $\mathbf{S} \leftarrow \mathbf{S}/\mathbf{T}$ ;
```

4.2.数据集描述

经过分析比较,使用AVIRIS、圣地亚哥机场、Cri、PaviaC、Salinas 5个真实HSI数据集进行验证本文提出的方法。

前两个高光谱数据集分别由 AVIRIS 和圣地亚哥机场表示,是从圣地亚哥机场数据集生成的两个不同的子图像,该数据集在[23,24]中获得。圣地亚哥机场数据集由机载可见光/红外成像光谱仪 (AVIRIS) 传感器捕获,覆盖美国加利福尼亚州圣地亚哥机场的场景。它的空间分辨率为每像素3.5m,具有224个光谱通道,波长范围为370至2510nm。去除低信噪比和吸水区域对应的谱带后,我们的实验中保留了189个谱带。接下来,对 AVIRIS 数据集 (如图1a所示)和 San Diego 数据集 (如图1b所示)进行裁剪,分别覆盖一个 150 150 像素的场景和另一个 100 100 像素的场景。在AVIRIS数据集中,位于图像上侧的三架飞机由58个像素组成,占整个图像的0.25%。

因此,这三架飞机被认为是异常物体,如图1a所示。类似地,在圣地亚哥数据集中,图像中三架飞机的像素在光谱上有所不同,因此飞机被视为异常检测中的感兴趣对象,如图1b所示。

第三个数据集由[25]中的Nuance Cri传感器收集,覆盖面积为400 400,光谱分辨率为10nm。它由46个光谱带组成,带宽范围为0.65至1.1 lm。如图1c所示,草状物体构成了背景,其中有十块岩石,排列成两列。这些岩石由 1254




图 1. 数据 (a) AVIRIS 的伪彩色图像。(b) 圣地亚哥机场。(c) 克里。(d) 帕维亚C。(e) 萨利纳斯。

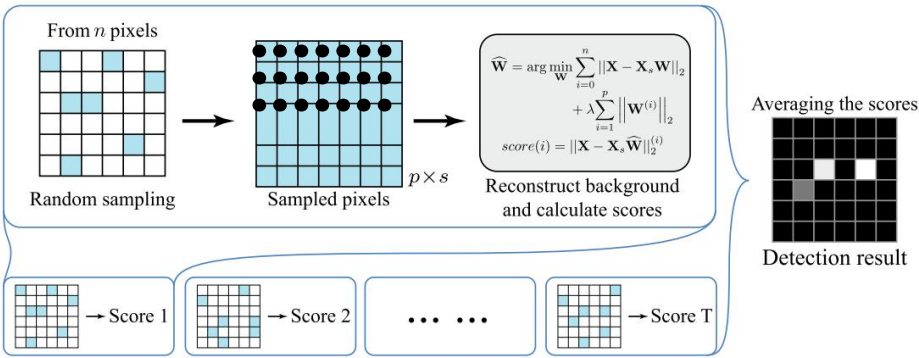


图 2. (该图已更新。)ECRD 的方法概要。主要思想是集成学习。在每个 epoch 中,对像素 (s 列向量)进行采样随机构造一个大小为 p s 的矩阵。然后利用稳健的 2;1-范数回归,我们可以估计全局背景权重矩阵XsWc 大小为 p n。我们可以根据实际像素 X 与估计像素XsWc 之间的欧氏距离,得到本轮的评分矩阵每个像素。通过重复相同的过程,我们可以计算每个像素的这些分数的平均值。

像素,占场景的0.78%。因此,在实验中场景中的岩石被识别为异常物体,如图1c所示。

本文使用的第四个高光谱数据集是从 PaviaC 数据集裁剪而来,由 Reflective Optics 收集系统成像光谱仪 (ROSIS)传感器[26],已在相关出版物中广泛使用。它被捕获了意大利北部帕维亚市中心。原始PaviaC数据集包含1096×1096像素的图像,带有噪声带包括。去除低信噪比 (SNR)波段后选择 108 120 像素的子图像,其中 102 个光谱光谱范围为 430 至 860nm。空间分辨率为每像素 1.3 米。如图1d所示,背景由桥和水组成,桥上的车辆和桥附近的裸露土壤被认为是异常点,因为它们覆盖了43个像素,仅占0.33%。图像,并且在光谱上与原理地面不同

对象。异常地物如图1d所示。

使用的另一个数据集是从[27]中获得的 Salinas 数据集裁剪的子图像,该数据集是由 AVIRIS 在 1998 年,美国加利福尼亚州萨利纳斯谷。原始数据集由 512 217 个像素、224 个光谱带的图像组成。这 Salinas 数据集的空间分辨率为每像素 3.7m。去除水吸收和低 SNR 频带后原始数据集,裁剪了 180 180 像素的子图像。蔬菜、裸露的土壤和葡萄园田地构成了背景这一幕。图1e显示了异常的地面物体,其光谱特征与主要地面的光谱特征不同对象。

4.3.算法性能

关于参数设置,我们在实验中对每个数据设置 2;1-范数的惩罚。如[20]中所述,该参数的选择始终是经验性的。这里为了方便比较,我们将传统的k 1/4 106设置为

CRD 方法和我们的方法。对于本地方法,我们选择与相关工作中最佳性能相对应的窗口大小。该方法中的随机采样过程遵循均匀分布。

首先,我们说明样本大小 s 对部分数据集的影响。我们使用箱形图来反映统计特征。AUC 值的中位数绘制为框中的短中心线。缺口代表中位数附近的置信区间 (CI)。框的上边界是第 75 个百分位数 (Q3),下边界是第 25 个百分位数 (Q1)。上须线延伸到小于 75% 的最后一个数据,超过框高度的 1.5 倍 (Q3 Q1)。下须线也是如此。除了晶须之外,AUC 值被视为异常值,并绘制为单独的圆圈。盒子越小,我们得到的结果就越稳定。

图3显示了PaviaC随着随机样本大小的增加ROC曲线下面积的统计范围。

根据图1d 中 PaviaC 的伪彩色图像,背景像素包含大面积的水域和一座桥墩附近有裸土的桥梁。停在桥上的汽车被认为是异常的。这些像素的位置表明桥梁像素构成了这种情况下汽车像素的背景。当采样大小 s 较小时,对桥梁进行采样以构建背景的机会较低。因此背景估计 $XsWc$ 主要包含水的信息,很难正确区分汽车和桥梁。随着 s 的增加,桥可以被建模并描述为背景,并且 AUC 值上升。然而,当 s 增长到一定程度后,背景被异常估计,这使得 AUC 值略有下降。图4 中萨利纳斯数据的实验也出现了类似的现象。不同之处在于背景类型的数量。萨利纳斯数据包含多种类型的田地,包括蔬菜田、裸土和葡萄园田。因此,我们需要采样更多的像素才能整体估计各种背景。有一个与前面不同的例子。图 5 说明了 Cri 数据的实验。如图1c所示,背景仅包含草状物体,并且可以通过几个样本像素轻松建模。当样本量 s 增加时,异常现象更有可能被采样然后误判。

ERCRD 的时间消耗主要取决于计算矩阵逆的执行,尤其是计算 Moore-Penrose 逆。因此,很难讨论时间消耗的变化。但在大多数情况下,在一定的带量和传感器分辨率的情况下,复杂度符合一致的规律。

另一方面,我们将 ERCRD 与几种本地和全局方法进行了比较,包括 LRaSMD、LSMAD、全局 RX、本地 RX 和 CRD。对于 Cri 数据来说,异常的数量并不算少,而且这些像素与背景的偏差很大。我们在图6a中说明了检测性能。与 (a) 中的图例相关,AUC (百分比)分别为 96.80、91.34、67.76、96.21、83.19 和 91.60。此外,图6b中的热图描绘了每种方法中的分数 (例如,残差的欧几里德距离、马哈拉诺比斯距离等)。如果某个像素得分较高,则该像素在地图上会较亮。我们可以发现,对于这个数据,很难过滤掉 LRaSMD 图和本地 RX 图的异常。可以在剩余图中区分异常像素。然而,CRD 和 GRX 中的异常点得分并不高于背景像素,这很可能会导致异常点边界的误判。LSMAD 的异常分数很高,但整个背景也有很高的分数。因此,它对于检测过程来说不够鲁棒。ERCRD 展示了这些对象之间的最佳对比度,并反映了具有异常值的背景建模的鲁棒性。

在热图中,背景部分较暗,异常部分较亮。因此,ERCRD 估计的背景是这些方法中最接近原始背景的,并且几乎不受异常值的影响,这证实了我们的方法可以优于传统检测器。

对于 PaviaC,如图7所示,AUC (百分比)分别为 99.73、99.82、88.90、95.12、91.17、99.76。ERCRD、全局 RX 和 LSMAD 的表现优于其他。正如我们之前讨论的,水背景分数明显低于异常分数,因为水像素被采样的机会很高。CRD、LSMAD 和 GRX 也可以区分水像素中的异常。此外,ERCRD 中的桥分数低于其他方法,这有利于检测过程的鲁棒性。对于其他数据集,如图8中绘制的 ROC 所示,ERCRD 的 AVIRIS、圣地亚哥机场和萨利纳斯数据也优于其他数据集。

最后,表1总结了六种算法分别针对所有五个数据集的性能和时间消耗。

这里我们取 64 个实验的平均 AUC 作为结果,以及时间消耗。我们发现,在 AVIRIS、圣地亚哥机场、PaviaC 和 Salians 数据中,全局 RX 的执行速度比其他方法更快。然而,它在某些数据上表现不佳。运行时间比 ERCRD 少 6.03、4.34、3.57 和 21.39 秒。对于 Cri 数据,ERCRD 的执行速度比全局 RX 更快,Cri 数据是实验数据集中最大的。对于 PaviaC,全局 RX 具有最高的 AUC 值并且非常接近 ERCRD。对于其余的,ERCRD 显著优于其他五种方法。与传统的 CRD 方法相比,ERCRD 在执行时间和性能方面均优于传统 CRD 方法。

4.4. 参数设置

主要实验的参数设置 (如图6、图7和图8所示)如表2所示。此外,我们还针对集成大小 T 对所提方法性能的影响进行了实验。对于 PaviaC 数据,集成大小 T 从 1 到 10 变化。同时,将其他参数设置为相应的最优值。如图9所示,AUC 随着 T 的增长而增加,结果会更加稳定。根据经验, T 1/4 10 对于大多数情况来说已经足够大了。对于本文的所有实验,我们将集成大小 T 设置为 10 以进行比较。




图3. PaviaC数据的ROC曲线下面积 (蓝色)和时间消耗 (橙色)的统计范围。所提出的 ERCRD 算法重复 64 次,以便计算 AUC 值并跟踪时间消耗。这些箱线图描绘了相应值的第 25 个百分位数、中位数、第 75 个百分位数和异常值。




图4. Salinas数据的ROC曲线下面积 (蓝色)和时间消耗 (橙色)的统计范围。






图5. Cri数据的ROC曲线下面积 (蓝色)和时间消耗 (橙色)的统计范围。



(A)



(二)

图 6. 对于 Cri 数据,(a) 不同异常检测方法的 ROC 评估。(b) 检测分数的二维图。热图中采用的方法分别是LRSMD,LSMAD,GRX,LRX,CRD和ERCRD (按行)。





图 7. 对于 PaviaC 数据,(a) 不同异常检测方法的 ROC 评估。(b) 检测分数的二维图。热图中采用的方法分别是LRSMD、LSMAD、GRX、LRX、CRD和ERCRD（按行）。

5.结论

在本文中,我们提出了一种基于CRD的新型异常检测方法。具体来说,通过联合“2;1-范数回归”从随机选择的像素中估计全局背景,该回归具有待解决的迭代方法。“2;1-范数”承诺异常值在回归中的权重较小,因此,它反映了估计的稳健性。此外,批处理用于稳定的评分和检测增强,这在未来的研究中很有可能实现高性能并行计算优化。我们证明鲁棒随机增强 CRD 优于经典算法,并且复杂度保持在较低水平。我们未来的研究目标是根据统计特征对提升批次进行加权。




图 8. 对数据 (a) AVIRIS 的不同异常检测方法的 ROC 评估。(b) 圣地亚哥机场。(c) 萨利纳斯。

表格1

所有实验数据集（包括 AViris、圣地亚哥机场、CRI、PAViaC 和 SALinas。粗体字体突出显示了数据集中最高的 AUC 性能和最短的执行时间。对于这里的本地 RX 和 CRD,我们选择11和3作为外窗尺寸和内窗尺寸。在CRD中,我们将范数的惩罚设置为106

方法	AVI	存储网络	星色指数	如图	将
LRaSMD	82.21	87.77	83.19	91.17	86.01
	13.53	10.17	50.84	9.07	36.08
LSMAD	97.17	96.84	91.60	99.76	94.72
	13.98	10.66	48.19	8.72	36.73
格瑞克斯	91.11	94.03	91.34	99.82	88.72
	0.20	0.15	0.44	0.07	0.42
LRX	96.85	86.56	67.76	88.90	81.88
	147.88	68.50	124.91	31.24	190.29
CRD	95.99	96.44	96.21	95.12	81.90
	147.62	17.96	556.77	34.14	22.03
ERCRD	98.32	98.44	96.80	99.73	95.10
	7.82	8.83	40.99	3.05	43.76

表2

所有实验数据集的参数设置。

方法	参数	数据集				
		AVI	存储网络	星色指数	如图	将
LRaSMD	基数 k	0.445	0.45	1.5	0.45	0.45
LSMAD	基数 k	0.005	0.005	0.015	0.005	0.005
格瑞克斯	—	—	—	—	—	—
LRX	责怪	15 15 29	15 15 17	11 11	5 5 11	3 3
	酒责怪	29 13 13	17 15 15	17 17 11	11	7 7
CRD	酒	19 19	17 17	11 17 17	5 5	3 3
				106	11 11	7 7
ERCRD	正则化 k					
	样本量	10	10	10	10	60
	合奏尺寸 T			10		
	正则化 k			106		




图 9. 集成大小 T 对性能的影响。每个不同集合大小 T 的实验都会在数据 PaviaC 上重复 64 次以上。上层每条线的破折号表示最高的 AUC 值,下面的也是如此。

CRediT 作者贡献声明

Shaoxi Wang: Methodology, Software, Validation. Xintao Hu: Visualization. Jialong Sun: Validation. Jinzhuo Liu: Super-vision, Writing - review & editing.

数据可用性

作者没有共享数据的权限。

竞争利益声明

作者声明,他们没有已知的相互竞争的经济利益或个人关系,可能会导致似乎影响了本文报告的工作。

致谢

该工作得到太仓市科技发展计划 (No.TC2019DYDS07)、西安市科技发展计划 (No.201805042YD 20CG26)、陕西省科技发展计划 (No.2020GY-097)和国家自然科学基金委的资助 (编号 :61866039)。

参考

[1]张丽,张丽,杜斌,尤建,陶德,鲁棒流形矩阵分解的高光谱图像无监督分类,信息科学 485 (2019)154-169。

[2] Z. Zhu,S. Jia,S. He,Y. Sun,Z. Ji,L. Shen,使用模因进行高光谱图像分类的三维 Gabor 特征提取框架,信息科学 298 (2015) 274–287。

[3] J. Ham,Y. Chen,MM Crawford,J. Ghosh,用于高光谱数据分类的随机森林框架的调查,IEEE Transactions 地球科学与遥感 43 (3) (2005) 492–501。

[4] C.石,C.-M.双关语,用于高光谱图像分类的 3d 多分辨率小波卷积神经网络,信息科学 420 (2017) 49–65。

[5] M. Khodadadzadeh,J. Li,A. Plaza,H. Ghassemian,JM Bioucas-Dias,X. Li,使用局部和全局的高光谱数据的光谱空间分类混合像素表征的概率,IEEE Transactions on Geoscience and Remote Sensing 52 (10) (2014) 6298–6314。

[6]李X.,黄J.黄J.-J.邓,T.-Z.黄,基于双边滤波器的稀疏高光谱图像分解的全变差正则化,信息科学 504 (2019)334-353。

[7] S. Jia,Y. Qi,高光谱分解的约束非负矩阵分解,IEEE Transactions on Geoscience and Remote Sensing 47 (1) (2008)161-173。

[8] J. Frontera-Pons,MA Veganzones,F. Pascal,J.-P. Ovarlez,使用稳健估计器的高光谱异常检测器,IEEE应用地球观测和遥感精选主题杂志9 (2) (2015) 720–731。

[9] MJ Carlotto,一种基于集群的方法,用于检测人造物体和图像变化,IEEE 地球科学和遥感学报 43 (2) (2005)374-387。

[10] Q. Wang, Z. Yuan, Q. Du, X. Li, Getnet:用于高光谱图像变化检测的通用端到端 2-d CNN 框架,IEEE Transactions 地球科学与遥感 57 (1) (2018) 3-13。

[11] MA Veganzones,J. Frontera-Pons,F. Pascal,J. Ovarlez,J. Chanussot,基于二元划分树的鲁棒自适应高光谱 RX 异常检测,见:2014 年 IEEE 国际图像处理会议 (ICIP) ,2014 年,第 5077–5081 页, <https://doi.org/10.1109/ICIP.2014.7026028>。

[12] W. Sun,G. Yang,J. Li,D. Zhang,使用压缩列稳健主成分分析的高光谱异常检测,见:IGARSS 2018–2018 IEEE国际地球科学与遥感研讨会,2018,第6372页– 6375。 doi:10.1109/IGARSS.2018.8518817。

[13] Y. Xu,Z. Wu,Z. Wei,H. Liu,X. Xu,一种基于低秩表示的新型高光谱图像异常检测方法,in,in:2015 IEEE国际地球科学与遥感研讨会 (IGARSS)),2015 年,第 4444–4447 页, <https://doi.org/10.1109/IGARSS.2015.7326813>。

[14] R.Zhao,B.Du,L.Zhang,一种鲁棒的非线性高光谱异常检测方法,IEEE应用地球观测专题杂志和遥感 7 (4) (2014) 1227–1234, <https://doi.org/10.1109/JSTARS.2014.2311995>。

[15] J. Li, H. Zhang, L. Zhang, L. Ma,利用背景联合稀疏表示进行高光谱异常检测,IEEE Journal of Selected Topics in 应用地球观测和遥感 8 (6) (2015) 2523–2533。

[16] Y. Yuan,D. Ma,Q. Wang,通过图像选择进行高光谱异常检测,IEEE 控制论交易 46 (12) (2015) 3123–3134。

[17] Y. Qu,W. Wang,R.Guo,B.Ayhan,C.Kwan,S.Vance,H. Qi,通过光谱分解和基于字典的低秩分解进行高光谱异常检测,IEEE地球科学汇刊和遥感 56 (8) (2018) 4391–4405。

[18] L. Zhu,G. Wen,基于背景估计和自适应加权稀疏表示的高光谱异常检测,遥感10 (2) (2018)272。

[19] F. Nie,H. Huang,X. Cai,CH Ding,通过联合 L2,1范数最小化进行高效鲁棒的特征选择,见:神经信息的进展处理系统,2010 年,第 1813–1821 页。

[20] W. Li,Q. Du,高光谱异常检测的协作表示,IEEE 地球科学与遥感学报 53 (3) (2014) 1463–1474。

[21] JY Chen,JS Reed,杂波中光学目标的检测算法,IEEE Transactions on Aerospace and Electronic Systems 1 (1987) 46–59。

[22] J. Kerekes,接收器工作特征曲线置信区间和区域,IEEE 地球科学与遥感快报 5 (2) (2008) 251–255。

[23] Y.Zhang,B.Du,L.Zhang,高光谱图像目标检测的正则化框架,IEEE地球科学与遥感快报11 (1) (2013)313-317。

[24] Z. Zhou,X. Li,J. Wright,E. Candes,Y. Ma,稳定主成分追求,见:2010 IEEE 国际信息论研讨会, IEEE,2010,第 1518–1522 页。

[25]周涛,陶德,吴晓,流形弹性网络:稀疏降维的统一框架,数据挖掘与知识发现22 (3) (2011) 340–371。

S. Wang,X. Hu,J. Sun 等。

信息科学624 (2023)748–760

[26] N. Billor,AS Hadi,PF Velleman,Bacon:阻塞自适应计算高效异常值提名者,计算统计和数据分析 34 (3) (2000)279-298。
[27] Y. Yuan,Q. Wang,G. Zhu,通过高阶二维交叉滤波器进行快速高光谱异常检测,IEEE地球科学与遥感学报 53 (2) (2014)620-630。